Explicando Decisões de Modelos de Linguagem de Grande Escala via Otimização Inversa

Resumo

Modelos de Linguagem de Grande Escala (LLMs), particularmente quando utilizadas no paradigma do Aprendizado em Contexto, exibem consistência surpreendente em tarefas de classificação, mas seus critérios decisórios implícitos permanecem opacos. Este trabalho busca o entendimento desses critérios usando a otimização inversa como ferramenta. Seja uma tarefa relacionada a um conjunto de amostras rotuladas por um LLM em problemas de classificação binária. Infere-se o vetor de parâmetros de uma métrica de *Mahalanobis* diagonal, vetor de parâmetros *w*, por meio de dois estimadores independentes, um *Perceptron* Estruturado com maximização de margem (MMSP) e um método de Mínimos Quadrados Não-Negativos (NNLS), cuja concordância direcional serve de controle de robustez. O objetivo da estimativa da métrica é aprender o critério decisório que o LLM utiliza e, consequentemente, medir o seu grau de reprodutibilidade. Entretanto, ressalva-se que o LLM reproduz apenas parcialmente, com teto de fidelidade abaixo de 100%, este critério em conjuntos de novas instâncias rotuladas a partir da métrica inferida. Para se realizar este estudo o trabalho divide-se em três blocos: (1) LLM como especialista ou fonte (problemas A–D), avaliando a fidelidade da métrica aprendida, vetor *w*, bem como a análise de sua reprodutibilidade através da transferência entre geometrias de um mesmo conjunto de instâncias comparando o esquema de rotulação produzido pelo LLM com o esquema gerado a partir do uso da métrica inferida e do algoritmo de classificação baseado no centróide mais próximo. Para tanto, um teste-oráculo de aderência é realizado nos estimadores sendo observando também o efeito de vieses semânticos nas escolhas de *prompt*. (2) LLM como um aprendiz ou classificador via Aprendizado em Contexto (Problemas E–F), comparando seus esquemas de rotulação aos resultados produzidos por classificadores *baselines*. (3) Um estudo de caso real (Problema G) onde também se avalia o poder de acurácia do LLM em diferentes cenários de *prompt (zero-shot, few-shot* e *instant feedback)* em um quadro comparativo com respostas de classificadores *baselines* e indivíduos humanos. Utilizando-se os modelos gpt-4o-mini e gemini-2.5-flash-lite a temperatura zero, com três diferentes sementes e três repetições, os resultados demostram que os dois métodos de Aprendizado de Métrica concordam com um cosseno do ângulo entre os respectivos vetores de 0,986 em relação a métrica aprendida sendo que o LLM reproduz a métrica com fidelidade de 82,7 a 86,7%. O teste-oráculo recupera métricas sintéticas conhecidas com fidelidade de 95 a 100%, validando os estimadores sendo a transferência heterogênea (κ de 0,33 a 0,75) em *zero-shot*, subindo a (k de 0,67 a 0,92) com poucas amostras em *few-shot. A* direção de *w* é estável entre sementes (cosseno 0,971), enquanto a magnitude varia por alteração de escala. Como aprendiz, o LLM é praticamente cego em *zero-shot*, com 55,2% de acurácia na média. Entretanto, melhora a sua acurácia com a apresentação de poucas amostras em *few-shot*, mas não superando de forma consistente os classificadores *baselines.* Como exemplo, a Regressão Logística atinge de 97 a 98% de acurácia em média e, finalmente, a hipótese de que amostras difíceis ensinam melhor é refutada em um estudo comparativo com amostras mais fáceis e aleatórias. O contraste entre modelos revela ainda uma diferença de determinismo a T=0, sendo a taxa de *flip* em consultas repetidas de 4,3 no gpt-4o-mini contra 0,0 no gemini-2.5-flash-lite.

Palavras-chave: Otimização Inversa, Modelos de Linguagem de Grande Escala, Aprendizado de Métrica, Aprendizado em Contexto, Viés Semântico, Interpretabilidade.

I - Introdução

Modelos de Linguagem de Grande Escala, ou LLM, tornaram-se ferramentas onipresentes em tarefas cognitivas, da geração de texto à classificação de dados como pode ser visto em Min et al., 2022. Apesar do desempenho notável, os mecanismos que governam suas decisões permanecem largamente opacos, o que dificulta a auditabilidade das respostas, a detecção de vieses e a previsão de comportamento em novos domínios. Avaliações recentes, por exemplo, Shojaee et al., 2025, questionam até que ponto os traços de raciocínio desses modelos refletem processos genuínos de resolução de problemas.

Uma linha de pesquisa em ascensão investiga a capacidade do Aprendizado em Contexto dos modelos LLM, o qual consiste em aprender novas tarefas apenas a partir de exemplos no *prompt*, sem atualização de parâmetros, capacidade esta demonstrada em escala pelo GPT-3 (Brown et al., 2020) e estudada formalmente em Garg et al., 2022. Trabalhos nesta linha sugerem que o aprendizado em contexto pode implementar internamente processos de otimização conhecidos. Xi et al., 2022 apresentam uma análise teórica no sentido de que o aprendizado em contexto pode ser formalizado como um processo de Inferência Bayesiana. Por outro lado, Razeghi et al., 2022 mostram que o aprendizado em contexto está altamente correlacionado com a frequência de termos no processo de pré-treinamento dos dados. Em um estudo de investigativo utilizando modelos lineares de regressão Akyurek et al., 2023, apresentam um conjunto de evidências de que o Aprendizado em Contexto compartilha características com classificadores baseados no gradiente estocástico, regularização *L2* e mínimos quadrados codificados nas ativações do *Transformer* (Vaswani et al., 2017). Isso levanta uma questão fundamental. Se o LLM implementa internamente algum processo de otimização implícito, é possível recuperar explicitamente o critério dessa otimização?

Este trabalho aborda esta questão pelo uso de Otimização Inversa (Chan et al.,2023), ou seja, dados os resultados observados de um processo de rotulação realizado por meio do LLM, infere-se o critério, representado por um conjunto de parâmetros, que possa reproduzir o comportamento dessas classificações. Especificamente, considerando a adoção de hipóteses lineares, estima-se o vetor de parâmetros w de uma métrica de *Mahalanobis* diagonal, a qual, utilizada no método de classificação pelo centroide mais próximo, reproduz as decisões do LLM. Adota-se a terminologia estimada ou inferida, e não métrica aprendida, para enfatizar que o vetor estimado w é um ajuste *a posteriori* às decisões observadas.

Adianta-se, também, que *explicar* é a aspiração que orienta o trabalho, e não uma promessa de reconstruir o processo interno do modelo. O que de fato se aborda, e se sustenta com resultados experimentais, é uma caracterização da geometria do critério decisório e de seus limites, ou seja, o teto de fidelidade da acurácia e da reprodutibilidade, a não-transferência da direção estimada em *zero-shot,* a forte dependência semântica e o fenômeno de inversão de rótulo. A Otimização Inversa é a ferramenta que possibilita tornar essa caracterização mensurável, não um fim de desempenho em si.

Sendo assim, de uma forma sucinta, pode-se arguir neste estudo a seguinte questão principal:

“ Em que medida é possível estimar, a partir das classificações de um LLM, uma métrica matemática ou raciocínio explícito o qual caracteriza o seu processo decisório implícito e quais são os limites desta aproximação quando generalizada para novas tarefas? ”

Neste sentido, para uma melhor compreensão do estudo, considera-se um conjunto de hipóteses definidas a seguir:

H1 — Estabilidade do critério:
O LLM possui um critério decisório consistente, aproximável por uma métrica de *Mahalanobis* diagonal, com concordância ao menos moderada, $k > 0{,}4$ (piso da faixa moderada de Landis e Koch) na transferência entre problemas. O limiar de 0,4 testa a existência de um critério consistente, não seu domínio, que seria substancial para $k > 0{,}7$.

H2 — Transferência de conhecimento:
A métrica estimada em uma tarefa generaliza para problemas geometricamente distintos.

H3 — Viés semântico:
Os nomes atribuídos a classes e atributos influenciam sistematicamente o critério, alterando a métrica inferida e a acurácia do LLM.

H4 — Qualidade das amostras:
Amostras mais difíceis ou próximas à fronteira de decisão transmitem o critério do LLM mais eficientemente que amostras mais fáceis.

H5 — Estabilidade estatística:
O comportamento é reprodutível entre execuções para múltiplas sementes e repetições.

A contribuição central do trabalho é de caracterização e não de desempenho. O objetivo não é classificar melhor com a métrica inferida, e sim utilizar a Otimização Inversa como ferramenta para descrever o raciocínio e as fragilidades do critério decisório de um LLM. Resumidamente, podem-se citar as seguintes contribuições:

1. Uma caracterização quantitativa do critério decisório de modelos LLM em classificação binária sob o paradigma do Aprendizado em Contexto. O critério é direccionalmente estável (a magnitude é pouco identificável sob invariância de escala); é fortemente modulado por viés semântico (nomes de classe e de atributos) e por variantes de *prompt;* exibe um fenômeno de inversão sistemática de rótulo quando faltam âncoras semânticas (a separação espacial é preservada, mas a nomeação das classes torna-se arbitrária).

2. Um protocolo de diagnóstico com garantia de normalidade. A estimativa da métrica é feita com dois algoritmos independentes, cuja concordância direcional é atestada e validada por um teste-oráculo, o qual verifica a recuperação de uma métrica sintética previamente conhecida.

3. Uma avaliação criteriosa do LLM como aprendiz via aprendizado em contexto, incluindo a refutação da hipótese *a priori* de que exemplos mais difíceis ensinam melhor e a constatação de que o LLM não supera de forma consistente, nas tarefas apresentadas, os classificadores *baselines*.

4. Um contraste de determinismo entre modelos a T=0 (taxa de *flip* entre consultas repetidas), quantificado como piso de ruído de medição das próprias métricas de concordância.

5. A extensão do protocolo a não linearidade com a realização de projeções em R^3 e R^4 e, também, a realização de um estudo de caso real com um novo tipo de sequencia de *prompt*, baseado em um retorno imediato, reportando o número absoluto de erros, dado a pequena escala amostral do conjunto de treinamento.

A metodologia do trabalho emprega três blocos, descritos a seguir:

Bloco 1 — LLM como fonte:
O LLM rotula problemas sintéticos (problemas A–D) e dele se estima o vetor *w* de métrica. Avaliam-se a fidelidade e a transferência entre geometrias. Realiza-se um teste-oráculo de normalidade onde os estimadores recuperam uma métrica conhecida, bem como o efeito de não-linearidade (projeções em R^3 e R^4) e de vieses semânticos e de *prompts*.

Bloco 2 — LLM como aprendiz:
Neste caso, os papéis se invertem. Um especialista externo, com uma métrica conhecida rotula os dados (problemas E linear e F meia-lua) e o LLM deve reproduzir esse critério via Aprendizado em Contexto. Comparam-se estratégias de sequencia de *prompts*, de seleção de amostras e de vieses semânticos. Os resultados obtidos são confrontados com resultados provenientes de classificadores *baselines*, como exemplo, k-NN, MLP, Regressão Logística e SVM.

Bloco 3 — Estudo de caso real:
Uma base real (Problema G, com uma fronteira de decisão aproximadamente elíptica) é utilizada, submetendo todo o estudo anterior a dados não sintéticos. Este bloco apresenta, também, um estudo comparativo com decisões provenientes de humanos assumindo o papel do modelo LLM.

O restante do trabalho organiza-se da seguinte forma: a Seção II apresenta a fundamentação teórica, a saber, Otimização Inversa, Predição Estruturada, Aprendizado de Métrica , Estimadores e Aprendizado em Contexto; a Seção III discute o trabalho relacionado ao Aprendizado em Contexto com o uso de modelos LLM abordando questões como viés semântico, estratégias de *prompt* , fronteiras de decisão e critério decisório; a Seção IV descreve a metodologia dos três blocos; a Seção V descreve as métricas utilizadas, apresenta os experimentos e analisa as hipóteses levantadas, com base nos resultados obtidos; a Seção VI discute as limitações e trabalho futuro; e, finalmente, a Seção VII apresenta as considerações finais. O Apêndice A detalha o protocolo experimental de coleta. O Apêndice B o pseudo-código dos algoritmos.

II -Fundamentação Teórica

Como já afirmado anteriormente, no primeiro passo deste trabalho procura-se encontrar os parâmetros ocultos responsáveis pelo critério de decisões dos modelos LLM.

Este problema é comumente considerado um problema inverso, onde os parâmetros ocultos podem ser encontrados com base em um conjunto de dados estruturados de entrada e saída que reproduzem a função de decisão desconhecida. Este é um importante campo de pesquisa em Aprendizado de Máquinas, denominado Predição Estruturada (Bakir et al, 2006), (Taskar et al.,2005), o qual aborda este problema de forma geral, considerando a forma estruturada do mapeamento. Assim, o modelo visa aprender o conjunto de parâmetros ocultos, o qual, posteriormente, usando um algoritmo de otimização apropriado, produzirá a saída correta de acordo com o conhecimento do especialista (LLM). Neste sentido, para casos futuros, este especialista pode ser substituído por este modelo de aprendizado. Também, será possível customizar o modelo LLM, no sentido de produzir respostas mais efetivas para tarefas específicas de aplicação.

II.1 – O Problema Inverso

Formalmente, o problema de Otimização Inversa consiste em: dado um conjunto de soluções observadas $x^* \in R^D$ de um problema de otimização parametrizado por θ, inferir os parâmetros de θ que tornariam x^* uma solução ótima ou quase ótima (Chan et al., 2023). Para um determinado problema P de minimização, definido como:

$$P(\theta) = Min_{x \in F} f(x, \theta),$$

a otimização inversa buscar determinar:

$$\theta = Arg\ Min_{\theta}\ L\ \{x^*,\ Arg\ Min_{x \in F} f(x, \theta)\},$$

onde a função L mede quão ótimo x^* é sob θ e F representa o domínio de x. Neste sentido, as decisões observadas consistem nas classificações do modelo LLM, e o conjunto de parâmetros θ a métrica a ser estimada a qual controla o processo de classificação. A seguir, no contexto da área de Aprendizado de Máquinas, este problema será reformulado como um problema de Predição Estruturada e, posteriormente, como um problema de Aprendizado de Métrica.

II.2 - O problema de Predição Estruturada

Em modelos estruturados, dispõe-se de um conjunto de informações fornecido por um especialista. Neste caso, considera-se o modelo LLM como fonte. Este conjunto é definido por uma coleção de pares (entrada, saída). Formalmente, tem-se: $Z = \{(x(i), y(i)), i=1,...,n\}$, onde $x(i)$ denota um objeto estruturado do conjunto de entrada X e $y(i)$ o mapeamento desejado do conjunto de imagem Y. O espaço de saída Y deve satisfazer um conjunto de restrições, e cada um de seus objetos pode ser definido por um subconjunto de elementos pertencentes ao espaço de entrada X.

Como exemplo, tem-se um problema de Análise de Agrupamento definido por:

- Um espaço de entrada *X* onde cada elemento *x(i),* ou simplesmente *x*, é composto por um conjunto de amostras sob a forma de vetores em R^D, possuindo uma representação geométrica espacial.

- Um espaço de saída *Y* onde cada elemento *y(i),* ou simplesmente *y*, representa uma partição do elemento *x* correspondente, resultando em um processo de agrupamento, com base em um esquema de rotulação ou de relações de similaridade, definido previamente pelo LLM.

Dessa forma, cada saída específica *y* pode ser representada por uma partição de um conjunto de amostras pertencentes a um objeto *x* do espaço de entrada. O problema de inferência em um cenário de predição estruturada pode ser resolvido por meio de um problema de otimização. Nesse sentido, para um critério de minimização, deve-se determinar:

$$y^* = Arg \{ Min_{y \in Y} \{ S_x(y) \} \},$$

onde $S_x: Y(x) \rightarrow R$ é a função responsável por avaliar cada saída específica *y* associada a um objeto de entrada *x*, a qual pode ser definida por uma família linear de hipóteses representada por um vetor de parâmetros *w*. Neste sentido, pode-se reescrever o problema de maximização como:

$$y^* = Arg \{ Min_{y \in Y} \{ w^* f(x,y) \} \}.$$

Assim, o objetivo principal é calcular o vetor de parâmetros ótimo *w** de modo a possibilitar a obtenção das saídas desejadas, isto é:

Para cada par (x(i), y(i)):

$$y(i) \approx y^*(i) = Arg \{ Min_{y \in Y} \{ w^* f(x(i), y) \} \}.$$

Alternativamente, pode-se formular um conjunto de restrições como um sistema de inequações na forma:

Para cada par (x(i), y(i)):

$$w^* f(x(i), y(i)) \leq w^* f(x(i), y) \text{ para todo } y \in Y,$$

sendo que a solução equivalente de máxima margem pode ser obtida minimizando a norma Euclidiana do vetor de parâmetros *w*, ou seja:

$$Min_w \tfrac{1}{2} ||w||_2^2$$

Sujeito a:

$$\forall i: wf(x(i), y(i)) \leq Min_{y \in Y} \{ wf(x(i), y) \}.$$

Para a solução deste problema é possível adotar um método baseado no conceito de margem geométrica. Seja o melhor falso exemplo, considerando um vetor de parâmetros *w*, dado pela equação:

$y^*(i) = Arg\ \{Min_{y \in Y\ \wedge\ y \neq y(i)}\ \{wf(x(i), y)\}\}.$

O valor da margem geométrica correspondente pode ser obtido considerando a divisão do valor funcional pela norma do vetor *w*. Assim, a margem geométrica de cada objeto, para um vetor de pesos ótimo, pode ser calculada como:

$\gamma(i) = w^* f(x(i), y^*(i)) - f(x(i), y(i)))/||w^*||_2$

Dessa forma, para determinar a solução ótima w^*, introduz-se o parâmetro de margem γ, que deve ser maximizado, obtendo a seguinte formulação:

$Max_w\ \gamma$

Sujeito a:

$\forall i: w(f(x(i), y^*(i)) - f(x(i), y(i))) \geq \gamma ||w||_2.$

Esta nova solução pode ser computada através do emprego de uma estratégia incremental do valor da margem e, também, por um método de projeção iterativa que considera o erro ou a diferença observada em cada restrição. Este método, denominado *Perceptron* Estruturado (Coelho et al. , 2012), resulta na seguinte regra de correção:

Para cada par (x(i), y(i)):

Se $w(f(x(i), y^*(i)) - f(x(i), y(i))) < \gamma ||w||_2$, *então fazer:*

$w \leftarrow w(1 - \eta\ \gamma/||w||_2) - \eta\ (f(x(i), y(i)) - f(x(i), y^*(i))),$

onde η é a taxa de aprendizado, γ é uma margem fixa e $y^*(i)$ é o melhor falso exemplo, o qual pode ser obtido por um método de amostragem explícita ou de otimização.

A derivação da regra de correção é obtida pela aplicação do método do gradiente local a função de erro do modelo *Perceptron* parametrizada pelo valor da margem imposta γ. Neste caso, tem-se:

$J(w, \gamma) = - Min\ \{0, w(f(x(i), y^*(i)) - f(x(i), y(i))) - \gamma ||w||_2\}.$

Fornecendo como gradiente local condicionado ao erro da amostra $f(x(i),y(i))$:

$\partial J/\partial w = \gamma w/||w||_2 - (f(x(i), y^*(i)) - f(x(i), y(i)))\ .$

Aplicando o método do gradiente descendente tem-se:

$w = w - \eta\ \partial J/\partial w$

$= w - \eta\ (\gamma w/||w||_2 + (f(x(i), y^*(i)) - f(x(i), y(i)))$

$= w(1 - \eta\ \gamma/||w||_2) + \eta\ (f(x(i), y^*(i)) - f(x(i), y(i))),$

Após uma execução bem-sucedida do método para um valor de margem fixa, o valor da margem de parada é maior ou igual a esse valor. Então, torna-se necessário incrementar

o valor da margem fixa para uma nova execução, forçando, dessa forma, a maximização da mesma. O processo para quando não houver mais solução viável.

É importante ressaltar que o objetivo principal do problema inverso de Predição Estruturada é conhecer as decisões do especialista, neste caso do modelo LLM. Quando o LLM toma suas decisões, ele desconhece os parâmetros ocultos que as influenciam diretamente. Nesse sentido, é importante descrever os três elementos importantes que constituem o modelo de Predição Estruturada: o algoritmo de otimização, o vetor de características e o vetor de parâmetros.

O algoritmo de otimização simula o comportamento do LLM se for estimado os parâmetros ocultos. Portanto, é um elemento importante do modelo de Predição Estruturada.

O vetor de características captura os dados essenciais que permitem codificar as informações necessárias para a tomada de decisão. Deve ter a mesma dimensão do vetor de parâmetros. Formalmente, captura a projeção do objeto de saída *y* pertencente ao espaço de imagem *Y* em relação ao objeto *x* pertencente ao espaço de domínio *X*.

Finalmente, o vetor de parâmetros, o qual é responsável por produzir o custo de cada mapeamento. Neste estudo considera-se uma hipótese linear.

II.3 – O Problema de Aprendizado de Métrica

Considere, inicialmente, a adequação do problema de Predição Estruturada no sentido de resolver um problema de Análise de Agrupamento com múltiplas classes e seus respectivos centroides. Neste caso, o domínio do problema consiste em um conjunto de vetores e cada objeto de entrada *x(i)* representa um sub-conjunto de vetores que apresentam uma relação de similaridade definida pelo LLM. O mapeamento *y(i)* de cada objeto *x(i)* é representado por um valor real que mede a respectiva distância intra-grupo de cada sub-conjunto de vetores similares.

Portanto, seja um conjunto de *n* vetores ou amostras em um espaço R^D definido como $S = \{ v(i) \in R^D , i = 1 , \ldots , n \}$. Estes vetores representam um conjunto de amsotras as quais podem ser agrupadas em diferentes categorias. Considere, também, um conjunto de restrições proposto por um LLM, indicando a existência de relações de similaridade entre os pares de *S* o qual poderá ser particionado em *k* subconjuntos disjuntos: $S_1 , S_2 , \ldots , S_k$, cada um associado a uma categoria ou agrupamento. Neste sentido, tem-se:

$(v(i),v(j)) \in S_l \rightarrow v(i)$ *e* $v(j)$ *são similares.*

$S = S_1 \cup S_2 \cup \ldots \cup S_k$ *e* $Si \cap Sj = \emptyset$ *para* $\forall \; i \neq j.$

Por outro lado, se os pontos são dissimilares, tem-se, para um conjunto de dissimilaridade:

$D: (v(i),v(j)) \in D_l \rightarrow v(i)$ *e* $v(j)$ *são dissimilares.*

Geralmente, o problema de Aprendizado de Métrica com relações de similaridade aos pares (Xing et al., 2002) é formulado como um problema de otimização cujo objetivo é reduzir as distâncias entre pares similares, ao mesmo tempo em que se aumenta a distância em relação aos pares dissimilares. Essa abordagem envolve um número quadrático de termos na função objetivo e a solução de um problema de Otimização Quadrática e Programação Semi-definida. No entanto, esse problema pode ser reformulado como um simples problema de Análise de Agrupamentos se for considerada a existência de duas propriedades:

Transitividade: se (v(i),v(j)) e (v(j),v(k)) são similares, então (v(i),v(k)) são similares.

Simetria: se (v(i),v(j)) são similares, então (v(j),v(i)) são similares.

Estas duas propriedades possibilitam a criação de um grafo de similaridades, não orientado e desconexo, formado por um conjunto de componentes conexas cada qual associada a um grupo ou categoria. Deste grafo é possível extrair um esquema de rotulação das amostras, dado por $Y = \{y(i) \in \{0,1\}, i=1,...,n\}$ bem como os respectivos centroides, dados por $C=\{c(1),c(2),...,c(k)\}$. Consequentemente, o conhecimento ou decisões do especialista pode ser obtido diretamente do esquema de rotulação das amostras sem a necessidade de construção do grafo de similaridades.

Esta nova forma de informação facilita a definição de tarefas, formulação de *prompts* e interpretação de respostas de um modelo LLM. No contexto da Otimização Inversa e do Aprendizado Supervisionado transforma-se um problema de Análise de Agrupamentos em um problema de Multi-Classificação, mais especificamente, considerando somente duas categorias, em um problema de Classificação Binária com distâncias parametrizadas.

Seja uma medida de distância parametrizada entre dois vetores, definida em função de uma matriz simétrica $A \in R^{DxD}$, positiva semi-definida (PSD) e não nula :

$d_A(v(i),v(j)) = ||v(i)-v(j)||^2_A = (v(i)-v(j))^T A(v(i)-v(j))$.

Esta medida possui as seguintes propriedades:

Não negatividade: $d_A(v(i)-v(j)) \geq 0$.

Distinguibilidade: $d_A(v(i),v(j)) = 0 \Rightarrow v(i) = v(j)$

Simetria: $d_A(v(i),v(j)) = d_A(v(j),v(i))$,

Inequação triangular: $d_A(v(i),v(j)) < d_A(v(i),v(k)) + d_A(v(k),v(j))$.

O problema de Aprendizado de Métricas pode ser reformulado como um problema de Análise de Agrupamentos, considerando a relação de cada subconjunto S_l com seu respectivo grupo. Assim, deve-se resolver:

$Min \sum_l \sum_{(v(i),v(j)) \in Sl} ||v(i)-v(j)||^2_A$

Sujeito a:

$A \succcurlyeq 0$ *(PSD)*

Entretanto, se a matriz de parâmetros A for uma matriz diagonal, deve-se aprender um vetor de parâmetros não negativos, $w \in R^D_+$, correspondente a diagonal principal de *A*. Como observação, se for considerado o uso de uma matriz identidade *I*, obtém-se um conjunto de distâncias Euclidianas. No caso da matriz diagonal, a condição de positiva semi-definida (PSD) é satisfeita se todos os componentes do vetor *w* forem não negativos.

A simplificação da matriz A, com redução para um número linear de parâmetros, foi proposta no trabalho de Weinberger e Saul, 2009, o qual aborda o problema do Aprendizado de Métrica, também sob a perspectiva de maximização da margem, em problemas de classificação com o uso do algoritmo k-NN.

Assim, o problema acima para uma matriz diagonal, representada pelo vetor *w*, pode ser reformulado na forma:

$Min_{w \geq 0} \sum_l \eta_l \sum_{v(i) \in Sl} ||v(i)-c(l)||^2_W$

onde η_l representa a cardinalidade de cada sub-conjunto S_l.

Considerando d_I a distância Euclidiana e d_w a distância parametrizada em *w* entre uma amostra *v(i)* e o centro *c(l)*, pode-se escrever:

$d_I(v(i),c(l)) = ((v(i)_1 - c(l)_1)^2 + \cdots + (v(i)_D - c(l)_D)^2,$

$d_w(v(i),c(l)) = w d_I(v(i),c(l)),$

$d_w(v(i),c(l)) = w_1((v(i)_1 - c(l)_1)^2 + \cdots + w_D(v(i)_D - c(l)_D)^2.$

Consequentemente, o problema pode ser reescrito na forma:

$Min_{w \geq 0} \sum_l \eta_l \sum_{v(i) \in Sl} (w_1(v(i)_1 - c(l)_1)^2 + \ldots + w_D(v(i)_D - c(l)_D)^2)$

A equivalência entre a formulação baseada em pares e a formulação baseada em centroides é sustentada por (Edwards & Cavalli-Sforza, 1965), levando-se em conta que a distância intra-grupo dos vetores é proporcional à soma das distâncias entre todos os pares de vetores pertencentes ao mesmo grupo. A demonstração deste teorema baseia-se no fato de que o centroide de cada grupo pode ser calculado como a média dos vetores do respectivo grupo, ou seja:

$c(l) = 1/\eta_l \sum_{v(i) \in Sl} v(i)$

Para resolver o problema de Aprendizado de Métrica sem a partição dos pares de amostras em grupos, Xing et al. (2002) propõem uma formulação relaxada que envolve a minimização de uma função objetivo irrestrita com um termo de penalidade adicional o qual garante a propriedade *(PSD)* da matriz A de parâmetros:

$Min \sum_{(v(i),v(j)) \in S} ||v(i)-v(j)||^2_A - log \sum_{(v(i),v(j)) \in D} ||v(i)-v(j)||^2_A$

Sujeito a:

$A \succcurlyeq 0$ *(PSD)*

onde *S* é o conjunto de amostras similares e *D* é o conjunto de amostras dissimilares.

Entretanto, a abordagem adotada no trabalho de Schultz e Joachims (2004) para resolver o problema de Aprendizado de Métrica é a que mais se aproxima da abordagem aqui sugerida. Este trabalho propõe uma extensão da Máquina de Vetores de Suporte (Cortes e Vapnik, 1995) e se baseia na satisfação de um conjunto de restrições de relações comparativas. Essas relações comparativas apresentam a seguinte expressão envolvendo uma tripla de vetores:

(v(i),v(j),v(k)) → v(i) está mais próximo de v(j) do que de v(k).

Consequentemente, pode-se deduzir que *v(i)* é similar a *v(j),* mas não se pode deduzir que *v(i)* e *v(k)* sejam similares. Assim, é necessário modelar um número da ordem de $O(n^3)$ restrições, considerando a representação de cada subconjunto de triplas. Seja *w* o vetor de parâmetros associado a cada distância parametrizada. Cada restrição, referente a uma tripla, pode ser escrita na forma:

$\forall\ i, j, k : d_w(v(i),v(k)) - d_w(v(i),v(j)) > 0$

Este sistema de inequações pode apresentar inúmeras soluções. Nesse sentido, os autores propuseram uma solução semelhante à solução do problema SVM de máxima margem suavizada, considerando a minimização da norma Euclidiana do vetor de parâmetros *w* e a flexibilização das restrições, ou seja:

$Min_w\ 1/2\ ||w||^2 + C\sum_{i,j,k} \xi_{i,j,k}$

Sujeito a:

$\forall\ i, j, k : d_w(v(i),v(k)) - d_w(v(i),v(j)) > 1 - \xi_{i,j,k}$,

$\xi, w \geq 0$,

onde ξ representa o vetor de variáveis de folga e *C* uma constante de penalização.

Para superar a limitação relacionada ao elevado número de restrições desta formulação, propõe-se, neste trabalho, um conjunto de comparações entre cada amostra e seu respectivo centroide, reduzindo o número de restrições para ordem de $O(n)$. Além disso, utiliza-se como método de solução uma técnica baseada na versão estruturada do modelo *Perceptron* (Coelho et al. (2012)), evitando assim a resolução de um problema de programação quadrática mais complexo como proposto em Xing et al. (2002).

II.4 - Aprendizado de Métrica e *Perceptron* Estruturado

A abordagem apresentada até o momento para a solução do problema de Aprendizado de Métrica pode ser descrita como um processo de correção em lote que considera na função objetiva quadrática a soma das distâncias intra-grupo de todas as classes, considerando o vetor *w* como parâmetro e a posição dos centroides conhecidas a partir das decisões do modelo LLM. No entanto, ao considerar o erro total, o processamento em lote resultaria em grandes correções no vetor *w*, tornando o método do gradiente instável e exigindo um controle mais rigoroso da taxa de aprendizado.

É importante observar que para um esquema de rotulação pré-definido por um LLM, o aprendizado da métrica representa o problema inverso relacionado ao problema de Análise de Agrupamentos. Por outro lado, o problema direto consiste em, dada uma métrica pré-definida, determinar o esquema de rotulação e a respectiva posição dos centroides.

Para superar a correção em lote é possível considerar a regra de atualização para cada erro, individualmente, utilizando o método do gradiente estocástico e o processamento *sample-by-sample*, (da Silva et al., 2020) observando o esquema de rótulos fornecido pelo LLM. Em outras palavras, se a distância parametrizada entre uma amostra *v(i)* e seu respectivo centroide *c(l)* for maior do que a distância até o melhor centroide candidato *c(k)* , escolhido como falso exemplo, sendo:

$k = arg\ \{ Min_j ||v(i) - c(j)||_w \},$

realiza-se a correção do vetor *w* no sentido de forçar a viabilidade desta restrição.

Assim, se for considerada a distância parametrizada entre dois vetores:

$d_w(v(i),c(j)) = (v(i) - c(j))^T w(v(i) - c(j)),$

deve-se resolver o seguinte problema relacionado a minimização da norma:

$Min_w\ 1/2\ ||w||^2 + C \sum_i \xi_i$

Sujeito a:

$\forall i:\ d_w(v(i),c(k)) - d_w(v(i),c(l)) \geq 1 - \xi_i$

$\xi, w \geq 0,$

onde ξ representa o vetor de variáveis de folga e *C* a constante de penalização.

Para evitar a solução de um problema de otimização de uma função quadrática, pode-se reformular o problema com a introdução do parâmetro de margem Υ e do conceito de margem geométrica. Assim, tem-se:

$Max_w \Upsilon$

Sujeito a:

$\forall i:\ d_w(v(i),c(k)) - d_w(v(i),c(l)) + \lambda.\alpha_i \geq \Upsilon.||w||_2$

$\alpha, w \geq 0,$

onde o parâmetro de $\lambda = 1/C$ representa o inverso da constante de penalização e α o vetor de variáveis duais. Esta formulação permite um processo de suavização da margem semelhante à penalidade quadrática do vetor de variáveis de folga ξ (Villela, Fonseca Neto, 2016).

Neste sentido, a nova regra de correção *sample-by-sample* se torna:

Para cada par (v(i), c(l)):

Se $d_w(v(i),c(k)) - d_w(v(i),c(l)) + \lambda \alpha_i < \gamma ||w||_2$ *então fazer:*

$w \leftarrow w(1 - \eta \gamma/||w||_2) + \eta (d_I(v(i),c(k)) - d_I(v(i),c(l))),$

$\alpha \leftarrow \alpha. (1 - \eta \gamma/||w||_2),$

$\alpha_i \leftarrow \alpha_i + \eta .$

A equação de correção do vetor *w* apresenta uma forma de regularização semelhante à regularização *L2* a qual minimiza, na função de perda regularizada, a norma Euclidiana do mesmo. Este efeito é proporcionado pelo reescalonamento do vetor a cada erro, controlando desta forma a magnitude das suas componentes e, consequentemente, o crescimento de sua norma.

Seja a função de perda com regularização, sem os parâmetros de margem e de suavização, definida para uma amostra *v(i)* acompanhada de seu centro *c(l):*

$L(w) = -(d_w(v(i),c(k)) - d_w(v(i),c(l))) + \tau||w||_2^2$

$= -w(d_I(v(i),c(k)) - d_I(v(i),c(l))) + \tau (ww^T),$

sendo τ o parâmetro de regularização.

Portanto, considerando a existência de um erro associado a amostra *v(i)*, tem-se:

$\partial L/\partial w = -((d_I(v(i),c(k)) - d_I(v(i),c(l))) + \tau w.$

Tratando-se de um problema de minimização, e aplicando-se o método do gradiente descendente, tem-se:

$w = w - \eta \partial L/\partial w$

$= w + \eta((d_I(v(i),c(k)) - d_I(v(i),c(l))) - \tau w)$

$= w(1-\eta\tau) + \eta ((d_I(v(i),c(k)) - d_I(v(i),c(l))),$

equivalente portanto a equação de correção apresentada, considerando o parâmetro de regularização $\tau = \Upsilon/||w||_2$.

Para problemas envolvendo somente duas classes pode-se considerar *c(k)* como o falso centroide e *c(l)* como o verdadeiro centroide associado ao rótulo *y(i)* do vetor *v(i).*

Também, considera-se, inicialmente, no processo de otimização, um valor de margem nula. Após a primeira execução, o algoritmo termina com uma margem de parada positiva. A próxima margem pode ser determinada sempre como o dobro da margem de parada anterior até que não se obtenha mais uma solução viável. Pode-se utilizar uma técnica de pesquisa binária para alcançar a maior margem final de parada.

II.5 - Estimadores da Métrica

Dois estimadores independentes foram desenvolvidos. O primeiro, já explicado nas seções anteriores, se refere ao *Perceptron* Estruturado adaptado ao problema de Aprendizado de Métrica e o segundo, utilizado para a certificação do primeiro método, um método de Mínimos Quadrados Não Negativos. A medida de congruência entre os vetores de parâmetros estimados pelos mesmos é utilizada como controle, independentemente da magnitude. A escolha do *Perceptron* Estruturado como método principal se deve a sua forma de correção *sample-by-sample* mais adequada em termos comparativos aos esquemas de inserção de *prompts* do Aprendizado em Contexto. É importante considerar que os dois métodos adotados utilizam critérios de otimização que, segundo Akyurek et al., 2023, compartilham características com o modelo *Transformer*.

O *Perceptron* Estruturado generaliza o modelo do *Perceptron* clássico para espaços de entrada e saída estruturados, atualizando os parâmetros quando a predição diverge do objetivo alvo. A variante usada para bases de dados binárias, com relaxação de margem está descrita no Algoritmo 1. Na descrição do algoritmo, tratando-se de problemas com duas classes somente, considera-se como centroides das classes *c(1)* e *c(2).* A condição de parada, para uma determinada margem fixa γ, é controlada por um número máximo de iterações T. A obtenção de uma solução que maximiza a margem, Algoritmo 2, é realizada através do uso de uma estratégia incremental seguida de uma pesquisa binária.

Entrada : Dados: $\{(v(i),y(i)), v(i) \in R^2, y(i) \in \{0,1\}, i=1,\cdots,n\}$ *, e centróides c(1) e c(2)*

Parâmetros: η, γ, λ, T

Parâmetros referência: Vetor primal $w \in R^2_+$, *Vetor dual* $\alpha \in R^n+$,

Saida: Vetor primal $w^* \in R^2_+$, *Vetor dual* $\alpha^* \in R^n_+$, *Número iterações t*

Inicio

stop $\leftarrow F$; $t \leftarrow 0$;

Enquanto $(t \leqslant T) \wedge (\sim stop)$ *Faça*

stop $\leftarrow V$;

Para $i \leftarrow 1$ *até n Faça*

Y^(i) ← Arg {Min $_{k\in\{1,2\}}$ $d_w(v(i),c(k)\}$;

Se y(i) ≠ y^(i) Então

Se $(d_w(v(i),c(y^{(i)})) - d_w(v(i),c(y(i))) + \lambda\partial_i) < \Upsilon||w||_2$ Então

stop ← F;

$w \leftarrow Max\{0, w(1 - \eta . \gamma/||w||_2) + \eta (d_l(v(i),c(y^{(i)})) - d_l(v(i),c(y(i))))\}$;

$\alpha \leftarrow \alpha . (1 - \eta \gamma/||w||_2)$;

$\alpha i \leftarrow \alpha i + \eta$;

Fim_Se;

Fim_Se;

Fim_Para;

t ← t+1;

Fim_Enquanto;

Retorne w;

Fim.

Algoritmo 1: *Perceptron* Estruturado com Relaxação de Margem.

Entrada: fator de incremento da margem: Δ

Número máximo de iterações: T

Erro de tolerância: ε

Saida: Vetor primal $w^* \in R^2_+$

Inicio

Y ← 0; t ← 0; w ← [1,1]; α* ← 0;*

Enquanto t ≤ T Faça

w ← w; α ← α*;*

Algoritmo1(Y,t,w, α);

Se t ≤T Então

$\Upsilon_{ini} \leftarrow \Upsilon$;

$w^* \leftarrow w$; $\alpha^* \leftarrow \alpha$;

$\Upsilon \leftarrow \Upsilon.\Delta$

Senão

$\Upsilon_{fim} \leftarrow \Upsilon$

Fim_Se;

Fim_Enquanto;

Enquanto (Υ_{fim}-Υ_{ini}) > ε *Faça*

$\Upsilon \leftarrow (\Upsilon_{ini} + \Upsilon_{fim})$;

$w \leftarrow w^*$; $\alpha \leftarrow \alpha^*$;

Algoritmo1(Υ,t,w, α);

Se t > T Então

$\Upsilon_{fim} \leftarrow \Upsilon$

Senão

$\Upsilon_{ini} \leftarrow \Upsilon$

Fim_Se;

$w^* \leftarrow w$; $\alpha^* \leftarrow \alpha$;

Fim_Enquanto;

Retorne w, α*;*

Fim.

***Algoritmo 2**: Estratégia Incremental com Pesquisa Binária*

O segundo estimador formula a recuperação do vetor de parâmetros *w* como um problema de Mínimos Quadrados com restrição de não negatividade, ou seja:

$W^* = Arg_{w \geq 0} Min_w ||Aw - 1||_2^2$

Resumidamente, resolve-se o seguinte problema considerando a minimização da soma dos quadrados dos resíduos representados pelo vetor de folgas ξ :

$Min_w \sum_i \xi i^2$

Sujeito a:

$\forall i: d_w(v(i),c(k)) - d_w(v(i),c(l)) = 1 - \xi i$

$w \geq 0$

Considerando a distância parametrizada em w entre uma amostra $v(i)$ e o centro $c(l)$ dada por:

$d_w(v(i),c(l)) = (w_1(v(i)1 - c(l)_1)^2 + \cdots + w_D(v(i)_D - c(l)_D)^2$,

pode-se afirmar que cada linha da matriz $A \in R^{nxD}$ codifica a diferença entre as distâncias Euclidianas de um vetor $v(i)$ em relação ao falso $c(k)$ e verdadeiro $c(l)$ centroides para cada dimensão do problema.

Esta formulação é equivalente a formulação do primeiro estimador sem utilizar, no entanto, o parâmetro de margem. Para sua solução adota-se uma forma fechada com a utilização do algoritmo clássico de Lawson e Hanson, 1974, implementação *scipy.optimize.nnls.* Este algoritmo foi desenvolvido para a solução do problema de Mínimos Quadrados com restrição de não negatividade. Ao contrário do *Perceptron* Estruturado o mesmo não possui hiper-parâmetros, o que o torna um método apropriado para a certificação do primeiro estimador. Contudo, o método apresentado fica restrito ao problema com duas classes e, também, não possibilita a maximização da margem. Para tanto, seria necessário acrescentar a minimização da norma Euclidiana do vetor w em um processo semelhante à regressão de *ridge* a qual utiliza a regularização de Tikhonov ou, simplesmente a regularização *L2*. Neste caso, o problema de mínimos quadrados com regularização *L2* se tornaria:

$W^* = Arg_{w \geq 0} Min_w ||Aw - 1||_2^2 + \tau ||w||_2^2$,

sendo τ o parâmetro de regularização o qual regula o *trading-off* entre o viés e variância.

II.6 - Aprendizado em Contexto

Inicialmente, considera-se a possibilidade de um modelo LLM aprender uma classe de funções F a partir de exemplos fornecidos no contexto. Este modelo é capaz de aprender F em contexto se, para a maioria das funções $f \in F$, o modelo conseguir aproximar $f(x)$ para uma nova consulta x, após uma sequência de *prompts* $((x1, f(x1)), \ldots, (xk, f(xk)), x)$ que contem exemplos em contexto e a entrada da consulta. Portanto, cada exemplo é representado por um par ordenado possuindo uma entrada do conjunto de domínio da função e seu respectivo mapeamento no conjunto de imagem da função. O aprendizado em contexto segundo Brown et al, 2020, pode ser de três tipos considerando a sequência de *prompts* :

Zero-shot: o modelo prevê a resposta dado somente uma descrição da tarefa. Não são apresentados exemplos e não são realizadas correções de parâmetros.

One-*shot:* Em adição a descrição da tarefa o modelo é alimentado com um único exemplo. Também não são realizadas correções de parâmetros.

Few-shot: Além da descrição da tarefa, o modelo recebe um conjunto de exemplos. Também não são realizadas correções de parâmetros.

Neste estudo, propõe-se uma forma alternativa de sequência de *prompt* chamada de *instant feedback* a qual consiste na alimentação sequencial do modelo com uma consulta *x* e um *prompt* imediato indicando se o modelo acertou ou errou a resposta esperada.

De acordo com Garg, et al., 2023 afirma-se que um modelo M é capaz de aprender a classe de funções F em contexto com precisão ϵ, em relação a sequência de *prompts* P, se, fornecido x, ele conseguir prever $f(x)$ com um erro médio:

$$E_P [\ell (M_p , f(x))] \leq \epsilon,$$

em que ℓ é uma função de perda apropriada e ϵ uma constante de erro.

A partir deste cenário argui-se a possibilidade de um modelo LLM aprender uma classe de funções em contexto, sendo este aprendizado uma característica exclusiva do modelo *M*. Em nosso estudo investiga-se esta capacidade de aprendizado empiricamente considerando uma classe de funções lineares em tarefas relacionadas a problemas de classificação binária considerando o enfoque da Otimização Inversa.

Em alguns cenários do Aprendizado em Contexto talvez seja necessário um ajuste da métrica. Seja, por exemplo, a resposta a uma pergunta em tempo de teste. Caso haja uma discordância entre as respostas geradas pelo LLM e a classificação fornecida pela métrica é possível, se necessário, fazer uma correção da mesma no sentido de torná-la mais aderente as decisões do LLM. Seja o problema de classificação binária e o algoritmo de classificação pelo centroide mais próximo. Suponha que a resposta do LLM para uma entrada $v(i)$ esteja relacionada ao centroide $c(k)$ mais próximo, diferente do centroide $c(l)$ relacionado à métrica inferida. Neste caso, deve-se, primeiramente, ajustar a posição dos centroides em relação à amostra $v(i)$, ou seja:

$c(k)^* \leftarrow c(k) + \eta (v(i) - c(k))$, *aproximando o centro vencedor c(k) da amostra v(i),*

$c(l)^* \leftarrow c(l) - \eta (v(i) - c(k))$, *afastando o centro perdedor c(l) da amostra v(i),*

e, em seguida, corrigir a métrica considerando a ocorrência do erro da amostra $v(i)$ e a diferença entre as respectivas distâncias parametrizadas em relação aos centroides corrigidos, ou seja:

$$w \leftarrow w(1 - \eta \gamma / ||w||_2) + \eta (d_l(v(i),c(k)^*) - d_l(v(i),c(l)^*)).$$

As equações de correção são obtidas diretamente da aplicação do método do gradiente descendente a amostra local *v(i)* considerando a minimização da função de perda quadrática do algoritmo K-Means (MacQueen, 1967).

Bakır, G., Hofmann, T., Schölkopf, B., Smola, A., Taskar, B., Vishwanathan, S.V.N.: Predicting structured data. MIT Press, Cambridge (2006)

Taskar, B., Chatalbashev, V., Koller, D., & Guestrin, C. (2005). Learning structured prediction models: A large margin approach. In Proceedings of the 22nd International Conference on Machine Learning . In ICML' 05 (pp. 896 – 903). New York, NY, USA.

Timothy C.Y. Chan, Rafid Mahmood, e Ian Yihang Zhu. Inverse optimization: Theory and applications. Operations Research, 73(2):1046 – 1074, 2025. (Publicado online Dez/2023.)

Coelho, M. A., Neto, R. F., & Borges, C. C. (2012). Perceptron models for online struc- tured prediction. In Proceedings of the 13th international conference on intelligent data engineering and automated learning: 7435 (pp. 320 – 327). Berlin , Heidelberg: Springer-Verlag.

Eric P. Xing, Andrew Y. Ng, Michael I. Jordan, e Stuart Russell. Distance metric learning, with application to clustering with side-information. Em Advances in Neural Information Processing Systems 15 (NIPS 2002), 2002.

Edwards, A. W. F., & Cavalli-Sforza, L. L. (1965). A method for cluster analysis. Bio- metrics, 21 , 362 – 375.

Kilian Q. Weinberger e Lawrence K. Saul. Distance metric learning for largemargin nearest neighbor classification. Journal of Machine Learning Research, 10:207 – 244, 2009.

Schultz, M. , & Joachims, T. (2004). Learning a distance metric from relative compar- isons. In S. Thrun, L. K. Saul, & B. Schölkopf (Eds.), Advances in neural information processing systems 16 (pp. 41 – 48). MIT Press .

Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20 (3), 273 – 297.

Villela, S. M., de Castro Leite, S., & Neto, R. F. (2016). Incremental p-margin algo- rithm for classification with arbitrary norm. Pattern Recognition, 55 , 261 – 272.

Charles L. Lawson e Richard J. Hanson. Solving Least Squares Problems. Prentice-Hall, Englewood Cliffs, NJ, 1974.

Angelo C. M. da Silva, Maurício A. N. Coelho e Raul Fonseca Neto. A Music Classification model based on metric learning applied to MP3 audio files. Expert Systems With Applications 144 (2020) 113071, 2020.

J. B. MacQueen. Some Methods for classification and Analysis of Multivariate Observations. Proceedings of 5th Berkeley Symposium on Mathematical Statistics and Probability. 1. University of California Press. pp. 281 – 297, 1967.