## IV - Metodologia

### IV.1 – Nomenclatura de Blocos e Problemas

Para melhor compreensão do estudo e do papel do LLM como especialista ou aprendiz foi proposta uma configuração de dados apoiada em três blocos de sete tarefas segundo a descrição da tabela 1.

Tabela 1: Tarefas de classificação binária $2^D$ e seu papel nos blocos.

| Tarefa | Bloco | Descrição |
|---|---|---|
| A | 1 | Linear, centroides Gaussianos, LLM como fonte |
| B | 1 | Linear, centroides com rotação horária (±1,5), transferência |
| C | 1 | Linear, centroides com rotação anti-horária (±1,5), transferência |
| D | 1 | Não Linear, Meia-Lua, não-linearidade |
| E | 2 | Linear, especialista com métrica w* conhecida, LLM como aprendiz |
| F | 2 | Não Linear, Meia-Lua, *ground truth*, LLM como aprendiz |
| G | 3 | Base Real, peso × altura, fronteira elíptica, LLM como aprendiz |

### IV.2 - Protocolo Experimental

Para a realização dos experimentos relacionados às tarefas de Aprendizado em Contexto (ICL) utilizam-se dois modelos de LLMs, gpt-4o-mini (OpenAI) e gemini-2.5-flash-lite (Google,via OpenRouter), ambos com temperatura T = 0, minimizando a aleatoriedade para não introduzir um ruído na avaliação do critério decisório. A narrativa principal segue o gpt-4o-mini, com o gemini-2.5-flash-lite usado como réplica de contraste, sendo que as diferenças relevantes são destacadas explicitamente. Ressalva-se que T = 0 não garante um determinismo estrito, pois roteamento, *batching* e não associatividades de ponto flutuante podem introduzir certa aleatoriedade, fenômeno este já documentado em estudos de estabilidade de LLMs (Atil et al., 2024 e Windisch et al., 2026). Os experimentos utilizam múltiplas sementes, a saber {42, 123, 7} e três repetições por configuração justamente para medir essa variância.

Os detalhes de como as respostas foram coletadas estão descritos no Apêndice A. As consultas ao modelo foram feitas em paralelo, com um limite de dez ao mesmo tempo, sendo que cada resposta passou por um tratamento que reconhece o rótulo mesmo quando o modelo responde com variações de formato, por exemplo: "Classe A" em vez de "A”, e o mesmo protocolo foi repetido para todas as combinações de

nomes de classe, nomes de atributo, versões de enunciado e quantidades de exemplos.

Quando uma resposta não pode ser interpretada, mesmo depois de reenviar a pergunta, o protocolo atribui um rótulo por um sorteio fixo, calculado a partir das coordenadas do ponto. Entretanto, vale registrar que esse recurso não precisou ser usado nenhuma vez nesta execução: das 129.868 consultas feitas aos dois modelos de LLMs, todas foram interpretadas normalmente. Assim, as medidas de concordância apresentadas no artigo refletem apenas decisões reais do modelo, sem nenhum rótulo atribuído por sorteio.

Depois da coleta, uma verificação foi realizada sobre o registro de todas as consultas medindo quanto cada modelo muda de resposta quando recebe exatamente a mesma pergunta mais de uma vez, mesmo com a temperatura ajustada em zero, que em tese deveria tornar a resposta sempre igual. Aqui os dois modelos se comportam de forma diferente. O gpt-4o-mini alterou sua resposta em 4,3% das perguntas repetidas; o gemini-2.5-flash-lite não alterou em nenhuma. Para o gpt-4o-mini esse percentual de 4,3% funciona como o ruído inerente da medição. Se o próprio modelo discorda de si mesmo em cerca de 4,3% dos casos, nenhuma medida de concordância com ele, seja a fidelidade da métrica estimada, a consistência ou o coeficiente *kappa*, pode passar de aproximadamente 95,7%. Neste sentido, todos os resultados desse modelo devem ser lidos tendo estes dados em mente.

**Variáveis de controle:**

- Sementes utilizadas: $s \in \{42, 123, 7\}$

- Repetições: $R = 3$ por configuração.

- Nomes de classe: neutros (A/B, 0/1), semânticos (Positivo/Negativo), cromáticos (Azul/Vermelho) e suas inversões (ordem/posição).

- Nomes de atributos: x1/x2 (neutro), altura/peso (semântico), atributo 1/atributo 2 (técnico).

- Variantes de *prompt*: padrão, geométrico, cot (*chain-of-thought*), tabular.

- Tamanhos *few-shot*: $n \in \{0, 4, 10\}$ (transferência) e $n \in \{0, 4, 10, 20, 40\}$ (ICL). Os tamanhos são pares para garantir uma seleção balanceada entre as duas classes, com metade dos exemplos para cada uma.

**IV.3 – Métricas de Avaliação**

**- Fidelidade**

A fidelidade é a fração de pontos em que a classificação pelo centroide mais próximo para um dado vetor w estimado concorda com a classificação do LLM (problema A), ou seja:

$F = 1/n \sum_{i=1,\ldots,n} | [ y_w(v(i) = y_{LLM}v(i)]$,

medindo o quanto a métrica reproduz o LLM, e não sua correção. Distingue-se da acurácia versus *ground truth*, que mede a concordância com o rótulo verdadeiro do problema.

**- Consistência**

Idem à fidelidade, mas com valores $y_w$ calculados em relação aos centroides de novos problemas porém resguardando a métrica (problemas B e C). Neste caso, apenas o vetor *w* é transferido do Problema A, sendo os centroides recalculados localmente a partir dos rótulos que o LLM atribui aos problemas de destino modificados pelas transformações geométricas dos dados. Isso isola o efeito da métrica do efeito da geometria, dado pela nova posição dos centroides, evitando que uma eventual queda de consistência nos problemas B e C sejam mero artefato de centroides deslocados entre distribuições.

**Cohen's k**

Esta métrica avalia a concordância entre dois avaliadores considerando também a possibilidade de concordância pelo acaso, ou seja:

$k = (P_0 – P_e) / (1 - P_e)$,

onde $P_0$ é a proporção de concordância relativa observada e $P_e$ a probabilidade de concordância ao acaso, sendo:

$P_e=\sum_k p_k p'_k$ ,

sendo $p_k$ a probabilidade estimada de classificação de um item na classe *k* pela métrica *w* e $p'_k$ a probabilidade marginal de classificação de um item na classe *k* pela LLM. A interpretação desta métrica pode ser feita pelas faixas descritas em Landis e Koch, 1977 e pelo coeficiente de *Kappa k*, onde: *κ<0,2 (fraca), 0,2–0,4 (razoável), 0,4–0,6 (moderada), 0,6–0,8 (substancial), 0,8 (quase perfeita)*. Valores negativos indicam concordância pior que o acaso.

**- F1-Score**

Este estimador avalia a média harmônica entre precisão e recall. Para cada classe *k*, com precisão:

$P_k = VP_k/(VP_k + FP_k)$,

*recall*:

$R_k = VP_k/(VP_k + FN_k)$,

define-se:

$F1_k = 2P_kR_k/(P_k + R_k)$,

sendo *VP* referente ao número de verdadeiros positivos, *FP* referente ao número de falsos positivos e *FN* ao número de falsos negativos. Os valores da métrica variam entre *0 (pior) e 1 (melhor)* .

**IV.4 – Projeções Não-Lineares**

A métrica l utilizada para o cálculo das distâncias parametrizadas produz somente fronteiras lineares de decisão. Isto é suficiente em problemas com separação linear em $R^2$ com atributos *x1 e x2*. Entretanto, para entender se o modelo LLM captura interações não lineares entre os atributos em problemas não linearmente separáveis, aumenta-se a dimensão do espaço do problema sem comprometer o formalismo linear.

Para tanto, se realiza uma projeção em $R^3$ acrescentando um terceiro atributo, *x3 = x1.x2*, possibilitando uma fronteira de decisão hiperbólica. Também, se realiza uma projeção em $R^4$ acrescentando dois novos atributos, $x1^2$ *e* $x2^2$ , possibilitando uma fronteira de decisão elíptica. Comparando-se os resultados com dois, três e quatro atributos, avalia-se a expressividade adicional da aproximação da métrica bem como a captura de interações não lineares entre os atributos pelo raciocínio do LLM.

**IV.5 - Bloco 1 – Modelo LLM como Fonte**

Inicialmente, o LLM rotula os pontos do Problema A em *zero-shot* e *few-shot*. A partir deste esquema de rotulação estima-se o vetor de parâmetros *w* utilizando *o Perceptron* Estruturado como estimador principal e o NNLS como um calibrador no sentido de atestar a concordância da métrica estimada. A comparação entre os dois estimadores é realizada a partir do cálculo da similaridade do cosseno.

Em seguida, a métrica estimada é transferida para novos conjuntos de dados, com a mesma quantidade de amostras obtidos por meio de transformações geométricas dos dados do problema A, a saber, problema B com rotação horária e

problema C com rotação anti-horária. Após esta etapa de transferência o LLM volta a classificar as amostras de duas formas. A primeira em *zero-shot* e a segunda em *few-shot* com a utilização de um número de exemplos, n ∈ {4, 10}, na fase de demonstração.

Como métricas de avaliação são calculadas a fidelidade, consistência, coeficiente *Kappa k* e o *F1-Score* entre a métrica estimada *w* e o LLM nos problemas A-D. Os testes de viés em relação as variantes de *prompt*, considerando nomes de classes e nomes de atributos também são realizados nestes problemas. O teste-oráculo que atesta a corretude dos estimadores é realizado fornecendo-se uma métrica conhecida para a rotulação de um conjunto de dados sintéticos formando assim um *ground truth*. Em seguida, classifica-se este mesmo conjunto com os dois estimadores avaliando as respectivas fidelidades. Testam-se configurações Euclidianas ([1,0; 1,0]) e anisotrópicas ([0,3; 1,5], [1,5; 0,3]), além de transferência entre geometrias.

**IV.6 – Bloco 2 - Modelo LLM como Aprendiz**

Neste caso, os papéis se invertem. Um especialista externo com uma métrica *w* conhecida onde o atributo x2 é cinco vezes mais relevante que o atributo x1, rotula o Problema E com separação linear. Para o Problema F relacionado ä Meia-Lua, o especialista é o próprio *ground truth*. No Aprendizado em Contexto em *few-shot*, seleciona-se um subconjunto de *k* pontos como exemplos e avalia se o LLM reproduz o critério do especialista nos demais. São utilizadas quatro estratégias de seleção de exemplos, descritas a seguir:

- Fácil

São escolhidas as *k* amostras de maior margem ou longe da fronteira.

- Difícil

São escolhidas as *k* amostras de menor margem ou próximas à fronteira.

-Mista

São escolhidas *k* amostras sendo metades fáceis e metades difíceis.

- Aleatória

São escolhidas *k* amostras de forma aleatória seguindo uma distribuição uniforme.

Como referência, treinam-se classificadores *baselines* clássicos, k-NN, Regressão Logística e SVM-RBF nos mesmos exemplos selecionados para a fase de demonstração no sentido de testar a acurácia do Aprendizado em Contexto com o modelo LLM.

Testa-se também o viés proporcionado pela mudança de ordenação das amostras na sequência de *prompt*.

**IV.7 - Bloco 3 - Estudo de Caso Real**

Uma base real com atributos de peso e altura é utilizada para a classificação do gênero homem ou mulher, Problema G. Este problema apresenta como solução ótima, associada ao classificador *Bayesiano*, uma fronteira de separação com formato aproximadamente elíptico. A base contém 100 amostras, sendo 50 de homens e 50 de mulheres.

A divisão treino/teste merece explicação, pois influência nos valores reportados nos resultados. Em cada semente, as 100 amostras são permutadas e divididas em 70 de treino e 30 de teste. Para a estimativa da métrica se utiliza as 70 amostras de treino. Em seguida, o LLM classifica o mesmo conjunto de treino em *zero-shot* e *few-shot* e as métricas são avaliadas utilizando-se estes resultados seguindo os mesmos passos do problema A.

Em seguida, na etapa do Aprendizado em Contexto, em sua fase de demonstração, os exemplos são selecionados de forma aleatória do conjunto de treino e a avaliação é realizada nas 30 amostras do conjunto de teste, garantindo que nenhum exemplo mostrado ao LLM apareça no conjunto avaliado. Este mesmo protocolo de divisão é aplicado ao Problema E e, também, ao Problema F.

Testa-se o viés semântico dos nomes de classes com variantes de nomes neutros, perguntando “A ou B” em vez de “homem” ou “mulher”, para isolar o prior semântico. Da mesma forma, testa-se o nome dos atributos com variantes neutras, considerando “x1” e “x2” ao invés de “peso” e “altura”. Dada a pequena escala do conjunto de amostras, reporta-se o número absoluto de erros além dos respectivos percentuais.

Para a análise da influência da não linearidade no problema, considerando a fronteira de decisão uma superfície quadrática, alimenta-se o *prompt* com novos atributos sendo estes $x1.x2$ para projeção em $R^3$ e $x1^2, x2^2$ para projeção em $R^4$.

Reportam-se intervalos de confiança de 95% via *bootstrap* com $10^4$ amostragens repetidas e o valor do coeficiente *kappa k* de *Cohen*. Artstein e Poesio, 2008, sistematizam os coeficientes de concordância, justificando Cohen’s $\kappa$ quando o LLM e a métrica *w* são tratados como dois anotadores fixos e independentes.

**Bibliografia**

Berk Atil, Alexa Chittams, Lisheng Fu, Ferhan Ture, Lixinyu Xu, e Breck Baldwin. stability: A detailed analysis with some surprises. Preprint arXiv:2408.04667, 2024.

Paul Windisch, Carole Koechli, Fabio Dennstädt, Daniel M. Aebersold, Daniel R. Zwahlen, Robert Förster, e Christina Schröder. Is one run enough? reproducibility of flagship large language models across temperature and reasoning settings in biomedical text processing. Preprint medRxiv, 2026.

Ron Artstein e Massimo Poesio. Inter-coder agreement for computational linguistics. Computational Linguistics, 34(4):555–596, 2008.

J. Richard Landis e Gary G. Koch. The measurement of observer agreement for categorical data. Biometrics, 33(1):159–174, 1977.