III – Trabalho Relacionado

Nesta seção serão abordados diversos trabalhos relacionados ao Aprendizado em Contexto que possuem algum alinhamento com o trabalho aqui desenvolvido. Particularmente, enfatiza-se, além dos trabalhos mais importantes e precursores, aqueles cujas tarefas estão relacionadas ao aprendizado de funções lineares, aqueles que abordam questões relativas ao viés semântico, sequencia de *prompts* e fronteiras de decisão e também aqueles que procuram explicar os mecanismo de funcionamento do *Transformer* quando utilizado para o Aprendizado em Contexto, e sua conexão teórica em relação as técnicas usuais de Otimização e Aprendizado de Máquinas como o Gradiente Descendente, Mínimos Quadrados e Inferência *Bayesiana*.

Inicialmente, pode-se destacar o trabalho pioneiro de Brown et al., 2020. Neste trabalho um grupo de autores, pesquisadores da OpenAI, demonstram que modelos LLM, com uma quantidade de parâmetros em alta escala, até 175 bilhões, conseguem obter um desempenho competitivo em determinadas tarefas específicas considerando o cenário do Aprendizado em Contexto. Este desempenho é comparável a modelos LLM com pré-treinamento em grandes corpora de texto, seguido de um ajuste fino, *fine-tuning.*

Especificamente, os autores testam a acurácia do modelo auto-regressivo GPT-3 com diversas escalas de parâmetros e sequencia de *prompt*, a saber, *zero-shot*, *one-shot e few-shot*. Vários tipos de tarefas foram utilizados, incluindo tradução, resposta a perguntas e tarefas de preenchimento de lacunas, bem como diversas tarefas que exigem raciocínio em tempo real ou adaptação de domínio, como desembaralhar palavras, usar uma palavra nova em uma frase ou realizar operações aritméticas com números de três dígitos.

Contudo, foram identificadas tarefas nas quais o Aprendizado em Contexto falhou, bem como tarefas nas quais o modelo enfrentou questões metodológicas relacionadas ao treinamento em grande corpus de dados da *web*. Por fim, foi constatado que o GPT-3 consegue gerar artigos de texto informativos nos quais avaliadores possuem grande dificuldade em distinguir de artigos redigidos por humanos.

LLMs podem exibir vieses semânticos sistemáticos dependentes dos nomes de classes e atributos. Rótulos com conotação semântica tendem a distorcer as distribuições previstas de saída do modelo, independentemente do conteúdo dos exemplos. De acordo com Zhao et al., 2021, o Aprendizado em Contexto com poucos exemplos de treinamento, ou seja *few-shot*, pode ser instável sendo que a escolha do formato do *prompt*, dos exemplos de treinamento e até mesmo da ordem de inserção desses exemplos pode fazer com que a precisão varie de um nível próximo ao do acaso até um nível próximo ao estado da arte.

Os autores identificam três fontes principais deste problema, a saber, preferência por rótulos majoritários, recência e frequência de *tokens* no pré-treinamento. Foram testados sistematicamente o efeito de nomes das classes (neutros, semânticos, cromáticos) e de atributos no preenchimento de *prompts*. Demonstra-se no trabalho que essa instabilidade decorre do vieses dos modelos de linguagem em prever certas respostas, por exemplo, aquelas mais repetitivas, posicionadas mais perto das últimas perguntas ou que são mais frequentes nos dados de pré-treinamento. Esses vieses, normalmente, provocam uma mudança na distribuição de saída do modelo.

Para neutralizar esses vieses e mitigar esta deficiência os autores propõem uma calibração da distribuição de saída. Resumidamente, estima-se o viés do modelo em relação a determinadas respostas fornecendo uma entrada de teste fictícia e desprovida de conteúdo. Em seguida, ajusta-se os parâmetros de calibração para que a entrada sem conteúdo resulte em pontuações uniformes para cada resposta. Esse procedimento de calibração contextual permite definir adequadamente os parâmetros de calibração sem a necessidade de dados de treinamento adicionais.

Min et al., 2022, questionam o papel dos mapeamentos, entradas-rótulos, mostrando que a alimentação do modelo com exemplos apresentando rótulos corretos, *ground truth*, não é de fato uma necessidade. A substituição aleatória de rótulos na sequência de *prompts* praticamente não prejudica o desempenho em diversas tarefas de classificação e de múltipla escolha, mostrando ser um resultado consistente em doze modelos diferentes, incluindo o GPT-3.

De outra forma, os autores constatam que outros aspectos no preenchimento de *prompts* são os principais fatores determinantes do desempenho na fase de teste. Citam como exemplo:

1 - O espaço de rótulos e a distribuição do texto de entrada especificado pelos pares entrada-rótulo;

2 – Preenchimento de lacunas, por exemplo, quando o espaço de rótulos é desconhecido, usar palavras aleatórias como rótulos é significativamente melhor do que não usar rótulos.

Para avaliar o impacto de entradas e rótulos corretos, *ground-truth input-label* , os autores propõem três formas de sequencia de *prompts:*

1 - Ausência de exemplos ou *zero-shot*. Consiste de um método que não utiliza nenhum dado rotulado. A previsão é feita por meio de $Arg\ Max\ y_{\in C}\ P(y|x)$, onde x é a entrada de teste e C um pequeno conjunto discreto de possíveis rótulos.

2 – Exemplos com rótulos corretos, *gold labels few-shot*. São utilizados k exemplos rotulados $(x(1), y(1)),...,(x(k), y(k))$. Assim, uma concatenação dos k pares é utilizada

para alimentar o *prompt* e predizer o rótulo de uma nova entrada *x*, por meio de *Arg Max* $_{y \in C}$ $P(y|(x(1), y(1),...,x(k),y(k),x)$.

3 – Exemplos com rótulos aleatórios. Neste caso, também são utilizados *k* exemplos de entrada-rótulo, mas em vez de se utilizar os rótulos corretos, *gold labels*, utiliza-se um conjunto de rótulos amostrados aleatoriamente de *C* seguindo uma distribuição uniforme. A concatenação dos *k* pares é então utilizada para se predizer o rótulo de uma nova entrada *x* por meio de *Arg Max* $_{y \in C}$ $P(y|(x(1), y^(1),...,x(k),y^(k),x)$.

De forma contrária, o trabalho de Su et al., 2022, mostra que a seleção estratégica de exemplos, com equilíbrio entre diversidade e representatividade, supera a seleção aleatória. Neste sentido, os autores examinam as implicações do Aprendizado em Contexto para a criação de conjuntos de dados destinados a novas tarefas em Processamento de Linguagem Natural.

Partindo de métodos recentes de Aprendizado em Contexto, os autores formulam a seguinte estratégia de seleção de exemplos baseada em dois passos. Uma primeira etapa de anotação seletiva, onde se escolhe, antecipadamente, um conjunto de exemplos ainda não rotulados a serem rotulados antes da fase de teste. Um método de anotação seletiva, não supervisionado e baseado em grafos, é utilizado para selecionar exemplos diversos e representativos para serem rotulados. Formalmente, dado um conjunto de amostras não rotuladas $X = \{x(i), i=1,...,n\}$, a anotação seletiva visa selecionar um subconjunto de amostras, $L \subset X$, para serem rotuladas.

Uma segunda etapa chamada de recuperação de *prompts*, reutiliza os exemplos selecionados anteriormente no momento do teste. Uma vez obtido um conjunto de exemplos rotulados *L*, proveniente da anotação seletiva, recupera-se alguns exemplos desse conjunto para servirem como exemplos para o Aprendizado em Contexto, para cada instância de teste. Os exemplos mais semelhantes a cada instância de teste são selecionados com base na medida da similaridade de cosseno.

O trabalho desenvolvido por Zhao et al.,2024 propõe investigar e compreender o Aprendizado em Contexto sob a perspectiva das fronteiras de decisão geradas para problemas de classificação binária com dados sintéticos, apresentando uma forte similaridade com o trabalho aqui desenvolvido. As fronteiras de decisão em R^2 são de fácil visualização e fornecem informações importantes sobre o comportamento qualitativo dos vieses indutivos em relação a classificadores *baselines*. Os autores constatam que as fronteiras de decisão fornecidas pelos modelos LLMs atuais em simples tarefas de classificação binária são frequentemente irregulares e não suaves, independentemente da separação linear da mesma, comparada às fronteiras apresentadas pelos classificadores KNN, SVM, Árvore Decisória e MLP. Neste sentido, os autores investigam os fatores que influenciam essas fronteiras de decisão e exploram métodos para aprimorar sua capacidade de generalização.

Foram consideradas diversas abordagens, incluindo métodos que dispensam treinamento e técnicas de ajuste fino*, fine-tuning*, para LLMs, o impacto da arquitetura do modelo e a eficácia de técnicas de sequencia de *prompt* com o intuito de suavizar as fronteiras de decisão. Dentre os fatores analisados e que impactam a saída dos modelos utilizados, de código aberto LLama e código fechado GPT em suas recentes versões, estão a complexidade do modelo em parâmetros, o pré-treinamento de dados, o número de exemplos apresentados para o Aprendizado em Contexto em *few-shot* e seu ordenamento e os vieses semânticos.

Ainda no que tange a questões relativas ao pré-treinamento de LLMs e sua influência no Aprendizado em Contexto pode-se comentar o trabalho de Razeghi et al., 2022. Neste trabalho os autores demonstram que modelos de linguagem pré-treinados desenvolvem capacidade de realizar raciocínio numérico ao extrapolarem a partir de poucos exemplos em cenários de Aprendizado em Contexto em *few-shot*. No entanto, não deixam claro em que medida essa extrapolação se baseia em um raciocínio coerente e robusto.

Neste sentido, os autores investigam a capacidade desses modelos de raciocinar com termos que são menos frequentes nos dados de pré-treinamento. Em particular, examinam as correlações entre o desempenho do modelo em instâncias de teste e a frequência dos termos presentes nessas instâncias nos dados de pré-treinamento.

São utilizados vários modelos de linguagem baseados no modelo GPT em diversas tarefas de dedução numérica, por exemplo, aritmética e conversão de unidades. Os resultados demonstram de forma consistente que os modelos apresentam maior precisão em instâncias cujos termos são mais frequentes na fase de pré-treinamento. De forma geral, os autores constatam um desempenho aceitável dos LLMs em tarefas de raciocínio numérico com base nos resultados obtidos, mas levantaram a questão da generalização deste desempenho para além dos dados de pré-treinamento.

O trabalho descrito por Marks e Tegmark, 2024 utiliza base de dados de alta qualidade compostas por uma sequência de perguntas cujas respostas devem ser sim ou não no sentido de concordarem ou discordarem das assertivas. O objetivo dos autores é estudar detalhadamente a estrutura interna das representações de verdade nos LLMs, baseando-se em três linhas de evidência: 1. Visualizações em R^2 das representações geométricas das respostas verdadeiro/falso dos LLMs, as quais revelam, claramente, uma estrutura linear de separação. 2. Experimentos de transferência nos quais visualizações específicas treinadas em uma base de dados generalizam para bases de dados diferentes. 3. Evidências causais obtidas por meio de intervenções assertivas no processamento completo de *tokens* de um LLM, fazendo com que ele trate afirmações falsas como verdadeiras e vice-versa.

De modo geral, os autores apresentam evidências de que, em escala suficiente, os LLMs representam as respostas binárias em modelos lineares considerando a veracidade ou falsidade do conjunto de afirmações factuais. Também demonstram que perguntas simples baseadas no valor absoluto da diferença entre médias generalizam tão bem quanto outras técnicas de sondagem, ao mesmo tempo em que identificam traços de respostas mais casualmente associados na saída dos modelos.

A constatação feita pelos autores, baseada em um conjunto de evidências, de que LLMs representam a veracidade de afirmações como estruturas lineares em suas ativações, torna plausível a hipótese aqui sustentada de aproximar os critérios decisórios de um LLM por estruturas lineares. Os dois trabalhos diferem, no entanto, no tipo de análise. Ao contrário do trabalho de Marks e Tegmark, o trabalho aqui proposto opera sobre decisões observadas via API, o único acesso disponível a modelos fechados, investigando o critério decisório sem inspecionar ativações e estados internos do modelo.

O trabalho apresentado por Garg et al., 2022 considera, para o estudo do Aprendizado em Contexto, uma tarefa muito bem definida, representada por uma classe de funções lineares associadas ao problema de regressão. Formalmente, define-se uma classe de funções *F*, onde:

$F = \{f \mid f(x,w) = w^T x,\ x,w \in R^D\},$

onde o vetor *w* se apresenta como uma variável aleatória derivada de uma função Gaussiana isotrópica, ou seja, $w \in N(0,\sigma^2 I_D)$. Para cada escolha de *w* são gerados um conjunto de vetores, $x \in R^D$, também obtidos de uma distribuição Gaussiana isotrópica, formando assim um conjunto de treinamento $\{(x,f(x,w))_k,\ k=1,...,n\}$ contendo *k* funções lineares ou regressores. O objetivo consiste em, uma vez treinado pelo Aprendizado em Contexto, se alimentando o modelo com uma sequência de *prompts* para cada regressor, avaliar se o mesmo seria capaz de generalizar para um conjunto de novas funções e dados.

Os resultados obtidos demonstram que modelos auto-regressivos de um LLM, representados pelo GPT-3 Brown et al.,2020, e pela arquitetura *decoder* do *Transformer* , Vaswani et al., 2017, são capazes de generalizar para novas funções de mesma classe com parâmetros desconhecidos, obtendo um desempenho comparável aos estimador de Mínimos Quadrados, *Least-Square*, usando como métrica o Erro Quadrático Médio (MSE) .

Durante os experimentos duas formas de *shift* nos exemplos de teste foram utilizadas. A primeira, adicionando um ruído Gaussiano ao conjunto de teste dos regressores e a segunda, representada por uma transformação geométrica, através da geração dos exemplos de treinamento em um ortante e dos exemplos de teste em outro.

O trabalho de Akyurek et al., 2023, avalia o Aprendizado em Contexto também sob a perspectiva de modelos lineares de regressão. Entretanto, ao contrário do trabalho de Garg et al., 2022 , cujo objetivo é descrever quais funções o Aprendizado em Contexto pode aprender, os autores se preocupam em mostrar de que forma e como este aprendizado acontece. Para tanto, os autores investigam a hipótese de que o Aprendizado em Contexto, representada pela pilha *decoder* do *Transformer,* implementa, implicitamente, algum algoritmo de aprendizado.

São oferecidos três conjuntos de evidências. Inicialmente, é mostrado por construção que o *Transformer* implementa, para o aprendizado de modelos lineares, algoritmos baseados no método do Gradiente Descendente ou na solução da Regressão de *Ridge* que consiste na solução dos mínimos quadrados com regularização. Em segundo lugar, é mostrado empiricamente que o Aprendizado em Contexto apresenta resultados de acurácia comparáveis a estes métodos clássicos e, finalmente, os autores apresentam evidências de que o aprendizado em contexto compartilha características semelhantes com estes métodos no computo de parâmetros.

Para uma melhor compreensão dos mecanismos de Aprendizado em Contexto em modelos *Transformer* Oswald, et al., 2023 sugerem que o treinamento auto-regressivo do mesmo está intimamente relacionado a formulações de meta-aprendizado baseadas no método do Gradiente Descendente. Neste sentido os autores propõem a construção e execução de modelos no sentido de demonstrar esta equivalência.

Esta demonstração se baseia no cálculo explícito do conjunto de pesos de uma única camada linear de auto-atenção da pilha de *decoder* do *Transformer*. Processo este equivalente a correção dos pesos pelo método do Gradiente aplicado a uma função de perda representada pelo Erro Quadrático médio (MSE).

Com base nesta equivalência os autores mostram empiricamente que o modelo *Transformer*, composto apenas por uma camada linear de auto-atenção, treinado em conjunto de dados de regressão, apresenta resultados bem alinhados com modelos treinados pelo método do gradiente. Neste sentido, o trabalho propõe a otimização do treinamento do *Transformer* com o uso do método do gradiente descendente. Adicionalmente, com a utilização de redes MLP na arquitetura do *Transformer*, torna-se possível a solução de tarefas de regressão não linear sendo esta proposta também estendida para o uso de métodos *kerne*l paramétricos e não paramétricos.

Os resultados obtidos permitem, pelo menos no domínio de problemas de regressão, compreender de forma mecanicista, o funcionamento interno do Aprendizado em Contexto em *Transformers* otimizados superando o desempenho de meta-aprendizado baseados no método do Gradiente Descendente padrão.

Partindo da constatação de que, diversos trabalhos recentes demonstram que *Transformers* podem implementar algoritmos como o Gradiente Descendente, o trabalho apresentado por Ahn et al., 2023 questiona até que ponto podem os *Transformers* aprender a implementar tais algoritmos ao serem treinados com instâncias aleatórias de problemas.

Neste sentido, em consonância com os trabalhos anteriormente citados (Garg et al, 2023, Ayurek et al, 2023 e Oswald et al, 2023) os autores apresentam uma análise da função de perda de *Transformers* lineares, com uma única camada de auto-atenção linear, treinados com instâncias aleatórias do modelo de regressão linear. Como resultado desta análise o trabalho demonstra que para atingir o mínimo global da função de perda relacionada aos exemplos de treinamento o *Transformer* executa uma única iteração do gradiente descendente pré-condicionado. Vale ressaltar que a matriz de pré-condicionamento se adapta não apenas à distribuição de entrada, mas também à variância induzida pela aleatoriedade dos dados. Para um *Transformer* com múltiplas camadas de atenção, os autores provam que, para alcançar mínimos globais da função de perda dos exemplos de treinamento, torna-se necessário executar uma quantidade correspondente de iterações do gradiente descendente pré-condicionado.

No entanto, os resultados obtidos apontam para a necessidade de futuros estudos teóricos sobre o aprendizado de algoritmos de otimização por meio do treinamento de *Transformers*.

Nesta mesma linha, considerando a proposição empírica de que, no Aprendizado em Contexto *Transformers*, treinados com instâncias aleatórias de problemas de Regressão Linear, se comportam como algoritmos de Aprendizado Supervisionado, mimetizando os resultados do método dos Mínimos Quadrados, o trabalho de Zhang et al., 2023 busca compreender os mecanismos subjacentes a esse fenômeno.

Para tanto, os autores investigam a dinâmica do Aprendizado em Contexto com o uso de *Transformers* com uma única camada de atenção linear treinados via fluxo de gradiente em tarefas de regressão linear. Demonstra-se no trabalho que, apesar da não convexidade, o fluxo de gradiente com uma inicialização aleatória adequada encontra um mínimo global da função de perda. Nesse mínimo global, ao receber um *prompt* de teste com exemplos rotulados de uma nova tarefa de previsão, o *Transformer* alcança um erro competitivo com os melhores classificadores lineares para a distribuição dos exemplos de teste.

Adicionalmente, os autores testam a robustez do *Transformer* treinando o mesmo para diferentes distribuições de *prompt*. Entretanto, embora algumas variações sejam toleradas, mudanças na distribuição das covariáveis dos *prompts* não são assimiladas. Complementa-se essa constatação com experimentos em arquiteturas

Tranformer não lineares e com múltiplas camadas, as quais demonstraram ser mais robustas a mudanças nas covariáveis.

Complementando, Dai et al., 2023 mostram de forma experimental que a Aprendizagem em Contexto, *few-shot*, em *Transformes* executa o método do Gradiente Descendente em sua fase de demonstração sendo uma forma de meta-otimização. Fornecem também evidências que interpretam o Aprendizado em Contexto como um processo de ajuste fino ou *finetuning* implícito comparável ao pré-treinamento explícito de *Transformers* através do uso do método *Backpropagation*.

Ainda, neste trabalho, os autores estabelecem uma linha de conexão entre estes dois processos relacionando o mecanismo de auto-atenção do *Transfomer* a uma forma dual do método do gradiente descendente. Neste sentido, os autores propõem um novo mecanismo de atenção baseado no método *Momentum* provando a sua eficiência quando comparado ao mecanismo de atenção padrão.

Segundo os autores o Aprendizado em Contexto em sua fase de demonstração gera, inicialmente, meta-gradientes em função dos passos de execução do *Transformer* nos exemplos apresentados. Em seguida, estes meta-gradientes são aplicados ao modelo estático, sem novos ajustes de parâmetros, na fase de perguntas-respostas, configurando, portanto, o Aprendizado em Contexto como um meta-otimizador.

Relacionado à Teoria *Bayesiana* de Inferência pode-se citar o trabalho de Muller et al., 2022. Este trabalho propõe um modelo de arquitetura denominado PFNs, *Prior-Data Fitted Networks*, no sentido de aproximar um processo de Inferência Bayesiano. Este modelo, baseado em modificações no *Transformer encoder*, faz uso de um conhecimento explícito ou de um conhecimento prévio, *a priori*, no sentido de capturar com mais precisão a incerteza do Aprendizado em Contexto em seu tempo de teste. Desta forma, PFNs possibilitam o Aprendizado em Contexto de se aproximar de técnicas de Aprendizado de Máquina, mais especificamente de Meta-Aprendizado, as quais utilizam uma vasta quantidade de conhecimento prévio, no sentido de prever com maior acerto um conjunto de distribuições a posteriori.

Segundo os autores, o único requisito para o funcionamento das PFNs é a capacidade de amostrar a partir de uma distribuição a *priori* sobre tarefas de Aprendizado Supervisionado. Nesse sentido, o método proposto reformula o problema relacionado à aproximação da distribuição *a posteriori*, como um problema de classificação supervisionada com um conjunto de treinamento. Para tanto, o modelo seleciona repetidamente uma tarefa da distribuição *a priori*, extrai um conjunto de dados e seus respectivos rótulos, oculta um dos rótulos e aprende a realizar previsões probabilísticas para o mesmo com base na entrada composta pelo restante dos pares entradas-rótulos. Ao receberem como entrada um conjunto de amostras de uma nova tarefa de aprendizado supervisionado, as PFNs realizam previsões probabilísticas no tempo de teste realizando uma única propagação direta, *forward propagation*, similar a um processo de inferência *Bayesiana*.

Como resultados, os autores demonstram que as PFNs conseguem emular Processos Gaussianos com extrema precisão e também viabilizar uma Inferência Bayesiana eficiente para problemas intratáveis. Foram obtidos resultados robustos em áreas bastante distintas, como regressão por Processos Gaussianos, Redes Neurais Bayesianas, classificação de pequenos conjuntos de dados tabulares e classificação de imagens com poucos exemplos, demonstrando a generalidade das PFNs.

O trabalho desenvolvido por Xie et al.,2022, estuda como o Aprendizado em Contexto pode emergir quando os documentos de pré-treinamento apresentam um conjunto de conceitos coerentes e latentes. Nesse cenário, o LLM, durante o pré-treinamento, deve inferir estes conceitos latentes da base de documentação para gerar subsequentes *tokens* relacionados a este conceito. No tempo de teste, o Aprendizado em Contexto ocorre quando o LLM também infere um conceito latente compartilhado entre os exemplos de um *prompt*. Os autores demonstram em que condições isso ocorre, apesar de existir uma discrepância de distribuição entre os *prompts* e os dados de pré-treinamento, em um cenário no qual a distribuição de pré-treinamento é uma mistura de HMMs, *Hidden Markov Models.*

De uma forma sucinta, os autores afirmam que o Aprendizado em Contexto pode depender de conceitos latentes inferidos da fase de pré-treinamento. Posteriormente, ao realizar o condicionamento em um *prompt*, o Aprendizado em Contexto emerge quando o LLM também infere um conceito compartilhado entre os exemplos do *prompt* para realizar uma previsão. Inicialmente, assume-se que o LLM se ajusta exatamente à distribuição de pré-treinamento *p*.

Consequentemente, a questão principal do Aprendizado em Contexto passa a ser a caracterização da distribuição preditiva *a posteriori* das respostas, dado determinado *prompt*, ou seja, *p(saída/prompt)* considerando as distribuições condicional e *a priori* do pré-treinamento, ou seja, *p(conceito,prompt/resposta)*, *p(conceito/prompt)* e *d(conceito)*, sendo:

$$p(saída/prompt) = \int_{conceito} p(conceito,prompt/resposta)p(conceito/prompt)d(conceito).$$

Neste sentido, pode-se afirmar que o LLM aprende via marginalização através da seleção de múltiplos exemplos em *p(conceito/prompt)* . Portanto, o Aprendizado em Contexto pode ser visto como uma forma de Inferência Bayesiana implícita.

Em contraste com os conjuntos de dados complexos e de grande escala usados para treinar LLMs capazes de realizarem o Aprendizado em Contexto, é gerado um conjunto de dados sintético de pequena escala (GINC) no qual tanto *Transformers* quanto *LSTMs* são capazes de exibirem o Aprendizado em Contexto. Experimentos realizados com este conjunto de dados revelam fenômenos do mundo real observados em larga escala, incluindo a melhoria do desempenho do Aprendizado em Contexto com o aumento da escala do modelo, a sensibilidade à ordem dos exemplos e tarefas contra intuitivos nas quais o aprendizado *zero-shot* supera o *few-shot* .

Finalmente, destaca-se o trabalho de Shojaee et al., 2025. Neste trabalho os autores realizam um estudo comparativo entre dois grupos de LLMs. Um grupo de LLMs padrões representadas pelos modelos Claude 3.7 Sonnet sem raciocínio e DeepSeek V3 e outro grupo , LRMs, o qual emprega processos de raciocínio detalhados, representado pelos modelos Claude 3.7 Sonnet com raciocínio e DeepSeek R1. O conjunto de tarefas escolhidas para serem resolvidas consiste de quatro problemas do tipo quebra-cabeça, a saber: Torre de Hanoi, Salto de Damas, Problema da Travessia e Mundo dos Blocos.

Os autores constatam que, embora os modelos LRMs que empregam raciocínio demonstrem desempenho superior em tarefas recíprocas, suas capacidades fundamentais, propriedades de escalabilidade e limitações permanecem insuficientemente compreendidas. De acordo com os autores as avaliações atuais de LRMs concentram-se, principalmente, em tarefas consolidadas de matemática e programação, enfatizando a precisão da resposta final. No entanto, esse paradigma de avaliação frequentemente sofre com a contaminação de dados e não fornece *insights* suficientes sobre a estrutura e a qualidade dos traços de raciocínio.

No artigo, são investigadas de forma sistemática essas lacunas utilizando-se ambientes de jogos quebra-cabeças controláveis, os quais permitem a manipulação precisa da complexidade composicional enquanto mantêm estruturas lógicas consistentes. Essa abordagem possibilita a análise não apenas das respostas finais, mas também dos traços de raciocínio, oferecendo *insights* sobre como os modelos LRMs pensam. Por meio de experimentos os autores demonstram que os LRMs sofrem um colapso total de precisão ao se depararem com certos níveis de complexidade das tarefas. Além disso, eles apresentam um limite de escalabilidade contra-intuitivo: o esforço de raciocínio aumenta com a complexidade do problema até certo ponto e, em seguida, diminui.

Ao comparar LRMs com seus equivalentes modelos LLMs padrões, com condições equivalentes de inferência, identificam-se três regimes de desempenho: (1) tarefas de baixa complexidade, nas quais modelos padrão surpreendentemente superam os LRMs; (2) tarefas de média complexidade, nas quais o raciocínio adicional dos LRMs demonstra vantagem; e (3) tarefas de alta complexidade, nas quais ambos os modelos sofrem colapso total.

Bibliografia:

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, et al. Language models are few-shot learners. Em Advances in Neural Information Processing Systems 33 (NeurIPS 2020), 2020.

Zihao Zhao, Eric Wallace, Shi Feng, Dan Klein, e Sameer Singh. Calibrate before use: Improving few-shot performance of language models. In Proceedings of ICML 2021, volume 139 of PMLR, pp 12697–12706, 2021.

Sewon Min, Xinxi Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, e Luke Zettlemoyer. Rethinking the role of demonstrations: What makes in-context learning work? In Proceedings of EMNLP 2022, pp 11048 -11064, 2022.

Hongjin Su, Jungo Kasai, Chen Henry Wu, Weijia Shi, Tianlu Wang, Jiayi Xin, Rui Zhang, Mari Ostendorf, Luke Zettlemoyer, Noah A. Smith, e Tao Yu. Selective annotation makes language models better few-shot learners. In ICLR 2023, 2023.

Siyan Zhao, Tung Nguyen, e Aditya Grover. Probing the decision boundaries of in-context learning in large language models. In Advances in Neural Information Processing Systems 37 (NeurIPS 2024), 2024.

Yasaman Razeghi, Robert L. Logan, Matt Gardner e Sameer Singh. Impact of Pretraining Term Frequencies on Few-Shot Numerical Reasoning. In EMNLP 2022, pp 840-854, 2022.

Samuel Marks e Max Tegmark. The geometry of truth: Emergent linear structure in large language model representations of true/false datasets. In Conference on Language Modeling (COLM 2024), 2024.

Shivam Garg, Dimitris Tsipras, Percy Liang, e Gregory Valiant. What can Transformers learn in-context? a case study of simple function classes. In Advances in Neural Information Processing Systems 35 (NeurIPS 2022), 2022.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, e Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems 30 (NIPS 2017), 2017.

Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, e Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. In ICLR 2023 (Oral), 2023.

Johannes von Oswald, Eyvind Niklasson, Ettore Randazzo e João Sacramento. ransformers Lear In-Context by Gradient Descent. In Proceedings of the 40th ICML 2023, 2023.

Kwangjun Ahn, Xiang Cheng, Hadi Daneshmand e Suvrit Sra. Transformers Learn to Implement Preconditioned Gradient Descent for In-Context Learning. In NeurIPS, 2023, 2023.

Damai Dai, Yutao Sun, Li Dong, Yaru Hao, Shuming Ma, Zhifang Sui e Furu Wei. Why Can GPT Learn In-Context? Language Models Implicitly Perform Gradient Descent as Meta-Optimizers. arXiv : 2212.10559v3, 2023.

Samuel Muller, Noah Hollmann, Sebastian Pineeda, Josif Grabocka e Frank Hutter. Transformers can do Bayesian Inference. In ICLR 2022, 2022.

Sang M. Xie, Percy Liang, Aditi Raghunathan e Tengyu Ma. An Explanation of In-Context Learning as Implicit Bayesian Inference. arXiv: 02080v6, 2022.

Parshin Shojaee, Iman Mirzadeh, Keivan Alizadeh, Maxwell Horton, Samy Bengio, e Mehrdad Farajtabar. The illusion of thinking: Understanding the strengths andlimitations of reasoning models via the lens of problem complexity. Technical Report, Apple Machine Learning Research, 2025.