

Explicando Decisões de Modelos de Linguagem de Grande Escala via Otimização Inversa

Relatório de Pesquisa de Mestrado

George Silva

Programa de Pós-Graduação em Ciência da Computação

Julho de 2026

Resumo

Modelos de Linguagem de Grande Escala (LLMs) exibem consistência surpreendente em tarefas de classificação, mas seus critérios decisórios implícitos permanecem opacos. Este trabalho investiga se é possível *estimar* uma métrica matemática explícita que reproduza o critério decisório de um LLM a partir de suas classificações observadas. A abordagem é a *otimização inversa*: dado um conjunto de classificações realizadas por um LLM em problemas de classificação binária bidimensional, infere-se uma métrica de Mahalanobis diagonal $\hat{W}$ por meio de *dois* estimadores independentes, um Perceptron Estruturado com Relaxação de Margem e Mínimos Quadrados Não-Negativos (NNLS), cuja concordância direcional serve de controle de robustez. O trabalho organiza-se em três blocos: (i) o LLM como *fonte* de decisões (Problemas A–D), avaliando a fidelidade de $\hat{W}$, sua transferência entre geometrias, um teste-oráculo de sanidade e o efeito de vieses semânticos e de *prompt*; (ii) o LLM como *aprendiz* via *in-context learning* (Problemas E–F), comparado a classificadores clássicos; e (iii) um estudo de caso *real* de peso $\times$ altura (Problema G). Com os modelos **gpt-4o-mini** e **gemini-2.5-flash-lite** a temperatura zero, três sementes e três repetições, os resultados (**gpt-4o-mini**, salvo indicação) mostram: (a) $\hat{W}$ reproduz o LLM com fidelidade de 82,7–86,7% (Perceptron/NNLS concordam com cosseno 0,986); (b) o teste-oráculo recupera métricas sintéticas conhecidas com fidelidade de 95–100%, validando os estimadores; (c) a transferência é heterogênea (κ de 0,33 a 0,75 em zero-shot, subindo a 0,67–0,92 com poucos exemplos); (d) a direção de $\hat{W}$ é estável entre sementes (cosseno 0,971), mas sua magnitude não (coeficiente de variação de 88%); (e) o critério é fortemente sensível à semântica de rótulos e *features*; (f) como aprendiz, o LLM é praticamente “cego” em zero-shot (55,2% na média sobre três peritos) e aprende com poucos exemplos, mas *não supera* de forma consistente baselines triviais (a Regressão Logística atinge 97–98%); e (g) a hipótese de que exemplos difíceis ensinam melhor é **refutada**: exemplos fáceis dominam com poucos exemplos. O contraste entre modelos revela ainda uma diferença de determinismo a $T = 0$: a taxa de *flip* em consultas repetidas é de 4,3% no **gpt-4o-mini** contra 0,0% no **gemini-2.5-flash-lite**.

Palavras-chave: Otimização Inversa, Modelos de Linguagem de Grande Escala, *Metric Learning*, Perceptron Estruturado, NNLS, In-Context Learning, Viés Semântico, Explicabilidade.

Índice

1	Introdução	2
2	Fundamentação Teórica	4
2.1	Otimização Inversa	4

2.2	Métrica de Mahalanobis Diagonal	4
2.3	Estimadores da Métrica Inversa	5
2.4	Projeções Não-Lineares (R3 e R4)	6
2.5	In-Context Learning em LLMs	6
2.6	Viés Semântico em LLMs	6
2.7	Métricas de Avaliação	6
3	Trabalhos Relacionados	7
4	Metodologia	8
4.1	Nomenclatura: Blocos e Problemas	8
4.2	Protocolo Experimental	8
4.3	Bloco 1 — LLM como Fonte	10
4.4	Bloco 2 — LLM como Aprendiz	10
4.5	Bloco 3 — Estudo de Caso Real	11
4.6	Análise Estatística	11
5	Resultados	11
5.1	Bloco 1 — Estimação e Fidelidade (Problema A)	11
5.2	Bloco 1 — Teste-Oráculo de Sanidade	11
5.3	Bloco 1 — Transferência (Problemas B e C)	12
5.4	Bloco 1 — Não-Linearidade (R3/R4)	13
5.5	Bloco 1 — Viés Semântico e de Prompt	13
5.6	Bloco 2 — LLM como Aprendiz (Problemas E–F)	14
5.7	Bloco 2 — Diluição e Viés de Ordem dos Exemplos	16
5.8	Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)	17
5.9	Estabilidade de $\hat{W}$ (H5)	19
6	Análise e Discussão	19
6.1	H1 — Estabilidade do critério	19
6.2	H2 — Transferência de conhecimento	19
6.3	H3 — Viés semântico	20
6.4	H4 — Qualidade dos exemplos	20
6.5	H5 — Estabilidade estatística	20
6.6	O LLM diante de baselines triviais	21
7	Limitações	21
8	Trabalho Futuro	22
9	Conclusão	23

1 Introdução

Modelos de Linguagem de Grande Escala (LLMs) tornaram-se ferramentas onipresentes em tarefas cognitivas, da geração de texto à classificação de dados. Apesar do desempenho notável, os mecanismos que governam suas decisões permanecem largamente opacos, o que dificulta auditabilidade, detecção de vieses e previsão de comportamento em domínios novos. Avaliações recentes questionam até que ponto os “traços de raciocínio” desses modelos refletem processos genuínos de resolução de problemas [16].

Uma linha de pesquisa em ascensão investiga a capacidade de *in-context learning* (ICL) dos LLMs: aprender novas tarefas apenas a partir de exemplos no *prompt*, sem atualização de parâmetros, capacidade demonstrada em escala pelo GPT-3 [15] e estudada formalmente em [6, 7]. Trabalhos recentes sugerem que o ICL pode implementar internamente algoritmos de otimização conhecidos, como gradiente descendente, codificados nas ativações do Transformer [7]. Isso levanta uma questão fundamental: *se o LLM implementa algum processo de otimização implícito, é possível recuperar explicitamente o critério dessa otimização?*

Este trabalho aborda a questão pelo *framework* de *otimização inversa* [1]: dados os resultados observados de um processo de otimização (as classificações do LLM), inferir o critério (função objetivo) que tornaria essas classificações ótimas. Especificamente, estima-se uma *métrica de Mahalanobis diagonal* $\hat{W}$ que, usada em classificação por vizinho mais próximo, reproduz as decisões do LLM. Adota-se a terminologia $\hat{W}$ *estimada/inferida*, e não “métrica aprendida”, para enfatizar que $\hat{W}$ é um *ajuste a posteriori* às decisões observadas, não um objeto treinado dentro do LLM.

O trabalho vai além da estimação isolada. Estrutura-se em três blocos auto-contidos:

Bloco 1 — LLM como fonte: o LLM rotula problemas sintéticos (Problemas A–D) e dele se estima $\hat{W}$. Avaliam-se fidelidade, transferência entre geometrias, um *teste-oráculo* de sanidade (os estimadores recuperam uma métrica conhecida?), o efeito de não-linearidade (projeções R3/R4) e de vieses semânticos e de *prompt*.

Bloco 2 — LLM como aprendiz: os papéis se invertem. Um especialista externo com métrica conhecida rotula os dados (Problemas E linear e F meia-lua) e o LLM deve reproduzir esse critério via ICL. Comparam-se estratégias de seleção de exemplos e baselines clássicos (k-NN, Regressão Logística, SVM).

Bloco 3 — Estudo de caso real: uma base real de peso $\times$ altura (Problema G, fronteira aproximadamente elíptica) submete todo o *pipeline* a dados não sintéticos.

Pergunta de Pesquisa

É possível estimar uma métrica matemática explícita e transferível a partir das classificações de um LLM, de modo que ela capture o critério decisório implícito do modelo e generalize para novos problemas de distribuição diferente?

Hipóteses

- H1 — Estabilidade do critério:** o LLM possui um critério decisório consistente, aproximável por uma métrica de Mahalanobis diagonal, com concordância mensurável ($\kappa > 0,4$) na transferência entre problemas.
- H2 — Transferência de conhecimento:** $\hat{W}$ estimada em um problema generaliza para problemas geometricamente distintos.
- H3 — Viés semântico:** os nomes atribuídos a classes e *features* influenciam sistematicamente o critério, alterando $\hat{W}$.
- H4 — Qualidade dos exemplos:** exemplos geometricamente *difíceis* (próximos à fronteira) transmitem o critério do especialista mais eficientemente que exemplos *fáceis*. (*Hipótese a priori, submetida a teste.*)
- H5 — Estabilidade estatística:** o comportamento é reprodutível entre execuções (múltiplas sementes e repetições).

Contribuições

1. Um *framework* experimental que estima a métrica de Mahalanobis diagonal de um LLM com *dois* algoritmos independentes (Perceptron Estruturado e NNLS) e mede sua concordância direcional, isolando robustez do método de estimação.
2. Um *teste-oráculo* de sanidade que verifica se os estimadores recuperam uma métrica sintética conhecida antes de qualquer alegação sobre o LLM.
3. Evidência quantitativa de que o critério do LLM é *direcionalmente estável mas de magnitude instável*, e fortemente modulado por viés semântico (classe e *feature*) e por variantes de *prompt*.
4. Uma avaliação honesta do LLM como aprendiz via ICL, incluindo a *refutação* da hipótese de que exemplos difíceis ensinam melhor e a comparação com baselines clássicos que o LLM não supera.

5. A extensão do *pipeline* a não-linearidade (projeções R3/R4) e a um estudo de caso *real* (peso $\times$ altura), reportando o número absoluto de erros dada a pequena escala amostral.

2 Fundamentação Teórica

2.1 Otimização Inversa

O problema de *otimização inversa* consiste em, dadas soluções observadas $x^* \in \mathbb{R}^d$ de um problema de otimização parametrizado por θ , inferir os parâmetros θ que tornariam x^* ótima (ou quase-ótima) [1]. Seja $\mathcal{P}(\theta) = \min_{x \in \mathcal{F}} c(x; \theta)$ o problema direto. A otimização inversa busca

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L} \left(x^*, \arg \min_{x \in \mathcal{F}} c(x; \theta) \right), \quad (1)$$

onde $\mathcal{L}$ mede o quão ótima x^* é sob θ . Aqui, as *decisões observadas* são as classificações do LLM e o parâmetro a inferir é a métrica W que governa a função de distância usada na classificação.

2.2 Métrica de Mahalanobis Diagonal

A distância de Mahalanobis generaliza a Euclidiana por uma matriz semidefinida positiva $M \in \mathbb{R}^{d \times d}$: $d_M(x, c) = \sqrt{(x - c)^\top M (x - c)}$. Adota-se a restrição diagonal $M = \text{diag}(w)$, $w \in \mathbb{R}_+^d$, reduzindo a $O(d)$ parâmetros e preservando a interpretabilidade dos pesos w_j como *importâncias de feature*:

$$d_W(x, c) = \sqrt{\sum_{j=1}^d w_j (x_j - c_j)^2}. \quad (2)$$

A classificação por vizinho mais próximo sob d_W atribui x à classe k^* cujo centroide c_{k^*} minimiza $d_W(x, c_{k^*})$.

Observação (invariância de escala). A regra sob d_W é *invariante a reescalamentos positivos* de w : para $\alpha > 0$, $d_{\alpha W}$ induz a mesma fronteira que d_W . Logo $\hat{W}$ é identificável apenas *a menos de escala*, e comparações entre métricas usam a *direção* de w (equivalentemente, a razão w_2/w_1), não os valores absolutos. Essa distinção é central para os resultados de estabilidade (Seção 5.9).

A simplificação diagonal é análoga à do LMNN [2], que aprende Mahalanobis com margem larga para classificação k -NN.

2.3 Estimadores da Métrica Inversa

Dois estimadores independentes inferem $\hat{W}$ a partir das mesmas decisões. A congruência entre eles é usada como controle: se ambos convergem para a mesma direção, o resultado não é artefato de um método particular.

(i) Perceptron Estruturado com Relaxação de Margem. O Perceptron Estruturado [3] generaliza o perceptron clássico para espaços de saída estruturados, atualizando os pesos quando a predição diverge do alvo. A variante usada, com relaxação de margem e busca binária no parâmetro γ , segue a formulação de Coelho, Borges e Fonseca Neto [4] para aprendizado de métrica: incorpora um fator de escala $f \in [0, 1]$ que suaviza a atualização e é ajustado por busca binária para satisfazer a relaxação de margem γ (Algoritmo 1).

Algoritmo 1: Perceptron Estruturado com Relaxação de Margem (variante diagonal)

Input: Dados $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$ com $y^{(i)} \in \{0, 1\}$, centroides μ_0, μ_1 , parâmetros η, γ, T
Output: Vetor de pesos $w \in \mathbb{R}_+^2$

```

1 Inicializar  $w \leftarrow [1, 1]$ 
2 for  $t = 1, \dots, T$  do
3   for  $i = 1, \dots, N$  do
4      $\hat{y}^{(i)} \leftarrow \arg \min_{k \in \{0, 1\}} d_W(x^{(i)}, \mu_k)$ 
5     if  $\hat{y}^{(i)} \neq y^{(i)}$  then
6        $g_j \leftarrow (x_j^{(i)} - \mu_{y,j})^2 - (x_j^{(i)} - \mu_{\hat{y},j})^2$ 
7        $f \leftarrow$  busca binária em  $[0, 1]$  satisfazendo a relaxação de margem  $\gamma$ 
8        $w \leftarrow \max(0, w - \eta \cdot f \cdot g)$ 
9     end
10  end
11 end
12 return  $w$ 
```

(ii) Mínimos Quadrados Não-Negativos (NNLS). O segundo estimador formula a recuperação de w como um problema de mínimos quadrados com restrição de não-negatividade,

$$\hat{W}_{\text{NNLS}} = \arg \min_{w \geq 0} \|Aw - b\|_2^2, \quad (3)$$

onde cada linha de A codifica a diferença de distâncias quadráticas do ponto aos dois centroides e b codifica a decisão do LLM. Resolve-se (3) pelo algoritmo clássico de Lawson e Hanson [5] (implementação `scipy.optimize.nnls`). Ao contrário do Perceptron, o NNLS *não possui hiperparâmetros*, o que o torna um controle valioso: concordância entre os dois sugere que $\hat{W}$ não depende de ajuste fino. Um terceiro estimador (LP Max-Margin) foi avaliado e *descartado* por não respeitar a restrição de convexidade; dois estimadores congruentes bastam para demonstrar robustez.

2.4 Projeções Não-Lineares (R3 e R4)

A métrica diagonal sobre as *features* originais só induz fronteiras lineares. Para sondar se o LLM captura interações, aumenta-se o espaço de *features* sem sair do formalismo linear: a *projeção R3* acrescenta $x_3 = x_1x_2$ (termo de interação, fronteira hiperbólica) e a *projeção R4* acrescenta ainda x_1^2 e x_2^2 (fronteira elíptica, o classificador ótimo do caso peso $\times$ altura). Comparando a fidelidade com 2, 3 e 4 *features*, avalia-se se a expressividade adicional aproxima $\hat{W}$ do LLM em problemas não-lineares.

2.5 In-Context Learning em LLMs

In-context learning (ICL) é a capacidade de realizar novas tarefas fornecendo apenas exemplos $(x_1, y_1), \dots, (x_k, y_k)$ no *prompt*, sem atualizar parâmetros. O fenômeno foi formalizado e demonstrado em escala por Brown et al. [15] com o GPT-3, sobre a arquitetura Transformer [14], cujo mecanismo de atenção descende do alinhamento suave introduzido por Bahdanau et al. [13] para tradução automática. Garg et al. [6] mostraram que Transformers treinados do zero realizam ICL de classes de funções, igualando estimadores ótimos. Akyürek et al. [7] provaram por construção que Transformers podem implementar internamente gradiente descendente e regressão ridge. Essas descobertas justificam a premissa central: se o LLM implementa otimização interna, é possível recuperar seu critério via otimização inversa.

2.6 Viés Semântico em LLMs

LLMs exibem vieses sistemáticos dependentes dos nomes de classe [9]. Rótulos com conotação semântica tendem a distorcer as distribuições previstas, independentemente do conteúdo do exemplo. Zhao et al. identificam três fontes: preferência por rótulos majoritários, recência e frequência de *tokens* no pré-treinamento. Este trabalho testa sistematicamente o efeito de nomes de classe (neutros, semânticos, cromáticos) e de *features* sobre $\hat{W}$.

2.7 Métricas de Avaliação

Fidelidade (vs. LLM). A *fidelidade* é a fração de pontos em que a classificação por vizinho mais próximo sob $\hat{W}$ concorda com o LLM: $\text{Fid} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\hat{y}_{\hat{W}}(x^{(i)}) = \hat{y}_{\text{LLM}}(x^{(i)})]$. Mede o quanto a métrica *reproduz o LLM*, e não sua correção. Distingue-se de *acurácia vs. ground truth*, que mede concordância com o rótulo verdadeiro do problema.

Consistência (transferência). Idem à fidelidade, com $\hat{y}_{\hat{W}}$ calculado com os centroides do problema de destino (Problemas B, C). Trata-se de um controle metodológico

deliberado: apenas o vetor w é transferido do Problema A, e os centroides são recalculados localmente a partir dos rótulos que o LLM atribui no problema de destino. Isso isola o efeito da métrica (os pesos) do efeito da geometria (a posição dos centroides), evitando que uma eventual queda de consistência em B/C seja mero artefato de centroides deslocados entre distribuições.

Cohen’s κ [12]. Corrige a concordância pelo acaso:

$$\kappa = \frac{P_o - P_e}{1 - P_e}, \quad (4)$$

onde P_o é a proporção de concordância observada e P_e a esperada ao acaso ($P_e = \sum_k \hat{p}_k \tilde{p}_k$, produto das marginais dos dois “anotadores”). O LLM e a métrica $\hat{W}$ são os dois anotadores fixos. Interpretação: $\kappa < 0,2$ (fraca), $0,2$ – $0,4$ (razoável), $0,4$ – $0,6$ (moderada), $0,6$ – $0,8$ (substancial), $> 0,8$ (quase perfeita). Valores negativos indicam concordância *pior que o acaso*.

F1-score macro. Para cada classe k , com precisão $P_k = \frac{VP_k}{VP_k + FP_k}$ e revocação $R_k = \frac{VP_k}{VP_k + FN_k}$, define-se $F1_k = \frac{2P_k R_k}{P_k + R_k}$ (média harmônica de precisão e revocação). O F1 *macro* é a média aritmética simples $\frac{1}{K} \sum_{k=1}^K F1_k$, tratando as classes com igual peso, o que é apropriado para detectar degradação em uma classe minoritária.

3 Trabalhos Relacionados

Esta pesquisa situa-se na interseção de cinco áreas.

Otimização Inversa. Chan et al. [1] apresentam o survey definitivo da área, unificando formulações baseadas em KKT, dualidade forte e modelos *data-driven*. Inferir $\hat{W}$ a partir das classificações do LLM é uma instância direta: dadas as soluções observadas, busca-se o parâmetro que as tornaria ótimas sob vizinho mais próximo. Diferimos ao aplicar o *framework* a um “otimizador” que não é um solver, mas um LLM, e ao validar a recuperação com um teste-oráculo.

Metric Learning. Weinberger e Saul [2] introduziram o LMNN, que aprende Mahalanobis via otimização convexa com margem. Nosso Perceptron com relaxação de margem é conceitualmente análogo, com a restrição diagonal proposital. Diferimos ao usar a métrica não para classificar melhor, mas para *explicar* um classificador externo (o LLM).

Predição Estruturada. Collins [3] introduziu o Perceptron Estruturado, ancestral direto do estimador (i). A regra $w \leftarrow w - \eta fg$ é uma instância da regra de Collins adaptada para *metric learning* bidimensional, na formulação com relaxação de margem de Coelho et al. [4], da qual o estimador (i) é implementação direta.

In-Context Learning. Garg et al. [6] e Akyürek et al. [7] estabelecem o LLM como aprendiz implícito de funções. Min et al. [10] questionam o papel dos mapeamentos *input-label*, mostrando que a estrutura das demonstrações importa mais que a correção dos rótulos, achado com implicações diretas para o Bloco 2 e para a refutação de H4. Su et al. [8] mostram que a seleção estratégica de exemplos, com equilíbrio entre diversidade e representatividade, supera a aleatória. Investigamos uma dimensão diferente: o eixo *fácil vs. difícil* pela margem à fronteira.

Fronteiras de Decisão de LLMs. Zhao et al. [11] investigaram a geometria das fronteiras de decisão de LLMs em classificação binária 2D, achando irregularidades significativas. Seu *setup* é diretamente comparável ao nosso, validando o uso de dados sintéticos bidimensionais. Artstein e Poesio [12] sistematizam os coeficientes de concordância, justificando Cohen’s κ quando LLM e $\hat{W}$ são tratados como dois anotadores fixos.

4 Metodologia

4.1 Nomenclatura: Blocos e Problemas

Para evitar ambiguidade entre o *papel* do LLM e a *configuração de dados*, fixa-se: *Blocos* 1–3 designam os três estudos; *Problemas* A–G designam as configurações de dados (Tabela 1).

4.2 Protocolo Experimental

Avaliam-se dois modelos, `gpt-4o-mini` (OpenAI) e `gemini-2.5-flash-lite` (Google, via OpenRouter), ambos com temperatura $T = 0,0$, minimizando estocasticidade para isolar o critério. A narrativa principal segue o `gpt-4o-mini`, com o `gemini-2.5-flash-lite` usado como réplica de contraste (as diferenças relevantes são destacadas explicitamente). Ressalva-se que $T = 0$ *não garante* determinismo estrito (roteamento, *batching* e não-associatividade de ponto flutuante introduzem variação), fenômeno já documentado em estudos de estabilidade de LLMs [17, 18]; o desenho usa múltiplas sementes e repetições justamente para medir essa variância. As chamadas são assíncronas com concorrência limitada. As respostas passam por um *parser*

Tabela 1: Problemas de classificação binária 2D e seu papel nos blocos.

Prob.	Bloco	Descrição
A	1	Linear, centroides Gaussianos; base da estimação zero-shot (150 pontos).
B	1	Linear, centroides rotacionados no sentido horário ($\pm 1,5$); transferência.
C	1	Linear, rotação anti-horária ($\pm 1,5$); transferência com orientação oposta.
D	1	Meia-lua não-linear (make_moons); teste de não-linearidade.
E	2	Linear, rotulado por especialista com $W_{\text{exp}} = [0,3; 1,5]$; ICL.
F	2	Meia-lua, especialista = <i>ground truth</i> ; ICL não-linear.
G	3	Real: peso $\times$ altura (≈ 70 amostras, fronteira elíptica).

de 8 camadas (0–7) que trata variações de formato; respostas irrecuperáveis após re-envios recebem rótulo por *hash* MD5 determinístico das coordenadas (evitando viés geométrico). Nesta execução *não houve* acionamento do *fallback* em nenhum dos modelos (0,00% de 129 868 chamadas): as métricas de κ /consistência não contêm rótulos pseudo-aleatórios.

A auditoria *offline* das interações registradas quantificou também o não-determinismo residual, e aqui os dois modelos divergem nitidamente: a taxa de *flip* em consultas repetidas a $T = 0$ é de 4,3% no **gpt-4o-mini**, mas de 0,0% no **gemini-2.5-flash-lite** (determinismo estrito no provedor pinado). Para o **gpt-4o-mini**, esse valor constitui o *piso de ruído de medição* do protocolo: nenhuma métrica de concordância com o LLM (fidelidade, consistência, κ) pode exceder $\approx 96\%$, e os resultados devem ser interpretados contra esse teto. As decisões foram coletadas em 05/07/2026; o **gpt-4o-mini** resolveu para o *snapshot* **gpt-4o-mini-2024-07-18** (registrado em cada chamada, ver Limitações).

Variáveis de controle:

- **Sementes:** $s \in \{42, 123, 7\}$ (robustez estatística).
- **Repetições:** $R = 3$ por configuração.
- **Nomes de classe:** neutros (A/B, 0/1), semânticos (Positivo/Negativo), cromáticos (Azul/Vermelho) e suas inversões (ordem/posição).
- **Nomes de *feature*:** x_1/x_2 (neutro), altura/peso (semântico), `feature_1/feature_2` (técnico).
- **Variantes de *prompt*:** *default*, *geometric*, *cot* (*chain-of-thought*), *tabular*.

- **Tamanhos few-shot:** $n \in \{0, 4, 10\}$ (transferência) e $n \in \{0, 4, 10, 20, 40\}$ (ICL). Os tamanhos são pares para garantir seleção balanceada entre as duas classes ($n/2$ exemplos de cada) sem exemplo excedente.

4.3 Bloco 1 — LLM como Fonte

O LLM classifica os pontos do Problema A em *zero-shot*; dessas decisões estimam-se $\hat{W}$ pelo Perceptron e pelo NNLS simultaneamente (Seção 2). A fidelidade de cada estimador e a similaridade de cosseno entre os dois $\hat{W}$ são registradas. As métricas estimadas são então transferidas aos Problemas B e C, medindo-se consistência, κ e F1 em função de n . A projeção R3/R4 é aplicada aos Problemas A–D para sondar não-linearidade, e os testes de viés (nomes de classe, nomes de *feature*) e de variantes de *prompt* rodam sobre a mesma estrutura.

Teste-oráculo (sanidade). Antes de qualquer alegação sobre o LLM, geram-se dados sintéticos rotulados por uma métrica *conhecida* $W_{\text{oráculo}}$ e verifica-se se os estimadores a recuperam. Se falharem quando o oráculo realmente existe, qualquer achado sobre o LLM fica comprometido. Testam-se configurações euclidiana ($[1,0; 1,0]$) e anisotrópicas ($[0,3; 1,5]$, $[1,5; 0,3]$), além de transferência entre geometrias.

4.4 Bloco 2 — LLM como Aprendiz

Os papéis se invertem: um especialista externo com métrica conhecida $W_{\text{exp}} = [0,3; 1,5]$ (o atributo x_2 é $5\times$ mais relevante) rotula o Problema E; para o Problema F (meia-lua), o especialista é o próprio *ground truth*. Seleciona-se um subconjunto de n pontos como exemplos e avalia-se se o LLM reproduz o critério do especialista nos demais. Quatro estratégias de seleção:

Easy: n pontos de maior margem (longe da fronteira);

Hard: n pontos de menor margem (próximos à fronteira);

Mixed: $\lfloor n/2 \rfloor$ easy + $\lceil n/2 \rceil$ hard;

Random: n pontos aleatórios (baseline).

Como referência, treinam-se *baselines clássicas* (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot, respondendo: “o LLM faz algo que um classificador trivial não faria?”. Testam-se ainda múltiplas configurações de especialista, o experimento de diluição e o viés de ordem dos exemplos.

4.5 Bloco 3 — Estudo de Caso Real

Uma base real de peso $\times$ altura (rótulo homem/mulher, fronteira aproximadamente elíptica, ≈ 70 amostras) submete o *pipeline* a dados não sintéticos. Roda-se a estimação com 2/3/4 *features* (R2/R3/R4), sob variantes de *prompt* com nomes neutros (x_1/x_2) e semânticos (peso/altura), identifica-se a melhor métrica e executa-se o ICL. Os exemplos *few-shot* do ICL são selecionados *aleatoriamente* (estratégia *random*) entre os pontos de treino, com 3 repetições por configuração usando sorteios independentes, e são sempre excluídos do conjunto de avaliação (sem *leakage*). Testa-se ainda a variante de *nomes de classe* neutros, perguntando “A ou B” em vez de “homem ou mulher”, para isolar o prior semântico dos nomes de classe, complementando a variante de *features* neutras. Dada a pequena escala, reporta-se o *número absoluto de erros* além das porcentagens.

4.6 Análise Estatística

Reportam-se intervalos de confiança de 95% via *bootstrap* (10^4 reamostragens), testes de Wilcoxon pareados e o tamanho de efeito de Cohen (d) para as comparações principais. A estabilidade de $\hat{W}$ entre sementes é medida pela similaridade de cosseno e pelo coeficiente de variação (CV) da razão w_2/w_1 .

5 Resultados

Todos os números provêm da execução 2026-07-05_12-34-52_completa (gpt-4o-mini e gemini-2.5-flash-lite, $T = 0$, sementes $\{42, 123, 7\}$, $R = 3$, 129 868 chamadas). Salvo indicação explícita, os valores referem-se ao gpt-4o-mini.

5.1 Bloco 1 — Estimação e Fidelidade (Problema A)

A Tabela 2 apresenta a fidelidade dos dois estimadores no Problema A. Os valores são *modestos*, um sinal honesto de que a métrica diagonal captura o LLM apenas parcialmente. O NNLS supera levemente o Perceptron, e ambos concordam em direção (cosseno médio 0,986; ver Seção 5.9).

5.2 Bloco 1 — Teste-Oráculo de Sanidade

Antes de interpretar a fidelidade modesta como propriedade do LLM, verifica-se que os estimadores *funcionam quando o oráculo existe*. A Tabela 3 confirma: sobre dados rotulados por métricas conhecidas, a fidelidade é de 95–100% e a direção recuperada tem cosseno até 0,9999. Portanto, a fidelidade modesta no LLM (Tabela 2) reflete o *LLM*, não uma deficiência dos estimadores.

Tabela 2: Fidelidade da estimação no Problema A, por semente (classes A/B, zero-shot).

Semente	Fid. Perceptron (%)	Fid. NNLS (%)
42	82,7	83,3
123	86,7	86,7
7	82,7	87,3
Média	84,0	85,8

Tabela 3: Teste-oráculo: recuperação de W conhecido. “cos” é o cosseno entre o W recuperado e o verdadeiro.

Config.	W verd.	Perceptron		NNLS	
		Fid. (%)	cos	Fid. (%)	cos
Prob. A (euclid.)	[1,0; 1,0]	98,0	0,709	98,0	0,707
Prob. B (euclid.)	[1,0; 1,0]	98,0	0,9999	98,0	0,971
Expert aniso. x_2	[0,3; 1,5]	100,0	0,9999	95,3	0,993
Expert aniso. x_1	[1,5; 0,3]	100,0	0,998	99,3	0,989

5.3 Bloco 1 — Transferência (Problemas B e C)

A Tabela 4 apresenta consistência e κ (com IC *bootstrap* de 95%) nas transferências, em zero-shot e com 4 exemplos. O padrão é claro e *assimétrico*: o Problema B é difícil em zero-shot ($\kappa = 0,33$, “razoável”), enquanto o Problema C já nasce alto ($\kappa = 0,75$, “substancial”). Poucos exemplos elevam ambos a $\kappa \approx 0,67$ – $0,92$. O salto zero→10-shot na consistência tem tamanho de efeito *grande* em C (Cohen’s $d = 5,78$) e *grande* também em B, embora com maior incerteza ($d = 1,86$; a transferência para B é mais ruidosa entre sementes).

Tabela 4: Transferência: consistência e κ (Perceptron), IC *bootstrap* 95%.

Problema	n -shot	Consistência [IC ₉₅]	κ [IC ₉₅]
B	0	0,697 [0,670; 0,750]	0,333 [0,255; 0,449]
B	4	0,837 [0,719; 0,927]	0,670 [0,432; 0,853]
C	0	0,880 [0,860; 0,900]	0,746 [0,703; 0,789]
C	4	0,962 [0,948; 0,990]	0,923 [0,895; 0,979]

Métrica estimada vs. euclidiana. No Problema B em zero-shot, a métrica estimada é *significativamente inferior* à euclidiana ($\Delta_{\text{métrica-euclid.}} = -0,087$; IC₉₅ = $[-0,180; -0,040]$, exclui zero). Ou seja, a deformação diagonal aprendida a partir das decisões do LLM em zero-shot chega a *atrapalhar* a transferência frente à distância trivial: a vantagem de $\hat{W}$ não é intrínseca, e sim contextual, dependente de exemplos




Figura 1: Bloco 1: comparação Perceptron $\times$ NNLS (fidelidade no Problema A, consistência nas Fases B/C e dispersão das direções de $\hat{W}$ estimadas). Os dois estimadores produzem métricas quase colineares (cosseno 0,986).

que ancorem a métrica.

5.4 Bloco 1 — Não-Linearidade (R3/R4)

Aumentar o espaço para 3 ou 4 *features* produz ganhos *marginais* de fidelidade nos problemas lineares A/B/C (Tabela 5), coerente com o fato de fronteiras lineares não requerem termos de interação: a média sobe de 84,9% (R3) para 86,2% (R4), próximo da faixa da estimação em 2 *features*. No caso *não-linear* peso $\times$ altura, ao contrário, a projeção R4 (que introduz a fronteira elíptica correta) eleva a fidelidade com *features* neutras (x_1/x_2) de 56,2% para 69,0%, evidência de que a expressividade adicional só ajuda quando o problema efetivamente exige não-linearidade. O teste-oráculo na meia-lua confirma que os estimadores recuperam a métrica anisotrópica mesmo em geometria curva (Perceptron 100%; NNLS 95,3%).

5.5 Bloco 1 — Viés Semântico e de Prompt

A Tabela 6 mostra que *o critério do LLM muda com a rotulagem*. Nomes com conotação (Positivo/Negativo) elevam a fidelidade a 99,3%, ao passo que a mera inversão de posição (A/B $\rightarrow$ B/A) a reduz de 82,7% a 68,0%, evidência de viés de *ordem*. O efeito dos nomes de *feature*, neste modelo, é pequeno (“altura/peso” 84,7% contra 82,7% de




Figura 2: Teste-oráculo: recuperação de W conhecido. Sobre dados rotulados por uma métrica sintética, os estimadores atingem fidelidade de 95–100%, confirmando que a fidelidade modesta observada no LLM reflete o modelo, não uma falha do método.

Tabela 5: Fidelidade média (Perceptron) ao aumentar *features* nos problemas lineares A/B/C, por semente.

n -features	Seed 42	Seed 123	Seed 7	Média
3 (R3, $+x_1x_2$)	83,3	88,7	82,7	84,9
4 (R4, $+x_1^2, x_2^2$)	81,3	86,7	90,7	86,2

Valores em %. Fonte: `final_cross_linearity__gpt4mini.csv`.

x_1/x_2). Já a variante *tabular* de *prompt degrada* a medição a 64,7%, alertando que a forma de apresentação das coordenadas confunde o modelo.

5.6 Bloco 2 — LLM como Aprendiz (Problemas E–F)

Cegueira em zero-shot. Sem exemplos, o LLM é praticamente incapaz de reproduzir o critério do especialista: a acurácia média, sobre os três peritos, é de $55,2\% \pm 5,6\%$, pouco acima do acaso. A Tabela 7 mostra a curva de aprendizado por estratégia (especialista aniso. x_2).

H4 refutada. A hipótese *a priori* de que exemplos difíceis ensinam melhor é **refutada**. Na média sobre $n > 0$ e os três peritos, a ordem é *Random* (90,3%) > *Mixed* (88,0%) > *Easy* (81,1%) > *Hard* (75,1%): a estratégia *hard* é a *pior*. A vantagem

Tabela 6: Efeito de rotulagem e *prompt* sobre a fidelidade (seed 42; classe: 10-shot; *feature/prompt*: zero-shot).

Nome de classe	Fid. (%)	Nome de feature	Fid. (%)	Prompt	Fid. (%)
Positivo/Negativo	99,3	altura/peso	84,7	<i>default</i>	82,7
Negativo/Positivo	88,7	feature_1/2	84,0	<i>cot</i>	76,7
Azul/Vermelho	86,7	x_1/x_2	82,7	<i>geometric</i>	68,0
1/0	83,3			<i>tabular</i>	64,7
A/B	82,7				
B/A	68,0				




Figura 3: Bloco 1: efeito das variantes de *prompt* sobre a direção de $\hat{W}$ e a fidelidade. A variante *tabular* desloca a medição, alertando que a forma de apresentar as coordenadas interfere no critério inferido.

de *easy* sobre *hard* é estatisticamente significativa com poucos exemplos e desaparece com muitos: no especialista aniso. x_2 , $\Delta_{10\text{-shot}} = +0,188$ ($IC_{95} = [+0,107; +0,257]$) e $\Delta_{20\text{-shot}} = +0,064$ ($IC_{95} = [-0,154; +0,215]$, não significativo). A interpretação, coerente com Min et al. [10]: com poucos exemplos o LLM precisa de *âncoras prototípicas* (alta margem); com muitos, a informação sobre a geometria da fronteira (exemplos difíceis) supera o ruído: daí *hard* atingir 97,9% em 40-shot. O padrão se repete no *gemini-2.5-flash-lite* (*easy* 93,5% vs. *hard* 78,1% na média sobre $n > 0$), reforçando a refutação de H4 nos dois modelos.

O LLM não supera baselines triviais. A Tabela 8 compara o LLM a classificadores clássicos treinados nos mesmos 40 exemplos. Todos os métodos ficam numa faixa estreita (92–98%) e nenhum domina: no especialista aniso. x_2 o LLM (*hard*, 97,9%) supera marginalmente a Regressão Logística (97,3%), ao passo que no aniso. x_1 a Regressão Logística (98,0%) supera o LLM (92,4%). O achado é importante e honesto: no regime linear, o LLM *não supera de forma consistente* um classificador trivial. O valor do LLM está na *flexibilidade* (não requer treino nem especificação de modelo), não na acurácia.

Problema F: colapso frágil e dependente de modelo/semente. No regime não-linear (meia-lua), o zero-shot do *gpt-4o-mini* *colapsa em classe única* em duas

Tabela 7: Bloco 2: acurácia LLM $\times$ especialista por estratégia e n -shot (aniso. x_2). Melhor por linha em **negrito**.

n -shot	Easy	Hard	Mixed	Random
0	61,1	61,1	61,1	61,1
4	85,4	62,1	82,2	84,3
10	86,7	67,9	79,3	88,3
20	90,3	83,8	86,2	92,1
40	87,6	97,9	98,5	94,1




Figura 4: Bloco 2: curva de aprendizado por estratégia de seleção de exemplos. *Easy* e *Random* dominam com poucos exemplos; *Hard* só alcança as demais em alto volume (40-shot).

das três sementes (123 e 7): o modelo atribui um único rótulo a todos os 105 pontos de treino, e sem duas classes o *pipeline* few-shot é abortado. Na semente 42 o *pipeline* roda, mas o desempenho é fraco: a acurácia vs. rótulo real parte de 53,3% (zero-shot) e satura em $\approx 68\%$ com exemplos, muito abaixo do teto atingido nos problemas lineares. O *gemini-2.5-flash-lite*, por contraste, *não colapsa* em nenhuma semente, o que mostra que o colapso é uma fragilidade específica do modelo e da semente, não uma propriedade universal da geometria. A Figura 6 ilustra o caso da semente 42 por contraste com um SVM gaussiano (RBF) treinado no *ground truth*. Um teste-oráculo que ajusta a métrica diagonal diretamente ao rótulo verdadeiro da meia-lua satura em $\approx 86,7\%$ (20/150 erros), e as projeções R3/R4 *não* ajudam: o limite é estrutural (a curvatura em “S” exigiria termo fora da diagonal), não de dados. O teste mais informativo do LLM como aprendiz em regime não-linear genuíno é, portanto, o caso real do Bloco 3.

5.7 Bloco 2 — Diluição e Viés de Ordem dos Exemplos

Diluição não dilui. Fixando 4 exemplos *hard* e acrescentando exemplos *easy* progressivamente, a acurácia *cresce monotonicamente*: de 63,0% (apenas os 4 *hard*) a 84,1% (4 *hard* + 20 *easy*), estabilizando em torno de 84% (Figura 7). Não se observa o efeito hipotético de “diluição” em que exemplos fáceis prejudicariam: ao contrário, cada bloco de fáceis *ajuda*, reforçando a leitura de H4 de que âncoras prototípicas

Tabela 8: Bloco 2: LLM vs. baselines clássicos (40-shot).

Especialista	LLM (hard)	k-NN	Reg. Log.	SVM-RBF
aniso. x_2	97,9% ($\kappa 0,957$)	94,5% ($\kappa 0,891$)	97,3% ($\kappa 0,947$)	94,5% ($\kappa 0,891$)
aniso. x_1	92,4% ($\kappa 0,850$)	95,6% ($\kappa 0,912$)	98,0% ($\kappa 0,961$)	95,5% ($\kappa 0,911$)




Figura 5: Bloco 2: LLM *in-context* vs. baselines clássicos (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot. No regime linear, todos os métodos ficam numa faixa estreita, sem dominância clara.

transmitem o critério.

Viés de ordem é modesto. Reordenar os mesmos exemplos (*class0_first*, *class1_first*, *shuffled*, *alternating*) altera pouco o resultado: a dispersão entre ordenações é de apenas 1,8–7,6 pontos percentuais, sem uma ordenação consistentemente vencedora (*shuffled* é marginalmente melhor com poucos exemplos). O critério do LLM, neste *setup*, é relativamente robusto à ordem das demonstrações, em contraste com a forte sensibilidade a *quais* exemplos são escolhidos (Tabela 7).

5.8 Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)

O caso real expõe a *dependência semântica* das *features* (Tabela 9, médias das 3 sementes, 2 *features*). Distinguem-se três quantidades: a *fidelidade* (a métrica reproduz o LLM), a *acurácia do LLM vs. real* (as decisões do LLM contra o rótulo verdadeiro) e a *acurácia da métrica vs. real* (a métrica estimada contra o rótulo verdadeiro). Com nomes *semânticos* (peso/altura), o LLM classifica melhor que com neutros (acurácia própria 56,7% vs. 45,2%, este último abaixo do acaso da classe majoritária, 57,1%), e a métrica estimada a partir dessas decisões recupera a estrutura real com robustez (89,5%, ≈ 7 erros em 70 nas três sementes). Com nomes *neutros* (x_1/x_2), a métrica vs. real torna-se *arbitrária*: entre sementes ela vale 8,6%, 92,9% e 31,4% (a média 44,3% é enganosa), porque, sem âncora semântica, o mapeamento rótulo $\leftrightarrow$ classe inverte de semente para semente. O contexto semântico das *features* é, no caso real, determinante.




Figura 6: Problema F (meia-lua, seed 42, gpt-4o-mini): superfície de separação do SVM RBF treinado no *ground truth* (esq.) vs. rótulos zero-shot do LLM (dir.). Nas sementes 123 e 7 o zero-shot colapsa em classe única e o *pipeline* é abortado.




Figura 7: Esquerda: experimento de diluição (acrescentar exemplos fáceis a 4 difíceis fixos melhora a acurácia monotonicamente). Direita: viés de ordem (as quatro ordenações diferem por poucos pontos percentuais).

Nomes de classe A/B: o mapeamento é arbitrário. Repetindo a classificação com nomes de classe *neutros* (“A ou B” em vez de “homem ou mulher”), a acurácia da métrica estimada (Perceptron) vs. rótulo real, na média das 3 sementes, despenca de 0,895 para 0,110 ($\approx 62/70$ erros) com *features* semânticas (Tabela 10). O valor, muito *abaixo* do acaso, não é ruído: é *inversão sistemática de convenção*. O LLM continua separando os dois grupos (invertendo-se os rótulos, a acurácia beira 0,89), mas, sem âncora semântica nos nomes, o mapeamento rótulo $\leftrightarrow$ classe é arbitrário e emergiu na convenção oposta à do *ground truth*. O prior semântico atua, portanto, também nos *nomes de classe*, não apenas nas *features*. No ICL, o LLM adota a convenção dos exemplos que recebe: a concordância com a métrica-alvo sobe de 0,778 (zero-shot) a 0,974 (40-shot), enquanto a acurácia vs. real permanece $\approx 0,14$ (a métrica-alvo herdou a convenção invertida), e o Perceptron *baseline* treinado nos mesmos exemplos acompanha (0,12–0,19), indicando consistência entre aprendizes, não defeito do LLM.

No ICL (Tabela 11), o LLM *in-context* iguala ou supera o Perceptron *baseline* na maioria das configurações, com vantagem de até +15,6 pontos (seed 42, 4-shot). Poucos exemplos bastam: a acurácia real salta de 53–60% (zero-shot) para 79–90% com apenas 4 exemplos.

Tabela 9: Bloco 3: estimação no Problema G (2 *features*, médias das 3 sementes). “Fid.” = métrica vs. LLM; “LLM real” = LLM vs. rótulo verdadeiro; “Métrica real” = métrica estimada vs. rótulo verdadeiro.

Nomes	Fid. (%)	LLM real (%)	Métrica real (%)	err. (métrica)
peso/altura	59,5	56,7	89,5	$\approx 7/70$
x_1/x_2	56,2	45,2	arbitrária [†]	$\approx 39/70$

[†] Entre sementes: 8,6 / 92,9 / 31,4% (o mapeamento rótulo $\leftrightarrow$ classe inverte por semente).

Tabela 10: Bloco 3: efeito dos nomes de classe (A/B vs. homem/mulher) na acurácia da métrica estimada (Perceptron) vs. rótulo real (zero-shot, média das 3 sementes, treino = 70).

Classes	Features	Acc. real	Erros
homem/mulher	peso/altura	0,895	$\approx 7/70$
A/B	peso/altura	0,110	$\approx 62/70$
homem/mulher	x_1/x_2	0,443	$\approx 39/70$
A/B	x_1/x_2	0,186	$\approx 57/70$

5.9 Estabilidade de $\hat{W}$ (H5)

A direção de $\hat{W}$ é *estável* entre sementes (cosseno médio 0,971, faixa [0,955; 0,984]), e os dois estimadores concordam (cosseno Perceptron–NNLS 0,986). Contudo, a *magnitude* não é estável: a razão w_1/w_2 tem média 0,214 com $IC_{95} = [0,114; 0,356]$ e *coeficiente de variação* de 88,0%. Ou seja, *para onde* o LLM olha é reprodutível; *quão intensamente* não. Isso qualifica H5: a estabilidade é direcional, não de intensidade, o que é consistente com a invariância de escala da métrica (Seção 2), que torna a magnitude intrinsecamente menos identificável.

6 Análise e Discussão

6.1 H1 — Estabilidade do critério

Parcialmente confirmada. $\hat{W}$ reproduz o LLM com fidelidade modesta (82,7–86,7% entre sementes) e transfere com κ de “razoável” (B, 0,33) a “substancial” (C, 0,75) já em zero-shot. Há um critério estimável, mas a métrica diagonal o captura só em parte: o teste-oráculo (95–100%) prova que a limitação é do LLM, não do estimador.

6.2 H2 — Transferência de conhecimento

Confirmada com qualificações. $\hat{W}$ generaliza melhor para C do que para B, e a adição de exemplos eleva ambos a $\kappa \approx 0,67$ –0,92 (Cohen’s $d = 5,78$ na consistência em C). Porém, em zero-shot $\hat{W}$ é *significativamente inferior* à métrica euclidiana no

Tabela 11: Bloco 3: ICL no Problema G, acurácia real (%) do LLM vs. Perceptron (peso/altura).

n -shot	Seed 42		Seed 123	
	LLM	Perc.	LLM	Perc.
0	60,0	–	53,3	–
4	90,0	74,4	78,9	80,0
10	90,0	83,3	77,8	73,3
20	88,9	83,3	81,1	78,9
40	91,1	83,3	81,1	78,9

Problema B ($\Delta = -0,087$, IC exclui zero): a deformação aprendida não tem valor intrínseco, e sim *contextual*, dependente de exemplos.

6.3 H3 — Viés semântico

Fortemente confirmada. A fidelidade oscila de 64,7% (*prompt* tabular) a 99,3% (Positivo/Negativo), extremos da grade de variantes medidos na seed 42, e a mera inversão de posição ($A/B \rightarrow B/A$) já custa 14,7 pontos ($82,7\% \rightarrow 68,0\%$). No caso real, nomes semânticos vs. neutros elevam a acurácia própria do LLM de 45,2% a 56,7%, e o experimento de nomes de classe A/B (Tabela 10) mostra o mecanismo em sua forma mais nítida: sem âncora semântica nos nomes, o LLM ainda separa os grupos, mas o mapeamento rótulo $\leftrightarrow$ classe emerge em convenção arbitrária (acurácia da métrica vs. real de 0,895 para 0,110, uma inversão quase perfeita). O LLM incorpora semântica extrínseca ao problema geométrico, e ela ancora tanto a separação quanto a *nomeação* das classes.

6.4 H4 — Qualidade dos exemplos

Refutada. Ao contrário do previsto, exemplos *fáceis* superam *difíceis* com poucos exemplos (diferença significativa em 10-shot), e *hard* é a pior estratégia na média. Exemplos difíceis só compensam em alto volume (40-shot). A refutação vale nos *dois* modelos testados. A leitura: âncoras prototípicas transmitem o critério; exemplos ambíguos sem contexto suficiente chegam a orientar o LLM na direção errada.

6.5 H5 — Estabilidade estatística

Confirmada em direção, refutada em magnitude. O cosseno entre sementes (0,971) sustenta reprodutibilidade direcional; o CV de 88% na razão w_1/w_2 mostra que a intensidade dos pesos não é estável. Dada a invariância de escala, a direção é a quantidade cientificamente relevante, e ela é estável.




Figura 8: Bloco 3: base real peso $\times$ altura (rótulo homem/mulher) com a fronteira aproximadamente elíptica. A pequena escala (≈ 70 amostras) motiva o reporte de erros absolutos além das porcentagens.

6.6 O LLM diante de baselines triviais

O achado mais sóbrio: no regime linear, o LLM e os classificadores triviais ficam numa faixa estreita (92–98%), sem dominância clara (a Regressão Logística supera o LLM num especialista, o LLM a supera no outro). O LLM não “resolve melhor”: ele resolve *sem treino e sem especificação de modelo*. O quadro, porém, tem dois regimes: na base real (fronteira aproximadamente elíptica), o LLM *in-context* iguala ou supera o Perceptron *baseline* treinado nos mesmos exemplos na maioria das configurações (até +15,6 pontos), e no regime não-linear sintético (meia-lua) o zero-shot do `gpt-4o-mini` chega a colapsar em classe única. A contribuição do ICL é de *flexibilidade*, condicionada a haver exemplos e semântica que o ancoram, não de acurácia, e qualquer alegação de superioridade geral deve ser resistida.

7 Limitações

1. **Dados majoritariamente 2D:** embora o Bloco 3 use dados reais, a validade externa em alta dimensionalidade permanece aberta.
2. **Métrica diagonal:** $M = \text{diag}(w)$ ignora correlações entre *features*, provável

causa da fidelidade modesta; uma Mahalanobis completa poderia elevá-la.

3. **Dois modelos, mesma família de escala:** avaliaram-se `gpt-4o-mini` e `gemini-2.5-flash-lite` (modelos rápidos/econômicos); a generalização a modelos maiores ou de outras famílias (Llama, DeepSeek) permanece aberta.
4. **Versão do modelo:** o `gpt-4o-mini` resolveu para o *snapshot* `gpt-4o-mini-2024-07-18` (registrado em cada chamada); ainda assim o provedor pode aposentar o *snapshot*, o que limita a reprodutibilidade exata a longo prazo.
5. **Temperatura zero:** minimiza variância, mas não captura o comportamento estocástico; $T = 0$ não garante determinismo estrito. A taxa de *flip* medida pela auditoria foi de 4,3% das consultas repetidas no `gpt-4o-mini` (impondo um teto de $\approx 96\%$ a qualquer métrica de concordância com esse modelo), mas de 0,0% no `gemini-2.5-flash-lite`.
6. **Escala do caso real:** ≈ 70 amostras tornam cada erro pesado (por isso reportam-se erros absolutos); conclusões sobre o Problema G são indicativas.
7. **Classificação binária:** a extensão a múltiplas classes exige adaptar o *framework* inverso.

8 Trabalho Futuro

1. **Métrica completa:** remover a restrição diagonal e avaliar o *trade-off* expressividade $\times$ interpretabilidade, testando se a fidelidade sobe.
2. **Alta dimensionalidade e mais dados reais:** estender o Bloco 3 a datasets maiores e $d \gg 2$.
3. **Mais modelos e famílias:** estender a comparação (já iniciada com `gpt-4o-mini` e `gemini-2.5-flash-lite`) a modelos maiores e de outras famílias (ex.: Llama, DeepSeek), aprofundando o contraste de critérios implícitos e das taxas de *flip* a $T = 0$ como medida de não-determinismo por modelo.
4. **Seleção ativa de exemplos:** integrar o eixo de margem [10] com diversidade/representatividade [8] e incerteza.
5. **Geometria de fronteiras:** comparar a fronteira induzida por $\hat{W}$ com a fronteira real do LLM, seguindo Zhao et al. [11].

9 Conclusão

Este trabalho investigou se é possível estimar uma métrica matemática explícita que capture o critério decisório implícito de um LLM. Com **gpt-4o-mini** e **gemini-2.5-flash-lite** sobre sete configurações de problema organizadas em três blocos (129 868 chamadas, 3 sementes $\times$ 3 repetições, *fallback* do *parser* de 0,00% e piso de ruído de medição de 4,3% a $T = 0$ no **gpt-4o-mini**), os experimentos sustentam seis achados (**gpt-4o-mini**, salvo indicação):

1. **O critério é estimável, mas só parcialmente por uma métrica diagonal:** fidelidade de 82,7–86,7% entre sementes (média 0,840, $IC_{95} = [0,827; 0,867]$), com dois estimadores congruentes (cosseno Perceptron–NNLS 0,986) e validados por um teste-oráculo (95–100%); a lacuna até o teto de $\approx 96\%$ imposto pelo ruído de medição é, portanto, do LLM, não do estimador. O teto é também *estrutural*: no oráculo da meia-lua, a métrica diagonal satura em $\approx 86,7\%$ e R3/R4 não ajudam.
2. **Transfere de modo heterogêneo:** κ de 0,33 (Problema B) a 0,75 (Problema C) em zero-shot, subindo a 0,67–0,92 com poucos exemplos (efeito grande em C, $d = 5,78$); em zero-shot, porém, $\hat{W}$ chega a ser inferior à distância euclidiana trivial.
3. **É direcionalmente estável mas de magnitude instável:** cosseno 0,971 entre sementes, mas CV de 88% na razão dos pesos: dada a invariância de escala, a direção é a quantidade identificável, e ela é reproduzível.
4. **É fortemente semântico, nas *features* e nos nomes de classe:** variantes de *prompt* movem a fidelidade de 64,7% a 99,3%; no caso real, a semântica das *features* eleva a acurácia própria do LLM de 45,2% a 56,7%, e com nomes de classe neutros (A/B) o mapeamento rótulo $\leftrightarrow$ classe emerge em convenção arbitrária ($0,895 \rightarrow 0,110$, inversão quase perfeita): a semântica ancora até a *nomeação* das classes.
5. **Como aprendiz, o LLM é cego em zero-shot e aprende com poucos exemplos:** 55,2% (média sobre três peritos) $\rightarrow$ 97,9% no regime linear, sem contudo superar de forma consistente a Regressão Logística (97–98%); no regime não-linear sintético o zero-shot do **gpt-4o-mini** *colapsa* em classe única em duas das três sementes (o **gemini-2.5-flash-lite** não colapsa), enquanto na base real, com exemplos, o LLM iguala ou supera o Perceptron *baseline* na maioria dos n -shot ($\approx 87\%$).
6. **A hipótese de que exemplos difíceis ensinam melhor é refutada** na forma *a priori*, nos dois modelos: *easy* supera *hard* com significância em 10-shot ($\Delta =$

+0,188, IC excluindo zero), com reversão apenas em alto volume (40-shot, *hard* 97,9%).

Esses resultados constituem um passo deliberadamente cético em direção à explicabilidade dos critérios decisórios de LLMs: o que uma métrica interpretável captura (direção do critério, transferência parcial, dependências semânticas) e o que ela expõe por não capturar (o teto de fidelidade, o colapso não-linear, a arbitrariedade do mapeamento sem semântica). A aplicação potencial está em auditoria de sistemas de IA, detecção de vieses e transferência de conhecimento especializado, sempre com as métricas de concordância lidas contra o piso de ruído que o próprio protocolo quantifica.

Referências

- [1] Timothy C.Y. Chan, Rafid Mahmood, e Ian Yihang Zhu. Inverse optimization: Theory and applications. *Operations Research*, 73(2):1046–1074, 2025. (Publicado online Dez/2023.)
- [2] Kilian Q. Weinberger e Lawrence K. Saul. Distance metric learning for large margin nearest neighbor classification. *Journal of Machine Learning Research*, 10:207–244, 2009.
- [3] Michael Collins. Discriminative training methods for hidden markov models: Theory and experiments with perceptron algorithms. Em *Proceedings of EMNLP 2002*, páginas 1–8, 2002.
- [4] Maurício A. N. Coelho, Carlos C. H. Borges, e Raul Fonseca Neto. Uso de predição estruturada para o aprendizado de métrica. Em *XXXVIII Iberian Latin-American Congress on Computational Methods in Engineering (CILAMCE)*, Florianópolis, Brasil, 2017.
- [5] Charles L. Lawson e Richard J. Hanson. *Solving Least Squares Problems*. Prentice-Hall, Englewood Cliffs, NJ, 1974.
- [6] Shivam Garg, Dimitris Tsipras, Percy Liang, e Gregory Valiant. What can transformers learn in-context? a case study of simple function classes. Em *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022.
- [7] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, e Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. Em *ICLR 2023 (Oral)*, 2023.

- [8] Hongjin Su, Jungo Kasai, Chen Henry Wu, Weijia Shi, Tianlu Wang, Jiayi Xin, Rui Zhang, Mari Ostendorf, Luke Zettlemoyer, Noah A. Smith, e Tao Yu. Selective annotation makes language models better few-shot learners. Em *ICLR 2023*, 2023.
- [9] Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein, e Sameer Singh. Calibrate before use: Improving few-shot performance of language models. Em *Proceedings of ICML 2021*, volume 139 of *PMLR*, páginas 12697–12706, 2021.
- [10] Sewon Min, Xinxu Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, e Luke Zettlemoyer. Rethinking the role of demonstrations: What makes in-context learning work? Em *Proceedings of EMNLP 2022*, páginas 11048–11064, 2022.
- [11] Siyan Zhao, Tung Nguyen, e Aditya Grover. Probing the decision boundaries of in-context learning in large language models. Em *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*, 2024.
- [12] Ron Artstein e Massimo Poesio. Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4):555–596, 2008.
- [13] Dzmitry Bahdanau, Kyunghyun Cho, e Yoshua Bengio. Neural machine translation by jointly learning to align and translate. Em *International Conference on Learning Representations (ICLR 2015)*, 2015.
- [14] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, e Illia Polosukhin. Attention is all you need. Em *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017.
- [15] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, et al. Language models are few-shot learners. Em *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020.
- [16] Parshin Shojaei, Iman Mirzadeh, Keivan Alizadeh, Maxwell Horton, Samy Bengio, e Mehrdad Farajtabar. The illusion of thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity. Relatório técnico, Apple Machine Learning Research, 2025.
- [17] Berk Atil, Alexa Chittams, Lisheng Fu, Ferhan Ture, Lixinyu Xu, e Breck Baldwin. LLM stability: A detailed analysis with some surprises. Preprint arXiv:2408.04667, 2024.
- [18] Paul Windisch, Carole Koechli, Fabio Dennstädt, Daniel M. Aebersold, Daniel R. Zwahlen, Robert Förster, e Christina Schröder. Is one run enough? reproducibility

of flagship large language models across temperature and reasoning settings in biomedical text processing. Preprint medRxiv, 2026.