

Explicando Decisões de Modelos de Linguagem de Grande Escala via Otimização Inversa

Alcances e Limites de uma Aproximação Interpretável

Relatório de Pesquisa de Mestrado

George Silva

Programa de Pós-Graduação em Ciência da Computação

Julho de 2026

Resumo

Modelos de Linguagem de Grande Escala (LLMs) exibem consistência surpreendente em tarefas de classificação, mas seus critérios decisórios permanecem opacos. Este trabalho *caracteriza* a geometria e as fragilidades desse critério usando a *otimização inversa* como lente: dado um conjunto de classificações realizadas por um LLM em problemas de classificação binária, infere-se o vetor de parâmetros de uma métrica de Mahalanobis diagonal $\hat{W}$ por meio de *dois* estimadores independentes, um Perceptron Estruturado com Relaxação de Margem e Mínimos Quadrados Não-Negativos (NNLS), cuja concordância direcional serve de controle de robustez. O objetivo não é classificar melhor com $\hat{W}$, e sim descrever o critério que ela aproxima. Ressalva-se, coerentemente, que $\hat{W}$ reproduz o LLM apenas parcialmente (teto de fidelidade abaixo de 100%): ela *caracteriza* a geometria das decisões, não reconstrói o processo decisório interno. O trabalho divide-se em três blocos: (i) o LLM como *fonte* de decisões (Problemas A–D), avaliando a fidelidade de $\hat{W}$, sua transferência entre geometrias, um teste-oráculo de sanidade e o efeito de vieses semânticos e de *prompt*; (ii) o LLM como *aprendiz* via aprendizado em contexto (Problemas E–F), comparado a classificadores clássicos; e (iii) um estudo de caso *real* de peso $\times$ altura (Problema G). Com os modelos `gpt-4o-mini` e `gemini-2.5-flash-lite` a temperatura zero, três sementes e três repetições, os resultados (`gpt-4o-mini`, salvo indicação) mostram: (a) $\hat{W}$ reproduz o LLM com fidelidade de 82,7–86,7% (Perceptron/NNLS concordam com cosseno 0,986); (b) o teste-oráculo recupera métricas sintéticas conhecidas com fidelidade de 95–100%, validando os estimadores; (c) a transferência é heterogênea (κ de 0,33 a 0,75 em zero-shot, subindo a 0,67–0,92 com poucos exemplos); (d) a direção de $\hat{W}$ é estável entre sementes (cosseno 0,971), enquanto a magnitude varia (CV 88%), embora esta seja, por invariância de escala e com apenas 3 sementes, uma quantidade pouco identificável; (e) o critério é fortemente sensível à semântica de rótulos e atributos; (f) como aprendiz, o LLM é praticamente “cego” em zero-shot (55,2% na média sobre três peritos) e aprende com poucos exemplos, mas *não supera* de forma consistente *baselines* triviais (a Regressão Logística atinge 97–98%); e (g) a hipótese de que exemplos difíceis ensinam melhor é **refutada**: exemplos fáceis dominam com poucos exemplos. O contraste entre modelos revela ainda uma diferença de determinismo a $T = 0$: a taxa de *flip* em consultas repetidas é de 4,3% no `gpt-4o-mini` contra 0,0% no `gemini-2.5-flash-lite`.

Palavras-chave: Otimização Inversa, Modelos de Linguagem de Grande Escala, Aprendizado de Métrica, Perceptron Estruturado, NNLS, Aprendizado em Contexto, Viés Semântico, Explicabilidade.

Índice

1	Introdução	4
2	Fundamentação Teórica	6
2.1	Otimização Inversa	6
2.2	Métrica de Mahalanobis Diagonal	7
2.3	Estimadores da Métrica Inversa	8
2.4	Projeções Não-Lineares ($\mathbb{R}^3$ e $\mathbb{R}^4$)	9
2.5	Aprendizado em Contexto em LLMs	9
2.6	Viés Semântico em LLMs	10
2.7	Métricas de Avaliação	10
3	Trabalhos Relacionados	11
4	Metodologia	13
4.1	Nomenclatura: Blocos e Problemas	13
4.2	Protocolo Experimental	13
4.3	Bloco 1 — LLM como Fonte	14
4.4	Bloco 2 — LLM como Aprendiz	15
4.5	Bloco 3 — Estudo de Caso Real	15
4.6	Análise Estatística	16
5	Resultados	16
5.1	Bloco 1 — Estimação e Fidelidade (Problema A)	16
5.2	Bloco 1 — Teste-Oráculo de Sanidade	17
5.3	Bloco 1 — Transferência (Problemas B e C)	19
5.4	Bloco 1 — Não-Linearidade ($\mathbb{R}^3/\mathbb{R}^4$)	20
5.5	Bloco 1 — Viés Semântico e de Prompt	20
5.6	Bloco 2 — LLM como Aprendiz (Problemas E–F)	21
5.7	Bloco 2 — Diluição e Viés de Ordem dos Exemplos	25
5.8	Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)	25
5.9	Estabilidade de $\hat{W}$ (H5)	28
6	Análise e Discussão	29
6.1	H1 — Estabilidade do critério	29
6.2	H2 — Transferência de conhecimento	29
6.3	H3 — Viés semântico	30
6.4	H4 — Qualidade dos exemplos	31
6.5	H5 — Estabilidade estatística	31
6.6	O LLM diante de <i>baselines</i> triviais	31

7	Limitações	31
8	Trabalho Futuro	32
9	Conclusão	33
A	Detalhamento do Protocolo Experimental	34
A.1	Coleta e tratamento de respostas	34
A.2	Variáveis de controle	35
A.3	Exemplos dos estilos de prompt	35
A.4	Tabelas complementares do experimento de viés	37

1 Introdução

Modelos de Linguagem de Grande Escala (LLMs) tornaram-se ferramentas onipresentes em tarefas cognitivas, da geração de texto à classificação de dados. Apesar do desempenho notável, os mecanismos que governam suas decisões permanecem largamente opacos, o que dificulta auditabilidade, detecção de vieses e previsão de comportamento em domínios novos. Avaliações recentes questionam até que ponto os “traços de raciocínio” desses modelos refletem processos genuínos de resolução de problemas [27].

Uma linha de pesquisa em ascensão investiga a capacidade de *aprendizado em contexto* (*in-context learning*) dos LLMs: aprender novas tarefas apenas a partir de exemplos no *prompt*, sem atualização de parâmetros, capacidade demonstrada em escala pelo GPT-3 [26] e estudada formalmente em [10, 11]. Trabalhos recentes sugerem que o aprendizado em contexto pode implementar internamente algoritmos de otimização conhecidos, como gradiente descendente, codificados nas ativações do Transformer [11]. Isso levanta uma questão fundamental: *se o LLM implementa algum processo de otimização implícito, é possível recuperar explicitamente o critério dessa otimização?*

Este trabalho aborda esta questão pelo uso de *otimização inversa* [1]: dados os resultados observados de um processo de classificação realizado por meio do LLM, infere-se o critério (conjunto de parâmetros) que reproduziria o comportamento dessas classificações. Especificamente, estima-se o vetor de parâmetros W de uma *métrica de Mahalanobis diagonal* $\hat{W}$ que, usada em classificação por centróide mais próximo, reproduz as decisões do LLM. Adota-se a terminologia $\hat{W}$ *estimada/inferida*, e não “métrica aprendida”, para enfatizar que $\hat{W}$ é um *ajuste a posteriori* às decisões observadas, não um objeto treinado dentro do LLM.

Adianta-se, para calibrar as expectativas, que “explicar” é aqui a *aspiração* que orienta o trabalho, não uma promessa de reconstruir o processo interno do modelo. O que o trabalho de fato entrega, e sustenta com honestidade experimental, é uma *caracterização* da geometria do critério decisório e de seus limites: o teto de fidelidade da aproximação, a não-transferibilidade da direção estimada em zero-shot, a forte dependência semântica e o fenômeno de inversão de rótulo. A otimização inversa é a *lente* que torna essa caracterização mensurável, não um fim de desempenho em si.

Questão Principal

Em que medida é possível estimar, a partir das classificações de um LLM, uma métrica matemática explícita que caracterize seu critério decisório implícito, e quais são os limites dessa aproximação quando aplicada a novos problemas com distribuições de dados diferentes?

Hipóteses

- H1 — Estabilidade do critério:** o LLM possui um critério decisório consistente, aproximável por uma métrica de Mahalanobis diagonal, com concordância ao menos *moderada* ($\kappa > 0,4$, piso da faixa “moderada” de Landis e Koch [23]) na transferência entre problemas. O limiar 0,4 testa a *existência* de um critério consistente, não seu domínio ($\kappa > 0,7$, que seria “substancial”).
- H2 — Transferência de conhecimento:** $\hat{W}$ estimada em um problema generaliza para problemas geometricamente distintos.
- H3 — Viés semântico:** os nomes atribuídos a classes e atributos influenciam sistematicamente o critério, alterando $\hat{W}$.
- H4 — Qualidade dos exemplos:** exemplos geometricamente *difíceis* (próximos à fronteira) transmitem o critério do especialista mais eficientemente que exemplos *fáceis*. (*Hipótese a priori, submetida a teste.*)
- H5 — Estabilidade estatística:** o comportamento é reprodutível entre execuções (múltiplas sementes e repetições).

Contribuições

A contribuição central é de *caracterização*, não de desempenho: o objetivo não é classificar melhor com $\hat{W}$, e sim usar a otimização inversa como *lente* para descrever a geometria e as fragilidades do critério decisório de um LLM. Concretamente:

1. **Uma caracterização quantitativa do critério decisório de LLMs** em classificação binária: ele é *direcionalmente estável* (a magnitude é pouco identificável sob invariância de escala), é fortemente modulado por viés semântico (nomes de classe e de atributo) e por variantes de *prompt*, e exhibe um fenômeno de *inversão sistemática de rótulo* quando faltam âncoras semânticas (a separação espacial é preservada, mas a nomeação das classes torna-se arbitrária).
2. **Um instrumento de diagnóstico com garantia de sanidade:** a estimação de $\hat{W}$ com *dois* algoritmos independentes (Perceptron Estruturado e NNLS), cuja concordância direcional controla artefato de método, validada por um *teste-oráculo* que verifica a recuperação de uma métrica sintética conhecida antes de qualquer alegação sobre o LLM. É o que torna a caracterização (item 1) crível, e não um produto de desempenho em si.
3. **Uma avaliação honesta do LLM como aprendiz via aprendizado em contexto**, incluindo a *refutação* da hipótese a priori de que exemplos difíceis

ensinam melhor e a constatação de que o LLM *não supera de forma consistente baselines* clássicos no regime linear.

4. **Um contraste de determinismo entre modelos** a $T = 0$ (taxa de *flip* entre consultas repetidas), quantificado como piso de ruído de medição das próprias métricas de concordância.
5. A extensão do protocolo a não-linearidade (projeções $\mathbb{R}^3/\mathbb{R}^4$) e a um estudo de caso *real* (peso $\times$ altura), reportando o número absoluto de erros dada a pequena escala amostral.

Divisão e Organização do Trabalho

O trabalho divide-se em três blocos auto-contidos, descritos a seguir:

Bloco 1 — LLM como fonte: o LLM rotula problemas sintéticos (Problemas A–D) e dele se estima $\hat{W}$. Avaliam-se fidelidade, transferência entre geometrias, um *teste-oráculo* de sanidade (os estimadores recuperam uma métrica conhecida?), o efeito de não-linearidade (projeções $\mathbb{R}^3/\mathbb{R}^4$) e de vieses semânticos e de *prompt*.

Bloco 2 — LLM como aprendiz: os papéis se invertem. Um especialista externo com métrica conhecida rotula os dados (Problemas E linear e F meia-lua) e o LLM deve reproduzir esse critério via aprendizado em contexto. Comparam-se estratégias de seleção de exemplos e resultados provenientes de *baselines* clássicos (k-NN, Regressão Logística, SVM).

Bloco 3 — Estudo de caso real: uma base real de peso $\times$ altura (Problema G, fronteira aproximadamente elíptica) também é utilizada, submetendo todo o estudo a dados não sintéticos.

O restante do texto organiza-se da seguinte forma: a Seção 2 apresenta a fundamentação teórica (otimização inversa, métrica de Mahalanobis, estimadores e aprendizado em contexto); a Seção 3 discute os trabalhos relacionados; a Seção 4 descreve a metodologia dos três blocos; a Seção 5 apresenta os resultados; a Seção 6 analisa as hipóteses à luz da evidência; as Seções 7 e 8 discutem limitações e trabalho futuro; e a Seção 9 conclui. O Apêndice A detalha o protocolo experimental de coleta.

2 Fundamentação Teórica

2.1 Otimização Inversa

O problema de *otimização inversa* consiste em, dadas soluções observadas $x^* \in \mathbb{R}^d$ de um problema de otimização parametrizado por θ , inferir os parâmetros θ que tornariam

x^* ótima (ou quase-ótima) [1, 8]. Seja $\mathcal{P}(\theta) = \min_{x \in \mathcal{F}} c(x; \theta)$ o problema direto. A otimização inversa busca

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L} \left(x^*, \arg \min_{x \in \mathcal{F}} c(x; \theta) \right), \quad (1)$$

onde $\mathcal{L}$ mede o quão ótima x^* é sob θ . Na formulação clássica de Ahuja e Orlin [8], $\mathcal{L}$ é a norma (ℓ_1 ou ℓ_∞) da menor perturbação dos parâmetros que torna x^* exatamente ótima. Quando as observações são ruidosas ou apenas aproximadamente ótimas, Keshavarz, Wang e Boyd [7] relaxam as condições de otimalidade em resíduos, lineares em θ , e escolhem θ minimizando a soma dos quadrados desses resíduos, o que reduz a otimização inversa a um problema de mínimos quadrados com restrições; é essa a formulação seguida pelo segundo estimador descrito adiante. Aqui, as *decisões observadas* são as classificações do LLM e o parâmetro a inferir é a métrica W que governa a função de distância usada na classificação.

2.2 Métrica de Mahalanobis Diagonal

A distância de Mahalanobis generaliza a Euclidiana por uma matriz semidefinida positiva $M \in \mathbb{R}^{d \times d}$: $d_M(x, c) = \sqrt{(x - c)^\top M (x - c)}$. Adota-se a restrição diagonal $M = \text{diag}(w)$, $w \in \mathbb{R}_+^d$, reduzindo a $O(d)$ parâmetros e preservando a interpretabilidade dos pesos w_j como *importâncias de atributo*:

$$d_W(x, c) = \sqrt{\sum_{j=1}^d w_j (x_j - c_j)^2}. \quad (2)$$

A classificação por centróide mais próximo sob d_W atribui x à classe k^* cujo centróide c_{k^*} minimiza $d_W(x, c_{k^*})$.

Observação (invariância de escala). A regra sob d_W é *invariante a reescalamentos positivos* de w : para $\alpha > 0$, $d_{\alpha W}$ induz a mesma fronteira que d_W . Logo $\hat{W}$ é identificável apenas *a menos de escala*, e comparações entre métricas usam a *direção* de w (equivalentemente, a razão w_1/w_2), não os valores absolutos. Essa distinção é central para os resultados de estabilidade (Seção 5.9).

Intuitivamente: a classificação só compara *qual* centróide está mais perto, nunca o valor da distância em si. Multiplicar todos os pesos pelo mesmo número positivo (por exemplo, $w = [0, 3; 1, 5]$ versus $w = [3; 15]$) multiplica todas as distâncias igualmente, e quem estava mais perto continua mais perto, como trocar uma régua de metros por centímetros: nenhuma decisão muda. Por isso os dados jamais conseguem determinar o “tamanho” de w , apenas a *proporção* entre seus componentes (aqui, “ x_2 pesa cinco vezes mais que x_1 ”), e é somente essa proporção, ou direção, que faz sentido comparar

entre sementes e entre estimadores.

O aprendizado de métricas de Mahalanobis a partir de dados foi inaugurado por Xing et al. [2], que formularam o problema como otimização convexa com restrições de similaridade. A simplificação diagonal adotada aqui é análoga à do LMNN [3], que aprende Mahalanobis com margem larga para classificação k -NN.

2.3 Estimadores da Métrica Inversa

Dois estimadores independentes inferem $\hat{W}$ a partir das mesmas decisões. A congruência entre eles é usada como controle: se ambos convergem para a mesma direção, o resultado não é artefato de um método particular.

(i) Perceptron Estruturado com Relaxação de Margem. O Perceptron Estruturado [4] generaliza o perceptron clássico para espaços de saída estruturados, atualizando os pesos quando a predição diverge do alvo. A variante usada, com relaxação de margem e busca binária no parâmetro γ , segue a formulação de Coelho, Borges e Fonseca Neto [5] para aprendizado de métrica: incorpora um fator de escala $f \in [0, 1]$ que suaviza a atualização e é ajustado por busca binária para satisfazer a relaxação de margem γ (Algoritmo 1).

Algoritmo 1: Perceptron Estruturado com Relaxação de Margem (variante diagonal)

Input: Dados $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$ com $y^{(i)} \in \{0, 1\}$, centroides μ_0, μ_1 , parâmetros η, γ, T
Output: Vetor de pesos $w \in \mathbb{R}_+^2$

```

1 Inicializar  $w \leftarrow [1, 1]$ 
2 for  $t = 1, \dots, T$  do
3   for  $i = 1, \dots, N$  do
4      $\hat{y}^{(i)} \leftarrow \arg \min_{k \in \{0, 1\}} d_W(x^{(i)}, \mu_k)$ 
5     if  $\hat{y}^{(i)} \neq y^{(i)}$  then
6        $g_j \leftarrow (x_j^{(i)} - \mu_{y,j})^2 - (x_j^{(i)} - \mu_{\hat{y},j})^2$ 
7        $f \leftarrow$  busca binária em  $[0, 1]$  satisfazendo a relaxação de margem  $\gamma$ 
8        $w \leftarrow \max(0, w - \eta \cdot f \cdot g)$ 
9     end
10  end
11 end
12 return  $w$ 
```

(ii) Mínimos Quadrados Não-Negativos (NNLS). O segundo estimador segue a formulação de mínimos quadrados para otimização inversa de Keshavarz, Wang e Boyd [7]: cada decisão observada gera um resíduo da sua condição de otimalidade, linear nos parâmetros do critério, e o critério estimado é aquele que minimiza a soma dos quadrados desses resíduos sob as restrições que mantêm o critério válido (aqui,

$w \geq 0$). Para a regra de centróide mais próximo, a condição de otimalidade da decisão $y^{(i)}$ do LLM sobre o ponto $x^{(i)}$ é que o centróide c_l da classe atribuída ($l = y^{(i)}$) esteja mais perto, sob d_W , do que o centróide rival c_k (o mais próximo de $x^{(i)}$ entre os demais, medido pela distância Euclidiana). Impondo essa condição com margem unitária, à maneira de Schultz e Joachims [9], obtém-se para cada ponto uma equação linear em w ,

$$\sum_{j=1}^d w_j \left[(x_j^{(i)} - c_{k,j})^2 - (x_j^{(i)} - c_{l,j})^2 \right] = 1, \quad (3)$$

ou seja, $A_{ij} = (x_j^{(i)} - c_{k,j})^2 - (x_j^{(i)} - c_{l,j})^2$ e $b_i = 1$. A decisão do LLM entra, portanto, na matriz A : ela define qual centróide é o correto e, com isso, o sinal de cada linha. O vetor $b = \mathbf{1}$ é a margem-alvo, que fixa a escala de w (indeterminada pela invariância discutida acima) e exclui a solução trivial $w = 0$, o mesmo papel da normalização usada por Keshavarz, Wang e Boyd. O sistema, em geral sobredeterminado e sem solução exata quando as decisões não são perfeitamente separáveis por centróides, é resolvido no sentido de mínimos quadrados com restrição de não-negatividade,

$$\hat{W}_{\text{NNLS}} = \arg \min_{w \geq 0} \|Aw - b\|_2^2, \quad (4)$$

pelo algoritmo clássico de Lawson e Hanson [6]¹, que garante $w \geq 0$ sem projeção posterior e, com isso, uma matriz diagonal semidefinida positiva. Ao contrário do Perceptron, o NNLS *não possui hiperparâmetros*, o que o torna um controle valioso: concordância entre os dois sugere que $\hat{W}$ não depende de ajuste fino. Um terceiro estimador (LP Max-Margin) foi avaliado e *descartado* por não respeitar a restrição de convexidade; dois estimadores congruentes bastam para demonstrar robustez.

2.4 Projeções Não-Lineares ($\mathbb{R}^3$ e $\mathbb{R}^4$)

A métrica diagonal sobre os atributos originais só induz fronteiras lineares. Para sondar se o LLM captura interações, aumenta-se o espaço de atributos sem sair do formalismo linear: a *projeção* $\mathbb{R}^3$ acrescenta $x_3 = x_1x_2$ (termo de interação, fronteira hiperbólica) e a *projeção* $\mathbb{R}^4$ acrescenta ainda x_1^2 e x_2^2 (fronteira elíptica); ambas as fronteiras são quadráticas. Comparando a fidelidade com 2, 3 e 4 atributos, avalia-se se a expressividade adicional aproxima $\hat{W}$ do LLM em problemas não-lineares.

2.5 Aprendizado em Contexto em LLMs

O *aprendizado em contexto* (*in-context learning*) é a capacidade de realizar novas tarefas fornecendo apenas exemplos $(x_1, y_1), \dots, (x_k, y_k)$ no *prompt*, sem atualizar parâmetros.

¹Implementação `scipy.optimize.nnls`.

O fenômeno foi formalizado e demonstrado em escala por Brown et al. [26] com o GPT-3, sobre a arquitetura Transformer [25], cujo mecanismo de atenção descende do alinhamento suave introduzido por Bahdanau et al. [24] para tradução automática. Garg et al. [10] mostraram que Transformers treinados do zero realizam aprendizado em contexto de classes de funções, igualando estimadores ótimos. Akyürek et al. [11] provaram por construção que Transformers podem implementar internamente gradiente descendente e regressão ridge. Xie et al. [12] explicam por que o fenômeno emerge do pré-treinamento: se os documentos são gerados por conceitos latentes, o aprendizado em contexto corresponde a uma inferência bayesiana implícita, em que o modelo infere o conceito compartilhado pelos exemplos do *prompt* e prevê a saída pela distribuição preditiva a posteriori, mesmo com a discrepância de distribuição entre *prompts* e pré-treinamento. Essas descobertas justificam a premissa central: se o LLM implementa otimização interna, é possível recuperar seu critério via otimização inversa.

2.6 Viés Semântico em LLMs

LLMs exibem vieses sistemáticos dependentes dos nomes de classe [14]. Rótulos com conotação semântica tendem a distorcer as distribuições previstas, independentemente do conteúdo do exemplo. Zhao et al. identificam três fontes: preferência por rótulos majoritários, recência e frequência de *tokens* no pré-treinamento. A terceira fonte foi quantificada para entradas numéricas por Razeghi et al. [15]: em adição, multiplicação e conversão de unidades com poucos exemplos, a acurácia de modelos GPT pré-treinados no corpus Pile cresce com a frequência dos números no pré-treinamento, com diferenças que chegam a 70 pontos percentuais entre os 10% de termos mais e menos frequentes, efeito que persiste após a remoção das instâncias memorizadas. Como aqui os pontos são apresentados ao LLM como números, esse resultado é uma fonte adicional de irregularidade a considerar na leitura de $\hat{W}$. Este trabalho testa sistematicamente o efeito de nomes de classe (neutros, semânticos, cromáticos) e de atributos sobre $\hat{W}$.

2.7 Métricas de Avaliação

Fidelidade (vs. LLM). A *fidelidade* é a fração de pontos em que a classificação por centróide mais próximo sob $\hat{W}$ concorda com o LLM: $\text{Fid} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\hat{y}_{\hat{W}}(x^{(i)}) = \hat{y}_{\text{LLM}}(x^{(i)})]$. Mede o quanto a métrica *reproduz o LLM*, e não sua correção. Distingue-se de *acurácia vs. ground truth*, que mede concordância com o rótulo verdadeiro do problema.

Consistência (transferência). Idem à fidelidade, com $\hat{y}_{\hat{W}}$ calculado com os centroides do problema de destino (Problemas B, C). Trata-se de um controle metodológico

deliberado: apenas o vetor w é transferido do Problema A, e os centroides são recalculados localmente a partir dos rótulos que o LLM atribui no problema de destino. Isso isola o efeito da métrica (os pesos) do efeito da geometria (a posição dos centroides), evitando que uma eventual queda de consistência em B/C seja mero artefato de centroides deslocados entre distribuições.

Cohen’s κ [22]. Corrige a concordância pelo acaso:

$$\kappa = \frac{P_o - P_e}{1 - P_e}, \quad (5)$$

onde P_o é a proporção de concordância observada e P_e a esperada ao acaso ($P_e = \sum_k \hat{p}_k \tilde{p}_k$, produto das marginais dos dois “anotadores”). O LLM e a métrica $\hat{W}$ são os dois anotadores fixos. Interpretação pelas faixas de Landis e Koch [23]: $\kappa < 0,2$ (fraca), $0,2-0,4$ (razoável), $0,4-0,6$ (moderada), $0,6-0,8$ (substancial), $> 0,8$ (quase perfeita). Valores negativos indicam concordância *pior que o acaso*.

F1-score macro. Para cada classe k , com precisão $P_k = \frac{VP_k}{VP_k + FP_k}$ e revocação $R_k = \frac{VP_k}{VP_k + FN_k}$, define-se $F1_k = \frac{2P_k R_k}{P_k + R_k}$ (média harmônica de precisão e revocação). O F1 *macro* é a média aritmética simples $\frac{1}{K} \sum_{k=1}^K F1_k$, tratando as classes com igual peso, o que é apropriado para detectar degradação em uma classe minoritária.

3 Trabalhos Relacionados

Esta pesquisa situa-se na interseção de seis áreas.

Otimização Inversa. A formulação clássica é a de Ahuja e Orlin [8], que buscam a menor perturbação do vetor de custos de um programa linear que torna a solução observada ótima, e mostram que o problema inverso sob as normas ℓ_1 e ℓ_∞ continua sendo um programa linear. Keshavarz, Wang e Boyd [7] estendem a ideia a decisões apenas aproximadamente ótimas: parametrizam o critério como combinação de funções-base com pesos não-negativos e estimam os pesos minimizando a soma dos quadrados dos resíduos das condições de otimalidade, formulação que fundamenta diretamente o estimador NNLS deste trabalho. Chan et al. [1] apresentam o survey definitivo da área, unificando formulações baseadas em KKT, dualidade forte e modelos *data-driven*. Inferir $\hat{W}$ a partir das classificações do LLM é uma instância direta: dadas as soluções observadas, busca-se o parâmetro que as tornaria ótimas sob centróide mais próximo. Diferimos ao aplicar essa abordagem a um “otimizador” que não é um solver, mas um LLM, e ao validar a recuperação com um teste-oráculo.

Aprendizado de Métrica. O primeiro trabalho da área é o de Xing et al. [2], que formularam o aprendizado de uma distância de Mahalanobis a partir de pares de similaridade como um problema de otimização convexa, com aplicação a agrupamento. Weinberger e Saul [3] introduziram depois o LMNN, que aprende Mahalanobis via otimização convexa com margem. O Perceptron com relaxação de margem aqui utilizado é conceitualmente análogo, com a restrição diagonal proposital. Diferimos ao usar a métrica não para classificar melhor, mas para *explicar* um classificador externo (o LLM).

Predição Estruturada. Collins [4] introduziu o Perceptron Estruturado, ancestral direto do estimador (i). A regra $w \leftarrow w - \eta fg$ é uma instância da regra de Collins adaptada para aprendizado de métrica bidimensional, na formulação com relaxação de margem de Coelho et al. [5], da qual o estimador (i) é implementação direta.

Aprendizado em Contexto. Garg et al. [10] e Akyürek et al. [11] estabelecem o LLM como aprendiz implícito de funções, em estudos majoritariamente empíricos sobre Transformers treinados de forma controlada, e Xie et al. [12] dão ao fenômeno uma explicação bayesiana, em que as demonstrações servem para inferir um conceito latente compartilhado, herdado da estrutura dos documentos de pré-treinamento. Uma segunda família de trabalhos, mais próxima da nossa, estuda o comportamento de LLMs prontos em tarefas de classificação apenas com demonstrações no *prompt*. Min et al. [16] questionam o papel dos mapeamentos *input-label*, mostrando que a estrutura das demonstrações importa mais que a correção dos rótulos, achado com implicações diretas para o Bloco 2 e para a refutação de H4. Su et al. [13] mostram que a seleção estratégica de exemplos, com equilíbrio entre diversidade e representatividade, supera a aleatória. Zhao et al. [14] documentam os vieses de rótulo que motivam nossos experimentos de nomes de classe, e Razeghi et al. [15] mostram que o desempenho numérico em aprendizado em contexto acompanha a frequência dos termos no pré-treinamento, alerta pertinente para um protocolo que apresenta pontos como coordenadas numéricas. Há ainda estudos de estabilidade que quantificam o não-determinismo de LLMs mesmo a $T = 0$ [28, 29], questão que nosso protocolo mede pela taxa de *flip*. Investigamos uma dimensão que esses trabalhos não cobrem: o eixo *fácil vs. difícil* pela margem geométrica à fronteira, com um especialista externo de critério conhecido.

Interpretabilidade Mecanística. Uma rota complementar para abrir a caixa-preta é a engenharia reversa das computações internas do Transformer [18], agenda dificultada pela superposição de conceitos em neurônios polissemânticos [19] e que exige técnicas dedicadas, como autoencoders esparsos, para extrair características interpretáveis [20]. Nessa linha, Marks e Tegmark [21] mostram que LLMs representam a

veracidade de afirmações como estrutura aproximadamente *linear* em suas ativações, evidência interna que torna plausível aproximar critérios decisórios por estruturas lineares. Diferimos na via de acesso: este trabalho opera inteiramente por fora, sobre decisões observadas via API, o único acesso disponível a modelos fechados, e caracteriza o critério sem inspecionar ativações.

Fronteiras de Decisão de LLMs. Zhao et al. [17] investigaram a geometria das fronteiras de decisão de LLMs em classificação binária 2D, achando irregularidades significativas. Seu *setup* é diretamente comparável ao nosso, validando o uso de dados sintéticos bidimensionais. Artstein e Poesio [22] sistematizam os coeficientes de concordância, justificando Cohen’s κ quando LLM e $\hat{W}$ são tratados como dois anotadores fixos.

4 Metodologia

4.1 Nomenclatura: Blocos e Problemas

Para evitar ambiguidade entre o *papel* do LLM e a *configuração de dados*, fixa-se: *Blocos* 1–3 designam os três estudos; *Problemas* A–G designam as configurações de dados (Tabela 1).

Tabela 1: Problemas de classificação binária 2D e seu papel nos blocos.

Prob.	Bloco	Descrição
A	1	Linear, centroides Gaussianos; base da estimação zero-shot (150 pontos).
B	1	Linear, centroides rotacionados no sentido horário ($\pm 1,5$); transferência.
C	1	Linear, rotação anti-horária ($\pm 1,5$); transferência com orientação oposta.
D	1	Meia-lua não-linear (<code>make_moons</code>); teste de não-linearidade.
E	2	Linear, rotulado por especialista com $W_{\text{exp}} = [0,3; 1,5]$; aprendizado em contexto.
F	2	Meia-lua, especialista = <i>ground truth</i> ; aprendizado em contexto não-linear.
G	3	Real: peso $\times$ altura (100 amostras: 70 de treino, 30 de teste; fronteira elíptica).

4.2 Protocolo Experimental

Avaliam-se dois modelos, `gpt-4o-mini` (OpenAI) e `gemini-2.5-flash-lite` (Google, via OpenRouter), ambos com temperatura $T = 0,0$, minimizando estocasti-

cidade para isolar o critério. A narrativa principal segue o `gpt-4o-mini`, com o `gemini-2.5-flash-lite` usado como réplica de contraste (as diferenças relevantes são destacadas explicitamente). Ressalva-se que $T = 0$ *não garante* determinismo estrito (roteamento, *batching* e não-associatividade de ponto flutuante introduzem variação), fenômeno já documentado em estudos de estabilidade de LLMs [28, 29]; o desenho usa múltiplas sementes ($s \in \{42, 123, 7\}$) e $R = 3$ repetições por configuração justamente para medir essa variância. Os detalhes operacionais da coleta (chamadas assíncronas, tratamento de respostas malformadas, grade completa de nomes de classe, nomes de atributo, variantes de *prompt* e tamanhos *few-shot*) estão descritos no Apêndice A; registra-se desde já que o *fallback* de respostas malformadas *não foi acionado* nesta execução (0,00% de 129 868 chamadas), de modo que as métricas de κ /consistência não contêm rótulos pseudo-aleatórios.

A auditoria *offline* das interações registradas quantificou também o não-determinismo residual, e aqui os dois modelos divergem nitidamente: a taxa de *flip* em consultas repetidas a $T = 0$ é de 4,3% no `gpt-4o-mini`, mas de 0,0% no `gemini-2.5-flash-lite` (determinismo estrito no provedor pinado). Para o `gpt-4o-mini`, esse valor constitui o *piso de ruído de medição* do protocolo: nenhuma métrica de concordância com o LLM (fidelidade, consistência, κ) pode exceder $\approx 96\%$, e os resultados devem ser interpretados contra esse teto. As decisões foram coletadas em 05/07/2026; o `gpt-4o-mini` resolveu para o *snapshot* `gpt-4o-mini-2024-07-18` (registrado em cada chamada, ver Limitações).

4.3 Bloco 1 — LLM como Fonte

O LLM classifica os pontos do Problema A em *zero-shot* (sem nenhum exemplo no *prompt*); dessas decisões estimam-se $\hat{W}$ pelo Perceptron e pelo NNLS simultaneamente (Seção 2). A fidelidade de cada estimador e a similaridade de cosseno entre os dois $\hat{W}$ são registradas. As métricas estimadas são então transferidas aos Problemas B e C. Nessa etapa de transferência, o LLM volta a classificar os pontos do problema de destino em duas condições: em *zero-shot* e também com $n \in \{4, 10\}$ exemplos rotulados no *prompt* (*few-shot*). A consistência, o κ e o F1 entre $\hat{W}$ e essas novas decisões são medidos em função de n : apenas a *estimação* de $\hat{W}$ é restrita ao *zero-shot* do Problema A; a *avaliação* da transferência cobre os dois regimes. A projeção $\mathbb{R}^3/\mathbb{R}^4$ é aplicada aos Problemas A–D para sondar não-linearidade, e os testes de viés (nomes de classe, nomes de atributo) e de variantes de *prompt* rodam sobre a mesma estrutura.

Teste-oráculo (sanidade). O teste-oráculo responde a uma pergunta prévia a qualquer alegação sobre o LLM: *os estimadores funcionam quando a resposta certa é conhecida?* O procedimento tem três passos. Primeiro, fixa-se uma métrica $W_{\text{oráculo}}$

conhecida (por exemplo, $[0,3; 1,5]$). Segundo, geram-se dados sintéticos e rotulam-se todos os pontos usando essa métrica, isto é, o “classificador” que produz os rótulos é a própria $W_{\text{oráculo}}$, sem nenhum LLM envolvido. Terceiro, entrega-se esse conjunto rotulado ao Perceptron e ao NNLS e verifica-se se o W que eles estimam recupera o $W_{\text{oráculo}}$ original (em fidelidade e em direção, pelo cosseno). Se os estimadores falhassem nesse cenário controlado, em que o critério existe e é conhecido, qualquer conclusão extraída deles sobre o LLM ficaria comprometida; se recuperam, ganha-se um piso de sanidade para todo o restante do trabalho. Testam-se configurações euclidiana ($[1,0; 1,0]$) e anisotrópicas ($[0,3; 1,5]$, $[1,5; 0,3]$), além de transferência entre geometrias.

4.4 Bloco 2 — LLM como Aprendiz

Os papéis se invertem: um especialista externo com métrica conhecida $W_{\text{exp}} = [0,3; 1,5]$ (o atributo x_2 é $5\times$ mais relevante) rotula o Problema E; para o Problema F (meia-lua), o especialista é o próprio *ground truth*. Seleciona-se um subconjunto de n pontos como exemplos e avalia-se se o LLM reproduz o critério do especialista nos demais. São utilizadas quatro estratégias de seleção de exemplos, descritas a seguir:

Easy: n pontos de maior margem (longe da fronteira);

Hard: n pontos de menor margem (próximos à fronteira);

Mixed: $\lfloor n/2 \rfloor$ easy + $\lceil n/2 \rceil$ hard;

Random: n pontos aleatórios (*baseline*).

Como referência, treinam-se *baselines clássicos* (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot, respondendo: “o LLM faz algo que um classificador trivial não faria?”. Testam-se ainda múltiplas configurações de especialista, o experimento de diluição e o viés de ordem dos exemplos.

4.5 Bloco 3 — Estudo de Caso Real

Uma base real de peso $\times$ altura (rótulo homem/mulher, fronteira aproximadamente elíptica, 100 amostras balanceadas) submete todo o estudo a dados não sintéticos.

A divisão treino/teste merece explicação, pois governa os denominadores reportados nos resultados. Em cada semente, as 100 amostras são permutadas e divididas em 70% de treino (70 pontos) e 30% de teste (30 pontos). A estimação de $\hat{W}$ usa os 70 pontos de treino: o LLM os classifica em zero-shot e as métricas são estimadas e avaliadas sobre esses mesmos 70 pontos (por isso os erros de estimação são reportados sobre 70). Já na etapa de aprendizado em contexto, os exemplos *few-shot* são sorteados entre os pontos de treino e a avaliação é feita nos 30 pontos de teste, garantindo que nenhum

exemplo mostrado ao LLM apareça no conjunto avaliado (sem *leakage*). O mesmo protocolo de divisão 70%/30% aplica-se ao estudo externo da meia-lua (Problema F: 150 pontos, 105 de treino e 45 de teste).

Roda-se a estimação com 2/3/4 atributos ($\mathbb{R}^2/\mathbb{R}^3/\mathbb{R}^4$), sob variantes de *prompt* com nomes neutros (x_1/x_2) e semânticos (peso/altura), identifica-se a melhor métrica e executa-se o aprendizado em contexto. Os exemplos *few-shot* são selecionados *aleatoriamente* (estratégia *random*) entre os pontos de treino, com 3 repetições por configuração usando sorteios independentes. Testa-se ainda a variante de *nomes de classe* neutros, perguntando “A ou B” em vez de “homem ou mulher”, para isolar o prior semântico dos nomes de classe, complementando a variante de atributos neutros. Dada a pequena escala, reporta-se o *número absoluto de erros* além das porcentagens.

4.6 Análise Estatística

Reportam-se intervalos de confiança de 95% via *bootstrap* (10^4 reamostragens) e o tamanho de efeito de Cohen (d) para as comparações principais. A significância é avaliada pelo IC *bootstrap* de 95% não conter zero; com apenas 3 sementes, o teste de Wilcoxon pareado *não é aplicável* ($n < 5$), e as conclusões estatísticas devem ser lidas como *indicativas*, não confirmatórias, dado o pequeno número de observações independentes. A estabilidade de $\hat{W}$ entre sementes é medida pela similaridade de cosseno e pelo coeficiente de variação (CV) da razão w_1/w_2 .

5 Resultados

Todos os números provêm de uma única campanha experimental (**gpt-4o-mini** e **gemini-2.5-flash-lite**, $T = 0$, sementes $\{42, 123, 7\}$, $R = 3$, 129 868 chamadas). Salvo indicação explícita, os valores referem-se ao **gpt-4o-mini**.

5.1 Bloco 1 — Estimação e Fidelidade (Problema A)

A Tabela 2 apresenta a fidelidade dos dois estimadores no Problema A, agora discriminada pelos dois modelos avaliados. Os valores são *modestos*, um sinal honesto de que a métrica diagonal captura o LLM apenas parcialmente. O NNLS supera levemente o Perceptron nos dois modelos, e os estimadores concordam em direção (cosseno médio 0,986; ver Seção 5.9). O **gemini-2.5-flash-lite** apresenta fidelidade média cerca de 3 pontos percentuais abaixo do **gpt-4o-mini** (81,3/82,7% contra 84,0/85,8%), com o mesmo padrão qualitativo, o que é coerente com seu papel de réplica de contraste.

Tabela 2: Fidelidade da estimação no Problema A, por semente e por modelo (classes A/B, zero-shot).

Semente	gpt-4o-mini		gemini-2.5-flash-lite	
	Fid. Perc. (%)	Fid. NNLS (%)	Fid. Perc. (%)	Fid. NNLS (%)
42	82,7	83,3	83,3	84,0
123	86,7	86,7	78,7	80,7
7	82,7	87,3	82,0	83,3
Média	84,0	85,8	81,3	82,7

5.2 Bloco 1 — Teste-Oráculo de Sanidade

Antes de interpretar a fidelidade modesta como propriedade do LLM, verifica-se que os estimadores *funcionam quando o oráculo existe*. A Tabela 3 confirma: sobre dados rotulados por métricas conhecidas, a fidelidade é de 95–100% e a direção recuperada tem cosseno até 0,9999. Portanto, a fidelidade modesta no LLM (Tabela 2) reflete o *LLM*, não uma deficiência dos estimadores.

Tabela 3: Teste-oráculo: recuperação de W conhecido. “cos” é o cosseno entre o W recuperado e o verdadeiro.

Config.	W verd.	Perceptron		NNLS	
		Fid. (%)	cos	Fid. (%)	cos
Prob. A (euclid.)	[1,0; 1,0]	98,0	0,709	98,0	0,707
Prob. B (euclid.)	[1,0; 1,0]	98,0	0,9999	98,0	0,971
Expert aniso. x_2	[0,3; 1,5]	100,0	0,9999	95,3	0,993
Expert aniso. x_1	[1,5; 0,3]	100,0	0,998	99,3	0,989




Figura 1: Bloco 1: comparação Perceptron $\times$ NNLS (fidelidade no Problema A, consistência nos Problemas B/C e dispersão das direções de $\hat{W}$ estimadas). Os dois estimadores produzem métricas quase colineares (cosseno 0,986).




Figura 2: Teste-oráculo: recuperação de W conhecido. Sobre dados rotulados por uma métrica sintética, os estimadores atingem fidelidade de 95–100%, confirmando que a fidelidade modesta observada no LLM reflete o modelo, não uma falha do método.

5.3 Bloco 1 — Transferência (Problemas B e C)

O ponto de partida da leitura é o próprio Problema A: a fidelidade de estimação *in-domain* do `gpt-4o-mini` é de 84,0% (Perceptron) a 85,8% (NNLS) na média das sementes (Tabela 2), e é contra esse patamar de origem que a transferência deve ser comparada. A Tabela 4 apresenta consistência e κ (com IC *bootstrap* de 95%) nas transferências, em zero-shot e com 4 exemplos, para os dois modelos. O padrão é claro e *assimétrico*: o Problema B é difícil em zero-shot ($\kappa = 0,33$, “razoável”), enquanto o Problema C já nasce alto ($\kappa = 0,75$, “substancial”). Poucos exemplos elevam ambos a $\kappa \approx 0,67$ – $0,92$. O salto zero→10-shot na consistência tem tamanho de efeito *grande* em C (Cohen’s $d = 5,78$) e *grande* também em B, embora com maior incerteza ($d = 1,86$; a transferência para B é mais ruidosa entre sementes).

A réplica com o `gemini-2.5-flash-lite` confirma a assimetria: em zero-shot, $\kappa = 0,26$ no Problema B contra $0,85$ no C, ou seja, *ambos os modelos* ficam abaixo do limiar $\kappa > 0,4$ de H1 no Problema B em zero-shot, e ambos o satisfazem com folga no C. Com 4 exemplos, porém, o `gemini-2.5-flash-lite` recupera o Problema B com mais força que o `gpt-4o-mini` (consistência $0,948$ contra $0,837$, com IC mais estreito), indicando que a re-ancoragem por exemplos é ainda mais eficaz nesse modelo.

Tabela 4: Transferência: consistência e κ (Perceptron), IC *bootstrap* 95%, por modelo.

Problema	n -shot	Consistência [IC ₉₅]	κ [IC ₉₅]
gpt-4o-mini			
B	0	0,697 [0,670; 0,750]	0,333 [0,255; 0,449]
B	4	0,837 [0,719; 0,927]	0,670 [0,432; 0,853]
C	0	0,880 [0,860; 0,900]	0,746 [0,703; 0,789]
C	4	0,962 [0,948; 0,990]	0,923 [0,895; 0,979]
gemini-2.5-flash-lite			
B	0	0,727 [0,690; 0,770]	0,263 [0,159; 0,339]
B	4	0,948 [0,938; 0,958]	0,896 [0,875; 0,917]
C	0	0,923 [0,920; 0,930]	0,846 [0,839; 0,859]
C	4	0,951 [0,948; 0,958]	0,902 [0,895; 0,917]

Métrica estimada vs. euclidiana. No Problema B em zero-shot, a métrica estimada é *significativamente inferior* à euclidiana ($\Delta_{\text{métrica-euclid.}} = -0,087$; IC₉₅ = $[-0,180; -0,040]$, exclui zero). O resultado é importante e merece leitura cuidadosa, pois *não* é falha de estimação: o teste-oráculo (Tabela 3) mostra que, quando existe uma métrica anisotrópica real, os estimadores a recuperam. O que ocorre é que *a direção codificada pelas decisões zero-shot do LLM no Problema A não generaliza geometricamente* para B: transferi-la deforma o espaço numa direção que não corresponde à nova disposição das classes, ficando atrás da distância trivial. É preciso separar dois

planos: a *estimação* de $\hat{W}$ funciona (oráculo), mas *o que as decisões zero-shot do LLM encodam* não é geometricamente transferível sem re-ancoragem. Só com exemplos few-shot, que reposicionam a métrica no problema de destino, $\hat{W}$ passa a agregar sobre a euclidiana. A vantagem de $\hat{W}$, portanto, não é intrínseca, e sim contextual.

5.4 Bloco 1 — Não-Linearidade ($\mathbb{R}^3/\mathbb{R}^4$)

Cabe explicar o desenho deste experimento antes dos números. Os Problemas A/B/C são *lineares* por construção; portanto, ao projetá-los em $\mathbb{R}^3/\mathbb{R}^4$ *não se espera* melhoria de fidelidade: fronteiras lineares não requerem termos de interação nem quadráticos. Eles entram aqui como *controle negativo*: se o simples acréscimo de atributos elevasse a fidelidade num problema que não exige não-linearidade, isso indicaria um artefato do procedimento (capacidade extra ajustando ruído), e não um ganho real. O contraste relevante é com os problemas genuinamente não-lineares, em que a mesma projeção *deve* ajudar.

O resultado confirma o desenho. Nos problemas lineares A/B/C, os ganhos são *marginais* (Tabela 5): a média sobe de 84,9% ($\mathbb{R}^3$) para 86,2% ($\mathbb{R}^4$), próximo da faixa da estimação em 2 atributos. Já no caso *não-linear* de peso $\times$ altura (a base real do Bloco 3, cujos resultados completos são apresentados na Seção 5.8; ela é antecipada aqui apenas como contraponto não-linear), a projeção $\mathbb{R}^4$ (que introduz a fronteira elíptica) eleva a fidelidade com atributos neutros (x_1/x_2) de 56,2% para 69,0%, evidência de que a expressividade adicional só ajuda quando o problema efetivamente exige não-linearidade. O teste-oráculo na meia-lua confirma que os estimadores recuperam a métrica anisotrópica mesmo em geometria curva (Perceptron 100%; NNLS 95,3%).

Tabela 5: Fidelidade média (Perceptron) ao aumentar os atributos nos problemas lineares A/B/C, por semente.

n atributos	Seed 42	Seed 123	Seed 7	Média
3 ($\mathbb{R}^3$, $+x_1x_2$)	83,3	88,7	82,7	84,9
4 ($\mathbb{R}^4$, $+x_1^2, x_2^2$)	81,3	86,7	90,7	86,2

Valores em % (fidelidade da métrica vs. LLM).

5.5 Bloco 1 — Viés Semântico e de Prompt

Este experimento mede o quanto o critério do LLM depende da forma como o problema é *apresentado*, mantendo os dados fixos. Importa deixar claro o desenho: as três manipulações da Tabela 6 são independentes e todas rodam sobre os *mesmos pontos sintéticos do Problema A*; muda apenas o texto do *prompt*. No primeiro bloco de linhas, variam-se os *nomes das classes* (perguntar “A ou B”, “Positivo ou Negativo”

etc.), incluindo as inversões de ordem. No segundo, variam-se os *nomes dos atributos*: as coordenadas são as mesmas, mas são apresentadas ao LLM como “ x_1/x_2 ”, “feature_1/feature_2” ou “altura/peso”. Ressalte-se que “altura/peso” aqui é apenas um *rótulo semântico* aplicado ao dado sintético, para medir o efeito do nome; não se trata da base real de peso $\times$ altura do Bloco 3. No terceiro bloco, variam-se os *estilos de prompt*, quatro formas de redigir a mesma pergunta: *default* (instrução direta, usada em todo o restante do trabalho), *geometric* (descreve a tarefa como classificação espacial por proximidade em um espaço métrico), *cot* (*chain-of-thought*, pede raciocínio passo a passo antes da resposta) e *tabular* (apresenta as coordenadas formatadas como tabela). Os textos completos dos quatro estilos, tal como enviados ao LLM, estão transcritos no Apêndice A.3.

Para cada variante reportam-se, para os *dois modelos* e como *média das três sessões*, duas quantidades: a fidelidade da estimacão no Problema A (a rotulacão do Problema A é única, em zero-shot, e por isso independe de n) e a consistência da transferência ao Problema B, medida em zero-shot e com $n = 10$ exemplos, que é onde o efeito do número de exemplos aparece. A Tabela 6 apresenta a manipulação principal, os *nomes de classe*; as tabelas homólogas para nomes de atributo e estilos de *prompt* estão no Apêndice A.4 (Tabelas 14 e 15).

A leitura central é que *o critério do LLM muda com a rotulagem, e o padrão da mudança depende do modelo*. No **gpt-4o-mini**, nomes com conotação (Positivo/Negativo) elevam a fidelidade a 99,1%, a inversão de posição ($A/B \rightarrow B/A$) custa 14,4 pontos ($84,0\% \rightarrow 69,6\%$) e os nomes numéricos 0/1 derrubam a fidelidade a 59,3%; no **gemini-2.5-flash-lite**, os mesmos 0/1 quase não incomodam ($82,4\%$) e a inversão custa menos ($81,3\% \rightarrow 76,9\%$). O efeito dos nomes de atributo também diverge (Tabela 14): “feature_1/feature_2” reduz o **gpt-4o-mini** a 74,7%, mas é o melhor nome para o **gemini-2.5-flash-lite** ($88,4\%$). O contraste mais nítido está nos estilos de *prompt* (Tabela 15): no **gpt-4o-mini** o estilo *tabular* é o que mais degrada ($66,7\%$), ao passo que no **gemini-2.5-flash-lite** o *tabular* é o *melhor* estilo ($87,6\%$) e quem degrada são *cot* e *geometric* ($\approx 67\%$). A conclusão robusta aos dois modelos é que a forma de apresentação interfere na medição; *qual* forma atrapalha, porém, é idiossincrático de cada modelo. Por fim, a consistência na transferência com 10 exemplos sobe em quase todas as variantes (por exemplo, B/A vai de $81,3\%$ a $96,7\%$ no **gpt-4o-mini**), confirmando o papel re-ancorador dos exemplos já observado na Seção anterior.

5.6 Bloco 2 — LLM como Aprendiz (Problemas E–F)

Cegueira em zero-shot. Sem exemplos, o LLM é praticamente incapaz de reproduzir o critério do especialista: a acurácia média, sobre os três peritos, é de $55,2\% \pm 5,6\%$, pouco acima do acaso. A Tabela 7 mostra a curva de aprendizado por estratégia (es-

Tabela 6: Efeito dos *nomes de classe* sobre a estimação, por modelo (média das 3 sementes; atributos x_1/x_2 , estilo *default*). “Fid. A” = fidelidade da estimação no Problema A (rotulação zero-shot, independe de n); “Cons. B (n)” = consistência da transferência ao Problema B com n exemplos. Valores em %.

Nome de classe	gpt-4o-mini			gemini-2.5-flash-lite		
	Fid. A	Cons. B (0)	Cons. B (10)	Fid. A	Cons. B (0)	Cons. B (10)
A/B	84,0	69,7	85,2	81,3	72,7	78,5
B/A	69,6	81,3	96,7	76,9	64,7	97,0
0/1	59,3	55,3	94,1	82,4	87,0	95,6
1/0	71,8	61,7	79,6	86,7	66,7	95,2
Positivo/Negativo	99,1	76,3	79,6	87,1	68,0	93,3
Negativo/Positivo	93,6	66,7	78,9	87,6	70,3	95,2
Azul/Vermelho	87,8	69,3	75,2	73,8	75,7	94,1
Vermelho/Azul	82,2	73,0	73,3	77,3	68,0	90,0




Figura 3: Bloco 1: efeito das variantes de *prompt* sobre a direção de $\hat{W}$ e a fidelidade. A variante *tabular* desloca a medição, alertando que a forma de apresentar as coordenadas interfere no critério inferido.

pecialista aniso. x_2).

Tabela 7: Bloco 2: acurácia LLM $\times$ especialista por estratégia e n -shot (aniso. x_2). Melhor por linha em **negrito**.

n -shot	Easy	Hard	Mixed	Random
0	61,1	61,1	61,1	61,1
4	85,4	62,1	82,2	84,3
10	86,7	67,9	79,3	88,3
20	90,3	83,8	86,2	92,1
40	87,6	97,9	98,5	94,1

H4 refutada. A hipótese *a priori* de que exemplos difíceis ensinam melhor é **refutada**. Na média sobre $n > 0$ e os três peritos, a ordem é *Random* (90,3%) $>$ *Mixed* (88,0%) $>$ *Easy* (81,1%) $>$ *Hard* (75,1%): a estratégia *hard* é a *pior*. A vantagem de *easy* sobre *hard* é estatisticamente significativa com poucos exemplos e desaparece com muitos: no especialista aniso. x_2 , $\Delta_{10\text{-shot}} = +0,188$ (IC₉₅ = [+0,107; +0,257]) e




Figura 4: Bloco 2: curva de aprendizado por estratégia de seleção de exemplos. *Easy* e *Random* dominam com poucos exemplos; *Hard* só alcança as demais em alto volume (40-shot).

$\Delta_{20\text{-shot}} = +0,064$ ($IC_{95} = [-0,154; +0,215]$, não significativo). A interpretação, coerente com Min et al. [16] e com a leitura bayesiana de Xie et al. [12], em que cada exemplo é um sinal sobre o conceito latente a inferir: com poucos exemplos o LLM precisa de *âncoras prototípicas* (alta margem), que dão sinal nítido sobre o critério; com muitos, a informação sobre a geometria da fronteira (exemplos difíceis) supera o ruído: daí *hard* atingir 97,9% em 40-shot. O padrão se repete no *gemin-2.5-flash-lite* (*easy* 93,5% vs. *hard* 78,1% na média sobre $n > 0$), reforçando a refutação de H4 nos dois modelos.

O LLM não supera *baselines* triviais. A Tabela 8 compara o LLM a classificadores clássicos treinados nos mesmos 40 exemplos. Todos os métodos ficam numa faixa estreita (92–98%) e nenhum domina: no especialista aniso. x_2 o LLM (*hard*, 97,9%) supera marginalmente a Regressão Logística (97,3%), ao passo que no aniso. x_1 a Regressão Logística (98,0%) supera o LLM (92,4%). O achado é importante e honesto: no regime linear, o LLM *não supera de forma consistente* um classificador trivial. O valor do LLM está na *flexibilidade* (não requer treino nem especificação de modelo), não na acurácia.

Tabela 8: Bloco 2: LLM vs. *baselines* clássicos (40-shot).

Especialista	LLM (hard)	k-NN	Reg. Log.	SVM-RBF
aniso. x_2	97,9% ($\kappa 0,957$)	94,5% ($\kappa 0,891$)	97,3% ($\kappa 0,947$)	94,5% ($\kappa 0,891$)
aniso. x_1	92,4% ($\kappa 0,850$)	95,6% ($\kappa 0,912$)	98,0% ($\kappa 0,961$)	95,5% ($\kappa 0,911$)

Problema F: colapso frágil e dependente de modelo/semente. No regime não-linear (meia-lua), o zero-shot do *gpt-4o-mini* *colapsa em classe única* em duas das três sementes (123 e 7): o modelo atribui um único rótulo a todos os 105 pontos de treino, e sem duas classes o protocolo few-shot é abortado. Na semente 42 o protocolo roda, mas o desempenho é fraco: a acurácia vs. rótulo real parte de 53,3% (zero-shot) e




Figura 5: Bloco 2: LLM com aprendizado em contexto vs. *baselines* clássicos (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot. No regime linear, todos os métodos ficam numa faixa estreita, sem dominância clara.

satura em $\approx 68\%$ com exemplos, muito abaixo do teto atingido nos problemas lineares. O *gemini-2.5-flash-lite*, por contraste, *não colapsa* em nenhuma semente, o que mostra que o colapso é uma fragilidade específica do modelo e da semente, não uma propriedade universal da geometria. A Figura 6 ilustra o caso da semente 42 por contraste com um SVM gaussiano (RBF) treinado no *ground truth*. Um teste-oráculo que ajusta a métrica diagonal diretamente ao rótulo verdadeiro da meia-lua satura em $\approx 86,7\%$ (20/150 erros), e as projeções $\mathbb{R}^3/\mathbb{R}^4$ *não* ajudam: o limite é estrutural (a curvatura em “S” exigiria termo fora da diagonal), não de dados. O teste mais informativo do LLM como aprendiz em regime não-linear genuíno é, portanto, o caso real do Bloco 3.




Figura 6: Problema F (meia-lua, seed 42, *gpt-4o-mini*): superfície de separação do SVM RBF treinado no *ground truth* (esq.) vs. treinado nos rótulos zero-shot do LLM (dir.). Em ambos os painéis os pontos aparecem nas classes *corretas* (*ground truth*, azul/vermelho): à direita, a lua vermelha inteira cai na região azul, evidenciando que o LLM erra muito mais que o SVM RBF de referência, que não erra nenhum ponto. Nas sementes 123 e 7 o zero-shot colapsa em classe única e o protocolo é abortado.

5.7 Bloco 2 — Diluição e Viés de Ordem dos Exemplos

Diluição não dilui. Fixando 4 exemplos *hard* e acrescentando exemplos *easy* progressivamente, a acurácia *cresce monotonicamente*: de 63,0% (apenas os 4 hard) a 84,1% (4 hard + 20 easy), estabilizando em torno de 84% (Figura 7). Não se observa o efeito hipotético de “diluição” em que exemplos fáceis prejudicariam: ao contrário, cada bloco de fáceis *ajuda*, reforçando a leitura de H4 de que âncoras prototípicas transmitem o critério.

Viés de ordem é modesto. Reordenar os mesmos exemplos (*class0_first*, *class1_first*, *shuffled*, *alternating*) altera pouco o resultado: a dispersão entre ordenações é de apenas 1,8–7,6 pontos percentuais, sem uma ordenação consistentemente vencedora (*shuffled* é marginalmente melhor com poucos exemplos). O critério do LLM, neste *setup*, é relativamente robusto à ordem das demonstrações, em contraste com a forte sensibilidade a *quais* exemplos são escolhidos (Tabela 7).




Figura 7: Esquerda: experimento de diluição (acrescentar exemplos fáceis a 4 difíceis fixos melhora a acurácia monotonicamente). Direita: viés de ordem (as quatro ordenações diferem por poucos pontos percentuais).

5.8 Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)

O caso real expõe a *dependência semântica* dos atributos (Tabela 9, médias das 3 sementes, 2 atributos). Distinguem-se três quantidades: a *fidelidade* (a métrica reproduz o LLM), a *acurácia do LLM vs. real* (as decisões do LLM contra o rótulo verdadeiro) e a *acurácia da métrica vs. real* (a métrica estimada contra o rótulo verdadeiro). Com nomes *semânticos* (peso/altura), o LLM classifica *pior* que com neutros (acurácia própria 43,3% vs. 54,8%, ambas abaixo do acaso da classe majoritária, 57,1%): os valores chegam normalizados em $[-1, 1]$, sem unidade, e o LLM rotula como “Homem” sobretudo os pontos de altura e peso negativos, os mais baixos e leves, invertendo a relação física. Uma explicação compatível é a dependência do raciocínio numérico em relação à frequência dos números no pré-treinamento, documentada por Razeghi et al. [15]: valores decimais normalizados são termos raros no corpus, ao contrário de alturas em metros e pesos em quilogramas. A métrica estimada a partir dessas decisões herda essa inversão de forma sistemática (10,5% vs. real, ≈ 63 erros em 70; entre 7,1% e 12,9% nas

três sementes), o que significa que ela *separa* os dois grupos reais em 89,5% dos pontos, mas com os nomes trocados. Com nomes *neutros* (x_1/x_2), a métrica vs. real torna-se *arbitrária*: entre sementes ela vale 91,4%, 7,1% e 68,6% (a média 55,7% é enganosa), porque, sem âncora semântica, o mapeamento rótulo $\leftrightarrow$ classe inverte de semente para semente. O contexto semântico dos atributos é, no caso real, determinante, mas no sentido de fixar uma convenção de nomeação, não de acertar o rótulo.

Por que a métrica separa melhor do que o LLM rotula (peso/altura). Um ponto merece explicação: com nomes semânticos, a métrica estimada concorda com a separação real em 89,5% dos pontos (a menos da troca de nomes), muito mais que a acurácia própria do LLM (43,3%, ou 56,7% após a mesma troca). Isso não é contradição nem artefato. A métrica classifica por centróide mais próximo, e os centróides são calculados como a *média* dos pontos rotulados pelo LLM em cada classe. Quando os erros do LLM são espacialmente *pouco estruturados* (dispersos, sobretudo perto da fronteira), eles se cancelam na média: o centróide de cada classe rotulada pelo LLM ainda cai perto da média verdadeira de um dos grupos. A regra por centróide mais próximo recupera então a separação correta apesar do ruído rótulo a rótulo. Em outras palavras, o LLM *localiza* os dois grupos no espaço melhor do que *rotula* pontos individuais, e a agregação por centróides extrai essa informação espacial. É também um alerta duplo: a concordância elevada da métrica com a separação real mede a qualidade da *separação espacial* induzida, não a acurácia ponto a ponto do LLM, que permanece modesta; e a acurácia vs. real nominal (10,5%) mostra que essa separação veio com a nomeação das classes invertida.

Tabela 9: Bloco 3: estimação no Problema G (2 atributos, médias das 3 sementes; estimação e avaliação sobre os 70 pontos de treino). “Fid.” = métrica vs. LLM; “LLM real” = LLM vs. rótulo verdadeiro; “Métrica real” = métrica estimada vs. rótulo verdadeiro.

Nomes	Fid. (%)	LLM real (%)	Métrica real (%)	err. (métrica)
peso/altura	59,5	43,3	10,5 [†]	$\approx 63/70$
x_1/x_2	56,2	54,8	arbitrária [†]	$\approx 31/70$

[†] Entre sementes: 91,4 / 7,1 / 68,6% (o mapeamento rótulo $\leftrightarrow$ classe inverte por semente).

[‡] Nomeação invertida nas três sementes: 89,5% de concordância com a separação real a menos da troca de nomes.

A métrica aprendida e a projeção elíptica. Para tornar explícito o aprendizado de métrica no caso real, a Tabela 10 apresenta os vetores de parâmetros $\hat{W}$ estimados com nomes semânticos (peso/altura), com 2 atributos e com a projeção elíptica de 4 atributos (peso², altura²), que corresponde à forma quadrática do classificador ótimo deste problema. A leitura deve ser *direcional* (invariância de escala): o NNLS identifica consistentemente a *altura* como atributo dominante ($w_{\text{altura}} \gg w_{\text{peso}}$ nas três sementes)

e, com 4 atributos, transfere peso substancial aos termos quadráticos, coerente com a geometria elíptica. O Perceptron, neste problema, quase não se afasta da inicialização $[1, \dots, 1]$ (direção pouco informativa), o que reforça o valor de usar dois estimadores: onde um é pouco sensível, o outro captura a estrutura.

Tabela 10: Bloco 3: vetores $\hat{W}$ estimados no caso real (nomes peso/altura, gpt-4o-mini), por semente. Com 2 atributos, $W = [w_{\text{peso}}; w_{\text{altura}}]$; com 4, acrescentam-se $[w_{\text{peso}^2}; w_{\text{altura}^2}]$ (projeção elíptica). Leitura direcional (invariância de escala).

Semente	2 atributos		4 atributos (elipse)	
	Perceptron	NNLS	Perceptron	NNLS
42	[0,97; 0,94]	[0,00; 2,38]	[0,98; 0,97; 1,00; 1,01]	[1,87; 4,70; 10,0; 17,3]
123	[0,89; 0,88]	[1,07; 1,34]	[0,89; 0,88; 1,00; 1,00]	[1,10; 1,53; 19,8; 6,75]
7	[0,95; 0,89]	[0,00; 1,88]	[0,96; 0,89; 1,02; 1,03]	[0,47; 2,14; 8,08; 8,93]

O efeito da projeção elíptica sobre o desempenho aparece na Tabela 11, e a leitura honesta tem duas partes. Primeiro, a elipse melhora o quanto a métrica *reproduz o LLM*: a fidelidade NNLS sobe de 58,6% (2 atributos) para 72,4% (4), e, com nomes neutros, a fidelidade Perceptron sobe de 56,2% para 69,0%, o já citado ganho da Seção do Bloco 1. Segundo, a acurácia da métrica *contra o rótulo verdadeiro* com nomes semânticos fica em 10,5% com 2 atributos e em 11,9% com 4, isto é, a separação real já é bem capturada no espaço original ($\approx 89\%$ a menos da troca de nomes) e a elipse não altera esse patamar: como os erros do LLM se cancelam na média dos centróides (ver acima), o ganho da expressividade quadrática se manifesta na aproximação ao *critério do LLM*, não ao *ground truth*.

Tabela 11: Bloco 3: efeito da projeção elíptica (2 vs. 4 atributos) no caso real (gpt-4o-mini, médias das 3 sementes, avaliação nos 70 pontos de treino).

Nomes	Atributos	Fid. Perc. (%)	Fid. NNLS (%)	Métrica real, Perc. (%)
peso/altura	2	59,5	58,6	10,5 [†]
peso/altura	4 (elipse)	60,0	72,4	11,9 [‡]
x_1/x_2	2	56,2	54,8	55,7 [†]
x_1/x_2	4 (elipse)	69,0	76,7	55,2 [†]

[†] Arbitrária entre sementes (inversão de rótulo, ver texto).

[‡] Nomeação invertida nas três sementes (ver texto).

Nomes de classe A/B: o mapeamento inverte nos dois casos. Repetindo a classificação com nomes de classe *neutros* (“A ou B” em vez de “homem ou mulher”), a acurácia da métrica estimada (Perceptron) vs. rótulo real, na média das 3 sementes, é 0,110 ($\approx 62/70$ erros) com atributos semânticos (Tabela 12), praticamente idêntica à obtida com os nomes semânticos (0,105). Valores tão *abaixo* do acaso não são ruído: são *inversão sistemática de convenção*. O LLM separa os dois grupos (invertendo-se os

rótulos, a acurácia beira 0,89 nos dois casos), mas o mapeamento rótulo $\leftrightarrow$ classe emerge na convenção oposta à do *ground truth*, e emerge assim tanto com “A/B” quanto com “homem/mulher”. Nesta base, portanto, os nomes de classe semânticos *não* ancoram a nomeação: com valores normalizados e sem unidade, o LLM associa “Homem” ao grupo de peso e altura negativos, o mais baixo e leve, e “A” a esse mesmo grupo. O prior semântico dos nomes de classe, visível no Bloco 1 (Tabela 6), não se manifesta aqui como acerto de convenção. Note-se um contraste: a inversão é *sistemática* quando os atributos são semânticos (as três sementes caem juntas em 0,07–0,13, com qualquer nome de classe), ao passo que a variante com nomes de classe semânticos e atributos neutros (homem/mulher, x_1/x_2) é *caótica* entre sementes (0,91, 0,07, 0,69). Uma leitura plausível, ainda que especulativa, é que a semântica dos atributos fixa uma convenção consistente (que inverte a do *ground truth*), enquanto atributos neutros deixam a convenção ao acaso de cada semente. No aprendizado em contexto, o LLM adota a convenção dos exemplos que recebe: com nomes A/B a concordância com a métrica-alvo sobe de 0,778 (zero-shot) a 0,974 (40-shot), enquanto a acurácia vs. real permanece $\approx 0,14$ (a métrica-alvo herdou a convenção invertida), e o Perceptron *baseline* treinado nos mesmos exemplos acompanha (0,12–0,19), indicando consistência entre aprendizes, não defeito do LLM.

Tabela 12: Bloco 3: efeito dos nomes de classe (A/B vs. homem/mulher) na acurácia da métrica estimada (Perceptron) vs. rótulo real (zero-shot, média das 3 sementes, treino = 70).

Classes	Features	Acc. real	Erros
homem/mulher	peso/altura	0,105	$\approx 63/70$
A/B	peso/altura	0,110	$\approx 62/70$
homem/mulher	x_1/x_2	0,557	$\approx 31/70$
A/B	x_1/x_2	0,186	$\approx 57/70$

No aprendizado em contexto (Tabela 13), os exemplos fornecidos ao LLM foram rotulados pela melhor métrica estimada na Fase A, que, como visto, carrega a nomeação invertida; o resultado deve ser lido, portanto, como adoção da convenção dos exemplos. É o que ocorre: a concordância do LLM com a métrica-alvo sobe de 53–73% (zero-shot) para 91–100% com 4 exemplos ou mais, e a acurácia contra o rótulo real cai de 40–47% para 9–22%, acompanhada pelo Perceptron *baseline* treinado nos mesmos exemplos (10–27%). Poucos exemplos bastam para o LLM assumir a convenção que lhe é apresentada, seja ela qual for.

5.9 Estabilidade de $\hat{W}$ (H5)

A direção de $\hat{W}$ é *estável* entre sementes (cosseno médio 0,971, faixa [0,955; 0,984]), e os dois estimadores concordam (cosseno Perceptron–NNLS 0,986). A *magnitude*, por

Tabela 13: Bloco 3: aprendizado em contexto no Problema G, acurácia real (%) do LLM vs. Perceptron (peso/altura); avaliação nos 30 pontos de teste. Os exemplos foram rotulados pela métrica estimada na Fase A, cuja nomeação é invertida em relação ao rótulo real (ver texto).

<i>n</i> -shot	Seed 42		Seed 123	
	LLM	Perc.	LLM	Perc.
0	40,0	—	46,7	—
4	10,0	25,6	21,1	20,0
10	10,0	16,7	22,2	26,7
20	11,1	16,7	18,9	21,1
40	8,9	16,7	18,9	21,1

outro lado, varia bastante: a razão w_1/w_2 tem média 0,214 com $IC_{95} = [0,114; 0,356]$ e coeficiente de variação de 88,0%. Duas ressalvas são necessárias aqui. Primeiro, a instabilidade de magnitude é *parcialmente esperada*: pela invariância de escala (Seção 2), a magnitude é intrinsecamente menos identificável que a direção, de modo que um CV alto na razão não é, por si só, surpreendente. Segundo, com apenas 3 sementes, tanto a estabilidade direcional quanto a variação de magnitude são estimativas de baixa potência e devem ser lidas como indicativas. Feitas essas ressalvas, a leitura defensável é que *para onde* o LLM olha (a direção) é a quantidade identificável e reproduzível, ao passo que *quão intensamente* (a magnitude) não é uma quantidade sobre a qual o desenho atual permita conclusão forte.

6 Análise e Discussão

6.1 H1 — Estabilidade do critério

Parcialmente confirmada. $\hat{W}$ reproduz o LLM com fidelidade modesta (82,7–86,7% entre sementes) e transfere com κ de “razoável” (B, 0,33) a “substancial” (C, 0,75) já em zero-shot. É importante ser explícito quanto ao limiar de H1: em zero-shot, o Problema B ($\kappa = 0,33$; 0,26 na réplica com o `gemini-2.5-flash-lite`) fica *abaixo* do $\kappa > 0,4$ estipulado, alcançando-o apenas com poucos exemplos; o Problema C o satisfaz de saída. A hipótese, portanto, sustenta-se para C em todas as condições e para B só com *few-shot*. Há um critério estimável, mas a métrica diagonal o captura só em parte: o teste-oráculo (95–100%) prova que a limitação é do LLM, não do estimador.

6.2 H2 — Transferência de conhecimento

Confirmada com qualificações. $\hat{W}$ generaliza melhor para C do que para B, e a adição de exemplos eleva ambos a $\kappa \approx 0,67$ –0,92 (Cohen’s $d = 5,78$ na consistência




Figura 8: Bloco 3: base real peso $\times$ altura (rótulo homem/mulher) com a fronteira quadrática (aproximadamente elíptica) sobreposta — classificador logístico sobre os atributos [peso, altura, peso², altura²] ajustado aos rótulos reais (91% de acurácia). A pequena escala (100 amostras, 70 de treino por semente) motiva o reporte de erros absolutos além das porcentagens.

em C), padrão que a réplica com o `gemini-2.5-flash-lite` reproduz (Tabela 4). Porém, em zero-shot $\hat{W}$ é *significativamente inferior* à métrica euclidiana no Problema B ($\Delta = -0,087$, IC exclui zero): a deformação aprendida não tem valor intrínseco, e sim *contextual*, dependente de exemplos.

6.3 H3 — Viés semântico

Fortemente confirmada. A fidelidade oscila de 59,3% (classes 0/1) a 99,1% (Positivo/Negativo), extremos da grade de variantes nas médias das três sementes, e a mera inversão de posição ($A/B \rightarrow B/A$) já custa 14,4 pontos (84,0% $\rightarrow$ 69,6%). O viés de apresentação é ainda *dependente de modelo*: o estilo *tabular*, que mais degrada o `gpt-4o-mini` (66,7%), é o melhor estilo no `gemini-2.5-flash-lite` (87,6%), cujos piores são *cot* e *geometric* (Tabela 6). No caso real, nomes de atributo semânticos vs. neutros *reduzem* a acurácia própria do LLM de 54,8% a 43,3%: com valores normalizados e sem unidade, o LLM aplica a semântica de “peso” e “altura” na direção errada. O experimento de nomes de classe A/B (Tabela 12) mostra o mecanismo em sua forma mais nítida: o LLM separa os grupos, mas o mapeamento rótulo $\leftrightarrow$ classe

emerge em convenção invertida em relação ao *ground truth*, com nomes neutros (0,110) e semânticos (0,105) por igual. O LLM incorpora semântica extrínseca ao problema geométrico, e ela ancora a separação e uma convenção de *nomeação* das classes, não necessariamente a correta.

6.4 H4 — Qualidade dos exemplos

Refutada. Ao contrário do previsto, exemplos *fáceis* superam *difíceis* com poucos exemplos (diferença significativa em 10-shot), e *hard* é a pior estratégia na média. Exemplos difíceis só compensam em alto volume (40-shot). A refutação vale nos *dois* modelos testados. A leitura: âncoras prototípicas transmitem o critério; exemplos ambíguos sem contexto suficiente chegam a orientar o LLM na direção errada.

6.5 H5 — Estabilidade estatística

Confirmada em direção; inconclusiva em magnitude. O cosseno entre sementes (0,971) sustenta reprodutibilidade direcional; o CV de 88% na razão w_1/w_2 indica que a intensidade dos pesos varia, embora, pela invariância de escala, a magnitude seja intrinsecamente menos identificável e essa variação seja em parte esperada. Com 3 sementes, não se afirma instabilidade de magnitude como propriedade do LLM; afirma-se apenas que a *direção*, a quantidade cientificamente relevante sob invariância de escala, é estável.

6.6 O LLM diante de *baselines* triviais

O achado mais sóbrio: no regime linear, o LLM e os classificadores triviais ficam numa faixa estreita (92–98%), sem dominância clara (a Regressão Logística supera o LLM num especialista, o LLM a supera no outro). O LLM não “resolve melhor”: ele resolve *sem treino e sem especificação de modelo*. O quadro, porém, tem dois regimes: na base real (fronteira aproximadamente elíptica), o LLM com aprendizado em contexto iguala ou supera o Perceptron *baseline* treinado nos mesmos exemplos na maioria das configurações (até +15,6 pontos), e no regime não-linear sintético (meia-lua) o zero-shot do **gpt-4o-mini** chega a colapsar em classe única. A contribuição do aprendizado em contexto é de *flexibilidade*, condicionada a haver exemplos e semântica que o ancorem, não de acurácia, e qualquer alegação de superioridade geral deve ser resistida.

7 Limitações

1. **Dados majoritariamente 2D:** embora o Bloco 3 use dados reais, a validade externa em alta dimensionalidade permanece aberta.

2. **Métrica diagonal:** $M = \text{diag}(w)$ ignora correlações entre atributos, provável causa da fidelidade modesta; uma Mahalanobis completa poderia elevá-la.
3. **Dois modelos, mesma família de escala:** avaliaram-se `gpt-4o-mini` e `gemini-2.5-flash-1` (modelos rápidos/econômicos); a generalização a modelos maiores ou de outras famílias (Llama, DeepSeek) permanece aberta.
4. **Versão do modelo:** o `gpt-4o-mini` resolveu para o *snapshot* `gpt-4o-mini-2024-07-18` (registrado em cada chamada); ainda assim o provedor pode aposentar o *snapshot*, o que limita a reprodutibilidade exata a longo prazo.
5. **Temperatura zero:** minimiza variância, mas não captura o comportamento estocástico; $T = 0$ não garante determinismo estrito. A taxa de *flip* medida pela auditoria foi de 4,3% das consultas repetidas no `gpt-4o-mini` (impondo um teto de $\approx 96\%$ a qualquer métrica de concordância com esse modelo), mas de 0,0% no `gemini-2.5-flash-lite`.
6. **Escala do caso real:** 100 amostras (70 de treino por semente) tornam cada erro pesado (por isso reportam-se erros absolutos); conclusões sobre o Problema G são indicativas.
7. **Entradas numéricas:** os pontos chegam ao LLM como números decimais normalizados (quatro casas, e em $[-1, 1]$ no caso real), termos raros no pré-treinamento; como o desempenho numérico *few-shot* de LLMs depende da frequência desses termos no corpus [15], parte da fidelidade perdida e da inversão física observada no Bloco 3 pode vir da representação numérica, e não do critério geométrico.

8 Trabalho Futuro

1. **Métrica completa:** remover a restrição diagonal e avaliar o *trade-off* expressividade $\times$ interpretabilidade, testando se a fidelidade sobe.
2. **Alta dimensionalidade e mais dados reais:** estender o Bloco 3 a datasets maiores e $d \gg 2$.
3. **Mais modelos e famílias:** estender a comparação (já iniciada com `gpt-4o-mini` e `gemini-2.5-flash-lite`) a modelos maiores e de outras famílias (ex.: Llama, DeepSeek), aprofundando o contraste de critérios implícitos e das taxas de *flip* a $T = 0$ como medida de não-determinismo por modelo.
4. **Seleção ativa de exemplos:** integrar o eixo de margem [16] com diversidade/representatividade [13] e incerteza.

5. **Geometria de fronteiras:** comparar a fronteira induzida por $\hat{W}$ com a fronteira real do LLM, seguindo Zhao et al. [17].
6. **Extensão a múltiplas classes:** a classificação por centróide mais próximo estende-se naturalmente a K classes (a métrica é única; muda apenas o número de centróides comparados), de modo que a formulação atual não precisa ser modificada em essência. Um candidato natural é a base Íris (3 classes, 4 atributos), replicando o protocolo do caso real: LLM rotulando em zero-shot e few-shot, comparação com classificadores clássicos e teste de nomes de atributo semânticos (sépala/pétala) contra neutros.

9 Conclusão

Este trabalho investigou se é possível estimar uma métrica matemática explícita que capture o critério decisório implícito de um LLM. Com `gpt-4o-mini` e `gemini-2.5-flash-lite` sobre sete configurações de problema organizadas em três blocos (129 868 chamadas, 3 sementes $\times$ 3 repetições, *fallback* do *parser* de 0,00% e piso de ruído de medição de 4,3% a $T = 0$ no `gpt-4o-mini`), os experimentos sustentam seis achados (`gpt-4o-mini`, salvo indicação):

1. **O critério é estimável, mas só parcialmente por uma métrica diagonal:** fidelidade de 82,7–86,7% entre sementes (média 0,840, $IC_{95} = [0,827; 0,867]$), com dois estimadores congruentes (cosseno Perceptron–NNLS 0,986) e validados por um teste-oráculo (95–100%); a lacuna até o teto de $\approx 96\%$ imposto pelo ruído de medição é, portanto, do LLM, não do estimador. O teto é também *estrutural*: no oráculo da meia-lua, a métrica diagonal satura em $\approx 86,7\%$ e as projeções $\mathbb{R}^3/\mathbb{R}^4$ não ajudam.
2. **Transfere de modo heterogêneo:** κ de 0,33 (Problema B) a 0,75 (Problema C) em zero-shot, subindo a 0,67–0,92 com poucos exemplos (efeito grande em C, $d = 5,78$); em zero-shot, porém, $\hat{W}$ chega a ser inferior à distância euclidiana trivial.
3. **É direcionalmente estável, com magnitude pouco identificável:** cosseno 0,971 entre sementes, com CV de 88% na razão dos pesos; dada a invariância de escala, a direção é a quantidade identificável e reprodutível, ao passo que a variação de magnitude é em parte esperada e, com 3 sementes, não permite conclusão forte.
4. **É fortemente semântico, nos atributos e nos nomes de classe:** variantes de apresentação movem a fidelidade de 59,3% a 99,1% (médias das sementes), com

o estilo prejudicial variando por modelo; no caso real, com valores normalizados e sem unidade, a semântica dos atributos *reduz* a acurácia própria do LLM de 54,8% a 43,3%, e o mapeamento rótulo↔classe emerge em convenção invertida em relação ao *ground truth* tanto com nomes de classe neutros (A/B, 0,110) quanto semânticos (homem/mulher, 0,105): a semântica fixa uma convenção de *nomeação*, não necessariamente a correta.

5. **Como aprendiz, o LLM é cego em zero-shot e aprende com poucos exemplos:** 55,2% (média sobre três peritos) → 97,9% no regime linear, sem contudo superar de forma consistente a Regressão Logística (97–98%); no regime não-linear sintético o zero-shot do gpt-4o-mini *colapsa* em classe única em duas das três sementes (o gemini-2.5-flash-lite não colapsa), enquanto na base real, com exemplos, o LLM iguala ou supera o Perceptron *baseline* na maioria dos n -shot ($\approx 87\%$).
6. **A hipótese de que exemplos difíceis ensinam melhor é refutada** na forma *a priori*, nos dois modelos: *easy* supera *hard* com significância em 10-shot ($\Delta = +0,188$, IC excluindo zero), com reversão apenas em alto volume (40-shot, *hard* 97,9%).

Esses resultados constituem um passo deliberadamente cético em direção à explicabilidade dos critérios decisórios de LLMs: o que uma métrica interpretável captura (direção do critério, transferência parcial, dependências semânticas) e o que ela expõe por não capturar (o teto de fidelidade, o colapso não-linear, a arbitrariedade do mapeamento sem semântica). A aplicação potencial está em auditoria de sistemas de IA, detecção de vieses e transferência de conhecimento especializado, sempre com as métricas de concordância lidas contra o piso de ruído que o próprio protocolo quantifica.

A Detalhamento do Protocolo Experimental

Este apêndice reúne os detalhes operacionais da coleta de decisões, complementando a Seção 4. Os resultados permanecem todos no corpo do artigo; aqui descreve-se apenas *como* os dados foram obtidos.

A.1 Coleta e tratamento de respostas

As chamadas à API são assíncronas com concorrência limitada (semáforo de 10 chamadas simultâneas). As respostas passam por um *parser de 8 camadas* (0–7) que trata variações de formato; respostas irrecuperáveis após reenvios recebem rótulo por *hash* MD5 determinístico das coordenadas (evitando viés geométrico). Nesta execução *não*

houve acionamento desse *fallback* em nenhum dos modelos (0,00% de 129 868 chamadas): as métricas de κ /consistência não contêm rótulos pseudo-aleatórios. Todas as interações (prompt, resposta bruta, rótulo interpretado, *snapshot* do modelo e provedor de inferência) são registradas em arquivos estruturados, sobre os quais roda a auditoria *offline* que mede a taxa de *flip* reportada na Seção 4.

A.2 Variáveis de controle

- **Sementes:** $s \in \{42, 123, 7\}$ (robustez estatística).
- **Repetições:** $R = 3$ por configuração onde há sorteio de exemplos.
- **Nomes de classe:** neutros (A/B, 0/1), semânticos (Positivo/Negativo), cromáticos (Azul/Vermelho) e suas inversões (ordem/posição).
- **Nomes de atributo:** x_1/x_2 (neutro), altura/peso (semântico), `feature_1/feature_2` (técnico).
- **Variantes de *prompt*:** *default*, *geometric*, *cot* (*chain-of-thought*), *tabular*.
- **Tamanhos *few-shot*:** $n \in \{0, 4, 10\}$ (transferência) e $n \in \{0, 4, 10, 20, 40\}$ (aprendizado em contexto). Os tamanhos são pares para garantir seleção balanceada entre as duas classes ($n/2$ exemplos de cada) sem exemplo excedente.

A.3 Exemplos dos estilos de prompt

Transcrevem-se a seguir, *verbatim*, exemplos reais de prompt zero-shot enviados ao LLM em cada um dos quatro estilos avaliados (registros da campanha experimental; apenas as coordenadas do ponto variam entre chamadas). Cada estilo combina uma mensagem de sistema (*system message*) e um corpo de prompt.

***default* (padrão, usado em todo o restante do trabalho).** Instrução direta, resposta restrita ao rótulo. Mensagem de sistema: `You are a classifier. Respond only with the class label.`

`You are a binary classifier for 2D points.`

`Classify the given point as Class A or Class B.
Answer ONLY with "A" or "B", nothing else.`

`Point to classify:`

`x1 = -3.6984`

`x2 = -0.5048`

Your classification:

geometric. Enquadra a tarefa explicitamente como classificação espacial por proximidade a centros de grupos em um espaço métrico. Mensagem de sistema: You are a geometric classifier analyzing point positions in metric space. Respond only with the class label.

You are a binary classifier for 2D points in Euclidean space.

Points exist in a 2D metric space. Classify the given point based on spatial proximity to cluster centers.

Classify as Class A or Class B.

Answer ONLY with "A" or "B", nothing else.

Point to classify:

x1 = -3.6984

x2 = -0.5048

Your classification:

cot (chain-of-thought). Pede raciocínio passo a passo antes da resposta final (limite de tokens ampliado de 50 para 300). Mensagem de sistema: You are a classifier. Think step by step, then give your final answer on the last line as just the class label.

You are a binary classifier for 2D points.

Classify the given point as Class A or Class B.

Point to classify:

x1 = -2.8425

x2 = -0.3932

Think step by step about which class this point belongs to, then state your final classification ("A" or "B") on the last line.

tabular. Idêntico ao *default*, mas com as coordenadas apresentadas como tabela *markdown* em vez de linhas " $x_i = \text{valor}$ ". Mensagem de sistema: You are a classifier. Respond only with the class label.

You are a binary classifier for 2D points.

Classify the given point as Class A or Class B.

Answer ONLY with "A" or "B", nothing else.

Point to classify:

```
| Feature | Value |  
|-----|-----|  
| x1 | -2.0864 |  
| x2 | 1.2042 |
```

Your classification:

Nos estilos few-shot, o mesmo corpo é precedido por um bloco **Examples:** com os n exemplos rotulados, mantendo o formato de coordenadas de cada estilo.

A.4 Tabelas complementares do experimento de viés

Complementando a Tabela 6 (nomes de classe), as Tabelas 14 e 15 reportam, com a mesma estrutura (média das 3 sementes, dois modelos), as outras duas manipulações do experimento de viés: os nomes de atributo e os estilos de *prompt*. Em ambas, a primeira linha (atributos x_1/x_2 ou estilo *default*, com classes A/B) é a configuração de referência, a mesma da Tabela 6.

Tabela 14: Efeito dos *nomes de atributo* sobre a estimação, por modelo (média das 3 sementes; classes A/B, estilo *default*). Colunas como na Tabela 6; valores em %. A variação de nome de atributo foi coletada apenas em zero-shot (“—”).

Nome de atributo	gpt-4o-mini			gemini-2.5-flash-lite		
	Fid. A	Cons. B (0)	Cons. B (10)	Fid. A	Cons. B (0)	Cons. B (10)
x_1/x_2	84,0	69,7	85,2	81,3	72,7	78,5
altura/peso	85,1	63,0	—	87,1	72,0	—
feature_1/2	74,7	69,0	—	88,4	82,7	—

Referências

- [1] Timothy C.Y. Chan, Rafid Mahmood, e Ian Yihang Zhu. Inverse optimization: Theory and applications. *Operations Research*, 73(2):1046–1074, 2025. (Publicado online Dez/2023.)

Tabela 15: Efeito dos *estilos de prompt* sobre a estimação, por modelo (média das 3 sementes; classes A/B, atributos x_1/x_2). Colunas como na Tabela 6; valores em %. Estilos transcritos no Apêndice A.3.

Estilo de prompt	gpt-4o-mini			gemini-2.5-flash-lite		
	Fid. A	Cons. B (0)	Cons. B (10)	Fid. A	Cons. B (0)	Cons. B (10)
<i>default</i>	84,0	69,7	85,2	81,3	72,7	78,5
<i>cot</i>	75,6	61,7	94,4	66,7	55,7	90,7
<i>geometric</i>	76,2	68,3	88,1	67,8	56,0	91,1
<i>tabular</i>	66,7	61,7	92,6	87,6	73,3	88,5

- [2] Eric P. Xing, Andrew Y. Ng, Michael I. Jordan, e Stuart Russell. Distance metric learning, with application to clustering with side-information. Em *Advances in Neural Information Processing Systems 15 (NIPS 2002)*, 2002.
- [3] Kilian Q. Weinberger e Lawrence K. Saul. Distance metric learning for large margin nearest neighbor classification. *Journal of Machine Learning Research*, 10:207–244, 2009.
- [4] Michael Collins. Discriminative training methods for hidden markov models: Theory and experiments with perceptron algorithms. Em *Proceedings of EMNLP 2002*, páginas 1–8, 2002.
- [5] Maurício A. N. Coelho, Carlos C. H. Borges, e Raul Fonseca Neto. Uso de predição estruturada para o aprendizado de métrica. Em *XXXVIII Iberian Latin-American Congress on Computational Methods in Engineering (CILAMCE)*, Florianópolis, Brasil, 2017.
- [6] Charles L. Lawson e Richard J. Hanson. *Solving Least Squares Problems*. Prentice-Hall, Englewood Cliffs, NJ, 1974.
- [7] Arezou Keshavarz, Yang Wang, e Stephen Boyd. Imputing a convex objective function. Em *Proceedings of the 2011 IEEE International Symposium on Intelligent Control (ISIC)*, páginas 613–619, Denver, CO, 2011.
- [8] Ravindra K. Ahuja e James B. Orlin. Inverse optimization. *Operations Research*, 49(5):771–783, 2001.
- [9] Matthew Schultz e Thorsten Joachims. Learning a distance metric from relative comparisons. Em *Advances in Neural Information Processing Systems 16 (NIPS 2003)*, 2003.
- [10] Shivam Garg, Dimitris Tsipras, Percy Liang, e Gregory Valiant. What can transformers learn in-context? a case study of simple function classes. Em *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022.

- [11] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, e Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. Em *ICLR 2023 (Oral)*, 2023.
- [12] Sang Michael Xie, Aditi Raghunathan, Percy Liang, e Tengyu Ma. An explanation of in-context learning as implicit Bayesian inference. Em *International Conference on Learning Representations (ICLR 2022)*, 2022.
- [13] Hongjin Su, Jungo Kasai, Chen Henry Wu, Weijia Shi, Tianlu Wang, Jiayi Xin, Rui Zhang, Mari Ostendorf, Luke Zettlemoyer, Noah A. Smith, e Tao Yu. Selective annotation makes language models better few-shot learners. Em *ICLR 2023*, 2023.
- [14] Zihao Zhao, Eric Wallace, Shi Feng, Dan Klein, e Sameer Singh. Calibrate before use: Improving few-shot performance of language models. Em *Proceedings of ICML 2021*, volume 139 of *PMLR*, páginas 12697–12706, 2021.
- [15] Yasaman Razeghi, Robert L. Logan IV, Matt Gardner, e Sameer Singh. Impact of pretraining term frequencies on few-shot numerical reasoning. Em *Findings of the Association for Computational Linguistics: EMNLP 2022*, páginas 840–854, Abu Dhabi, 2022.
- [16] Sewon Min, Xinxu Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, e Luke Zettlemoyer. Rethinking the role of demonstrations: What makes in-context learning work? Em *Proceedings of EMNLP 2022*, páginas 11048–11064, 2022.
- [17] Siyan Zhao, Tung Nguyen, e Aditya Grover. Probing the decision boundaries of in-context learning in large language models. Em *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*, 2024.
- [18] Nelson Elhage, Neel Nanda, Catherine Olsson, Tom Henighan, Nicholas Joseph, Ben Mann, et al. A mathematical framework for transformer circuits. *Transformer Circuits Thread*, Anthropic, 2021.
- [19] Nelson Elhage, Tristan Hume, Catherine Olsson, Nicholas Schiefer, Tom Henighan, et al. Toy models of superposition. *Transformer Circuits Thread*, Anthropic, 2022.
- [20] Trenton Bricken, Adly Templeton, Joshua Batson, Brian Chen, Adam Jermyn, et al. Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*, Anthropic, 2023.
- [21] Samuel Marks e Max Tegmark. The geometry of truth: Emergent linear structure in large language model representations of true/false datasets. Em *Conference on Language Modeling (COLM 2024)*, 2024.

- [22] Ron Artstein e Massimo Poesio. Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4):555–596, 2008.
- [23] J. Richard Landis e Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977.
- [24] Dzmitry Bahdanau, Kyunghyun Cho, e Yoshua Bengio. Neural machine translation by jointly learning to align and translate. Em *International Conference on Learning Representations (ICLR 2015)*, 2015.
- [25] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, e Illia Polosukhin. Attention is all you need. Em *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017.
- [26] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, et al. Language models are few-shot learners. Em *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020.
- [27] Parshin Shojaee, Iman Mirzadeh, Keivan Alizadeh, Maxwell Horton, Samy Bengio, e Mehrdad Farajtabar. The illusion of thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity. Relatório técnico, Apple Machine Learning Research, 2025.
- [28] Berk Atil, Alexa Chittams, Lisheng Fu, Ferhan Ture, Lixinyu Xu, e Breck Baldwin. LLM stability: A detailed analysis with some surprises. Preprint arXiv:2408.04667, 2024.
- [29] Paul Windisch, Carole Koechli, Fabio Dennstädt, Daniel M. Aebersold, Daniel R. Zwahlen, Robert Förster, e Christina Schröder. Is one run enough? reproducibility of flagship large language models across temperature and reasoning settings in biomedical text processing. Preprint medRxiv, 2026.