

Explicando Decisões de Modelos de Linguagem de Grande Escala via Otimização Inversa

Relatório de Pesquisa de Mestrado

George Silva

Programa de Pós-Graduação em Ciência da Computação

Julho de 2026

Resumo

Modelos de Linguagem de Grande Escala (LLMs) exibem consistência surpreendente em tarefas de classificação, mas seus critérios decisórios implícitos permanecem opacos. Este trabalho investiga se é possível *estimar* uma métrica matemática explícita que reproduza o critério decisório de um LLM a partir de suas classificações observadas. A abordagem é a *otimização inversa*: dado um conjunto de classificações realizadas por um LLM em problemas de classificação binária bidimensional, infere-se uma métrica de Mahalanobis diagonal $\hat{W}$ por meio de *dois* estimadores independentes — um Perceptron Estruturado com Relaxação de Margem e Mínimos Quadrados Não-Negativos (NNLS) — cuja concordância direcional serve de controle de robustez. O trabalho organiza-se em três blocos: (i) o LLM como *fonte* de decisões (Problemas A–D), avaliando a fidelidade de $\hat{W}$, sua transferência entre geometrias, um teste-oráculo de sanidade e o efeito de vieses semânticos e de *prompt*; (ii) o LLM como *aprendiz* via *in-context learning* (Problemas E–F), comparado a classificadores clássicos; e (iii) um estudo de caso *real* de peso $\times$ altura (Problema G). Com o modelo **gpt-4o-mini** a temperatura zero, três sementes e três repetições, os resultados mostram: (a) $\hat{W}$ reproduz o LLM com fidelidade de 76,7–85,3% (Perceptron/NNLS concordam com cosseno 0,993); (b) o teste-oráculo recupera métricas sintéticas conhecidas com fidelidade de 95–100%, validando os estimadores; (c) a transferência é heterogênea (κ de 0,30 a 0,73 em zero-shot, subindo a 0,84–0,89 com poucos exemplos); (d) a direção de $\hat{W}$ é estável entre sementes (cosseno 0,990), mas sua magnitude não (coeficiente de variação de 58%); (e) o critério é fortemente sensível à semântica de rótulos e *features*; (f) como aprendiz, o LLM é praticamente “cego” em zero-shot (54,9% na média sobre três peritos; 42,9% no caso real) e aprende com poucos exemplos, mas *não supera* baselines triviais (Regressão Logística atinge 100%); e (g) a hipótese de que exemplos difíceis ensinam melhor é **refutada** — exemplos fáceis dominam com poucos exemplos.

Palavras-chave: Otimização Inversa, Modelos de Linguagem de Grande Escala, *Metric Learning*, Perceptron Estruturado, NNLS, In-Context Learning, Viés Semântico, Explicabilidade.

Índice

1	Introdução	3
2	Fundamentação Teórica	5
2.1	Otimização Inversa	5
2.2	Métrica de Mahalanobis Diagonal	5
2.3	Estimadores da Métrica Inversa	6
2.4	Projeções Não-Lineares (R3 e R4)	7

2.5	In-Context Learning em LLMs	7
2.6	Viés Semântico em LLMs	7
2.7	Métricas de Avaliação	7
3	Trabalhos Relacionados	8
4	Metodologia	9
4.1	Nomenclatura: Blocos e Problemas	9
4.2	Protocolo Experimental	9
4.3	Bloco 1 — LLM como Fonte	10
4.4	Bloco 2 — LLM como Aprendiz	11
4.5	Bloco 3 — Estudo de Caso Real	11
4.6	Análise Estatística	12
5	Resultados	12
5.1	Bloco 1 — Estimção e Fidelidade (Problema A)	12
5.2	Bloco 1 — Teste-Oráculo de Sanidade	12
5.3	Bloco 1 — Transferência (Problemas B e C)	13
5.4	Bloco 1 — Não-Linearidade (R3/R4)	13
5.5	Bloco 1 — Viés Semântico e de Prompt	14
5.6	Bloco 2 — LLM como Aprendiz (Problemas E–F)	15
5.7	Bloco 2 — Diluição e Viés de Ordem dos Exemplos	17
5.8	Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)	17
5.9	Estabilidade de $\hat{W}$ (H5)	20
6	Análise e Discussão	20
6.1	H1 — Estabilidade do critério	20
6.2	H2 — Transferência de conhecimento	20
6.3	H3 — Viés semântico	20
6.4	H4 — Qualidade dos exemplos	21
6.5	H5 — Estabilidade estatística	22
6.6	O LLM diante de baselines triviais	22
7	Limitações	22
8	Trabalho Futuro	23
9	Conclusão	23

1 Introdução

Modelos de Linguagem de Grande Escala (LLMs) tornaram-se ferramentas onipresentes em tarefas cognitivas, da geração de texto à classificação de dados. Apesar do desempenho notável, os mecanismos que governam suas decisões permanecem largamente opacos, o que dificulta auditabilidade, detecção de vieses e previsão de comportamento em domínios novos — e avaliações recentes questionam até que ponto os “traços de raciocínio” desses modelos refletem processos genuínos de resolução de problemas [15].

Uma linha de pesquisa em ascensão investiga a capacidade de *in-context learning* (ICL) dos LLMs: aprender novas tarefas apenas a partir de exemplos no *prompt*, sem atualização de parâmetros — capacidade demonstrada em escala pelo GPT-3 [14] e estudada formalmente em [5,6]. Trabalhos recentes sugerem que o ICL pode implementar internamente algoritmos de otimização conhecidos, como gradiente descendente, codificados nas ativações do Transformer [6]. Isso levanta uma questão fundamental: *se o LLM implementa algum processo de otimização implícito, é possível recuperar explicitamente o critério dessa otimização?*

Este trabalho aborda a questão pelo *framework* de *otimização inversa* [1]: dados os resultados observados de um processo de otimização (as classificações do LLM), inferir o critério (função objetivo) que tornaria essas classificações ótimas. Especificamente, estima-se uma *métrica de Mahalanobis diagonal* $\hat{W}$ que, usada em classificação por vizinho mais próximo, reproduz as decisões do LLM. Adota-se a terminologia $\hat{W}$ *estimada/inferida* — e não “métrica aprendida” — para enfatizar que $\hat{W}$ é um *ajuste a posteriori* às decisões observadas, não um objeto treinado dentro do LLM.

O trabalho vai além da estimação isolada. Estrutura-se em três blocos auto-contidos:

Bloco 1 — LLM como fonte: o LLM rotula problemas sintéticos (Problemas A–D) e dele se estima $\hat{W}$. Avaliam-se fidelidade, transferência entre geometrias, um *teste-oráculo* de sanidade (os estimadores recuperam uma métrica conhecida?), o efeito de não-linearidade (projeções R3/R4) e de vieses semânticos e de *prompt*.

Bloco 2 — LLM como aprendiz: os papéis se invertem. Um especialista externo com métrica conhecida rotula os dados (Problemas E linear e F meia-lua) e o LLM deve reproduzir esse critério via ICL. Comparam-se estratégias de seleção de exemplos e baselines clássicos (k-NN, Regressão Logística, SVM).

Bloco 3 — Estudo de caso real: uma base real de peso $\times$ altura (Problema G, fronteira aproximadamente elíptica) submete todo o *pipeline* a dados não sintéticos.

Pergunta de Pesquisa

É possível estimar uma métrica matemática explícita e transferível a partir das classificações de um LLM, de modo que ela capture o critério decisório implícito do modelo e generalize para novos problemas de distribuição diferente?

Hipóteses

- H1 — Estabilidade do critério:** o LLM possui um critério decisório consistente, aproximável por uma métrica de Mahalanobis diagonal, com concordância mensurável ($\kappa > 0,4$) na transferência entre problemas.
- H2 — Transferência de conhecimento:** $\hat{W}$ estimada em um problema generaliza para problemas geometricamente distintos.
- H3 — Viés semântico:** os nomes atribuídos a classes e *features* influenciam sistematicamente o critério, alterando $\hat{W}$.
- H4 — Qualidade dos exemplos:** exemplos geometricamente *difíceis* (próximos à fronteira) transmitem o critério do especialista mais eficientemente que exemplos *fáceis*. (*Hipótese a priori, submetida a teste.*)
- H5 — Estabilidade estatística:** o comportamento é reprodutível entre execuções (múltiplas sementes e repetições).

Contribuições

1. Um *framework* experimental que estima a métrica de Mahalanobis diagonal de um LLM com *dois* algoritmos independentes (Perceptron Estruturado e NNLS) e mede sua concordância direcional, isolando robustez do método de estimação.
2. Um *teste-oráculo* de sanidade que verifica se os estimadores recuperam uma métrica sintética conhecida antes de qualquer alegação sobre o LLM.
3. Evidência quantitativa de que o critério do LLM é *direcionalmente estável mas de magnitude instável*, e fortemente modulado por viés semântico (classe e *feature*) e por variantes de *prompt*.
4. Uma avaliação honesta do LLM como aprendiz via ICL, incluindo a *refutação* da hipótese de que exemplos difíceis ensinam melhor e a comparação com baselines clássicos que o LLM não supera.

5. A extensão do *pipeline* a não-linearidade (projeções R3/R4) e a um estudo de caso *real* (peso $\times$ altura), reportando o número absoluto de erros dada a pequena escala amostral.

2 Fundamentação Teórica

2.1 Otimização Inversa

O problema de *otimização inversa* consiste em, dadas soluções observadas $x^* \in \mathbb{R}^d$ de um problema de otimização parametrizado por θ , inferir os parâmetros θ que tornariam x^* ótima (ou quase-ótima) [1]. Seja $\mathcal{P}(\theta) = \min_{x \in \mathcal{F}} c(x; \theta)$ o problema direto. A otimização inversa busca

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L} \left(x^*, \arg \min_{x \in \mathcal{F}} c(x; \theta) \right), \quad (1)$$

onde $\mathcal{L}$ mede o quão ótima x^* é sob θ . Aqui, as *decisões observadas* são as classificações do LLM e o parâmetro a inferir é a métrica W que governa a função de distância usada na classificação.

2.2 Métrica de Mahalanobis Diagonal

A distância de Mahalanobis generaliza a Euclidiana por uma matriz semidefinida positiva $M \in \mathbb{R}^{d \times d}$: $d_M(x, c) = \sqrt{(x - c)^\top M (x - c)}$. Adota-se a restrição diagonal $M = \text{diag}(w)$, $w \in \mathbb{R}_+^d$, reduzindo a $O(d)$ parâmetros e preservando a interpretabilidade dos pesos w_j como *importâncias de feature*:

$$d_W(x, c) = \sqrt{\sum_{j=1}^d w_j (x_j - c_j)^2}. \quad (2)$$

A classificação por vizinho mais próximo sob d_W atribui x à classe k^* cujo centroide c_{k^*} minimiza $d_W(x, c_{k^*})$.

Observação (invariância de escala). A regra sob d_W é *invariante a reescalamentos positivos* de w : para $\alpha > 0$, $d_{\alpha W}$ induz a mesma fronteira que d_W . Logo $\hat{W}$ é identificável apenas *a menos de escala*, e comparações entre métricas usam a *direção* de w (equivalentemente, a razão w_2/w_1), não os valores absolutos. Essa distinção é central para os resultados de estabilidade (Seção 5.9).

A simplificação diagonal é análoga à do LMNN [2], que aprende Mahalanobis com margem larga para classificação k -NN.

2.3 Estimadores da Métrica Inversa

Dois estimadores independentes inferem $\hat{W}$ a partir das mesmas decisões. A congruência entre eles é usada como controle: se ambos convergem para a mesma direção, o resultado não é artefato de um método particular.

(i) Perceptron Estruturado com Relaxação de Margem. O Perceptron Estruturado [3] generaliza o perceptron clássico para espaços de saída estruturados, atualizando os pesos quando a predição diverge do alvo. A variante usada incorpora um fator de escala $f \in [0, 1]$ que suaviza a atualização e é ajustado por busca binária para satisfazer uma relaxação de margem γ (Algoritmo 1).

Algoritmo 1: Perceptron Estruturado com Relaxação de Margem (variante diagonal)

Input: Dados $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$ com $y^{(i)} \in \{0, 1\}$, centroides μ_0, μ_1 , parâmetros η, γ, T
Output: Vetor de pesos $w \in \mathbb{R}_+^2$

```

1 Inicializar  $w \leftarrow [1, 1]$ 
2 for  $t = 1, \dots, T$  do
3   for  $i = 1, \dots, N$  do
4      $\hat{y}^{(i)} \leftarrow \arg \min_{k \in \{0, 1\}} d_W(x^{(i)}, \mu_k)$ 
5     if  $\hat{y}^{(i)} \neq y^{(i)}$  then
6        $g_j \leftarrow (x_j^{(i)} - \mu_{y,j})^2 - (x_j^{(i)} - \mu_{\hat{y},j})^2$ 
7        $f \leftarrow$  busca binária em  $[0, 1]$  satisfazendo a relaxação de margem  $\gamma$ 
8        $w \leftarrow \max(0, w - \eta \cdot f \cdot g)$ 
9     end
10  end
11 end
12 return  $w$ 
```

(ii) Mínimos Quadrados Não-Negativos (NNLS). O segundo estimador formula a recuperação de w como um problema de mínimos quadrados com restrição de não-negatividade,

$$\hat{W}_{\text{NNLS}} = \arg \min_{w \geq 0} \|Aw - b\|_2^2, \quad (3)$$

onde cada linha de A codifica a diferença de distâncias quadráticas do ponto aos dois centroides e b codifica a decisão do LLM. Resolve-se (3) pelo algoritmo clássico de Lawson e Hanson [4] (implementação `scipy.optimize.nnls`). Ao contrário do Perceptron, o NNLS *não possui hiperparâmetros*, o que o torna um controle valioso: concordância entre os dois sugere que $\hat{W}$ não depende de ajuste fino. Um terceiro estimador (LP Max-Margin) foi avaliado e *descartado* por não respeitar a restrição de convexidade; dois estimadores congruentes bastam para demonstrar robustez.

2.4 Projeções Não-Lineares (R3 e R4)

A métrica diagonal sobre as *features* originais só induz fronteiras lineares. Para sondar se o LLM captura interações, aumenta-se o espaço de *features* sem sair do formalismo linear: a *projeção R3* acrescenta $x_3 = x_1x_2$ (termo de interação, fronteira hiperbólica) e a *projeção R4* acrescenta ainda x_1^2 e x_2^2 (fronteira elíptica — o classificador ótimo do caso peso $\times$ altura). Comparando a fidelidade com 2, 3 e 4 *features*, avalia-se se a expressividade adicional aproxima $\hat{W}$ do LLM em problemas não-lineares.

2.5 In-Context Learning em LLMs

In-context learning (ICL) é a capacidade de realizar novas tarefas fornecendo apenas exemplos $(x_1, y_1), \dots, (x_k, y_k)$ no *prompt*, sem atualizar parâmetros. O fenômeno foi formalizado e demonstrado em escala por Brown et al. [14] com o GPT-3, sobre a arquitetura Transformer [13], cujo mecanismo de atenção descende do alinhamento suave introduzido por Bahdanau et al. [12] para tradução automática. Garg et al. [5] mostraram que Transformers treinados do zero realizam ICL de classes de funções, igualando estimadores ótimos. Akyürek et al. [6] provaram por construção que Transformers podem implementar internamente gradiente descendente e regressão ridge. Essas descobertas justificam a premissa central: se o LLM implementa otimização interna, é possível recuperar seu critério via otimização inversa.

2.6 Viés Semântico em LLMs

LLMs exibem vieses sistemáticos dependentes dos nomes de classe [8]. Rótulos com conotação semântica tendem a distorcer as distribuições previstas, independentemente do conteúdo do exemplo. Zhao et al. identificam três fontes: preferência por rótulos majoritários, recência e frequência de *tokens* no pré-treinamento. Este trabalho testa sistematicamente o efeito de nomes de classe (neutros, semânticos, cromáticos) e de *features* sobre $\hat{W}$.

2.7 Métricas de Avaliação

Fidelidade (vs. LLM). A *fidelidade* é a fração de pontos em que a classificação por vizinho mais próximo sob $\hat{W}$ concorda com o LLM: $\text{Fid} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\hat{y}_{\hat{W}}(x^{(i)}) = \hat{y}_{\text{LLM}}(x^{(i)})]$. Mede o quanto a métrica *reproduz o LLM*, e não sua correção. Distingue-se de *acurácia vs. ground truth*, que mede concordância com o rótulo verdadeiro do problema.

Consistência (transferência). Idem à fidelidade, com $\hat{y}_{\hat{W}}$ calculado com os centroides do problema de destino (Problemas B, C). Trata-se de um controle metodológico

deliberado: apenas o vetor w é transferido do Problema A, e os centroides são recalculados localmente a partir dos rótulos que o LLM atribui no problema de destino. Isso isola o efeito da métrica (os pesos) do efeito da geometria (a posição dos centroides), evitando que uma eventual queda de consistência em B/C seja mero artefato de centroides deslocados entre distribuições.

Cohen’s κ [11]. Corrige a concordância pelo acaso:

$$\kappa = \frac{P_o - P_e}{1 - P_e}, \quad (4)$$

onde P_o é a proporção de concordância observada e P_e a esperada ao acaso ($P_e = \sum_k \hat{p}_k \tilde{p}_k$, produto das marginais dos dois “anotadores”). O LLM e a métrica $\hat{W}$ são os dois anotadores fixos. Interpretação: $\kappa < 0,2$ (fraca), $0,2-0,4$ (razoável), $0,4-0,6$ (moderada), $0,6-0,8$ (substancial), $> 0,8$ (quase perfeita). Valores negativos indicam concordância *pior que o acaso*.

F1-score macro. Para cada classe k , com precisão $P_k = \frac{VP_k}{VP_k + FP_k}$ e revocação $R_k = \frac{VP_k}{VP_k + FN_k}$, define-se $F1_k = \frac{2P_k R_k}{P_k + R_k}$ (média harmônica de precisão e revocação). O F1 *macro* é a média aritmética simples $\frac{1}{K} \sum_{k=1}^K F1_k$, tratando as classes com igual peso — apropriado para detectar degradação em uma classe minoritária.

3 Trabalhos Relacionados

Esta pesquisa situa-se na interseção de cinco áreas.

Otimização Inversa. Chan et al. [1] apresentam o survey definitivo da área, unificando formulações baseadas em KKT, dualidade forte e modelos *data-driven*. Inferir $\hat{W}$ a partir das classificações do LLM é uma instância direta: dadas as soluções observadas, busca-se o parâmetro que as tornaria ótimas sob vizinho mais próximo. Diferimos ao aplicar o *framework* a um “otimizador” que não é um solver, mas um LLM, e ao validar a recuperação com um teste-oráculo.

Metric Learning. Weinberger e Saul [2] introduziram o LMNN, que aprende Mahalanobis via otimização convexa com margem. Nosso Perceptron com relaxação de margem é conceitualmente análogo, com a restrição diagonal proposital. Diferimos ao usar a métrica não para classificar melhor, mas para *explicar* um classificador externo (o LLM).

Predição Estruturada. Collins [3] introduziu o Perceptron Estruturado, ancestral direto do estimador (i). A regra $w \leftarrow w - \eta fg$ é uma instância da regra de Collins adaptada para *metric learning* bidimensional.

In-Context Learning. Garg et al. [5] e Akyürek et al. [6] estabelecem o LLM como aprendiz implícito de funções. Min et al. [9] questionam o papel dos mapeamentos *input-label*, mostrando que a estrutura das demonstrações importa mais que a correção dos rótulos — achado com implicações diretas para o Bloco 2 e para a refutação de H4. Su et al. [7] mostram que a seleção estratégica de exemplos, com equilíbrio entre diversidade e representatividade, supera a aleatória. Investigamos uma dimensão diferente: o eixo *fácil vs. difícil* pela margem à fronteira.

Fronteiras de Decisão de LLMs. Zhao et al. [10] investigaram a geometria das fronteiras de decisão de LLMs em classificação binária 2D, achando irregularidades significativas. Seu *setup* é diretamente comparável ao nosso, validando o uso de dados sintéticos bidimensionais. Artstein e Poesio [11] sistematizam os coeficientes de concordância, justificando Cohen’s κ quando LLM e $\hat{W}$ são tratados como dois anotadores fixos.

4 Metodologia

4.1 Nomenclatura: Blocos e Problemas

Para evitar ambiguidade entre o *papel* do LLM e a *configuração de dados*, fixa-se: *Blocos* 1–3 designam os três estudos; *Problemas* A–G designam as configurações de dados (Tabela 1).

4.2 Protocolo Experimental

O modelo é o `gpt-4o-mini` (OpenAI) com temperatura $T = 0,0$, minimizando estocasticidade para isolar o critério. Ressalva-se que $T = 0$ *não garante* determinismo estrito (roteamento, *batching* e não-associatividade de ponto flutuante introduzem variação); o desenho usa múltiplas sementes e repetições justamente para medir essa variância. As chamadas são assíncronas com concorrência limitada. As respostas passam por um *parser de 8 camadas* (0–7) que trata variações de formato; respostas irrecuperáveis após reenvios recebem rótulo por *hash* MD5 determinístico das coordenadas (evitando viés geométrico). Nesta execução *não houve* acionamento do *fallback*: as métricas de κ /consistência não contêm rótulos pseudo-aleatórios.

A auditoria *offline* das 119 713 interações registradas quantificou também o não-determinismo residual: 4,75% das 29 116 consultas repetidas (1 384) receberam res-

Tabela 1: Problemas de classificação binária 2D e seu papel nos blocos.

Prob.	Bloco	Descrição
A	1	Linear, centroides Gaussianos; base da estimação zero-shot (150 pontos).
B	1	Linear, centroides rotacionados no sentido horário ($\pm 1,5$); transferência.
C	1	Linear, rotação anti-horária ($\pm 1,5$); transferência com orientação oposta.
D	1	Meia-lua não-linear (make_moons); teste de não-linearidade.
E	2	Linear, rotulado por especialista com $W_{\text{exp}} = [0,3; 1,5]$; ICL.
F	2	Meia-lua, especialista = <i>ground truth</i> ; ICL não-linear.
G	3	Real: peso $\times$ altura (≈ 70 amostras, fronteira elíptica).

postas divergentes entre repetições a $T = 0$. Esse valor constitui o *piso de ruído de medição* do protocolo: nenhuma métrica de concordância com o LLM (fidelidade, consistência, κ) pode exceder $\approx 95\%$, e os resultados devem ser interpretados contra esse teto. As decisões foram coletadas em 30/06–01/07/2026 pelo *alias* gpt-4o-mini, que resolve para o *snapshot* vigente do provedor na data da chamada (ver Limitações).

Variáveis de controle:

- **Sementes:** $s \in \{42, 123, 7\}$ (robustez estatística).
- **Repetições:** $R = 3$ por configuração.
- **Nomes de classe:** neutros (A/B, 0/1), semânticos (Positivo/Negativo), cromáticos (Azul/Vermelho) e suas inversões (ordem/posição).
- **Nomes de *feature*:** x_1/x_2 (neutro), altura/peso (semântico), feature_1/feature_2 (técnico).
- **Variantes de *prompt*:** *default*, *geometric*, *cot* (*chain-of-thought*), *tabular*.
- **Tamanhos few-shot:** $n \in \{0, 5, 10\}$ (transferência) e $n \in \{0, 5, 10, 20, 40\}$ (ICL).

4.3 Bloco 1 — LLM como Fonte

O LLM classifica os pontos do Problema A em *zero-shot*; dessas decisões estimam-se $\hat{W}$ pelo Perceptron e pelo NNLS simultaneamente (Seção 2). A fidelidade de cada estimador e a similaridade de cosseno entre os dois $\hat{W}$ são registradas. As métricas estimadas são então transferidas aos Problemas B e C, medindo-se consistência, κ e

F1 em função de n . A projeção R3/R4 é aplicada aos Problemas A–D para sondar não-linearidade, e os testes de viés (nomes de classe, nomes de *feature*) e de variantes de *prompt* rodam sobre a mesma estrutura.

Teste-oráculo (sanidade). Antes de qualquer alegação sobre o LLM, geram-se dados sintéticos rotulados por uma métrica *conhecida* $W_{\text{oráculo}}$ e verifica-se se os estimadores a recuperam. Se falharem quando o oráculo realmente existe, qualquer achado sobre o LLM fica comprometido. Testam-se configurações euclidiana ($[1,0; 1,0]$) e anisotrópicas ($[0,3; 1,5]$, $[1,5; 0,3]$), além de transferência entre geometrias.

4.4 Bloco 2 — LLM como Aprendiz

Os papéis se invertem: um especialista externo com métrica conhecida $W_{\text{exp}} = [0,3; 1,5]$ (o atributo x_2 é $5\times$ mais relevante) rotula o Problema E; para o Problema F (meia-lua), o especialista é o próprio *ground truth*. Seleciona-se um subconjunto de n pontos como exemplos e avalia-se se o LLM reproduz o critério do especialista nos demais. Quatro estratégias de seleção:

Easy: n pontos de maior margem (longe da fronteira);

Hard: n pontos de menor margem (próximos à fronteira);

Mixed: $\lfloor n/2 \rfloor$ easy + $\lceil n/2 \rceil$ hard;

Random: n pontos aleatórios (baseline).

Como referência, treinam-se *baselines clássicos* (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot, respondendo: “o LLM faz algo que um classificador trivial não faria?”. Testam-se ainda múltiplas configurações de especialista, o experimento de diluição e o viés de ordem dos exemplos.

4.5 Bloco 3 — Estudo de Caso Real

Uma base real de peso $\times$ altura (rótulo homem/mulher, fronteira aproximadamente elíptica, ≈ 70 amostras) submete o *pipeline* a dados não sintéticos. Roda-se a estimação com 2/3/4 *features* (R2/R3/R4), sob variantes de *prompt* com nomes neutros (x_1/x_2) e semânticos (peso/altura), identifica-se a melhor métrica e executa-se o ICL. Os exemplos *few-shot* do ICL são selecionados *aleatoriamente* (estratégia *random*) entre os pontos de treino, com 3 repetições por configuração usando sorteios independentes, e são sempre excluídos do conjunto de avaliação (sem *leakage*). Testa-se ainda a variante de *nomes de classe* neutros — perguntando “A ou B” em vez de “homem ou mulher” — para isolar o prior semântico dos nomes de classe, complementando a variante de

features neutras. Dada a pequena escala, reporta-se o *número absoluto de erros* além das porcentagens.

4.6 Análise Estatística

Reportam-se intervalos de confiança de 95% via *bootstrap* (10^4 reamostragens), testes de Wilcoxon pareados e o tamanho de efeito de Cohen (d) para as comparações principais. A estabilidade de $\hat{W}$ entre sementes é medida pela similaridade de cosseno e pelo coeficiente de variação (CV) da razão w_2/w_1 .

5 Resultados

Todos os números provêm da execução 2026-06-30_23-46-58 (GPT-4o-mini, $T = 0$, sementes $\{42, 123, 7\}$, $R = 3$).

5.1 Bloco 1 — Estimação e Fidelidade (Problema A)

A Tabela 2 apresenta a fidelidade dos dois estimadores no Problema A. Os valores são *modestos* — o log da execução registra explicitamente “fidelidade baixa em ambos”, um sinal honesto de que a métrica diagonal captura o LLM apenas parcialmente. O NNLS supera levemente o Perceptron, e ambos concordam em direção (cosseno médio 0,993; ver Seção 5.9).

Tabela 2: Fidelidade da estimação no Problema A, por semente (classes A/B, zero-shot).

Semente	Fid. Perceptron (%)	Fid. NNLS (%)
42	76,7	82,0
123	85,3	85,3
7	82,0	80,0
Média	81,3	82,4

5.2 Bloco 1 — Teste-Oráculo de Sanidade

Antes de interpretar a fidelidade modesta como propriedade do LLM, verifica-se que os estimadores *funcionam quando o oráculo existe*. A Tabela 3 confirma: sobre dados rotulados por métricas conhecidas, a fidelidade é de 95–100% e a direção recuperada tem cosseno até 0,9999. Portanto, a fidelidade modesta no LLM (Tabela 2) reflete o *LLM*, não uma deficiência dos estimadores.




Figura 1: Bloco 1: comparação Perceptron $\times$ NNLS — fidelidade no Problema A, consistência nas Fases B/C e dispersão das direções de $\hat{W}$ estimadas. Os dois estimadores produzem métricas quase colineares (cosseno 0,993).

5.3 Bloco 1 — Transferência (Problemas B e C)

A Tabela 4 apresenta consistência e κ (com IC *bootstrap* de 95%) nas transferências, em zero-shot e com 5 exemplos. O padrão é claro e *assimétrico*: o Problema B é difícil em zero-shot ($\kappa = 0,30$, “razoável”), enquanto o Problema C já nasce alto ($\kappa = 0,73$, “substancial”). Poucos exemplos elevam ambos a $\kappa \approx 0,84$ – $0,89$. O salto zero $\rightarrow$ few-shot tem tamanho de efeito *grande* (Cohen’s $d = 6,44$ para a consistência em B; $d = 5,36$ em C).

Métrica estimada vs. euclidiana. A métrica estimada *não* supera significativamente a euclidiana no Problema B em zero-shot ($\Delta = +0,044$; $IC_{95} = [-0,102; +0,237]$, inclui zero). Ou seja, em zero-shot a deformação aprendida agrega pouco sobre a distância trivial — a vantagem de $\hat{W}$ manifesta-se sobretudo com exemplos.

5.4 Bloco 1 — Não-Linearidade (R3/R4)

Aumentar o espaço para 3 ou 4 *features* produz ganhos *marginais* de fidelidade nos problemas lineares A/B/C (Tabela 5), coerente com o fato de fronteiras lineares não requererem termos de interação: a média sobe de 81,6% (R3) para 83,6% (R4), dentro da faixa da estimação em 2 *features*. No caso *não-linear* peso $\times$ altura, ao contrário,

Tabela 3: Teste-oráculo: recuperação de W conhecido. “cos” é o cosseno entre o W recuperado e o verdadeiro.

Config.	W verd.	Perceptron		NNLS	
		Fid. (%)	cos	Fid. (%)	cos
Prob. A (euclid.)	[1,0; 1,0]	98,0	0,709	98,0	0,707
Prob. B (euclid.)	[1,0; 1,0]	98,0	0,9999	98,0	0,971
Expert aniso. x_2	[0,3; 1,5]	100,0	0,9999	95,3	0,993
Expert aniso. x_1	[1,5; 0,3]	100,0	0,998	99,3	0,989

Tabela 4: Transferência: consistência e κ (Perceptron), IC *bootstrap* 95%.

Problema	n -shot	Consistência [IC ₉₅]	κ [IC ₉₅]
B	0	0,679 [0,652; 0,707]	0,297 [0,239; 0,359]
B	5	0,921 [0,895; 0,948]	0,841 [0,786; 0,895]
C	0	0,871 [0,849; 0,890]	0,729 [0,685; 0,771]
C	5	0,947 [0,939; 0,955]	0,893 [0,877; 0,910]

a projeção R4 (que introduz a fronteira elíptica correta) eleva a fidelidade do NNLS de $\approx 70\%$ para até $81,4\%$ — evidência de que a expressividade adicional só ajuda quando o problema efetivamente exige não-linearidade. O teste-oráculo na meia-lua confirma que os estimadores recuperam a métrica anisotrópica mesmo em geometria curva (Perceptron 100%; NNLS 95,3%).

Tabela 5: Fidelidade média (Perceptron) ao aumentar *features* nos problemas lineares A/B/C, por semente.

n -features	Seed 42	Seed 123	Seed 7	Média
3 (R3, $+x_1x_2$)	80,0	83,3	81,3	81,6
4 (R4, $+x_1^2, x_2^2$)	78,0	83,3	89,3	83,6

Valores em %. Fonte: `final_cross_linearity.csv`.

5.5 Bloco 1 — Viés Semântico e de Prompt

A Tabela 6 mostra que *o critério do LLM muda com a rotulagem*. Nomes com conotação (Positivo/Negativo) elevam a fidelidade a $98,7\%$, ao passo que a mera inversão de posição (B/A) a reduz a $68,0\%$ — evidência de viés de *ordem*. Nomes de *feature* também importam: “altura/peso” rende $84,0\%$ contra $76,7\%$ de x_1/x_2 . Já a variante *tabular* de *prompt degrada* a medição a $56,7\%$, alertando que a forma de apresentação das coordenadas confunde o modelo.




Figura 2: Teste-oráculo: recuperação de W conhecido. Sobre dados rotulados por uma métrica sintética, os estimadores atingem fidelidade de 95–100%, confirmando que a fidelidade modesta observada no LLM reflete o modelo, não uma falha do método.

5.6 Bloco 2 — LLM como Aprendiz (Problemas E–F)

Cegueira em zero-shot. Sem exemplos, o LLM é praticamente incapaz de reproduzir o critério do especialista: a acurácia média, sobre os três peritos, é de $54,9\% \pm 5,8\%$ — pouco acima do acaso. A Tabela 7 mostra a curva de aprendizado por estratégia (especialista aniso. x_2).

H4 refutada. A hipótese *a priori* de que exemplos difíceis ensinam melhor é **refutada**. Na média sobre $n > 0$, a ordem é *Random* (90,5%) > *Mixed* (87,9%) > *Easy* (81,2%) > *Hard* (75,4%): a estratégia *hard* é a *pior*. A vantagem de *easy* sobre *hard* é estatisticamente significativa com poucos exemplos e desaparece com muitos: $\Delta_{5\text{-shot}} = +0,223$ ($IC_{95} = [+0,103; +0,336]$), $\Delta_{10\text{-shot}} = +0,197$ ($IC_{95} = [+0,105; +0,288]$), $\Delta_{20\text{-shot}} = +0,056$ ($IC_{95} = [-0,156; +0,192]$, não significativo). A interpretação, coerente com Min et al. [9]: com poucos exemplos o LLM precisa de *âncoras prototípicas* (alta margem); com muitos, a informação sobre a geometria da fronteira (exemplos difíceis) supera o ruído — daí *hard* atingir 97,8% em 40-shot.

O LLM não supera baselines triviais. A Tabela 8 compara o LLM a classificadores clássicos treinados nos mesmos 40 exemplos. A Regressão Logística — linear, como o problema — atinge *concordância perfeita* (100%, $\kappa = 1,0$), superando o LLM

Tabela 6: Efeito de rotulagem e *prompt* sobre a fidelidade (seed 42; classe: 10-shot; *feature/prompt*: zero-shot).

Nome de classe	Fid. (%)	Nome de feature	Fid. (%)	Prompt	Fid. (%)
Positivo/Negativo	98,7	altura/peso	84,0	<i>geometric</i>	81,3
Negativo/Positivo	93,3	x_1/x_2	76,7	<i>cot</i>	78,7
Azul/Vermelho	88,0	feature_1/2	76,0	<i>default</i>	76,7
A/B	76,7			<i>tabular</i>	56,7
1/0	79,3				
B/A	68,0				




Figura 3: Bloco 1: efeito das variantes de *prompt* sobre a direção de $\hat{W}$ e a fidelidade. A variante *tabular* desloca a medição, alertando que a forma de apresentar as coordenadas interfere no critério inferido.

(95,6%). O achado é importante e honesto: no regime linear, o LLM *não faz nada que um classificador trivial não faça*. O valor do LLM está na *flexibilidade* (não requer treino nem especificação de modelo), não na acurácia.

Problema F: colapso em classe única. No regime não-linear (meia-lua), o experimento “LLM como aprendiz” *não pôde ser coletado* nesta execução: em zero-shot, o LLM atribuiu uma única classe a todos os 105 pontos de treino nas três sementes, e sem duas classes o *pipeline* few-shot é abortado. O colapso é um achado em si — evidencia a fragilidade do zero-shot em geometria não-linear — e a Figura 6 o visualiza por contraste com um SVM gaussiano (RBF): treinado no *ground truth*, o SVM desenha a fronteira não-linear de referência; sobre os rótulos do LLM, não há fronteira alguma a ajustar. Em substituição, um teste-oráculo ajusta a métrica diagonal ao rótulo verdadeiro da meia-lua: a fidelidade satura em $\approx 86,7\%$ (20/150 erros) e as projeções R3/R4 *não* ajudam — o limite é estrutural (a curvatura em “S” exigiria termo fora da diagonal), não de dados. O teste do LLM como aprendiz em regime não-linear genuíno migra, portanto, para o caso real do Bloco 3.

Tabela 7: Bloco 2: acurácia LLM $\times$ especialista por estratégia e n -shot (aniso. x_2). Melhor por linha em **negrito**.

n -shot	Easy	Hard	Mixed	Random
0	60,9	60,9	60,9	60,9
5	84,9	62,6	81,4	85,2
10	87,1	67,5	79,8	88,3
20	89,8	84,2	87,4	92,1
40	88,3	97,8	96,9	94,1




Figura 4: Bloco 2: curva de aprendizado por estratégia de seleção de exemplos. *Easy* e *Random* dominam com poucos exemplos; *Hard* só alcança as demais em alto volume (40-shot).

5.7 Bloco 2 — Diluição e Viés de Ordem dos Exemplos

Diluição não dilui. Fixando 4 exemplos *hard* e acrescentando exemplos *easy* progressivamente, a acurácia *cresce monotonicamente* — de 62,2% (apenas os 4 *hard*) a 84,4% (4 *hard* + 20 *easy*), estabilizando em torno de 84% (Figura 7). Não se observa o efeito hipotético de “diluição” em que exemplos fáceis prejudicariam: ao contrário, cada bloco de fáceis *ajuda*, reforçando a leitura de H4 de que âncoras prototípicas transmitem o critério.

Viés de ordem é modesto. Reordenar os mesmos exemplos (*class0_first*, *class1_first*, *shuffled*, *alternating*) altera pouco o resultado: a dispersão entre ordenações é de apenas 2,3–7,5 pontos percentuais, sem uma ordenação consistentemente vencedora (*alternating* é marginalmente melhor). O critério do LLM, neste *setup*, é relativamente robusto à ordem das demonstrações — em contraste com a forte sensibilidade a *quais* exemplos são escolhidos (Tabela 7).

5.8 Bloco 3 — Estudo de Caso Real (Peso $\times$ Altura)

O caso real expõe a *dependência semântica* de forma dramática (Tabela 9). Com nomes *semânticos* (peso/altura), a estimação atinge fidelidade de 71–73% e a acurácia real do LLM chega a 91,4% — apenas **6 erros em ≈ 70 amostras**. Com nomes *neutros*

Tabela 8: Bloco 2: LLM vs. baselines clássicos (40-shot).

Especialista	LLM (hard)	k-NN	Reg. Log.	SVM-RBF
aniso. x_2	95,6% ($\kappa 0,945$)	98,2% ($\kappa 0,964$)	100% ($\kappa 1,0$)	90,9% ($\kappa 0,872$)
aniso. x_1	$\approx 95,6\%$	100% ($\kappa 1,0$)	100% ($\kappa 1,0$)	97,3% ($\kappa 0,944$)




Figura 5: Bloco 2: LLM *in-context* vs. baselines clássicos (k-NN, Regressão Logística, SVM-RBF) nos mesmos exemplos few-shot. No regime linear, a Regressão Logística iguala ou supera o LLM.

(x_1/x_2), tudo desaba: a acurácia real do LLM cai a 42,9% (*abaixo* do acaso da classe majoritária, 57,1%; **33 erros**). O contexto semântico das *features* é, no caso real, determinante.

Tabela 9: Bloco 3: estimação no Problema G (seed 42). “err.” = erros absolutos da métrica; “acc. real” = acurácia do LLM vs. rótulo verdadeiro.

Nomes	n -feat	Fid. (%)	acc. real LLM (%)	err. (Perc.)
peso/altura	2	71,4	68,6	6
peso/altura	3	71,4	68,6	6
peso/altura	4	72,9	68,6	7
x_1/x_2	2	55,7	42,9	33
x_1/x_2	3	65,7	42,9	50
x_1/x_2	4	74,3	42,9	44

Nomes de classe A/B: o mapeamento é arbitrário. Repetindo a classificação com nomes de classe *neutros* (“A ou B” em vez de “homem ou mulher”), a acurácia da métrica estimada (Perceptron) vs. rótulo real, na média das 3 sementes, despenca de 0,914 para 0,129 ($\approx 61/70$ erros) com *features* semânticas (Tabela 10). O valor, muito *abaixo* do acaso, não é ruído: é *inversão sistemática de convenção* — o LLM continua separando os dois grupos (invertendo-se os rótulos, $\approx 0,87$), mas, sem âncora semântica nos nomes, o mapeamento rótulo $\leftrightarrow$ classe é arbitrário e emergiu na convenção oposta à do *ground truth*. O prior semântico atua, portanto, também nos *nomes de classe*, não apenas nas *features*. No ICL, o LLM adota a convenção dos exemplos que recebe: a




Figura 6: Problema F (meia-lua, seed 42): superfície de separação do SVM RBF treinado no *ground truth* (esq.) vs. rótulos zero-shot do LLM (dir.) — classe única, sem fronteira. Mesmo colapso nas sementes 123 e 7.




Figura 7: Esquerda: experimento de diluição — acrescentar exemplos fáceis a 4 difíceis fixos melhora a acurácia monotonicamente. Direita: viés de ordem — as quatro ordenações diferem por poucos pontos percentuais.

concordância com a métrica-alvo sobe de 0,744 (zero-shot) a 0,957 (40-shot), enquanto a acurácia vs. real permanece $\approx 0,15$ (a métrica-alvo herdou a convenção invertida) — e o Perceptron *baseline* treinado nos mesmos exemplos acompanha (0,11–0,19), indicando consistência entre aprendizes, não defeito do LLM.

Tabela 10: Bloco 3: efeito dos nomes de classe (A/B vs. homem/mulher) na acurácia da métrica estimada (Perceptron) vs. rótulo real — zero-shot, média das 3 sementes, treino = 70.

Classes	Features	Acc. real	Erros
homem/mulher	peso/altura	0,914	$\approx 6/70$
A/B	peso/altura	0,129	$\approx 61/70$
homem/mulher	x_1/x_2	0,543	$\approx 32/70$
A/B	x_1/x_2	0,186	$\approx 57/70$

No ICL (Tabela 11), o LLM *in-context* supera o Perceptron *baseline* em todos os n , com vantagem de até +13,3 pontos (seed 123, 5-shot). Poucos exemplos bastam: a acurácia real salta de 56–67% (zero-shot) para 87–90% com apenas 5 exemplos.

Tabela 11: Bloco 3: ICL no Problema G — acurácia real (%) do LLM vs. Perceptron (peso/altura).

n -shot	Seed 42		Seed 123	
	LLM	Perc.	LLM	Perc.
0	66,7	—	56,7	—
5	87,4	76,7	90,0	76,7
10	86,3	80,7	90,0	80,7
20	86,3	84,1	96,7	84,1
40	87,8	84,1	93,3	84,1

5.9 Estabilidade de $\hat{W}$ (H5)

A direção de $\hat{W}$ é *estável* entre sementes (cosseno médio 0,990, faixa $[0,987; 0,993]$), e os dois estimadores concordam (cosseno Perceptron–NNLS 0,993). Contudo, a *magnitude* não é estável: a razão w_2/w_1 tem média 0,169 com $IC_{95} = [0,117; 0,229]$ e *coeficiente de variação* de 58,5%. Ou seja, *para onde* o LLM olha é reprodutível; *quão intensamente* não. Isso qualifica H5: a estabilidade é direcional, não de intensidade — consistente com a invariância de escala da métrica (Seção 2), que torna a magnitude intrinsecamente menos identificável.

6 Análise e Discussão

6.1 H1 — Estabilidade do critério

Parcialmente confirmada. $\hat{W}$ reproduz o LLM com fidelidade modesta (76,7–85,3% entre sementes) e transfere com κ de “razoável” (B, 0,30) a “substancial” (C, 0,73) já em zero-shot. Há um critério estimável, mas a métrica diagonal o captura só em parte — o teste-oráculo (95–100%) prova que a limitação é do LLM, não do estimador.

6.2 H2 — Transferência de conhecimento

Confirmada com qualificações. $\hat{W}$ generaliza melhor para C do que para B, e a adição de exemplos eleva ambos a $\kappa \approx 0,84$ –0,89 (Cohen’s $d > 5$). Porém, em zero-shot $\hat{W}$ não supera significativamente a métrica euclidiana (Δ com IC incluindo zero): o ganho da deformação aprendida é *contextual*, dependente de exemplos.

6.3 H3 — Viés semântico

Fortemente confirmada. A fidelidade oscila de 56,7% (*prompt* tabular) a 98,7% (Positivo/Negativo) — extremos da grade de variantes, medida na seed 42 —, e a mera inversão de posição (A/B $\rightarrow$ B/A) já custa 8,7 pontos (76,7% $\rightarrow$ 68,0%). No caso real,




Figura 8: Bloco 3: base real peso $\times$ altura (rótulo homem/mulher) com a fronteira aproximadamente elíptica. A pequena escala (≈ 70 amostras) motiva o reporte de erros absolutos além das porcentagens.

nomes semânticos vs. neutros separam 68,6% de 42,9% de acurácia — e o experimento de nomes de classe A/B (Tabela 10) mostra o mecanismo em sua forma mais nítida: sem âncora semântica nos nomes, o LLM ainda separa os grupos, mas o mapeamento rótulo $\leftrightarrow$ classe emerge em convenção arbitrária (acurácia da métrica vs. real de 0,914 para 0,129, uma inversão quase perfeita). O LLM incorpora semântica extrínseca ao problema geométrico, e ela ancora tanto a separação quanto a *nomeação* das classes.

6.4 H4 — Qualidade dos exemplos

Refutada. Ao contrário do previsto, exemplos *fáceis* superam *difíceis* com poucos exemplos (diferença significativa em 5/10-shot), e *hard* é a pior estratégia na média. Exemplos difíceis só compensam em alto volume (40-shot). A leitura: âncoras prototípicas transmitem o critério; exemplos ambíguos sem contexto suficiente chegam a orientar o LLM na direção errada.

6.5 H5 — Estabilidade estatística

Confirmada em direção, refutada em magnitude. O cosseno entre sementes (0,990) sustenta reprodutibilidade direcional; o CV de 58% na razão w_2/w_1 mostra que a intensidade dos pesos não é estável. Dada a invariância de escala, a direção é a quantidade cientificamente relevante — e ela é estável.

6.6 O LLM diante de baselines triviais

O achado mais sóbrio: no regime linear, a Regressão Logística iguala ou supera o LLM (100% vs. 95,6%). O LLM não “resolve melhor” — ele resolve *sem treino e sem especificação de modelo*. O quadro, porém, tem dois regimes: na base real (fronteira aproximadamente elíptica), o LLM *in-context* supera o Perceptron *baseline* treinado nos mesmos exemplos em todos os n -shot (até +13,3 pontos), e no regime não-linear sintético (meia-lua) o zero-shot simplesmente colapsa. A contribuição do ICL é de *flexibilidade* — condicionada a haver exemplos e semântica que o ancoram —, não de acurácia, e qualquer alegação de superioridade geral deve ser resistida.

7 Limitações

1. **Dados majoritariamente 2D:** embora o Bloco 3 use dados reais, a validade externa em alta dimensionalidade permanece aberta.
2. **Métrica diagonal:** $M = \text{diag}(w)$ ignora correlações entre *features* — provável causa da fidelidade modesta; uma Mahalanobis completa poderia elevá-la.
3. **Um único modelo:** os resultados são específicos ao `gpt-4o-mini`.
4. **Versão do modelo:** a coleta (30/06–01/07/2026) usou o *alias* `gpt-4o-mini`, sem fixar um *snapshot* datado; o provedor pode atualizar o modelo silenciosamente, o que limita a reprodutibilidade exata das decisões coletadas.
5. **Temperatura zero:** minimiza variância, mas não captura o comportamento estocástico; $T = 0$ não garante determinismo estrito — a taxa de *flip* medida pela auditoria foi de 4,75% das consultas repetidas, impondo um teto de $\approx 95\%$ a qualquer métrica de concordância com o LLM.
6. **Escala do caso real:** ≈ 70 amostras tornam cada erro pesado (por isso reportam-se erros absolutos); conclusões sobre o Problema G são indicativas.
7. **Classificação binária:** a extensão a múltiplas classes exige adaptar o *framework* inverso.

8 Trabalho Futuro

1. **Métrica completa:** remover a restrição diagonal e avaliar o *trade-off* expressividade $\times$ interpretabilidade, testando se a fidelidade sobe.
2. **Alta dimensionalidade e mais dados reais:** estender o Bloco 3 a datasets maiores e $d \gg 2$.
3. **Comparação entre modelos:** aplicar o protocolo a modelos de famílias distintas (ex.: Gemini, Llama, DeepSeek) para contrastar critérios implícitos — incluindo a comparação das taxas de *flip* a $T = 0$ como medida de não-determinismo por modelo.
4. **Seleção ativa de exemplos:** integrar o eixo de margem [9] com diversidade/representatividade [7] e incerteza.
5. **Geometria de fronteiras:** comparar a fronteira induzida por $\hat{W}$ com a fronteira real do LLM, seguindo Zhao et al. [10].

9 Conclusão

Este trabalho investigou se é possível estimar uma métrica matemática explícita que capture o critério decisório implícito de um LLM. Com **gpt-4o-mini** sobre sete configurações de problema organizadas em três blocos (119 713 chamadas, 3 sementes $\times$ 3 repetições, *fallback* do *parser* de 0,00% e piso de ruído de medição de 4,75% a $T = 0$), os experimentos sustentam seis achados:

1. **O critério é estimável, mas só parcialmente por uma métrica diagonal:** fidelidade de 76,7–85,3% entre sementes (média 0,811, $IC_{95} = [0,789; 0,832]$), com dois estimadores congruentes (cosseno Perceptron–NNLS 0,993) e validados por um teste-oráculo (95–100%) — a lacuna até o teto de $\approx 95\%$ imposto pelo ruído de medição é, portanto, do LLM, não do estimador. O teto é também *estrutural*: no oráculo da meia-lua, a métrica diagonal satura em $\approx 86,7\%$ e R3/R4 não ajudam.
2. **Transfere de modo heterogêneo:** κ de 0,30 (Problema B) a 0,73 (Problema C) em zero-shot, subindo a 0,84–0,89 com poucos exemplos (efeito grande, $d > 5$).
3. **É direcionalmente estável mas de magnitude instável:** cosseno 0,990 entre sementes, mas CV de 58% na razão dos pesos — dada a invariância de escala, a direção é a quantidade identificável, e ela é reprodutível.

4. **É fortemente semântico — nas *features* e nos nomes de classe:** variantes de *prompt* movem a fidelidade de 56,7% a 98,7%; no caso real, a semântica das *features* separa 68,6% de 42,9% de acurácia, e com nomes de classe neutros (A/B) o mapeamento rótulo $\leftrightarrow$ classe emerge em convenção arbitrária ($0,914 \rightarrow 0,129$, inversão quase perfeita): a semântica ancora até a *nomeação* das classes.
5. **Como aprendiz, o LLM é cego em zero-shot e aprende com poucos exemplos:** 54,9% (média sobre três peritos) $\rightarrow$ 95,6% no regime linear — sem, porém, superar a Regressão Logística (100%); no regime não-linear sintético o zero-shot *colapsa* em classe única (meia-lua, 3 sementes), enquanto na base real, com exemplos, o LLM supera o Perceptron *baseline* em todos os n -shot ($\approx 87\%$, ≈ 4 erros em 30).
6. **A hipótese de que exemplos difíceis ensinam melhor é refutada** na forma *a priori*: *easy* supera *hard* com significância em 5/10-shot (Δ até +0,223, IC excluindo zero), com reversão apenas em alto volume (40-shot, *hard* 97,8%).

Esses resultados constituem um passo — deliberadamente cético — em direção à explicabilidade dos critérios decisórios de LLMs: o que uma métrica interpretável captura (direção do critério, transferência parcial, dependências semânticas) e o que ela expõe por não capturar (o teto de fidelidade, o colapso não-linear, a arbitrariedade do mapeamento sem semântica). A aplicação potencial está em auditoria de sistemas de IA, detecção de vieses e transferência de conhecimento especializado — sempre com as métricas de concordância lidas contra o piso de ruído que o próprio protocolo quantifica.

Referências

- [1] Timothy C.Y. Chan, Rafid Mahmood, e Ian Yihang Zhu. Inverse optimization: Theory and applications. *Operations Research*, 73(2):1046–1074, 2025. (Publicado online Dez/2023.)
- [2] Kilian Q. Weinberger e Lawrence K. Saul. Distance metric learning for large margin nearest neighbor classification. *Journal of Machine Learning Research*, 10:207–244, 2009.
- [3] Michael Collins. Discriminative training methods for hidden markov models: Theory and experiments with perceptron algorithms. Em *Proceedings of EMNLP 2002*, páginas 1–8, 2002.
- [4] Charles L. Lawson e Richard J. Hanson. *Solving Least Squares Problems*. Prentice-Hall, Englewood Cliffs, NJ, 1974.

- [5] Shivam Garg, Dimitris Tsipras, Percy Liang, e Gregory Valiant. What can transformers learn in-context? a case study of simple function classes. Em *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022.
- [6] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, e Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. Em *ICLR 2023 (Oral)*, 2023.
- [7] Hongjin Su, Jungo Kasai, Chen Henry Wu, Weijia Shi, Tianlu Wang, Jiayi Xin, Rui Zhang, Mari Ostendorf, Luke Zettlemoyer, Noah A. Smith, e Tao Yu. Selective annotation makes language models better few-shot learners. Em *ICLR 2023*, 2023.
- [8] Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein, e Sameer Singh. Calibrate before use: Improving few-shot performance of language models. Em *Proceedings of ICML 2021*, volume 139 of *PMLR*, páginas 12697–12706, 2021.
- [9] Sewon Min, Xinxu Lyu, Ari Holtzman, Mikel Artetxe, Mike Lewis, Hannaneh Hajishirzi, e Luke Zettlemoyer. Rethinking the role of demonstrations: What makes in-context learning work? Em *Proceedings of EMNLP 2022*, páginas 11048–11064, 2022.
- [10] Siyan Zhao, Tung Nguyen, e Aditya Grover. Probing the decision boundaries of in-context learning in large language models. Em *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*, 2024.
- [11] Ron Artstein e Massimo Poesio. Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4):555–596, 2008.
- [12] Dzmitry Bahdanau, Kyunghyun Cho, e Yoshua Bengio. Neural machine translation by jointly learning to align and translate. Em *International Conference on Learning Representations (ICLR 2015)*, 2015.
- [13] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, e Illia Polosukhin. Attention is all you need. Em *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017.
- [14] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, et al. Language models are few-shot learners. Em *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020.
- [15] Parshin Shojaee, Iman Mirzadeh, Keivan Alizadeh, Maxwell Horton, Samy Bengio, e Mehrdad Farajtabar. The illusion of thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity. Relatório técnico, Apple Machine Learning Research, 2025.