

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/321006301>

Uso de Predição Estruturada para o Aprendizado de Métrica

Conference Paper · November 2017

CITATIONS

2

READS

110

3 authors:



Maurício Archanjo Nunes Coelho

Instituto Federal do Sudeste de Minas Gerais

7 PUBLICATIONS 31 CITATIONS

SEE PROFILE



Carlos Cristiano Hasenclever Borges

Universidade Federal de Juiz de Fora

55 PUBLICATIONS 352 CITATIONS

SEE PROFILE



Raul Fonseca Neto

Universidade Federal de Juiz de Fora

59 PUBLICATIONS 183 CITATIONS

SEE PROFILE



USO DE PREDIÇÃO ESTRUTURADA PARA O APRENDIZADO DE MÉTRICA

Maurício Archanjo Nunes

archanjomau@yahoo.com.br

Instituto Federal Sudeste Minas – Departamento Acadêmico de Ciência da Computação
Campus Rio Pomba, 36180-000, Minas Gerais, Rio Pomba, Brasil

Carlos Cristiano Hasenclever Borges

Raul Fonseca Neto

cchborges@ice.ufjf.br

raulfonsecaneto@ig.com.br

Universidade Federal de Juiz de Fora – Departamento de Ciência da Computação
Campus Universitário, 36036-900, Minas Gerais, Juiz de Fora, Brasil

Resumo. O sucesso de algoritmos de aprendizado depende da existência de uma boa métrica para o cálculo das distâncias. Este é o caso, por exemplo, dos algoritmos NCC (centroide mais próximo) para análise discriminante e do algoritmo K-means para análise de agrupamentos. Este artigo trata da solução do seguinte problema inverso: dado um conjunto de informações fornecidas por um especialista indicando quais instâncias do problema deva pertencer ao mesmo agrupamento determinar uma métrica de forma que o conjunto de distâncias parametrizadas satisfaçam as restrições fornecidas pelo mesmo. Este problema é formulado como um problema de otimização convexa onde o objetivo é a minimização de um conjunto parametrizado de distâncias de Mahalanobis. Neste artigo é proposto um novo método offline considerando uma abordagem de predição estruturada e a utilização do algoritmo perceptron estruturado. Dado a existência de inúmeras soluções que satisfazem as restrições fornecidas para o problema optou-se por uma solução que maximize a margem representada pela diferença das distâncias intergrupos. A formulação proposta apresenta uma vantagem em relação ao estado da arte pelo fato de gerar uma quantidade linear de restrições e utilizar uma técnica de relaxação. Os resultados obtidos foram bastante satisfatórios melhorando o poder de classificação dos algoritmos de aprendizado.

Palavras Chaves: Aprendizado de métricas, Predição estruturada, Distância de Mahalanobis parametrizada, Classificação pelo centroide mais próximo.

CILAMCE 2017

Proceedings of the XXXVIII Iberian Latin-American Congress on Computational Methods in Engineering
P.O. Faria, R.H. Lopez, L.F.F. Miguel, W.J.S. Gomes, M. Noronha (Editores), ABMEC, Florianópolis, SC,
Brazil, November 5-8, 2017.

1 INTRODUÇÃO

A eficiência de algoritmos de Aprendizado de Máquinas baseados em protótipos depende fundamentalmente do tipo de métrica utilizada para a avaliação da medida de similaridade entre pontos ou vetores no espaço de entrada. Por exemplo, no algoritmo de classificação KNN (Cover e Hart, 1967), dependendo do tipo de métrica empregada para a avaliação da distância entre vetores, pode-se obter diferentes tipos de classificação para novos dados ainda não vistos. O mesmo pode ser dito em relação ao algoritmo K-means (MacQueen, 1967) no que tange ao problema de Análise de Agrupamentos. Neste artigo aborda-se o seguinte tipo de problema: suponha que um especialista indique quais grupos de pontos devam pertencer ao mesmo agrupamento. Caso seja feita uma análise não supervisionada deste conjunto de entrada utilizando o algoritmo K-means com uma métrica Euclidiana, o resultado desta análise pode não concordar com as informações fornecidas pelo especialista. Neste sentido, o objetivo do aprendizado de uma métrica consiste em proporcionar um reescalonamento dos dados com uma consequente mudança de coordenadas de modo que a solução computada pelo algoritmo K-means concorde ou se aproxime da solução proposta pelo especialista. Esta estratégia é um pouco diferente do emprego de funções e do truque kernel (Scholkopf e Smola, 2002) já que o processo de cálculo da similaridade continua sendo feito no espaço de entrada sem alterar a dimensão dos dados. Este problema tem natureza semelhante ao problema de Análise de Agrupamentos semi-supervisionado, no qual um conjunto de restrições do tipo *must-link* e *cannot-link* são impostos a uma parte dos dados na forma de restrições de pares, denominadas *pairwise constraints*.

Originalmente, o problema de Aprendizado de Métrica tem sido tratado como um problema de minimização de um conjunto parametrizado de distâncias de Mahalanobis sujeito às restrições de não negatividade e de desigualdade triangular (Xing et al., 2002). Neste sentido, verificam-se diferentes abordagens, podendo ser considerado o aprendizado de toda matriz de parâmetros, equivalente ao uso da matriz de covariância inversa necessário ao computo da distância de Mahalanobis, como também o aprendizado de uma matriz diagonal, equivalente ao uso do inverso das variâncias, necessário ao cômputo da distância Euclidiana normalizada. Neste último caso, quando se restringe a matriz de parâmetros a uma matriz diagonal, tem-se o aprendizado de uma métrica que pondera as diferentes dimensões do problema. O aprendizado pode ocorrer na forma *offline*, onde todas as informações estão acessíveis em um dado momento, como também na forma *online*, onde as informações são conhecidas uma por vez. O escopo deste trabalho restringe-se aos estudos sobre a utilização da matriz diagonal, representada por um vetor de parâmetros e ao aprendizado do tipo *offline*.

O método proposto tem uma relação direta com o problema de Predição Estruturada podendo apresentar duas abordagens. A primeira, apresentada por Fagundes et al., 2016 é baseada na minimização da diferença entre a soma total das distâncias parametrizadas intragrupos relacionadas, respectivamente, a solução proposta pelo especialista e a solução obtida pelo algoritmo K-means. Trata-se, portanto, de uma técnica de redução de diferenças, que utiliza como regra básica de correção dos parâmetros o método do gradiente descendente com um comprimento de passo variável. Dado um vetor de parâmetros, o método utiliza para a geração de soluções potenciais o algoritmo K-means parametrizado, o qual recomputa de forma iterativa as distâncias Euclidianas modificadas em relação aos respectivos centroides, promovendo um novo esquema de rótulos para os dados e, conseqüentemente, uma nova

solução potencial. O processo continua até que a solução computada pelo K-means parametrizado se iguale ou se aproxime o suficiente da solução proposta pelo especialista.

A segunda, a qual será objeto de desenvolvimento neste trabalho, é baseada na satisfação de um conjunto de restrições que atestam a pertinência de cada ponto em relação ao seu respectivo centroide quando comparado a demais alternativas. Estas restrições representam o fato de que a distância parametrizada de um ponto em relação ao seu centroide, obtida da informação de um especialista, deva ser menor do que em relação a qualquer outro centroide do problema. Neste sentido, pode-se reformular o problema de aprendizado de métrica na forma de um sistema de inequações e empregar um método de relaxação para a sua solução. Neste trabalho, utiliza-se a versão primal do algoritmo perceptron estruturado com margem proposto por Coelho et al., 2016, com uma pequena modificação no sentido de permitir, quando necessário, a violação de algumas restrições possibilitando assim a solução de problemas não linearmente separáveis. Esta abordagem, baseada na comparação com centroides, possui duas premissas fundamentais. A primeira está relacionada ao fato de que o problema de Aprendizado de Métrica, originalmente representado por um conjunto de distâncias entre pontos denominadas *pairwise distances* e suas respectivas restrições de similaridade e dissimilaridade, denominadas *must-link* e *cannot-link*, pode ser modelado como um problema de aprendizado supervisionado, relacionado à existência de um conjunto de centroides determinando grupos disjuntos. A segunda está relacionada ao fato de que o somatório das distâncias entre todos pares de pontos que pertencem a um mesmo agrupamento é igual ao somatório das distâncias de cada ponto ao respectivo centroide multiplicado pelo número de pontos.

As seções subsequentes do trabalho estão organizadas da seguinte forma. Na seção 2 relatam-se os trabalhos relacionados, considerando principalmente a abordagem original do problema de Aprendizado de Métrica e suas extensões. Na seção 3 descreve-se a formulação do problema de Aprendizado de Métrica, bem como a sua relação com o problema de Análise de Agrupamentos utilizando-se uma função de distância Euclidiana parametrizada. Na seção 4 descreve-se as variantes parametrizadas do algoritmo K-means e NCC. Na seção 5 descreve-se o método proposto e a sua formulação como um problema de Predição Estruturada. Na seção 6 são mostrados os experimentos e os resultados alcançados e, finalmente, na seção 7 apresentam-se as conclusões finais e possíveis trabalhos futuros.

2 TRABALHOS RELACIONADOS

O problema de Análise de Agrupamentos com informação adicional a qual impõe um conjunto de restrições de pares a um subconjunto dos dados foi tratado inicialmente em (Wagstaff et al., 2001). Neste trabalho, os autores descrevem uma variante do algoritmo K-means denominada K-means com restrições, que incorporam as condições do tipo *must-link*, significando que dois vetores devem pertencer ao mesmo grupo, e *cannot-link*, significando o contrário. A modificação proposta no algoritmo trabalha no sentido de não permitir que estas restrições sejam violadas. Como não existe um aprendizado de métrica, o método não garante a convergência do algoritmo K-means para uma solução que atenda a todas as restrições de pares. Xing et al., 2002 propõem o Aprendizado de Métrica com aplicação ao problema de Análise de Agrupamentos com informações adicionais. Neste sentido, dado um conjunto de relações de similaridade e dissimilaridade envolvendo pares de dados, o método proposto computa uma matriz de parâmetros a partir da minimização ou maximização de um conjunto parametrizado de distâncias de Mahalanobis. No caso mais trivial, no qual a matriz de

parâmetros é uma matriz diagonal, os autores propõem a solução do problema de minimização utilizando o método de Newton-Raphson, considerando os pares de similaridade. Para o caso mais geral, contendo uma matriz cheia e pares de dissimilaridade, os autores propõem o uso do método do gradiente ascendente no problema de maximização, além de um algoritmo de projeção, no sentido de forçar a satisfação da condição da matriz de parâmetros ser semidefinida positiva. Os resultados reportados pelos autores mostram que, tanto no caso da matriz diagonal quanto no caso da matriz cheia, o índice de acerto dos experimentos é bem significativo em relação à métrica Euclidiana. As relações de similaridade são extraídas de forma randômica de conjuntos de dados supervisionados, abrangendo em torno de 90% das instâncias. Para efeito de visualização os experimentos de bases de dados artificiais possuem vetores em R^3 e estão divididos em subconjuntos disjuntos, formando dois e três grupos, sendo que as soluções dos dados projetados relacionadas à utilização de uma matriz diagonal apresentam melhor visibilidade dos resultados.

O trabalho desenvolvido por Jain et al., 2008 apresenta um método de solução para o problema de Aprendizado de Métrica do tipo *online*. A solução deste tipo de problema é baseada em consecutivas predições da similaridade entre os pares de dados apresentados. Desta forma, ao receber um par de vetores, o algoritmo decide com base na matriz de parâmetros atualizada se a distância computada confirma se os vetores são similares ou não. Caso haja discórdia, uma perda é imputada. O objetivo do aprendizado *online* é a minimização desta perda ao longo de todo período de observação. Os autores ressaltam que a solução deste tipo de problema é muito importante para tarefas de aprendizado *online*, relacionadas, sobretudo, ao reconhecimento de objetos em cenas com movimento. Os autores propõem a minimização acumulativa do somatório das perdas relacionadas a uma função de distância de Mahalanobis parametrizada. Para tanto, consideram a minimização de uma função com um termo de regularização que inclui a minimização da perda imediata, seguida de uma função de regularização *LogDet*, proposta por Davis et al., 2007, que computa uma diferença, também conhecida como *regret* em relação à decisão tomada por um algoritmo ótimo do tipo *offline*. Shalev-Shwartz et al., 2004 apresentam um algoritmo para o cálculo de pseudométricas na forma *online* baseado no uso do método do gradiente estocástico seguido de uma regularização baseada na divergência de Frobenius. A atualização da matriz de parâmetros é baseada em duas operações de projeção ortogonais utilizando-se do conjunto de autovetores para manter a propriedade de semidefinida-positiva da matriz de parâmetros. A contribuição principal deste trabalho está na possibilidade de utilização de um mapeamento *kernel* com a derivação de uma versão dual do algoritmo e o consequente aprendizado de relações não lineares.

Schultz e Joachims, 2003 apresentam para a solução do problema de Aprendizado de Métrica uma formulação de máxima margem baseada na minimização da norma Frobenius da matriz de parâmetros. As restrições do problema são moldadas de modo a satisfazerem um conjunto de comparações relativas na forma: “*A* é mais similar a *B* do que a *C* “. Assim, a distância parametrizada de *A* em relação a *B* deve ser menor do que a distância parametrizada de *A* em relação a *C*. Para uma simplificação do problema de otimização os autores optaram pela utilização de um vetor de parâmetros equivalente ao uso da matriz diagonal e a consequente minimização da norma Euclidiana de um vetor de parâmetros assim como é feito na formulação clássica SVM. Também, consideraram a possibilidade de flexibilização da margem permitindo, quando necessário, a violação das restrições.

No contexto de aprendizado supervisionado, pode-se citar o trabalho de (Hastie e Tibshirani, 1996) que apresenta o algoritmo de classificação KNN considerando o uso de uma métrica local adaptada. A estimativa desta métrica é baseada no uso discriminante linear de Fisher para um subconjunto de pontos mais próximos escolhidos de acordo com esta métrica adaptativa.

Yang e Jin, 2006 apresentam um estudo compreensivo e abrangente do problema de Aprendizado de Métrica, destacando-se a descrição do uso de métodos *kernel*. Bellet et al., 2013 e Kulis, 2013 apresentam um estudo bastante atualizado do problema de Aprendizado de Métrica destacando os principais paradigmas e a descrição dos respectivos métodos e aplicações.

3 APRENDIZADO DE MÉTRICA

3.1 Distância Parametrizada

Seja um conjunto de m pontos em um espaço de dimensão d , com $\{x_i, i = 1, \dots, m\} \subset R^d$. Considere, também, um conjunto de restrições fornecidas por um especialista indicando a existência de um conjunto S de similaridade entre todos pares de pontos, o qual pode dividir o espaço em k subconjuntos disjuntos: $S_1, S_2, \dots, S_k$, cada qual associado a formação de um grupo:

$S: (x_i, x_j) \in S_l \rightarrow x_i \text{ e } x_j \text{ são similares}$

$$S = S_1 \cup S_2 \cup \dots \cup S_k$$

Comumente, o problema de Aprendizado de Métrica é apresentado na forma de um conjunto de relações do tipo *pairwise constraints*, indicando quais pares de pontos são similares ou não. Caso os pares sejam dissimilares tem-se:

$D: (x_i, x_j) \in D_l \rightarrow x_i \text{ e } x_j \text{ são dissimilares}$

Entretanto, concordando com a primeira premissa apresentada neste artigo, pode-se reduzir o mesmo problema a um problema de Análise de Agrupamentos se forem consideradas nas relações as propriedades do tipo:

Transitividade: se (x_i, x_j) e (x_j, x_k) são similares, então (x_i, x_k) são similares.

Simetria: se (x_i, x_j) são similares, então (x_j, x_i) são similares.

Desta forma, se o total de relações envolverem todo conjunto de dados, é possível, por meio da computação dos fechos transitivos, determinar todos os subconjuntos fechados ou componentes conexas denominadas grupos. Assim, pode-se considerar que a informação do especialista está relacionada à existência de um conjunto de dados com seus respectivos rótulos, cada qual pertencendo ao seu respectivo grupo.

Considere, também, uma medida de distância parametrizada entre dois pontos definida em função de uma matriz $A_{d \times d}$ semidefinida positiva e simétrica:

$$d_A(x_i, x_j) = \|x_i - x_j\|_A^2 = (x_i - x_j)^T A (x_i - x_j), \quad (1)$$

com as seguintes propriedades:

$$d_A(x_i, x_j) \geq 0 \text{ (não negatividade)}$$

$$d_A(x_i, x_j) = 0, i=j \text{ (identidade)}$$

$$d_A(x_i, x_j) = d_A(x_j, x_i) \text{ (simetria)}$$

$$d_A(x_i, x_j) \leq d_A(x_i, x_k) + d_A(x_k, x_j) \text{ (desigualdade triangular)}$$

Estendendo este conceito para todos os grupos e para todos pares de pontos que pertençam ao mesmo grupo, ou seja, que compartilham da mesma similaridade, o aprendizado de uma métrica requer a solução do seguinte problema de otimização:

$$\text{Min } \sum_l \sum_{(x_i, x_j) \in S_l} \|x_i - x_j\|_A^2, \text{ sujeito a: } A \geq 0. \quad (2)$$

A restrição que requer que a matriz A seja semidefinida positiva é necessária para evitar que sejam calculadas distâncias com valores negativos. Uma matriz $A_{d \times d}$ é semidefinida positiva se todos seus autovalores não são negativos ou, de forma equivalente, se para todos vetores u não nulos com componentes reais, $u \in \mathbb{R}^d$, $u^T A u \geq 0$. Se for considerado o caso no qual a matriz A é uma matriz diagonal, tem-se o problema equivalente ao aprendizado de um vetor de parâmetros $w = [w_1, w_2, \dots, w_d]$, cuja solução é equivalente ao reescalonamento dos dados, multiplicando-se cada componente de um vetor de dados pela raiz quadrada do respectivo parâmetro. Ou seja, o vetor $x_i = [x_{i1}, x_{i2}, \dots, x_{id}]$ é substituído pelo vetor produto $x_i \sqrt{w} = [x_{i1} \sqrt{w_1}, x_{i2} \sqrt{w_2}, \dots, x_{id} \sqrt{w_d}]$.

De fato, caso exista uma matriz de métricas A associada a um conjunto de distâncias parametrizadas, pode-se obter os mesmos resultados utilizando-se uma transformação linear e computando-se a distância Euclidiana sobre o conjunto de dados reescalonados, ou seja:

$$(x_i - x_j)^T A (x_i - x_j) = \|x_i \sqrt{A} - x_j \sqrt{A}\|_2^2. \quad (3)$$

Pode ser observado na Eq. (1) que quando $A = I$, tem-se a distância Euclidiana, tomando-se A com a matriz inversa da covariância, tem-se a distância de Mahalanobis, e, finalmente, tomando-se $A = [1/\sigma_1^2, 1/\sigma_2^2, \dots, 1/\sigma_d^2]I$, tem-se a distância Euclidiana normalizada. Para o caso da matriz A diagonal, a condição de semidefinida positiva é satisfeita se todos os elementos da diagonal principal tiverem seus valores positivos, sendo assim o vetor de parâmetros w deve possuir cada componente $w_i \geq 0$.

É importante mencionar que a função de distância definida para o problema de Aprendizado de Métrica pode ser substituída por uma função de distância Euclidiana parametrizada do algoritmo K-means, concordando com a segunda premissa considerada na introdução do trabalho. Para o caso da matriz A diagonal e considerando c_l como o centroide de um cluster S_l com cardinalidade n_l , tem-se:

$$\begin{aligned} \sum_l \sum_{(x_i, x_j) \in S_l} \|x_i - x_j\|_A^2 &= \sum_l n_l \sum_{i|x_i \in S_l} \|x_i - c_l\|_A^2 = \\ &= \sum_l n_l \sum_{i|x_i \in S_l} (x_i - c_l)^T A (x_i - c_l) = \\ &= \sum_l n_l \sum_{i|x_i \in S_l} w_1 (x_{i1} - c_{l1})^2 + w_2 (x_{i2} - c_{l2})^2 + \dots + w_d (x_{id} - c_{ld})^2. \end{aligned} \quad (4)$$

Esta equivalência é demonstrada por Edwards e Cavalli-Sforza, 1965, levando em consideração o fato de que, para cada grupo, seu centroide é computado como a média de seus

vetores associados $c_l = \left(\frac{1}{n_l}\right) \sum_i x_i \quad \forall x_i \in S_l$. Neste sentido, pode-se afirmar que a função parametrizada proposta para o algoritmo K-means é equivalente ao valor esperado da função de distância definida para o problema de Aprendizado de Métrica relacionada ao somatório de um conjunto de distâncias de Mahalanobis parametrizadas, ou seja:

$$\sum_l \sum_{i|x_i \in S_l} (x_i - c_l)^T A (x_i - c_l) = \sum_l \frac{1}{n_l} \sum_{(x_i, x_j) \in S_l} \|x_i - x_j\|_A^2 =$$

$$E[\sum_l \sum_{(x_i, x_j) \in S_l} \|x_i - x_j\|_A^2]. \quad (5)$$

3.2 Relações de Similaridade

Para o problema envolvendo a matriz diagonal Xing et al. 2002 propõem a seguinte formulação envolvendo a minimização de uma função objetiva penalizada e sem restrições:

$$\text{Min} \sum_{(x_i, x_j) \in S} \|x_i - x_j\|_A^2 - \log \sum_{(x_i, x_j) \in D} \|x_i - x_j\|_A, \quad (6)$$

sendo S o conjunto total de pares similares e D o conjunto total de pares dissimilares. Para a solução deste problema, os autores propõem o uso do método de Newton-Raphson. Em se utilizando a matriz cheia, os autores consideram o seguinte problema de otimização:

$$\text{Max} \sum_{(x_i, x_j) \in D} \|x_i - x_j\|_A, \quad \text{sujeito a} \sum_{(x_i, x_j) \in S} \|x_i - x_j\|_A^2 \leq 1, \quad A \geq 0. \quad (7)$$

Este problema é resolvido com o uso do método do gradiente ascendente, seguido de um método iterativo que realiza duas projeções, de modo a satisfazer o conjunto de restrições. Embora estes problemas de otimização sejam convexos, os mesmos não possuem uma estrutura eficiente de solução, como é o caso da programação quadrática e programação semidefinida. Também, tem-se a restrição relacionada à quantidade de parâmetros, que escala de forma quadrática em relação à dimensão do problema.

3.3 Relações de Comparação

Schultz e Joachims, 2003 propõem a formulação do problema de Aprendizado de Métrica como uma extensão da Máquina de Vetores Suportes (Cortes e Vapnik, 1998). O aprendizado se baseia em um conjunto de comparações relativas relacionadas ao conjunto de pontos. Notadamente, estas comparações possuem a seguinte semântica:

“ x_i está mais próximo de x_j do que está de x_k .”

Neste caso, pode-se deduzir que x_i é similar a x_j , porém não se pode deduzir com certeza que x_i e x_k são similares ou dissimilares. Diante deste fato, os autores optaram por estabelecerem um conjunto de restrições que procuram expressar as comparações relativas entre grupos de três vetores. Considerando a distância parametrizada entre dois pontos definida pela equação:

$$d_{A,W}(x_i, x_j) = ((x_i - x_j)AWA^T(x_i - x_j)^T)^{1/2}, \quad (8)$$

onde A é uma matriz pré-definida de valores reais e W uma matriz diagonal que pode ser representada por um vetor w de parâmetros com valores não negativos assegurando a condição de que AWA^T seja semidefinida positiva no sentido de estabelecer uma métrica válida. O problema de Aprendizado de Métrica consiste em encontrar um vetor w que satisfaça o seguinte conjunto de inequações :

$$\forall i, j, k : d_{A,W}(x_i, x_k) - d_{A,W}(x_i, x_j) > 0. \quad (9)$$

Obviamente, pode não existir nenhuma ou um conjunto de inúmeras soluções que satisfaçam o sistema de inequações apresentado. Neste sentido, os autores propuseram uma forma de solução similar a formulação de margem flexível do SVM considerando uma margem funcional de valor unitário e a minimização da norma Frobenius da matriz AWA^T . Para o caso mais simples que considera a matriz A uma matriz identidade tem-se: $AWA^T = W$, derivando o seguinte problema de maximização de margem ou de minimização da norma Euclidiana do vetor de parâmetros w :

$$\text{Min } \frac{1}{2} \|w\|^2 + C \sum_{i,j,k} \xi_{i,j,k} \quad (10)$$

$$\text{Sujeito a: } \forall i, j, k : d_W(x_i, x_k) - d_W(x_i, x_j) \geq 1 - \xi_{i,j,k}$$

$$\xi, w \geq 0,$$

onde C representa uma constante de penalização e ξ o vetor de variáveis de folga. A maior crítica a esta formulação se refere ao número elevado de restrições que é da ordem de $O(m^3)$ sendo m a quantidade de dados relacionados ao conjunto de treinamento. Neste sentido, optou-se neste artigo pela formulação de um conjunto de restrições que representam relações de comparação entre vetores e centroides reduzindo o número de restrições para ordem $O(m)$. Também, optou-se por uma técnica de solução que emprega um método de relaxação baseado no algoritmo perceptron estruturado com margem evitando assim a solução de um problema mais complexo de programação quadrática.

A extensão do problema de Aprendizado de Métrica para o caso não linear pode ser tratada com o uso do mapeamento *kernel*. Para tanto se deve computar a distância de Mahalanobis parametrizada no espaço de características, conhecido como *feature space*, na forma: $(\phi(x_i) - \phi(x_j))^T A (\phi(x_i) - \phi(x_j))$, sendo a função $\Phi: x \rightarrow \phi(x)$ responsável pelo mapeamento dos vetores do espaço de entrada no espaço de características e o vetor $x_i = [x_{i1}, x_{i2}, \dots, x_{id}]$ substituído pelo vetor produto $x_i \sqrt{w} = [x_{i1}\sqrt{w_1}, x_{i2}\sqrt{w_2}, \dots, x_{id}\sqrt{w_d}]$. A implementação deste aprendizado pode ser feita utilizando-se do truque *kernel* (Girolami, 2002). A ideia básica do algoritmo consiste em explorar a não linearidade dos dados, definindo a formação dos grupos no espaço de características. A distância dos pontos no espaço de características deve ser expressa em termos de uma função *kernel* observando o fato de que $K(x, y) = K(\langle x, y \rangle) = \langle \phi(x), \phi(y) \rangle$. Neste sentido, é possível avaliar a distância de cada vetor x a um determinado centro c_l na forma:

$$d^2(x, c_l)_2 = \|x_i - c_l\|_2^2 = \|\phi(x) - \phi(c_l)\|_2^2 = \quad (11)$$

$$\begin{aligned}
&= \phi^2(x) - \left(\frac{2}{n_l}\right) \sum_{j \in S_l} \phi(x) \cdot \phi(x_j) + \left(\frac{1}{n_l^2}\right) \sum_{i \in S_l} \sum_{j \in S_l} \phi(x) \cdot \phi(x_j) = \\
&= K(x, x) - \left(\frac{2}{n_l}\right) \sum_{j \in S_l} K(x, x_j) + \left(\frac{1}{n_l^2}\right) \sum_{i \in S_l} \sum_{j \in S_l} K(x_i, x_j)
\end{aligned}$$

4 ALGORITMOS PARAMETRIZADOS

4.1 Algoritmo K-means Parametrizado

O algoritmo K-means minimiza a distância conhecida como intragrupo, relacionada a um conjunto de pontos distribuídos no espaço Euclidiano e a uma quantidade de grupos previamente definida. Mais especificamente, o algoritmo minimiza a soma dos quadrados das distâncias Euclidianas de cada ponto do espaço de entrada ao seu respectivo centroide calculado como a média de seus respectivos pontos. De certa forma pode-se dizer que o algoritmo minimiza a variância intragrupo dos dados em relação aos respectivos centroides.

A função de distância do algoritmo K-means é dada pela expressão:

$$J = \sum_l \sum_{i|x_i \in S_l} \|x_i - c_l\|_2^2 \text{ para } l = 1, \dots, k \text{ e } i = 1, \dots, m. \quad (12)$$

Esta função pode ser minimizada de duas formas. A primeira, conhecida como modo *online*, utiliza o método do gradiente estocástico descendente. Neste caso, computa-se a derivada parcial da função de distância tomando-se um vetor do conjunto de dados em relação ao seu respectivo centroide determinando a direção do gradiente: $\frac{\partial J(x_i)}{\partial c_l} = -(x_i - c_l)$.

A determinação do centroide vencedor é feita considerando a menor distância Euclidiana do vetor em relação a todos os centroides, ou seja, tomando c_l , onde: $l = \operatorname{argmin} j \|x_i - c_j\|_2 \text{ para } j = 1, \dots, k$.

Em seguida, corrige-se a posição do centroide vencedor em direção ao vetor x_i utilizando-se a seguinte equação de correção:

$$c_l(t+1) = c_l(t) + \eta \cdot (x_i - c_l(t)) \quad (13)$$

onde $0 < \eta \leq 1$ é a taxa de aprendizado ou comprimento do passo. Como critério de parada, pode-se considerar a redução dos valores da função de distância. O algoritmo converge após um número finito de iterações para uma taxa de aprendizado apropriada.

A segunda forma de minimização da função de distância do algoritmo K-means é conhecida como modo *offline*, sendo mais utilizada devido a sua implementação mais simples e a ausência de uma taxa de aprendizado. Ela é baseada nas equações de otimalidade de primeira ordem da função de distância, tomando-se as derivadas parciais da mesma em relação aos vetores centroides e igualando-a a zero. Ou seja:

$$\frac{\partial J(x_i)}{\partial c_l} = -\sum_{i|x_i \in S_l} \|x_i - c_l\|_2^2 = 0, \text{ para } l = 1, \dots, k \text{ e } i = 1, \dots, m \quad (14)$$

Derivando a determinação de cada centroide como a média de seus respectivos vetores, na forma:

$$c_l(t+1) = \left(\frac{1}{n_l}\right) \sum_{i|x_i \in S_l} x_i \quad \text{para } l = 1, \dots, k \text{ e } i = 1, \dots, m \quad (15)$$

Os valores dos centroides são computados de forma iterativa sempre que houver uma mudança em algum rótulo do vetor de dados. Assim, a cada iteração, todos os subconjuntos de grupos S_l devem ser atualizados considerando um novo esquema de rótulos dos dados com base nos centroides vencedores. A convergência é alcançada quando não ocorrerem mais modificações no esquema de rótulos ou nos subconjuntos. Em ambos os algoritmos os valores iniciais dos centros podem ser estabelecidos de forma randômica (Hamerly e Elkan, 2002).

A função de distância parametrizada do algoritmo K-means é construída, como foi visto na seção 3.1, com base na equivalência da soma das distâncias entre vetores de um mesmo grupo que compartilha uma relação de similaridade e a soma das distâncias intragrupo. Neste artigo optou-se como em (Schultz e Joachims, 2003) pela utilização de um vetor de parâmetros w de dimensão d em substituição a matriz cheia $A_{d \times d}$. Considerando a Eq. (4) tem-se:

$$\begin{aligned} \sum_l \left(\frac{1}{n_l}\right) \sum_{(x_i, x_j) \in S_l} \|x_i - x_j\|_A^2 &= \sum_l n_l \sum_{i|x_i \in S_l} (x_i - c_l)^T w (x_i - c_l) = \\ &= \sum_l n_l \sum_{i|x_i \in S_l} w (x_i - c_l)^2. \end{aligned} \quad (16)$$

Desta forma, a única alteração necessária no algoritmo K-means parametrizado em relação ao algoritmo K-means com correção no modo *offline* está na determinação do centro vencedor $l = \operatorname{argmin}_j \|x_i - c_j\|_w$ para $j = 1, \dots, k$, onde agora devem ser computadas as distâncias Euclidianas parametrizadas pelo vetor w .

A estratégia inicial de Aprendizado de Métrica apresentada em Fagundes et al., 2016 tem como base a sucessiva redução de diferenças entre a função de distância entre um conjunto de relações de similaridade, traduzidas em um esquema de rótulos S_{exp} , fornecidos por um especialista, e a função de distância parametrizada, oferecida pelo algoritmo K-means. Ou seja, a cada iteração, minimiza-se a função diferença Δ parametrizada pelo vetor w , estimada em função do esquema de rótulos $S_{kme}(t)$ fornecido pelo algoritmo K-means na iteração anterior, considerando em ambos os casos o conjunto de centroides definidos pelo especialista, ou seja:

$$\begin{aligned} \operatorname{Min} \Delta &= J_{exp}(t) - J_{kme}(t) = \\ &= \sum_l n_l \sum_{i|x_i \in S_{exp}} w(t)(x_i - c_l)^2 - \sum_l n_l \sum_{i|x_i \in S_{kme}(t)} w(t)(x_i - c_l)^2 \end{aligned} \quad (17)$$

Nesta estratégia utilizou-se para o cálculo da função J_{kme} o conjunto de centroides do especialista. Portanto, a diferença entre as duas funções de distância está somente no esquema de rótulos. Para o cálculo da função de distância J_{kme} relacionada ao esquema de rótulos do K-means, realiza-se um mapeamento do conjunto de centroides da solução provida pelo algoritmo para o conjunto de centroides computados pelo especialista, com base na menor

distância. Enquanto o conjunto de centroides computados pelo K-means sofre variações, no sentido de se aproximar do conjunto de centroides estabelecido pelo especialista, com base nas informações de similaridade, o conjunto de centroides do especialista se mantém fixo. Para efeito de minimização da função diferença, considera-se o seu módulo, pois nem sempre a função Δ possuirá valores positivos. O algoritmo converge para um valor de diferença zero quando o conjunto de centroides, computado pelo algoritmo K-means parametrizado, se iguala ao conjunto de centroides apresentado pelo especialista. Para a atualização do vetor w , que deve ser repassado a cada iteração ao algoritmo K-means, utiliza-se o método do gradiente descendente. Assim tem-se:

$$w(t+1) = w(t) - \eta \cdot \text{grad}_w(|\Delta|), \quad (18)$$

sendo as componentes do vetor w atualizadas segundo cada dimensão. Entretanto, observando a condição de semidefinida positiva da matriz de parâmetros, o vetor w deve possuir componentes com valores reais não negativos para garantir que sejam computadas somente distâncias nulas ou positivas.

4.2 Algoritmo Baseado no Centroide Mais Próximo Parametrizado

Fisher, 1936 sugeriu o primeiro algoritmo paramétrico de reconhecimento de padrões. Para um problema de classificação binária, onde a probabilidade condicional dos dados pertencentes às classes são descrita por uma distribuição normal representada pela função de Gauss multivariável, com centros em m_1 e m_2 e matrizes de covariância Σ_1 e Σ_2 , Fisher mostrou que a solução era uma superfície de decisão quadrática na forma:

$$f(x) = \varphi(1/2(x-m_1)^T \Sigma_1^{-1}(x-m_1) - 1/2(x-m_2)^T \Sigma_2^{-1}(x-m_2) + \ln |\Sigma_2| / |\Sigma_1|). \quad (19)$$

Conforme Cortes e Vapnik, 1995 a estimativa desta função requer a determinação de um número quadrático, ou seja, de ordem $O(d^2)$ de parâmetros sendo d a dimensão dos dados. Nos casos em que a quantidade de observações é pequena comparada a quantidade de parâmetros, inferior a $10 \cdot d^2$, esta estimativa deixa de ser viável. Neste sentido, Fisher recomenda a utilização de um discriminante linear obtido da Eq. (19) quando as matrizes de covariância são iguais, ou seja $\Sigma_1 = \Sigma_2$. Para os casos onde as duas matrizes de covariância são diferentes, Fisher sugeriu a adoção de uma matriz comum dada por: $\Sigma = \gamma \Sigma_1 + (1-\gamma) \Sigma_2$ para uma constante γ , $0 < \gamma < 1$, tornando o discriminante linear.

O algoritmo padrão NCC se baseia na comparação da distância Euclidiana de um novo vetor aos respectivos centroides das classes, classificando o mesmo segundo o centroide vencedor. Se for considerado um problema de duas classes com uma função de distância parametrizada pela matriz de parâmetros tem-se a mesma função de decisão apresentada na Eq. (19) substituindo-se a inversa da matriz de covariância pela matriz A , ou seja:

$$f(x) = \varphi((x-m_1)^T A(x-m_1) - (x-m_2)^T A(x-m_2)). \quad (20)$$

Neste sentido, pode-se afirmar que o aprendizado de uma métrica produz como hipótese um classificador linear no caso da distribuição dos dados não ser representada por gaussianas e possuírem a mesma matriz de métricas. Evidentemente, se for optado pelo aprendizado de duas matrizes diferentes de parâmetros tem-se, a exemplo do caso mais geral da Eq. (19), uma função de decisão quadrática. Entretanto, caso seja utilizado o vetor de parâmetros w tem-se também, para dois vetores diferentes de parâmetros, uma função quadrática porém, com uma quantidade linear de parâmetros.

5 FORMULAÇÃO DE PREDIÇÃO ESTRUTURADA

5.1 Problema de Predição Estruturada

O problema de Predição Estruturada se caracteriza pela existência de um conjunto de treinamento $Z = \{(x(i), y(i), i = 1, \dots, m)\}$ formado por uma coleção de pares de entrada e saída, sendo cada par formado por uma amostra representada por um objeto estruturado $x(i)$ (entrada) e um exemplo desejado $y(i)$ (saída). O modelo obedece às restrições e correlações do conjunto estruturado de saída Y em relação ao conjunto de entrada X . Os elementos de Y podem ser formados por objetos estruturados como sequências, árvores ou grafos. Pode-se considerar o problema de Aprendizado de Métrica como um exemplo de modelo de predição estruturada, no qual um conjunto de entrada X é formado por grafos completos e o conjunto de saída Y é formado por subgrafos ou grupos, concordando com um conjunto de relações de similaridade fornecidas pelo especialista.

O problema de inferência associado pode ser tratado como um problema de minimização, relacionado a uma função $Z_x: Y(x) \rightarrow \mathbb{R}$, responsável pela avaliação de cada saída particular. Portanto deve-se determinar: $y^* = \arg \{ \min_{y \in Y(x)} \{Z_x(y)\} \}$. Esta classe de modelos pode ser parametrizada por um vetor de parâmetros w . Desta forma, fazendo: $w \cdot f(x, y) = Z_x(y)$, tem-se a seguinte família linear de hipóteses:

$$H_w(x) = \arg \min_{y \in Y(x)} \{w \cdot f(x, y)\}, \quad (21)$$

onde $(x, y) \in Z = \{x(i), y(i), i = 1, \dots, m\}$, estando a saída y sujeita a alguma função restritiva $g(x, y)$. O objetivo é estimar o vetor w tal que $H_w(x)$ que retrate alguma saída desejada y . Ou seja:

$$y(i) \approx \arg \{ \min_{y \in Y(x(i))} \{w \cdot f(x(i), y)\} \} \quad \forall i.$$

Desta forma, considerando todas as possibilidades de saída, tem-se:

$$\forall y \in y(i): w \cdot f(x(i), y(i)) \leq w \cdot f(x(i), y) \quad \forall i. \quad (22)$$

A solução do problema de predição estruturada pode ser obtida por uma formulação de máxima margem segundo Taskar et al., 2005:

$$\text{Min } \frac{1}{2} ||w||^2 \quad (23)$$

$$\text{Sujeito a: } w \cdot f_i(y_i) \leq \min_{y \in Y(i)} \{w \cdot f_i(y) + l_i(y)\}, \text{ para } i = 1, \dots, m,$$

sendo $f_i(y) = f(x(i), y)$ e a função $l_i(y) = l(y(i), y)$ definida como uma função de perda que escalona o valor geométrico de margem requerido para o falso-exemplo y em relação ao exemplo selecionado $y(i)$. Se for considerada somente a viabilidade das restrições a solução deste problema pode ser obtida com a utilização de uma variante do algoritmo Perceptron Estruturado (Coelho et al., 2012). A regra de correção sem a função de perda pode ser descrita como:

$$\begin{aligned} &\text{Para cada par } (x(i), y(i)), i = 1, \dots, m, \text{ se } (wf_i(y_i) > wf_i(y^*)), \text{ então} \\ &w \leftarrow w - \eta(f_i(y_i) - f_i(y^*)), \end{aligned} \quad (24)$$

sendo $0 < \eta \leq 1$, uma taxa de aprendizado constante e y^* o melhor candidato computado para cada índice i por um algoritmo de otimização.

Fazendo uma analogia com a equação de correção do vetor de parâmetros w estabelecida para o problema de Aprendizado de Métrica pode-se dizer que $w \cdot f_i(y_i)$ representa o custo da função de distância da solução apresentada pelo especialista (J_{exp}) e $w \cdot f_i(y^*)$ o custo da função de distância computada pelo algoritmo K-means (J_{kme}). Esta função de distância pode ser decomposta e computada separadamente para cada grupo considerando a existência de m classes. Neste sentido, o aprendizado de uma métrica traduzida pelo vetor de parâmetros w pode ser modificado adaptando-se a estrutura de um modelo de predição estruturada e possibilitando a imposição de uma margem, representada pelo parâmetro γ , no sentido de encontrar uma solução única para o vetor w . Seguindo Coelho et al., 2012 tem-se a seguinte formulação:

$$\begin{aligned} &\text{Max } \gamma \\ &\text{Sujeito a : } w(f_i(y^*) - f_i(y_i)) \geq \gamma / \|w\|, i=1, \dots, m. \end{aligned} \quad (25)$$

Neste caso, a nova regra de correção para este problema pode ser descrita como:

$$\begin{aligned} &\text{Para cada par } (x(i), y(i)), i = 1, \dots, m, \text{ se } (wf_i(y_i) > wf_i(y^*) - \gamma / \|w\|), \\ &\text{então} \\ &w \leftarrow w(1 - \frac{\eta \gamma}{\|w\|}) - \eta(f_i(y_i) - f_i(y^*)). \end{aligned} \quad (26)$$

5.2 Algoritmo de Relaxação

A abordagem apresentada até então pode ser descrita como uma forma de correção em *batch* que considera o valor do somatório do erro de todos os vetores dentro de cada grupo e realiza a correção do vetor w pelo gradiente da função diferença. Entretanto, apesar da função de distância total computada pelo K-means apresentar valores sempre inferiores aos valores da função de distância total computada pela solução do especialista, até ocorrer a convergência não se garante que o mesmo seja verdade para cada grupo individualmente. Tal fato, prejudica a implementação multiclasse do perceptron estruturado com margem e a adoção de uma técnica de relaxação. Também, o processamento em *batch* provoca grandes variações de correção na componente do vetor w tornando o método do gradiente instável e exigindo um maior controle do tamanho do passo (taxa de aprendizagem η).

Neste sentido, para corrigir este problema, é possível considerar a correção do vetor w para cada erro individual de um vetor. Neste caso, adota-se uma estratégia diferente da solução abordada na seção 4.2, fixando-se o esquema de rotulação segundo a informação do especialista e modificando-se o conjunto de centroides. Ou seja, caso a distância parametrizada de um vetor x_i em relação ao seu centroide c_l seja maior do que a distância em relação ao melhor centroide candidato c_k onde $k = \operatorname{argmin}_{j \neq l} \|x_i - c_j\|_w$ então se promove a correção do vetor de parâmetros w para forçar a satisfação desta restrição. Desta forma, utilizando a definição de distância parametrizada entre o vetor e seu respectivo centroide:

$d_w(x_i, c_l) = (x_i - c_l)^T W (x_i - c_l) = \sum_j w_j (x_{ij} - c_{lj})^2$ tem-se que resolver o seguinte problema de maximização de margem:

$$\begin{aligned} & \text{Min } \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \\ & \text{Sujeito a: } d_w(x_i, c_k) - d_w(x_i, c_l) \geq 1 - \xi_i \\ & \xi, w \geq 0, \end{aligned} \quad (27)$$

onde ξ se refere ao vetor de variáveis de folga.

A fim de evitar a solução de um problema de otimização quadrático pode se reformular o problema de maximização de margem segundo a Eq. (25) relacionada ao modelo do perceptron estruturado com margem

$$\begin{aligned} & \text{Max } \gamma \\ & \text{Sujeito a: } d_w(x_i, c_k) - d_w(x_i, c_l) + \lambda \alpha_i \geq \gamma \|w\|, i=1, \dots, m. \\ & \alpha, w \geq 0, \end{aligned} \quad (28)$$

onde α representa o vetor de variáveis duais ou de multiplicadores de Lagrange associado as restrições do sistema e $\lambda = 1/C$ uma constante de penalização. Esta formulação garante o processo de flexibilização da margem semelhante à penalização quadrática do vetor de variáveis de folga ξ (Villela et al., 2016). Assim, a nova regra de correção fica estabelecida da seguinte forma :

$$\begin{aligned} & \text{Para qualquer vetor } x_i \text{ associado ao centroide } c_l \\ & \text{Se } d_w(x_i, c_k) - d_w(x_i, c_l) + \lambda \alpha_i < \gamma \|w\| \text{ então} \\ & w \leftarrow w(1 - \eta \gamma / \|w\|) - \eta(d_w(x_i, c_l) - d_w(x_i, c_k)), \\ & \alpha \leftarrow \alpha(1 - \eta \gamma / \|w\|) \\ & \alpha_i \leftarrow \alpha_i + \eta. \end{aligned} \quad (29)$$

A solução do sistema apresentado na Eq. (28) se inicia com uma margem γ de valor zero. Após a primeira execução do perceptron estruturado com margem há uma grande possibilidade da margem de parada não ser a máxima. A margem de parada é considerada a margem de menor valor entre as classes, ou seja:

$$\gamma^t = \text{Min}_{i=1, \dots, m} \{\gamma_i\}. \quad (30)$$

Pode-se calcular a nova margem para uma nova execução do algoritmo utilizando-se a margem de parada da iteração anterior, ou seja:

$$\begin{aligned} & \gamma^{t+1} \leftarrow 2 \cdot \gamma^t \text{ ou} \\ & \gamma^{t+1} \leftarrow \gamma^t + \Delta. \end{aligned} \quad (31)$$

Para a solução do novo problema pode-se utilizar como solução inicial os valores do vetor de parâmetros w da iteração anterior. Incrementa-se a margem até a solução não ser mais viável. Caso uma nova margem seja inviável utiliza-se um processo de aproximação baseado em uma pesquisa binária para encontrar a margem máxima admissível.

Para um conjunto de centroides e esquema de rótulos pré-definido por um especialista o problema acima se enquadra como a solução de um problema inverso ao problema de Análise de Agrupamentos resolvido pelo algoritmo K-means, ou seja: qual deve ser a métrica apropriada para que todas as restrições de pertinência de cada vetor ao seu respectivo grupo sejam satisfeitas? De modo contrário, caso a métrica esteja pré-definida, a posição dos centroides e consequente esquema de rótulos e que devem ser computados tendo como base o mesmo esquema de comparação de distâncias.

6 EXPERIMENTOS E RESULTADOS

Inicialmente, assim como em Xing. et al., 2002, apresenta-se os experimentos e resultados obtidos com a aplicação do método de aprendizado de métrica proposto utilizando duas bases de dados geradas artificialmente pelos próprios autores, uma com 2 e outra com 3 dimensões, com a finalidade de ilustrar graficamente a diferença de comportamento do K-means em relação ao K-means parametrizado, evidenciando a importância do aprendizado. Posteriormente, são demonstrados os resultados obtidos de 6 bases de dados não linearmente separáveis extraídas do repositório *UCI Machine Learning Repository* (Lichman, 2013). Para todos os experimentos deste trabalho, a taxa de aprendizado para correção dos vetores w foi definida como $\eta = 0,001$ e a constante de penalização da violação das restrições C variou de 1 até 0.1 dependendo do grau de dificuldade do problema. Vale destacar que toda bases de dados são não linearmente separáveis no espaço de entrada e linearmente separáveis no espaço de características com a utilização de um *kernel* polinomial de grau 2 ou 3. Também, os dados não foram normalizados o que de certa forma prejudica um pouco os resultados de acurácia dos experimentos reportados..

Na Figura 1, a base artificial gerada em duas dimensões possui 1000 vetores. Dois grupos (vermelho e preto) são indicados pelo especialista, no primeiro gráfico da esquerda para a direita, com 500 pontos em cada classe. No gráfico central é demonstrada a solução obtida pelo algoritmo K-means *offline*, cuja implementação está descrita seção 4 deste trabalho. No gráfico da direita está a solução obtida pelo K-means parametrizado, que acerta 100% em relação aos grupos apontados inicialmente pelo especialista. Neste último gráfico, é possível perceber que é reduzida a importância de uma das dimensões da base, fazendo com que a dimensão que tenha maior relevância, de acordo com a rotulação inicial dos dados feita pelo especialista, seja levada em consideração.




Figura 1. Base em R^2

Na Figura 2, da mesma forma que no primeiro exemplo, a técnica de Aprendizado de Métrica proposta neste trabalho fica evidente. Em três dimensões, na base gerada com 600 pontos divididos em dois grupos (conforme descrição do especialista) o K-means com métrica Euclidiana não foi efetivo na identificação dos grupos esperados. Já o K-means parametrizado

consegue aprender a métrica que gera o resultado esperado para a divisão em duas classes, acertando 100% em relação ao rotulado pelo especialista.




Figura 2. Base em R^3

Na Tabela 1 são apresentados os resultados obtidos pelo o método proposto em bases de dados do repositório *UCI Machine Learning Repository* (Lichman 2013) considerando 100% dos dados a fim de ratificar a importância do aprendizado com informações adicionais em relação a métrica Euclidiana. Neste sentido, comparou-se o resultado considerando o algoritmo K-means com métrica Euclidiana (K-means¹), K-means parametrizado (K-means²) e K-means parametrizado com margem (K-means³). Como dados de entrada do especialista foram utilizados informações referentes à classe a qual cada vetor pertencia. Sempre foi utilizado o processo de flexibilização da margem e atribuído erro de classificação as amostras que apresentaram uma margem negativa. Os erros de margem não foram considerados. Nos experimentos ficou evidenciado que o aprendizado de métrica e a utilização de uma margem contribuíram efetivamente para melhora dos resultados na identificação dos grupos. O método ainda demonstrou estabilidade, haja vista que convergiu em todos os experimentos.

Tabela 1. Descrição das Bases e Resultados

Base	Tamanho	Classes	Dimensões	Resultados Acurácia (%)		
				Kmeans ¹	Kmeans ²	Kmeans ³
Ionosphere	361	2	34	72,23	75,35	80,10
Wine	168	3	12	47,61	66,67	80,36
Balance	625	3	4	63,20	68,60	68,00
Breast Cancer	569	2	30	79,96	85,30	89,83
Iris	150	3	4	88,67	96,00	96,67
Parkinsons	197	2	23	72,82	73,85	74,36

Na Tabela 2 são apresentados os resultados para as mesmas bases relativos aos testes de generalização. Para tanto se considerou a realização de 20 experimentos para cada base escolhendo-se de forma randômica e balanceada 50% dos dados para treinamento e 50% dos dados para teste. Para realização da classificação das amostras dos conjuntos de testes foi utilizado o algoritmo NCC com as métricas correspondentes.

Tabela 2. Descrição das Bases e Resultados

Base	Tamanho	Classes	Dimensões	Resultados Teste (%)		
				NCC ¹	NCC ²	NCC ³
Ionosphere	361	2	34	68,10	81,20	86,74
Wine	168	3	12	44,80	69,90	72,04
Balance	625	3	4	56,50	73,00	72,60
Breast Cancer	569	2	30	77,21	82,47	90,10
Iris	150	3	4	91,50	93,60	93,30
Parkinsons	197	2	23	70,78	73,33	73,36

7 CONCLUSÕES

Neste trabalho apresentou-se uma abordagem de predição estruturada para a solução do problema de Aprendizado de Métrica considerando o aprendizado de um vetor de parâmetros a partir de um conjunto de informações fornecidas por um especialista. Utilizou-se de um conjunto de distâncias parametrizadas comparadas aos centroides que resultaram em um sistema de inequações propiciando a solução por uma técnica de relaxação bastante eficiente. Como pontos positivos do modelo comparado ao estado da arte cita-se a menor complexidade devido a existência de uma quantidade linear de restrições e a simplicidade da técnica de solução que evita a utilização de métodos de programação quadrática e semidefinida. Os resultados desta técnica demonstraram-se promissores possibilitando, ainda, a obtenção de um novo classificador linear de máxima margem. Como trabalhos futuros pretende-se estender a realização dos experimentos comparando-se os resultados com outros algoritmos de classificação de máxima margem como exemplo a Máquina de Vetores Suportes e utilizando-se, também, de uma métrica apropriada para cada classe. Também, se pretende aprimorar a solução do problema de Aprendizado de Métrica para dados não linearmente separáveis com a introdução de funções *kernel* e, consequente, realização da Análise de Agrupamento no espaço de características (Coelho et al., 2016). Finalmente, considera-se a possibilidade de desenvolvimento de um modelo de Aprendizado de Métrica para o aprendizado *online* explorando a mesma metodologia proposta neste trabalho.

AGRADECIMENTOS

Os autores agradecem ao CNPq, CAPES e FAPEMIG pelo apoio financeiro ao desenvolvimento desta pesquisa.

REFERÊNCIAS

- Bellet, A., Habrard, A., and Sebban, M., 2013. A survey on metric learning for feature vectors and structured data. Source in arXiv preprint arXiv:1306.6709.
- Coelho, M. A. N., Borges, C. C. H., and Neto, R. F., 2016. A dual method for solving the nonlinear structured prediction problem. *Pattern Recognition Letters*, 75, pp. 55-62.
- Coelho, M. A. N., Neto, R. F., and Borges, C. C. H., 2012. Perceptron models for online structured prediction. In *Proceedings of 13th International Conference on Intelligent Data Engineering and Automated Learning*. Springer Berlin Heidelberg, pp. 320-327.
- Cortes, C. and Vapnik, V., 1995. Support-Vector Networks. *Machine Learning*, 20, pp. 273-297.
- Cover, T., and Hart, P., 1967. Nearest neighbor pattern classification. *IEEE Transactions in Information Theory*, IT-13, pp. 21-27.
- Davis, J. V., Kulis, B., Jain, P., Sra, S., and Dhillon, I. S., 2007. Information-theoretic metric learning. In *Proceedings of the 24th International Conference on Machine Learning*, pp. 209-216.
- Edwards, A. W., Cavalli-Sforza, L. L., 1965. A method for cluster analysis. *Biometrics*, JSTOR, pp. 362-375.
- Fagundes, F.L., Borges, C.C.H. and Fonseca Neto, R., 2016. Aprendizado de Métrica utilizando uma Função de Distância Parametrizada e o Algoritmo K-means. *Anais do XIII Encontro Nacional de Inteligência Artificial e Computacional*, Recife, Brazil.
- Fisher, R.A., 1936. The use of multiple measurements in taxonomic problems. *Ann. Eugenics*, 7, pp. 111-132.
- Girolami, M., 2002. Mercer kernel-based clustering in feature space. *IEEE Transactions on Neural Networks*, 13(3), pp. 780-784.
- Hamerly, G., and Elkan, C., 2002. Alternative to the K-means algorithm that find better clusterings. In *Proceedings of the 11^{en} International Conference on Information and Knowledge Management (CIKM)*.
- Hastie, T. and Tibshirani, R., 1996. Discriminant adaptive nearest neighbor classification. *IEEE Trans. on Pattern Analysis and Machine Learning*, 18, pp. 607-616.
- Jain, P., Kulis, B., Dhillon, I. S., and Grauman, K., 2008. Online metric learning and fast similarity search. In *Advances in Neural Information Processing Systems*, 21, pp. 761-768.
- Kulis, B., 2013. Metric Learning: A Survey. *Foundations and Trends® in Machine Learning*, 5 (4), pp. 287-364.
- Lichman, M., 2013. UCI Machine Learning Repository [<http://archive.ics.uci.edu/ml>]. Irvine, CA: University of California, School of Information and Computer Science.
- MacQueen, J. B., 1967. Some Methods for classification and Analysis of Multivariate Observations. In *Proceedings of 5th Berkeley Symposium on Mathematical Statistics and Probability*. University of California Press., pp. 281-297.

- Shalev-Shwartz, S., Singer, Y., and Ng, A. Y., 2004. Online and batch learning of pseudo-metrics. *In Proceedings of the 21st International conference on Machine learning*, pp. 94.
- Scholkopf, B. and Smola, A., 2002. Learning with Kernels. *The MIT Press*.
- Schultz, M. and Joachims, T., 2003. Learning a Distance Metric from Relative Comparisons. *In Advances in Neural Information Processing Systems*, 16.
- Taskar, B., Chatalbashev, V., Koller, D., and Guestrin, C., 2005. Learning structured prediction models: A large margin approach. *In Proceedings of the 22nd International Conference on Machine Learning*, pp. 896-903.
- Villela, S.M., Leite, S.C. and Fonseca Neto, R., 2016. Incremental p-margin algorithm for classification with arbitrary norm. *Pattern Recognition*, 55, pp. 261-272.
- Wagstaff, K., Cardie, C., Rogers, S., and Schroedl, S., 2001. Constrained k-means clustering with background knowledge. *In Proceedings of the 18th International Conference on Machine Learning*.
- Xing, E., Ng, A.Y., Jordan, M., and Russell, S., 2002. Distance metric learning, with application to clustering with side information. *In Proceedings of 15th International Conference in Neural Information Processing Systems*, pp. 521-528.
- Yang, L., and Jin, R., 2006. Distance metric learning: A comprehensive Survey. *Michigan State University*, 2, 78.