

Subject: Re: rescrever

Date: Wednesday, 30 September 2026 at 08:34:43 Brasilia Standard Time

From: RAUL FONSECA NETO

To: George Gomes da Silva

Na sexta a tarde podemos combinar uma reunião?

Em qua., 30 de set. de 2026, 08:28, George Gomes da Silva <george.gomes@hotmail.com> escreveu:

Raul, bom dia.

Blz, vamos remover.

Att,

From: RAUL FONSECA NETO <raulfonseca.neto@ufjf.br>

Date: Tuesday, 29 September 2026 at 20:26

To: George Gomes da Silva <george.gomes@hotmail.com>

Subject: Re: rescrever

Ok. Então é melhor retirar do texto.

O que acha?

Em ter., 29 de set. de 2026, 14:26, George Gomes da Silva <george.gomes@hotmail.com> escreveu:

Raul,

IC Bootstrap é o intervalo de confiança de 95% da média.

Bootstrap é o método usado para calcular esse intervalo, por reamostragem:

Tenho os valores observados, um por semente.

Sorteio, com reposição, uma nova amostra do mesmo tamanho e calculo a média.

Repito isso 10.000 vezes.

O intervalo vai do percentil 2,5 ao percentil 97,5 dessas médias.

A vantagem é não precisar supor que os dados seguem a distribuição normal.

Faltou explicar isso no texto. Como são só 3 sementes, o intervalo fica limitado ao menor e ao maior valor observado, então ele indica pouco. É para manter o intervalo com a explicação, ou é melhor reportar a média com o mínimo e o máximo das 3 sementes?

Abraços,

From: RAUL FONSECA NETO <raulfonseca.neto@ufjf.br>
Date: Monday, 28 September 2026 at 15:26
To: George Gomes da Silva <george.gomes@hotmail.com>
Subject: Re: rescrever

Também não entendi:
IC bootstrap 95%.

Em seg., 28 de set. de 2026 às 15:20, RAUL FONSECA NETO
<raulfonseca.neto@ufjf.br> escreveu:

Oi George não entendi:
O salto zero→10-shot na consistência
tem tamanho de efeito grande em C (Cohen's $d = 5,78$) e grande também em B, embora
com maior incerteza ($d = 1,86$; a transferência para B é mais ruidosa entre sementes).
O que significa este Cohen's d ?
coeficiente de Cohens's não é o kappa k ?
Abraços.

Em seg., 28 de set. de 2026 às 15:00, RAUL FONSECA NETO
<raulfonseca.neto@ufjf.br> escreveu:

Oi George, tenho uma dúvida.
Ao estimar a métrica com o perceptron como vc não está fazendo a suavização da
margem como você termina o algoritmo em problemas não linearmente separáveis?
Abraços.

Em seg., 28 de set. de 2026 às 10:13, George Gomes da Silva
<george.gomes@hotmail.com> escreveu:

Raul, bom dia.

Problema A

Fidelidade: o LLM rotula os 150 pontos em *zero-shot*. Com esses rótulos
calculo os centróides e estimo W . A fidelidade é a fração dos pontos em que
a regra do centróide mais próximo, com d_W , coincide com o rótulo do LLM.

Split: não existe no A, a fidelidade é medida nos mesmos 150 pontos.
Calculei agora com validação cruzada e a diferença é pequena (gpt-4o-mini,
Perceptron: 84,0% na amostra e 81,0% fora dela). Se quiser posso adotar split
70/30 mas ainda não é feito.

Ground truth: estimando com os rótulos verdadeiros, a fidelidade fica entre
93% e 98%. Não chega a 100% porque as duas gaussianas se sobrepõem
(erro de Bayes de 4,8%). Com rótulos separáveis chega a 99% ou 100%. Isso
confirma a sua leitura: a fidelidade de 81% a 86% vem do LLM, que em *zero-
shot* acerta só 25% a 31% do ground truth.

Few-shot: ainda não foi feito. Uma forma seria usar k exemplos rotulados
pelo ground truth, k em {4, 10, 20, 40}, retirados do conjunto de estimação. É

para implementar dessa forma?

Problemas B e C

- As amostras são novas: 100 pontos em cada problema, gerados de forma independente, com centróides em outras posições. Não são os pontos do A deslocados.
- Somente W é transferido. Os centróides são recalculados com os rótulos do LLM no próprio B ou C.
- Hoje a consistência é calculada só com a métrica *zero-shot*. É para calcular também com a métrica *few-shot* e reportar as duas?

Problema D

- Sim, é estimada uma nova métrica, a partir dos rótulos do LLM na meia-lua, em R^2 , R^3 e R^4 . A fidelidade fica em torno de 82% no gemini. O gpt-4o-mini coloca todos os pontos em uma única classe em 2 das 3 sementes.
- A estimativa em relação ao ground truth já existe e dá cerca de 86%. A estimativa em *few-shot* ainda não existe. É para repetir no D o mesmo protocolo do A?

Abraços,

From: RAUL FONSECA NETO <raulfonseca.neto@ufjf.br>

Date: Saturday, 26 September 2026 at 06:51

To: George Gomes da Silva <george.gomes@hotmail.com>

Subject: Re: rescrever

Bom dia George,
vamos sanar algumas dúvidas em relação aos experimentos Bloco 1 problemas A-D.

Problema A:

Como é calculada a fidelidade da métrica em relação ao conjunto de amostras.

Existe um split treino/teste ?

Estimar a métrica em few-shot em relação a LLM.

Motivo: o problema é linear. Talvez a demonstração de alguns exemplos force uma rotulação melhor da LLM nos demais.

Assim os estimadores como são lineares podem apresentar uma fidelidade melhor.

Aproveitar e estimar também a métrica em relação ao ground truth.

Motivo: como o problema é linear a fidelidade deve ser de 100%. Isto explica melhor a fidelidade modesta em relação a LLM.

Problemas B e C:

Explicar melhor a transferência dos centroides. As amostras também são modificadas?

Para consistência usar a melhor métrica estimada lembrando que agora temos duas, zero-shot e few-shot, ou reportar o resultado com as duas.

Problema D:

É estimada uma nova métrica? Acredito que sim.

Repetir o mesmo protocolo do problema A inclusive estimando também em few-shot.

Abraços.

Em sex., 25 de set. de 2026 às 14:34, RAUL FONSECA NETO

<raulfonseca.neto@ufjf.br> escreveu:

Sim George é isto mesmo.

Realmente não faz sentido perguntar de novo para o mesmo exemplo.

Acho que este feedback deveria ser utilizado somente no problema real pesoxaltura.

Senão vai ficar trabalhoso demais.

Quanto ao problema A vale a pena fazer o few-shot primeiro, antes da rotulação.

Vai gerar mais uma tabela.

Pode ser que a fidelidade da métrica estimada melhore.

Acabei a metodologia, está em anexo.

Abraços.

Em sex., 25 de set. de 2026 às 14:21, George Gomes da Silva

<george.gomes@hotmail.com> escreveu:

Boa tarde Raul,

Entendi o teste do retorno imediato. Antes de implementar, queria confirmar dois pontos.

Primeiro, uma observação sobre o que o teste mede. Pela API o modelo não é alterado: a correção "errado, a classe é B" entra apenas como texto no contexto, do mesmo modo que um exemplo few-shot, só que chegando depois da resposta em vez de antes. O "gradiente no passo forward" é a leitura de Akyürek et al. sobre o que a atenção faz com esse contexto, mas o mecanismo é o mesmo do few-shot que já uso. Então o que o teste compara é: exemplos entregues como correção, na ordem do teste, ensinam mais ou menos que os mesmos exemplos entregues de uma vez no início? Um ponto de atenção é que os exemplos corrigidos são justamente os que o modelo errou, perto da fronteira, e o experimento da Fase E mostrou que exemplos assim ensinam menos que os claros.

Segundo, o desenho. Com duas classes, perguntar de novo o mesmo ponto depois de dizer que errou é trivial: só resta a outra classe e o modelo acerta sempre. O que faz sentido medir é o efeito sobre os pontos seguintes: o modelo erra no ponto i, recebe a correção na

conversa, e eu verifico se acerta mais nos pontos que vêm depois. Mediria a acurácia por posição na sequência e reestimaria a métrica em janelas, para ver se ela se aproxima do ground truth, comparando com a versão em que os exemplos entram todos no início.

Isso exige um novo modo de coleta com a conversa mantida, mas o custo é baixo. O senhor confirma que é para fazer nesse formato?

Abraços,

From: RAUL FONSECA NETO <raulfonseca.neto@ufjf.br>
Date: Monday, 21 September 2026 at 15:15
To: George Gomes da Silva <george.gomes@hotmail.com>
Subject: Re: rescrever

Oi George, gostaria que fizesse um teste.

Estamos propondo um feedback imediato quando o modelo responde errado .

Caso você informe este erro e pergunte novamente, será que isto melhora ?

Ou seja, ele utiliza esta informação positivamente e tende a acertar mais, melhorando a sua acurácia?

Estou falando isto pois é possível ajustarmos a métrica no tempo de teste no sentido dela ficar mais

fidedigna ao LLM e também ao ground truth.

Vou te enviar novamente a fundamentação teórica. Escrevi sobre isto no final dela.

Outra coisa importante, mas não agora, seria o cálculo do vetor alfa.

Para tanto teria que ajustar o algoritmo a versão final que te passei.

Este vetor mede a importância de cada amostra no processo classificatório e tem uma relação com o mecanismo de auto-atenção do transformer.

Vamos ver se marcamos uma reunião para semana que vem.

Esta semana é a defesa do Igor e eu estou muito atarefado. .

Abraços.

Em seg., 21 de set. de 2026 às 14:52, George Gomes da Silva <george.gomes@hotmail.com> escreveu:
| Raul, boa tarde.

No paragrafo 1 deixei a explicação do fallback em vermelho, porém ele não foi executado em nenhum momento, eu acho melhor remover essa explicação, pois pode gerar confusão e o código nunca chegou a ser executado.

Parágrafo 1

Os detalhes de como as respostas foram coletadas ficam no Apêndice A: as consultas ao modelo foram feitas em paralelo, com um limite de dez ao mesmo tempo, cada resposta passou por um tratamento que reconhece o rótulo mesmo quando o modelo responde com variações de formato (por exemplo, "Classe A" em vez de "A"), e o mesmo protocolo foi repetido para todas as combinações de nomes de classe, nomes de atributo, versões de enunciado e quantidades de exemplos. Quando uma resposta não pode ser interpretada nem depois de reenviar a pergunta, o protocolo atribui um rótulo por um sorteio fixo, calculado a partir das coordenadas do ponto, para que o rótulo não dependa da posição do ponto no plano. Vale registrar desde já que esse recurso não precisou ser usado nenhuma vez nesta execução: das 129.868 consultas feitas aos dois modelos, todas foram interpretadas normalmente. Assim, as medidas de concordância apresentadas no artigo refletem apenas decisões reais do modelo, sem nenhum rótulo atribuído por sorteio.

Parágrafo 2

Depois da coleta, uma verificação feita sobre o registro de todas as consultas mediu quanto cada modelo muda de resposta quando recebe exatamente a mesma pergunta mais de uma vez, mesmo com a temperatura ajustada em zero, que em tese deveria tornar a resposta sempre igual. Aqui os dois modelos se comportam de forma diferente. O gpt-4o-mini mudou de resposta em 4,3% das perguntas repetidas; o gemini-2.5-flash-lite não mudou em nenhuma. Para o gpt-4o-mini, esses 4,3% funcionam como o ruído inerente da medição: se o próprio modelo discorda de si mesmo em cerca de 4% dos casos, nenhuma medida de concordância com ele, seja a fidelidade da métrica estimada, a consistência ou o coeficiente kappa, pode passar de aproximadamente 96%. Todos os resultados desse modelo devem ser lidos tendo esse teto em mente. As decisões foram coletadas em 5 de julho de 2026, e a versão exata do gpt-4o-mini usada (gpt-4o-mini-2024-07-18) ficou registrada em cada consulta, conforme discutido nas Limitações.

Abraços.

From: RAUL FONSECA NETO <raulfonseca.neto@ufjf.br>
Date: Friday, 18 September 2026 at 14:51
To: George Gomes da Silva <george.gomes@hotmail.com>
Subject: rescrever

Oi George, reescreva estes dois parágrafos para mim, explicando melhor e com termos menos técnicos. Pode devolver em texto mesmo.
Abraços.

Os detalhes operacionais da coleta (chamadas assíncronas com concorrência limitada. As respostas passam por um tratamento de respostas malformadas, grade completa de nomes de classe, nomes de atributo, variantes de parser de 8 camadas prompt (0–7) que trata variações de formato; respostas irrecuperáveis após reenvios recebem rótulo por e tamanhos few-shot) estão descritos no Apêndice A; registra-se desde já que o fallback de respostas malformadas hash não foi acionado MD5 determinístico das coordenadas (evitando viés geométrico). Nesta execução não houve acionamento do fallback em nenhum dos modelos (0,00% de 129 868 chamadas): , de modo que as métricas de κ /consistência não contêm rótulos pseudo-aleatórios.

A auditoria offline das interações registradas quantificou também o não-determinismo residual, e aqui os dois modelos divergem nitidamente: a taxa de flip em consultas repetidas a $T = 0$ é de 4,3% no gpt-4o-mini, mas de 0,0% no gemini-2.5-flash-lite (determinismo estrito no provedor pinado). Para o gpt-4o-mini, esse valor constitui o piso de ruído de medição do protocolo: nenhuma métrica de concordância com o LLM (fidelidade, consistência, κ) pode exceder $\approx 96\%$, e os resultados devem ser interpretados contra esse teto.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF Nº 1, de 11 de janeiro de 2023.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF Nº 1, de 11 de janeiro de 2023.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF Nº 1, de 11 de janeiro de 2023.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF Nº 1, de 11 de janeiro de 2023.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF N° 1, de 11 de janeiro de 2023.

É obrigatório o uso do e-mail @ufjf.br ou @estudante.ufjf.br ou @visitante.ufjf.br em todas as comunicações oficiais, conforme o art. 6º da Resolução CGD/UFJF N° 1, de 11 de janeiro de 2023.