

Bom dia, professor. Vou apresentar minha dissertação de mestrado — *Explicando Decisões de LLMs via Otimização Inversa* — orientada pelo Prof. Raul Fonseca Neto. A apresentação está organizada em três blocos auto-contidos: no Bloco 1 o LLM é a fonte de decisões; no Bloco 2 o LLM é o aprendiz (Problema E); no Bloco 3 aplicamos tudo na base real peso $\times$ altura. Os números desta apresentação vêm de execução completa de produção com 3 sementes e 3 repetições.

LLMs são caixas-pretas. Pedir explicação em linguagem natural dá racionalização, não causa real. Em aplicações críticas isso é insuficiente. A pergunta central: o LLM tem um processo decisório estável e aprendível? Em vez de pedir explicação, observamos as decisões e recuperamos o critério por trás delas via otimização inversa.

Cinco hipóteses. H1 e H2 no Bloco 1: critério estável e few-shot amplifica. H3 e H4 no Bloco 2: LLM aprende via in-context learning e exemplos hard deveriam ensinar mais que easy. H5 transversal. Os achados desta execução mostram que H4 é refutada em `n_shot` pequeno mas revertida em `n_shot=40` — diagnóstico mais nuançado que o esperado.

Trato cada classificação do LLM como saída de um classificador nearest-centroid ponderado por Mahalanobis diagonal. Dados pares ponto-rótulo do LLM, encontro $W \geq 0$ que reproduz suas decisões. Uso dois algoritmos independentes — Perceptron Estruturado e NNLS. Se ambos chegam ao mesmo W , a evidência não depende do método.

A distância é $d_W(x, c) = \sum w_j (x_j - c_j)^2$. Classificador: argmin sobre as classes. Mahalanobis diagonal corresponde a Σ^{-1} quando features são independentes. $O(d)$ parâmetros e interpretabilidade direta. Destaco a nomenclatura das fases — Problema D é meia-lua não-linear (Bloco 1), Problema E é LLM aprendiz (Bloco 2).

Esta é a execução de produção completa: 3 sementes (42, 123, 7), 3 repetições por configuração, `n_shots` de 0 a 40, 4 estratégias, 3 experts. 9 observações por célula para bootstrap CI. Modelo gpt-4o-mini com temperatura zero. Foram 119.713 chamadas ao LLM ao todo, com taxa de fallback do parser de 0,00% — ou seja, nenhum rótulo foi decidido por hash, o que sustenta a credibilidade dos kappas. Rodamos também uma auditoria offline sobre todas as interações registradas, e ela mediu o não-determinismo da temperatura zero: 4,753% das 29.116 consultas repetidas — 1.384 delas — receberam respostas divergentes entre repetições. Esse número é importante porque é o piso de ruído da nossa medição: nenhuma métrica de concordância com o LLM pode passar de uns 95%, e é contra esse teto que os kappas e as fidelidades devem ser lidos. A coleta ocorreu entre 30 de junho e primeiro de julho de 2026, pelo alias gpt-4o-mini — sem snapshot datado do provedor, o que registramos como limitação. Hiperparâmetros do Perceptron: $\eta = 0,001$ e $C = 1,0$, conforme CILAMCE 2017.

Mostro o pseudocódigo completo do Perceptron Estruturado, do artigo de Coelho, Borges e Fonseca Neto, CILAMCE 2017, Seção 5.2. A estrutura tem duas camadas: busca binária no γ ótimo (loop externo, Equação 31) e Perceptron interno que corrige w por ponto violado (Equação 29). Os hiperparâmetros do artigo são $\eta = 0,001$ e C entre 0,1 e 1,0; usamos 1,0. Peço atenção para a projeção em $w \geq 0$ que garante semidefinição positiva da matriz diagonal. O atributo `gamma_history` capturado em cada iteração fornece o diagnóstico da busca binária que o professor pediu na reunião de 30/04 em torno de $\sim 520s$ — a figura aparece no slide 83.

Mostro o pseudocódigo do NNLS de Lawson e Hanson de 1974. Construção da matriz A com diferenças de quadrados de distâncias aos centróides e vetor b de uns (margem-alvo). Chamada única para `scipy.optimize.nnls(A, b)` resolve a otimização $\min \|Aw - b\|^2$ com $w \geq 0$. Vantagens sobre Perceptron: zero hiperparâmetros, determinístico (reproduzível bit-a-bit), otimalidade global garantida do problema convexo QP. Cosseno típico com o W do Perceptron acima de 0,97 — validação cruzada do método.

Pipeline com 5 camadas de proteção: parser de 7 camadas, até 5 tentativas para respostas malformadas, fallback determinístico por hash MD5 sem viés geométrico, concorrência assíncrona com semáforo de 10 que reduz tempo em uma ordem de magnitude, timeout de 60s com wrap de 90s contra travamento.

Entramos no Bloco 1, onde o LLM é a fonte de decisões. O LLM rotula, nós aprendemos a métrica W . Cobrirei os problemas A, B, C lineares e o D meia-lua. Hipóteses: H_1 e H_2 .

Apresento textualmente os 4 problemas que serão detalhados nos próximos slides. Problema A é a bancada de treinamento, gaussianas lineares com centróides em $(-2, 0)$ e $(2, 0)$, $n = 150$. Problema B é rotação horária agressiva, centróides em $(-2; +1,5)$ e $(2; -1,5)$, $n = 100$. Problema C é a rotação anti-horária pareada simetricamente, centróides em $(-2; -1,5)$ e $(2; +1,5)$. Problema D é a meia-lua sintética do `make_moons` com $n = 150$ e ruído 0,15 — problema-controle para R3/R4. Os primeiros 3 são lineares com transferência desafiadora; o 4º é o teste explícito de não-linearidade.

A bancada de treinamento. `make_blobs`, centróides em $(-2, 0)$ e $(2, 0)$, desvio padrão 1,2 isotrópico, 150 amostras. Linearmente separável em x_1 . Fácil para o LLM.

Testa transferência em geometria deslocada agressivamente. Centróides em $(-2; +1,5)$ e $(2; -1,5)$ — rotação horária. Magnitude $\pm 1,5$, simetricamente pareada com C. Mais agressiva que a versão anterior de $\pm 0,8$.

Mesma magnitude de B mas direção oposta: anti-horária. Centróides em $(-2; -1,5)$ e $(2; +1,5)$. O orientador pediu esta orientação oposta na reunião de 30 de abril, porque o C anterior parecia cópia de B. Agora B e C são pares: mesma severidade, direções opostas.

Meia-lua entra no Bloco 1 como problema-controle não-linear. `make_moons` com $n = 150$, ruído 0,15. O orientador disse na reunião: "a base da meia-lua você acha em qualquer lugar aí". Era onde esperávamos que a métrica diagonal satura em torno de 87% mesmo ajustada ao rótulo verdadeiro, então esse "controle positivo" vira, na verdade, uma demonstração do limite da diagonal.

Primeira parte do sanity check. Pergunta: se W verdadeiro fosse conhecido, Perceptron e NNLS o recuperariam? Gero dados sintéticos com W oráculo em três configurações anisotrópicas e aprendo $\hat{W}$ via os dois algoritmos. A tabela mostra resultado médio em 3 seeds. Em $x2_dom$ (razão verdadeira 16), NNLS chega a razão infinita (acerta a direção perfeitamente), cosseno 0,999; Perceptron normaliza para razão 1,32, cosseno 0,824. Mesmo padrão em $x1_dom$ e forte $_aniso$: NNLS preserva razões extremas, Perceptron tende a centralizar. Mensagem-chave: ambos atingem fidelidade 100% — o sinal classificatório foi capturado — mas NNLS é fiel à magnitude exata do W oráculo.

Aqui o gráfico grande do painel 2x2: cosseno por configuração, fidelidade por configuração, razão w_1/w_2 recuperada vs verdadeira, e scatter de W recuperado vs oráculo. Visualmente fica claro o padrão da tabela anterior: NNLS pontos próximos da diagonal (acerta razão), Perceptron pontos concentrados perto do meio (normaliza). Mensagem para a banca: a discrepância entre algoritmos não é bug — é diferença metodológica conhecida. NNLS é otim global, Perceptron é gradient descent com regularização implícita pela margem.

Segunda parte do sanity check, agora sobre transferência. Pergunta dual: se aprendo W em uma geometria, ele transfere para outra? Aprendo W em $x2_dom$, aplico em $x1_dom$, forte_aniso, Problemas A e E. A tabela mostra cosseno alto entre o W aprendido em origem e o W oráculo no destino. Em problemas com geometria similar, transferencia funciona; em Problema A (gaussianas isotrópicas), cosseno cai para 0,75 — a geometria é suficientemente diferente. Mensagem: implicação direta para Problemas B/C — sempre recalculamos centróides LOCAIS, não reaproveitamos do Problema A. A métrica não é independente da geometria do problema.

Quarto slide do Oracle. Gráfico grande mostrando os sub-painéis de transferência: cada expert origem com suas curvas para os experts destino. Conclusão do sanity check Oracle: ambos algoritmos passam — recuperam W ($\sim$ fidelidade 100%) e transferem com cosseno alto entre geometrias similares. Caminho está livre para aplicar o método ao LLM nas próximas seções.

A Problema A: LLM recebe 150 pontos em zero-shot, responde A ou B. As respostas formam (X, y_{LLM}) . Centróides recalculados a partir das respostas do LLM — ancoramos no que o LLM ACHA serem as classes. Perceptron e NNLS aprendem W . Medimos fidelidade.

Com as 3 seeds, a fidelidade média da Problema A foi 81,3% com desvio 4,4 pontos percentuais. Por seed: 76,7, 85,3, 82,0%. A acurácia do LLM contra o ground truth foi apenas cerca de 33% — o LLM inverteu classes em vários casos. Mesmo assim, a métrica reproduz 81% dessas decisões, demonstrando que H1 mede consistência interna, não correção. Esse ponto é importante para a banca: uma acurácia baixa contra a verdade não invalida a hipótese, porque a pergunta é se o critério do LLM é estável, não se ele está certo.

O painel mostra a distribuição do W aprendido pelos dois algoritmos nas três seeds. Boxplot, ratio w_1/w_2 , scatter de W . Estabilidade qualitativa entre seeds.

Perceptron e NNLS lado a lado: fidelidade, fases B/C, scatter de W . Mensagem: os dois algoritmos são congruentes com cosseno de 0,994 nesta execução. Robustez ao método de estimação.

Aqui faço uma decisão metodológica explícita para a banca. O trabalho mede consistência interna do critério decisório do LLM: fidelidade na Problema A (quanto $\hat{W}$ reproduz y_{LLM}), consistência em B/C (quanto $\hat{W}_A$ prevê y_{LLM} em novos problemas) e acurácia LLM-perito na Problema E. Decisão: não comparamos com ground truth nos problemas sintéticos. Razão: H1 testa se o LLM tem critério estável, não se ele está objetivamente correto. Um LLM pode inverter classes e ainda assim ser internamente consistente. Exceção: Bloco 3 (peso $\times$ altura) reportará acurácia vs rótulo real, atendendo solicitação explícita do orientador no e-mail das 22:04, ponto 4 — lá há ground truth significativo homem/mulher e classificador ótimo conhecido.

Aqui apresento os pesos $W = (w_1, w_2)$ aprendidos para o Problema A, separados por seed e por algoritmo (Perceptron e NNLS). Média das 3 repetições por seed. Os achados-chave:

Perceptron Estruturado: seed 42 $W = (0,00023, 0,00247)$ razão 0,094; seed 123 $W = (0,00030, 0,00091)$ razão 0,327; seed 7 $W = (0,00005, 0,00037)$ razão 0,138.

NNLS: seed 42 $W = (0,0357, 0,1420)$ razão 0,252; seed 123 $W = (0,0466, 0,1486)$ razão 0,313; seed 7 $W = (0,0394, 0,1522)$ razão 0,259.

Antes das observações, vale esclarecer o que é *fidelidade na Problema A*: é a porcentagem de pontos do Problema A em que o rótulo atribuído pela métrica $\hat{W}$ coincide com o rótulo que o LLM atribuiu. É medida *in-sample*, ou seja, nos mesmos pontos usados para estimar $\hat{W}$. Funciona como sanidade: se fosse baixa, o algoritmo não teria conseguido ajustar uma métrica diagonal aos rótulos do LLM, e tudo que viria depois (consistência em B/C) perderia o sentido. Observações importantes para a banca: as magnitudes diferem muito entre algoritmos (Perceptron cerca de cem vezes menor que NNLS), mas ambos apontam na mesma direção — o cosseno entre os dois W é 0,994, confirmando que a otimização inversa é invariante à escala. Em todas as seeds a razão w_1/w_2 fica abaixo de 1 (cerca de 0,25 no NNLS e entre 0,09 e 0,33 no Perceptron), revelando que o LLM pondera x_2 mais que x_1 , apesar do Problema A ser linearmente separável em x_1 — pequena anisotropia decisória. Vale registrar que a razão é justamente o parâmetro mais ruído entre seeds (coeficiente de variação em torno de 54%), enquanto a direção permanece estável. Por fim, a fidelidade na Problema A é quase idêntica entre os dois algoritmos, reforçando que a estimação de W é robusta.

Apresento a tabela das Fases B e C por seed e por algoritmo, média de 3 repetições por seed, zero-shot. Antes dos números, esclareço o que é consistência: é a porcentagem de pontos em que o rótulo atribuído pela métrica $\hat{W}_A$ — aquela que aprendemos no Problema A — coincide com o rótulo do LLM nos Problemas B e C, que têm geometrias rotacionadas. O Kappa de Cohen corrige por concordância ao acaso. Perceptron por seed: 42 dá B 65,0% / κ 0,20 e C 89,0% / 0,77; 123 dá B 66,7% / 0,28 e C 87,7% / 0,74; 7 dá B 74,3% / 0,44 e C 85,3% / 0,69. Média Perceptron: B 68,7% / 0,31 e C 87,3% / 0,73. NNLS por seed: 42 dá B 68,0% / 0,27 e C 90,0% / 0,79; 123 dá B 67,0% / 0,29 e C 89,0% / 0,77; 7 dá B 76,0% / 0,47 e C 84,0% / 0,66. Média NNLS: B 70,3% / 0,35 e C 87,7% / 0,74. Observações para a banca: H1 é sustentada em C (kappa 0,73) mas fica fraca em B (kappa 0,31), ou seja, parcialmente; em todas as seeds o Kappa em C é bem maior que em B, indicando que a rotação anti-horária preserva melhor o critério decisório do LLM. A seed 7 se comporta como outlier sutil — em B sobe (74%) mas em C cai mais que as outras. Nota metodológica: usamos centróides LOCAIS (recalculados em cada problema a partir de y_{LLM}), mais fiéis à decisão real. O ablativo métrica-contra-Euclidiana em B deu diferença de +0,044 com intervalo que contém zero (não significativa): em B, a rotação horária confunde tanto a métrica que ela não supera a distância Euclidiana simples; em C, o ganho é claro.

A pedido do orientador (reunião 20/05), separei o mapa de acertos e erros em um slide por problema, agora bem maior, para a banca conseguir enxergar ponto a ponto. Este é o Problema B, a rotação horária, com a seed 42 como representante — a tabela anterior já mostrou que ela fica próxima da média. Cada ponto verde é um acerto da métrica $\hat{W}_A$ contra o rótulo do LLM, cada vermelho é um erro. O que importa aqui é o padrão geométrico: os erros se concentram na faixa central, exatamente onde as duas gaussianas rotacionadas se sobrepõem. A métrica $\hat{W}_A$ foi aprendida no Problema A, que não tem rotação; a rotação horária de $\pm 1,5$ deslocou a fronteira do LLM para uma região onde a métrica antiga já não distingue bem. Por isso a consistência cai para cerca de 68% e o Kappa para 0,29. Esse mapa é a versão geométrica daquela estatística.

Este é o slide irmão, agora para o Problema C, a rotação anti-horária de mesma magnitude. A comparação com o slide anterior é o ponto central: aqui os erros aparecem esparsos e isolados, sem concentração em nenhuma região do plano. É justamente isso que faz a consistência subir para cerca de 90% e o Kappa para 0,79 — cerca de três vezes o Kappa do Problema B, mesmo com magnitude de rotação idêntica. A mensagem para a banca é que a direção da rotação importa: a anti-horária preserva muito melhor o critério decisório que o LLM usou no Problema A do que a horária. Ver os dois mapas, um em cada slide e em tamanho grande, deixa essa assimetria $\kappa_C \gg \kappa_B$ visualmente óbvia.

Tabela por seed comparando R2, R3 e R4 em dois problemas: o A (linear, três seeds) e a meia-lua (não-linear). B e C foram omitidos porque são lineares como A. Peso $\times$ altura fica no Bloco 3. Recapitulando: R2 é o espaço original (x_1, x_2); R3 acrescenta o produto $x_1 \cdot x_2$; R4 acrescenta x_1^2 e x_2^2 . No Problema A a fidelidade é contra os rótulos do LLM; o R2 é a fidelidade base de duas features (76,7 / 85,3 / 82,0 por seed, média 81,3%). No Perceptron, R3 fica em 80,0 / 83,3 / 81,3 (média 81,6) e R4 em 78,0 / 83,3 / 89,3 (média 83,6). No NNLS, R3 dá 81,3 / 86,7 / 80,7 (média 82,9) e R4 dá 85,3 / 88,0 / 90,0 (média 87,8). Leitura para A linear: os ganhos R3/R4 ficam dentro do ruído entre seeds — aumento pouco ajuda quando o problema já é linearmente separável. Agora o ponto que mudou nesta execução e que preciso ser honesto com a banca: na meia-lua o LLM colapsou todos os pontos em uma única classe no zero-shot nas TRÊS seeds — o log registra “classe única no LLM, pulando”. Sem dois grupos, não há rótulo do LLM para medir fidelidade, e o pipeline corretamente abortou. Então, em vez da fidelidade-contra-o-LLM, reporto o teste-oráculo: ajusto a métrica diagonal ao rótulo VERDADEIRO da meia-lua. E o resultado é revelador: mesmo com o rótulo certo, a métrica satura em torno de 86,7%, cerca de 20 erros em 150, e R3 e R4 não ajudam — o NNLS inclusive zera os termos aumentados porque exige pesos não-negativos. A mensagem é que a métrica diagonal tem um teto estrutural na meia-lua: capturar a curvatura em S exigiria um termo cruzado off-diagonal, que a nossa formulação diagonal não tem. Dois achados de uma vez: o zero-shot do gpt-4o-mini na meia-lua é instável, e a métrica diagonal é limitada nesse tipo de fronteira — o que motiva justamente o estudo de caso real do Bloco 3 e entra nas limitações.

Aqui apresento a tabela do experimento de inversão de ordem das classes. Para cada par semântico — letras, números, semântico positivo/negativo e cores — rodei o mesmo prompt em duas direções: ordem direta e ordem invertida ($n_shot=10$, média de 3 seeds vezes 3 repetições). Peço atenção para a coluna “Fid. A”: em A/B caiu de 81,3% para 68,9% quando invertemos para B/A; em 0/1 subiu de 59,8% para 76,3% ao virar 1/0; em positivo/negativo a inversão manteve fidelidade alta (98,9% contra 95,3%); em cores a variação foi pequena (88,7% contra 83,8%). Leitura para a banca: existe sim um viés de ordem, e ele varia entre ~ 5 e ~ 16 pontos percentuais na Fid. A dependendo do tipo semântico. Letras e números são mais sensíveis que cores e rótulos semânticos — o LLM parece ter um vínculo mais forte entre certas letras/números e “classe positiva” que persiste mesmo quando trocamos a ordem do prompt. Porém, o viés não é dominante: o critério decisório geral se mantém (consistências B e C continuam altas). Portanto o efeito existe, está documentado, mas não compromete os achados principais.

Complemento visual da tabela anterior. O gráfico `bloco1_12_class_order_bias.png` mostra, para cada par semântico, as barras lado a lado da consistência/Fidelidade em ordem direta versus invertida. Visualmente, a banca pode notar que os pares “A/B vs B/A” e “0/1 vs 1/0” são os de maior amplitude — corroborando a leitura numérica de que letras e números disparam viés maior que cores e rótulos semânticos. Para Pos/Neg e Azul/Vermelho as barras são quase idênticas. Conclusão: o viés de ordem está presente, principalmente em pares letra/número, mas não explica os achados principais do trabalho.

Antes de mostrar os números, exibo o conteúdo de cada variante para o ponto exemplo $x_1 = 1,23$, $x_2 = -0,45$ com classes A/B. O *default* é o template baseline, sem floreios, só pede a classe. O *geometric* acrescenta a frase explicando que os pontos vivem em um espaço métrico euclidiano e que a classificação deve se basear em proximidade espacial aos centros dos clusters. O *CoT* pede que o modelo pense passo a passo e dê a resposta final na última linha. O *tabular* formata as coordenadas em tabela markdown ao invés de prosa. Essas são perturbações pequenas mas controladas; o próximo slide mostra que essas perturbações mudam de fato a métrica recuperada — então o prompt não é neutro.

Aqui apresento a tabela com os resultados das 4 variantes de prompt rodadas nas Problemas A–C completas em todas as seeds. Em zero-shot, média de 3 seeds vezes 3 repetições, configuração A/B com features x_1/x_2 . A variante *default* é o template baseline. *Geometric* acrescenta contexto espacial explícito (eixos e regiões). *CoT* é chain-of-thought, pede raciocínio passo a passo. *Tabular* apresenta as coordenadas em tabela markdown. Os números: default fid A 81,3%, cons B 68,7% / κ_B 0,31, cons C 87,3% / κ_C 0,73. Geometric fica em 83,8 / 68,7 / 0,16 / 77,2 / 0,39. CoT em 76,7 / 61,7 / 0,16 / 79,3 / 0,59. Tabular é o pior: 62,0 / 61,4 / 0,13 / 72,2 / 0,21. Leitura para a banca: o critério para comparar aqui é a *consistência* (kappa em B e C), não a Fid. A isolada. O geometric até empata a Fid. A com o default, mas derruba o κ_C de 0,73 para 0,39 — ou seja, prompts mais elaborados não melhoram a coerência decisória, e o tabular piora tudo. O default puro é o que preserva melhor a consistência. CoT, especificamente, não ajuda em problemas geométricos simples como os nossos — talvez porque introduza ruído verbal sem informação adicional. A tabela markdown degrada ainda mais, provavelmente porque desloca o LLM para um modo de leitura tabular onde os pares (x_1 , x_2) perdem a intuição espacial. Sensibilidade ao prompt é portanto *real e não desprezível* (queda de até 20 p.p. em Fid. A) — adotamos o default como referência e os outros como controle ablativo.

Complemento visual da tabela anterior. A imagem `bloco1_13_prompt_variants.png` mostra, para cada variante de prompt, o scatter dos pesos W aprendidos e as métricas em A, B e C lado a lado. Visualmente fica claro que os pontos de *default* se separam dos pontos de *geometric*, *CoT* e *tabular*. Mensagem para a banca: a configuração do prompt não é neutra — escolhas que parecem inocentes (passar coordenadas em prosa versus tabela versus pedir CoT) modificam mensuravelmente o W que conseguimos recuperar. Por isso a apresentação toda foi padronizada no *default*, e este experimento serve como controle ablativo documentado.

Apresento a tabela com o efeito dos nomes sobre o W recuperado, dividida em duas partes. (a) Classes em $n_shot=10$ com features x_1/x_2 : A/B dá Fid. A 81,3% e cons B/C 94,1/94,6%; 0/1 colapsa Fid. A para 59,8%; Positivo/Negativo infla Fid. A para 98,9% mas degrada κ_B para 0,45; Azul/Vermelho fica próximo de A/B. Semânticas não são neutras — o LLM parece ancorar no significado da palavra. (b) Features em zero-shot, classes A/B — e aqui aviso a banca que esta parte é apenas seed 42, portanto ilustrativa: x_1/x_2 (baseline) Fid. A 76,7%, κ_B 0,20, κ_C 0,77. *altura/peso* reduz a consistência em B — κ_B cai de 0,20 para 0,15 —, mas nesta execução, diferente de antes, não a inverte, não fica negativo; a Fid. A até sobe (84%) e a direção de W é preservada. *feature_1/feature_2* fica em meio termo (76%, 0,32, 0,57). Mensagem para a banca: os nomes semânticos deslocam a magnitude de W e mexem na consistência, mas o efeito é mais brando do que em execuções anteriores; por conservadorismo adotamos x_1/x_2 como baseline em todo o Bloco 1.

Complemento visual: dois painéis lado a lado. À esquerda `bloco1_14a_class_names_effect.png` com o efeito de mudar nome de classe. À direita `bloco1_14b_feature_names_effect.png` com o efeito de mudar nome de feature. Visualmente fica claro que o impacto em features (b) é bem mais pronunciado que em classes (a) — argumento concreto para usar nomes neutros (x_1/x_2 , A/B) em todo o Bloco 1.

Para `n_shot` maior que zero, o prompt inclui exemplos rotulados antes do ponto-alvo. Mostro o template literal para `n_shot=5`: o LLM vê cinco exemplos com x_1 , x_2 e rótulo, e depois o ponto novo a classificar. As variantes `geometric`, `CoT` e `tabular` já foram cobertas no slide 31, portanto aqui só exibo o caso default com cinco exemplos para a banca ver como o few-shot é construído na prática.

Fechando o Bloco 1. Sou honesto com a banca no veredito: H1 fica *parcialmente* sustentada. O Kappa médio em C é 0,73, acima do limiar de 0,5 que fixamos, então a consistência se transfere para a rotação anti-horária; mas em B é só 0,31, abaixo do limiar, pela rotação horária agressiva. Em todas as seeds C supera B, mas não afirmo H1 como plenamente sustentada. Fidelidade da Problema A em torno de 81%. Acurácia do LLM contra real apenas 33% — LLM inverte classes mas continua consistente, o que é o cerne da H1. Os dois algoritmos concordam (cosseno 0,994). Sobre R3/R4: na meia-lua a métrica diagonal satura em cerca de 87% mesmo ajustada ao rótulo verdadeiro, então augmentação só compensa com não-linearidade real e dados suficientes — assunto do Bloco 3. Vieses marginais.

Bloco 2: inversão completa de papéis. Um perito externo rotula, o LLM tenta reproduzir o critério a partir de exemplos few-shot. É a Problema E. Problemas: E (linear com W expert) e F (meia-lua com perito = ground truth). Hipóteses: H3, H4, H5.

Mostro o problema E linear com fronteira do expert quase horizontal, porque w_2 é cinco vezes maior que w_1 . A imagem mostra fronteira de decisão, ground truth e margem.

Problema E é o antigo "Problema D" da Problema D antiga, agora renomeado. Linear, perito anisotrópico $W = [0,3,1,5]$. Fronteira quase horizontal. LLM precisa capturar o padrão a partir de exemplos.

F usaria a meia-lua com ground truth como perito, para testar se o LLM aprende a fronteira em S só com exemplos — seria o teste mais duro de H3. Mas já aviso a banca aqui, para não gerar confusão adiante: nesta execução esse experimento não pôde ser coletado, porque o LLM colapsou em classe única no zero-shot da meia-lua nas três seeds. Nos próximos slides eu explico o que fizemos no lugar, o teste-oráculo, e por que o teste de H3 em regime não-linear migra para a base real do Bloco 3.

Passo a passo: perito rotula os 150 pontos; divido em treino e teste; para cada n_{shot} de 0 a 40, seleciono exemplos via estratégia; envio exemplos + ponto de teste em prompt few-shot; meço acurácia, Kappa, F1 contra perito.

Apresento a tabela consolidada dos resultados da Problema E em que o LLM aprende com o perito linear $W = [0,3, 1,5]$ (x2 dominante). Média de 3 seeds vezes 3 repetições. Acurácia e Kappa do LLM contra o perito, separados por estratégia (easy, hard, mixed, random) e por n_shot (0 a 40). Em zero-shot, todas as estratégias degeneram para o mesmo número (60,9% / 0,23) — sem exemplos não há o que escolher. Em n_shot=5, easy já salta para 84,9% enquanto hard fica em 62,6%. Em n_shot=20 todos sobem, mas easy ainda lidera com 89,8%; note que o random é o melhor overall entre 5 e 20 exemplos. A inversão acontece em n_shot=40: hard salta para 97,8% e ultrapassa easy (88,3%). Mensagem para a banca: H2 (few-shot amplifica) está fortemente sustentada — saltos de quase 40 p.p. só por adicionar exemplos. E a H4 (exemplos difíceis ajudam mais) sai como *refutação nuançada*: refutada em regime de poucos exemplos, mas confirmada em n_shot=40. Estratégia não é monotonicamente boa, depende do regime de quantidade de exemplos — esse é um achado novo que vale destacar.

Quatro estratégias: easy alta margem, hard baixa margem, mixed 50/50, random baseline. A intuição de H4 era que hard ensina mais. Vamos ver que é mais complexo que isso.

Curvas de acurácia versus n_shot para cada estratégia, média de 3 seeds vezes 3 repetições. O LLM melhora em todas as estratégias — H3 sustentada.

Em modelos com gradiente, hard é informativo. LLM in-context não tem gradiente; usa exemplos como âncoras. Easy são pivots claros: "é isto que A parece". Hard são confusos. Com muitos exemplos, há contexto suficiente para hard ajustar fino o critério. Achado novo desta execução: dinâmica muda com `n_shot`.

Testei três experts: aniso_x2 com $W = [0,3,1,5]$ fronteira horizontal, aniso_x1 oposto, e euclidean. As acurácias médias: aniso_x2 vai de 60,9% em zero-shot a 94,3% em 40-shot; aniso_x1 começa quase no acaso (48,5%, o LLM tem viés contra fronteira vertical sem exemplos) e chega a 89,8%; euclidean vai de 55,2% a 91,8%. Todos ultrapassam 90% com 40 exemplos, e o aniso_x2 horizontal atinge o melhor patamar final. Mensagem: o LLM aprende qualquer geometria de perito via few-shot — H3 amplamente sustentada.

Diluição testa se easy dilui o sinal de hard fixos. Fixei 4 hard e adicionei easy progressivamente. Curva monotônica crescente — easy ajuda sempre, não há diluição. Reforça o achado.

Aqui mostro a tabela do experimento de viés de ordem. Fixei a estratégia *mixed* e os mesmos exemplos selecionados; variei apenas a ordem em que aparecem no prompt. Testo quatro ordenações: `class0_first` (todos da classe 0 primeiro), `class1_first` (todos da classe 1 primeiro), `shuffled` (ordem aleatória) e `alternating` (alternando 0, 1, 0, 1). Roda em `n_shot = 5, 10` e `20`. Em `n_shot=5`: amplitude máxima de 4,2 p.p. entre ordenações. Em `n_shot=10`: amplitude sobe um pouco para 7,5 p.p. (`shuffled` lidera com 87,4%, `class0_first` é o pior com 79,9%). Em `n_shot=20`: amplitude colapsa para 2,3 p.p. — todos próximos de 86%. O teste de Kruskal-Wallis não acusa diferença significativa em nenhum `n_shot`. Leitura para a banca: existe sim algum efeito de ordenação em `n_shot` intermediário, mas é marginal (menor que 8 p.p. no pior caso) e some quando se aumenta o número de exemplos. Recency bias não explica os achados principais; o critério decisório do LLM é robusto à ordem.

Complemento visual da tabela anterior. A imagem `bloco2_07_example_order.png` mostra, para cada `n_shot`, as barras das quatro ordenações lado a lado. Visualmente fica claro que as barras são parecidas dentro de cada `n_shot` — corrobora a leitura numérica de que recency bias é marginal.

Aqui preciso ser transparente com a banca: nesta execução o experimento de LLM-aprendiz na meia-lua não pôde ser coletado. O LLM colapsou em classe única no zero-shot nas três seeds — respondeu tudo como uma classe só —, e sem duas classes o pipeline few-shot foi abortado. É um achado honesto sobre a fragilidade do zero-shot em geometria não-linear. No lugar, mostro o teste-oráculo: ajusto a métrica diagonal ao rótulo verdadeiro da meia-lua. Ela satura em cerca de 86,7%, 20 erros em 150, e R3/R4 não ajudam. A métrica diagonal tem teto estrutural nesse problema — precisaria de termo off-diagonal para a curvatura em S.

Este slide atende o item 7 da reunião de 20/05: o professor pediu para sobrepor a superfície de separação de um SVM gaussiano à fronteira do LLM na meia-lua. A figura tem dois painéis com o mesmo SVM RBF como régua. No painel da esquerda, o SVM treinado no ground truth desenha a fronteira não-linear de referência — é o que um classificador competente enxerga nesse problema. No painel da direita, os rótulos zero-shot do LLM: todos os 105 pontos de treino receberam a mesma classe, nas três seeds. Não há fronteira alguma a comparar — e essa ausência é exatamente o resultado. Daí tiro duas lições: sobre o LLM, sem exemplos o gpt-4o-mini não percebe as duas semi-luas, uma fragilidade real do zero-shot em geometria não-linear, não um bug do pipeline; sobre a métrica, o teste-oráculo do slide anterior mostra teto estrutural de 87% da diagonal. A consequência prática é que o teste de “LLM aprendiz” em regime não-linear genuíno migra para o Bloco 3, na base real peso $\times$ altura, onde o LLM de fato recebe exemplos e aprende, e ali a H3 é avaliada com ground truth humano.

Comparo o LLM com k-NN, Logistic Regression e SVM, todos treinados nos MESMOS exemplos few-shot e avaliados no mesmo conjunto de teste, com o perito linear. E aqui vem um achado honesto e importante: no perito linear os baselines clássicos superam o LLM em TODOS os n_shot . A Regressão Logística, que casa exatamente com um perito linear, lidera: 84,6% em 5-shot, subindo a 98,3% em 40-shot, contra o LLM que vai de 74,7% a 92,0%. SVM e k-NN também ficam à frente. A leitura para a banca é direta: quando o critério é trivial e linear, o LLM não faz melhor que um classificador clássico simples — a vantagem do LLM, se houver, tem que aparecer em outro regime, e é o que investigamos no Bloco 3.

Pedido específico do orientador. Para cada n_{shot} , treino um Perceptron Estruturado nos mesmos exemplos. Como a meia-lua colapsou, essa comparação aparece na base real peso $\times$ altura, detalhada no Bloco 3. E o resultado se inverteu em relação a execuções anteriores: agora é o LLM que supera o Perceptron baseline em todos os n_{shot} , de +2,2 até +10,7 pontos percentuais. Em 5-shot, por exemplo, o LLM faz 87,4% contra 76,7% do Perceptron. Não existe mais o antigo “Perceptron 90% contra LLM 83%”.

Fechando o Bloco 2. H3 sustentada com ganho de cerca de 40 pontos percentuais de 0 para 40-shot no perito linear. H4 refutada em `n_shot` pequeno, com significância em 5 e 10-shot, mas revertida em 40-shot, onde o hard alcança 0,98 — diagnóstico mais sofisticado do que o esperado. Ponto honesto: os baselines clássicos superam o LLM em todos os `n_shot` no perito linear. E o regime não-linear, que seria a meia-lua, colapsou nesta execução — ele é retomado na base real do Bloco 3. Recency bias e viés de classes marginais.

Bloco 3: estudo de caso real, peso $\times$ altura, base do orientador. É onde aplicamos tudo o que vimos em dados reais com 100 amostras e fronteira elíptica conhecida. Pergunta: priors semânticos do LLM ajudam ou atrapalham?

Base enviada pelo orientador no e-mail das 19:15 do dia 30 de abril. 100 amostras, 50 homens e 50 mulheres. Features normalizadas em $[-1, 1]$. Classificador ótimo bayesiano fornecido pelo professor tem forma elíptica.

Duas variantes. NEUTRA: features = (x_1, x_2) , LLM não sabe que é peso e altura. SEMÂNTICA: features = (peso, altura), LLM ativa priors. Pergunta em ambas: homem ou mulher.

Aprendo W em três configurações. O gráfico tem quatro painéis: fidelidade e acurácia, pelos dois algoritmos. E, atendendo ao item 3 da reunião de 20/05, agora mostro também o próprio vetor W estimado, por seed e por algoritmo, na configuração de 2 features com prompt semântico. O Perceptron aprende um W quase isotrópico — razão entre os pesos de peso e altura perto de 1 nas três seeds —, enquanto o NNLS aprende um W anisotrópico dominado pela altura. Os dois chegam a acurácias reais próximas, o que ilustra um ponto importante para a banca: o W é identificável apenas a menos de escala, então comparamos direções e razões, não valores absolutos.

Tabela com prompt semântico. Fidelidade da métrica NNLS sobe de 65% em R2 para 75% em R4, enquanto a acurácia REAL fica entre 75 e 85% — e cai justamente em R4, o sinal do overfitting. Nota importante: essa queda em R4 é só do NNLS, porque a restrição de pesos não-negativos zera os termos aumentados; o Perceptron não cai, fica em torno de 91%. Em prompt NEUTRO $\times 1/\times 2$, a acurácia REAL despenca para 45-49%, nível do acaso — o LLM sem prior semântico está perdido.

Em prompt NEUTRO x_1/x_2 , a fidelidade do NNLS sobe de cerca de 59% em R2 para 78% em R4, mas a acurácia REAL fica no acaso — o NNLS vai de 44 para 49%, e o Perceptron até cai, de 54 para 45%. A métrica com 4 pesos para 70 amostras de treino decora o ruído das decisões erradas do LLM. É o overfitting clássico, e o paradoxo: quanto mais a métrica “imita” o LLM, pior ela acerta a verdade. Subir n_{feat} só vale com não-linearidade real E dados suficientes.

Tabela: LLM com prompt semântico atinge cerca de 96% de acurácia _metric em 40-shot — converge para o próprio critério —, e 87% de acurácia real, cerca de 4 erros em 30. E o ponto que mudou: o LLM supera o Perceptron baseline em TODOS os n_shot, de +2,2 até +10,7 pontos percentuais; em 5-shot faz 87,4% contra 76,7%. Diferente de execuções anteriores, em que o Perceptron vencia em 5-shot. Com dados rotulados, na base real, o LLM é competitivo ou melhor.

Este slide atende o pedido do e-mail do orientador de 20/05: repetir a classificação pedindo “A ou B” em vez de “homem ou mulher”. A ideia é isolar o prior semântico dos nomes de classe, complementando o teste de features neutras. O resultado é um dos mais interessantes do Bloco 3: com features semânticas peso e altura, a acurácia contra o rótulo real despenca de 91,4% para 12,9% — 61 erros em 70. E esse número, muito abaixo dos 50% do acaso, não é ruído: é inversão sistemática. O LLM continua separando os dois grupos — se invertêssemos os rótulos, teríamos cerca de 87% — mas, sem a âncora semântica de “homem” e “mulher”, ele não tem como saber qual grupo é “A” e qual é “B”, e a convenção saiu oposta à do ground truth. Ou seja: o prior semântico não atua só nas features, atua também nos nomes das classes — é ele que ancora o mapeamento entre rótulo e grupo. Na Fase E, com exemplos, o LLM adota fielmente a convenção dos exemplos que recebe: a concordância com a métrica-alvo sobe de 74% para 96% em 40-shot, e o baseline Perceptron treinado nos mesmos exemplos se comporta da mesma forma — consistência entre aprendizes, não um defeito do LLM.

Curvas separadas por variante, com dois painéis: LLM contra a métrica e LLM contra o real. O prompt semântico domina o neutro em acurácia real: fica em torno de 87% enquanto o neutro patina perto de 47%. É a evidência mais direta de que o prior semântico peso/altura é o que carrega o desempenho na base real.

Pedido específico do orientador. Mostro o gráfico com bar chart comparando LLM e Perceptron baseline em cada n_{shot} .

Tabela final, em 10-shot. Na base real o LLM supera o Perceptron baseline nos dois prompts: peso/altura semântico 86,3% contra 80,7%, e x1/x2 neutro 47,0% contra 43,7%. A diferença é que, no neutro, a acurácia absoluta é baixa para os dois — perto do acaso —, enquanto só com o prior semântico ela sobe a 88%. A meia-lua não entra na comparação porque colapsou. Mensagem honesta para a banca: a vantagem do LLM vem dos priors do treinamento massivo, não do mecanismo de ICL em si.

Atende adendo do e-mail das 22:06. Mostro lado a lado peso $\times$ altura com prompt semântico e neutro, ambos 5-shot da seed 42. Os mesmos pontos são classificados de forma muito diferente. Evidência visual do efeito do prior semântico.

Priors semânticos são reais: acurácia real peso/altura em torno de 88%, contra cerca de 47% no $\times 1/\times 2$ neutro. R4, a elipse, recupera a forma teórica mas overfit-a com 100 amostras. E nesta execução, na base real, o LLM supera o Perceptron baseline em todos os n_shot — resultado revertido em relação ao passado. A meia-lua não pôde ser comparada porque colapsou. A vantagem do LLM vem dos priors, não do ICL.

Tabela final cruzando os 3 blocos. A/B/C lineares: ganho praticamente zero na fidelidade, apenas ruído, como esperado. Meia-lua, pelo teste-oráculo: satura em 86,7% e R3/R4 não ajudam — a métrica diagonal tem teto. Peso $\times$ altura no prompt neutro: a fidelidade sobe cerca de 19 pontos percentuais mas a acurácia real cai cerca de 16 — overfit pesado com 100 amostras. O padrão geral: augmentação R3/R4 só compensa com não-linearidade real e dados suficientes.

Tabela: fidelidade Problema A $81,3\% \pm 4,4$, Consist B $68,7\% \pm 5,0$, Consist C $87,3\% \pm 1,9$, kappa B 0,31, kappa C 0,73. Desvios menores ou iguais a 5 p.p. entre seeds. A direção de W é estável entre seeds, cosseno acima de 0,99, e a razão w_1/w_2 é o parâmetro mais ruído. H5 sustentada.

Zero para 10-shot no Problema B, na consistência (isso é H2 no Bloco 1, não a Fase E): delta +0,255, intervalo de 0,15 a 0,33, Cohen d de 6,4, efeito enorme. Easy contra Hard em 5-shot: delta +0,223, intervalo de 0,10 a 0,34 — é a refutação de H4. Em 40-shot inverte para -0,095, o hard passa o easy. R2 contra R4 na meia-lua, pelo oráculo: praticamente zero, satura em 86,7%. Cosseno entre os dois W: 0,994. Diagnóstico de gamma no Perceptron: a figura final_10 mostra convergência monotônica de gamma_lo.

Três testes adicionais. Point-biserial entre margem e acerto, por seed: r entre 0,28 e 0,39, $p < 0,001$ — maior margem, mais acerto. Mann-Whitney comparando margem em acertos contra erros: $p < 0,001$ nas três seeds, erros concentrados em baixa margem. Kruskal-Wallis sobre ordem de exemplos: $p \geq 0,14$, não significativo em nenhum n_shot .

Síntese por bloco. Bloco 1: H1 *parcialmente* sustentada — confirmada em C, com kappa 0,73, mas fraca em B, com kappa 0,31 abaixo do limiar de 0,5; e H2 sustentada. Bloco 2: H3 sustentada, H4 refutada em n_shot pequeno com reversão em 40-shot. Transversal: H5 sustentada, desvio até 5 pontos percentuais. Quatro das cinco sustentadas, com nuances importantes que faço questão de expor honestamente.

Seis conclusões. Um: critério decisório estável no LLM, ortogonal a correção. Dois: few-shot amplifica. Três: o LLM aprende critério via ICL, mas os baselines clássicos o superam no perito linear em todos os n_shot . Quatro: easy supera hard em poucos exemplos mas hard reverte em 40-shot — achado nuançado. Cinco: R3/R4 só ajuda em não-linear E com dados; na meia-lua a métrica diagonal satura em 87% mesmo contra a verdade. Seis: a vantagem do LLM em peso $\times$ altura vem dos priors semânticos, e nessa base o LLM supera o Perceptron baseline.

Métrica diagonal não captura interações. 2D apenas. Peso $\times$ altura tem só 100 amostras. 1 LLM testado. Sem controle de versão do LLM entre execuções: a coleta usou o alias gpt-4o-mini, sem snapshot datado, entre 30 de junho e primeiro de julho de 2026 — o provedor pode atualizar o modelo silenciosamente. E há um limite físico da medição que fazemos questão de declarar: a auditoria mediu 4,753% de respostas divergentes em consultas idênticas a temperatura zero, então nenhuma concordância com o LLM pode passar de uns 95% — as nossas métricas são lidas contra esse teto. Honestidade nas limitações é o que separa pesquisa de marketing.

Encerro agradecendo o orientador Prof. Raul Fonseca Neto, o PPGCC da UFJF e minha família. Estou à disposição para perguntas. Tenho dez slides de apêndice técnico cobrindo formulação matemática, overfitting, literatura e reprodutibilidade — inclusive o diagnóstico da busca binária de gamma que o professor pediu.

Para perguntas matemáticas. Formulação primal Eq. 28: $\max \gamma$ sujeito à restrição de margem com relaxação $\lambda \alpha_i$. Regra de correção Eq. 29. Atualização da margem Eq. 31. Hiperparâmetros do artigo: $\eta = 0,001$, C entre 0,1 e 1,0.

NNLS: $\min \|Aw - b\|^2$ com $w \geq 0$. Linha i de A tem diferenças de quadrados aos centróides. b vetor de uns. Método de conjunto ativo de Lawson-Hanson 1974. Sem hiperparâmetros, determinístico, ótimo global.

Perceptron e NNLS são empiricamente equivalentes nesta execução: cosseno de 0,994 entre os W 's estimados. Robustez do achado ao método de estimação.

Caso emblemático: peso $\times$ altura com prompt neutro x_1/x_2 , 4 features. Fidelidade do NNLS em torno de 78% mas acurácia REAL apenas cerca de 49%, no nível do acaso. A métrica decora o ruído das decisões erradas do LLM. Mitigações: regularização L1/L2, mais dados, validação cruzada.

Conexões com literatura. Ahuja & Orlin 2001. Schultz & Joachims 2003. Coelho, Borges, Fonseca Neto CILAMCE 2017. Diferenciação: aplicação a LLMs, black-box, independente de arquitetura.

Brown et al. 2020 GPT-3 e few-shot. Min et al. 2022 ground truth doesn't matter. Wei et al. 2022 emergent abilities. Lyu et al. 2023 prompts canônicos — alinhado com refutação de H4 em few-shot pequeno.

Xing et al. 2002 original. Davis et al. 2007 ITML. Schultz & Joachims 2003 SVM-style. Justificativa diagonal Liu et al. 2010, Kedem et al. 2012.

Comando único para reprodução. Mostro o gráfico do diagnóstico da busca binária de gamma que o professor pediu na reunião em torno de 9 minutos: `gamma_lo` monotônico crescente confirma convergência em todas as execuções.

Honestamente: o LLM evolui silenciosamente entre execuções. Temperatura zero NÃO garante determinismo — batching em GPU produz diferenças residuais — e nós não só afirmamos isso, nós medimos: a auditoria offline das interações, feita pelo script `audit_interactions`, encontrou 4,753% de respostas divergentes entre as 29.116 consultas que se repetiram — 1.384 flips. Isso quantifica o ruído de medição do protocolo: qualquer fidelidade ou kappa tem um teto prático de uns 95%, e é assim que interpretamos os números. Usamos 3 seeds vezes 3 reps para 9 observações por configuração. Estocasticidade residual típica menor que 2% entre reps da mesma seed. Para execuções futuras, a recomendação é fixar o snapshot datado do modelo em vez do alias `gpt-4o-mini`, que o provedor pode atualizar sem aviso.