V - Resultados

Todos os resultados provêm de um único protocolo experimental utilizando os modelos gpt-4o-mini e gemini-2.5-flash-lite, com T = 0, sementes {42, 123, 7}, R = 3, totalizando 129 868 chamadas. Salvo indicação explícita, os valores referem-se ao uso do modelo gpt-4o-mini.

V.1 - Bloco 1 — Estimativa da Métrica e Fidelidade (Problema A)

A Tabela 2 apresenta a fidelidade dos dois estimadores no Problema A, representado por duas gaussianas com um total de 150 amostras. A fidelidade dos estimadores é calculada considerando as 150 amostras rotuladas pelo LLM e o processo de classificação baseado no centroide mais próximo. Os valores são modestos, um sinal de que a métrica diagonal captura o LLM apenas parcialmente. O NNLS e o *Perceptron* Estruturado concordam em direção com valor do cosseno médio igual a 0,986.

Tabela 2: Fidelidade da métrica no Problema A, com 3 sementes e *zero-shot*.

Acredita-se que a fidelidade moderada da métrica em relação ao modelo LLM seja devido ao fato do LLM gerar uma fronteira de decisão não linear se afastando do *ground truth*. A acurácia da métrica em relação aos rótulos verdadeiros fica entre 93% e 98%. Não chega a 100% porque as duas gaussianas se sobrepõem, apresentando um erro de *Bayes* de 4,8%. Entretanto, com duas gaussianas linearmente separáveis a acurácia chega a 100%. Isso confirma que o motivo da fidelidade moderada de 81% a 86% vem do processo decisório do LLM, o qual em *zero-shot* acerta somente de 25% a 31% do *ground truth*.

Falta fazer experimentos com few-shot e gerar uma nova tabela.

Seria interessante plotar as amostras das gaussianas rotulados pelo LLM e pelo ground truth.

Figura 1: Bloco 1: comparação da concordância dos estimadores, fidelidade da métrica no Problema A e consistência do LLM nas transferências, Problema B e Problema C.

V.2 - Bloco 1 - Teste-Oráculo

Antes de interpretar a fidelidade da métrica em relação ao LLM, verifica-se a acurácia dos estimadores em relação à métrica Euclidiana $w_{GT} = [1,0; 1,0]$ e a uma métrica proporcional $w_{GT} = [0,3; 1,5]$ utilizadas como *ground truth* para rotulação dos dados do problema A. A Tabela 3 confirma a acurácia dos estimadores bem como a

concordância direcional em relação às métricas utilizadas. A acurácia se situa na faixa de 95% a 100% e a concordância praticamente total, fornecendo cosseno igual a 0,9999. Neste sentido, pode-se considerar que a fidelidade modesta em relação ao LLM, observada na Tabela 2, reflete o processo decisório interno do LLM e não uma deficiência dos estimadores.

Tabela 3: Teste-oráculo: recuperação da métrica e concordância entre estimadores.

Qual a diferença entre problema A e B? As métricas foram utilizadas para rotular o problema A?

Renomear problemas Expert aniso. Nome muito esquisito.

Sugestão : Problema 1 problema 2 Problema 3 e Problema 4 com as métricas na frente.

Figura 2: Validação dos Estimadores

V.3 - Bloco 1 - Transferência da Métrica (Problemas B e C)

A transferência do da métrica estimada do Problema A para os problemas B e C é feita da seguinte forma. Para o Problema B é feita uma rotação no sentido horário nas coordenadas dos dois centroides. Para o Problema C a rotação é no sentido anti-horário. O teste de consistência consiste em comparar os esquemas de rotulação do LLM em *zero-shot* e *few-shot* com o esquema de rotulação gerado pelo estimador *Perceptron* Estruturado utilizando a melhor métrica estimada do problema A, porém considerando a nova posição dos centroides.

A Tabela 4 apresenta os valores da consistência e do coeficiente *Kappa* κ nas transferências, em *zero-shot* e *few-shot* com 4 exemplos. O padrão é assimétrico para *zero-shot*. Enquanto o Problema B é difícil, com um valor de $\kappa = 0{,}33$ ou razoável, o Problema C apresenta um valor alto para o coeficiente *Kappa*, $\kappa = 0{,}75$ ou substancial. Em *few-shot*, poucos exemplos elevam substancialmente o coeficiente *Kappa* nos dois problemas, embora este aumento seja menor no problema B.

Tabela 4: Transferência: consistência e κ (Perceptron), IC bootstrap 95%.

A baixa transferência observada no Problema B em *zero-shot*, onde a consistência da métrica estimada chega a ser inferior à da métrica Euclidiana deve ser mais bem interpretada. O teste-oráculo, cujos resultados são apresentados na Tabela 3, mostra que, quando existe uma métrica anisotrópica real, os estimadores a recuperam. O que ocorre de fato é que a direção codificada pelas decisões *zero-shot*

do LLM no Problema A não generaliza geometricamente para B. Para tanto é necessário realizar uma nova ancoragem. Somente com a demonstração de alguns exemplos, *few-shot*, a métrica, estimada no Problema A, se reposiciona no problema de destino, passando a concordar direccionalmente com as decisões do LLM.

V.4 - Bloco 1 - Não-Linearidade (Problema D)

Aumentar a dimensão do espaço com a introdução de novos atributos realizando de forma explícita projeções, $R^2 \rightarrow R^3$ *e* $R^2 \rightarrow R^4$, produz ganhos apenas marginais de fidelidade e consistência nos problemas lineares A, B e C como mostra a Tabela 5. Estes resultados são coerentes com o fato de fronteiras lineares não requererem termos de interação entre os atributos em R^2. A média sobe de 84,9% com 3 atributos para 86,2% com 4 atributos mas estando próximo da faixa de fidelidade com 2 atributos.

Entretanto, como será visto nos Blocos 3, no problemas não linear Peso x Altura, o aumento da dimensão com a introdução de novos atributos eleva de forma significativa a fidelidade dos estimadores. No teste-oráculo no problema Meia-Lua os estimadores recuperam a métrica de forma correta mesmo em geometria curva atingindo uma alta acurácia, *Perceptron* Estruturado 100% e NNLS 95,3%.

Tabela 5: Fidelidade média do *Perceptron* Estruturado em R^3 e R^4 para os problemas A,B e C

Falta resultados e tabela relativa ao problema D

V.5 - Bloco 1 - Viés Semântico e de *Prompt* "corrigir nomes peso/altura".

A Tabela 6 mostra que o critério decisório do LLM no Problema A muda com a nomenclatura. Nomes de classes com conotação, Positivo/Negativo, elevam a fidelidade a 99,3%, ao passo que a mera inversão de posição no nome das classes, A/B → B/A, reduz a fidelidade de 82,7% para 68,0%, evidenciando um viés de ordem. O efeito dos nomes de atributos, neste problema, é pequeno, altura/peso com 84,7% de fidelidade contra 82,7% de x1/x2. Já as variantes geométrica e tabular de *prompt* degradam a fidelidade, respectivamente para 68% e 64,7%, alertando que a forma de alimentação do *prompt* confunde o modelo.

Tabela 6 - Efeito da nomenclatura e variante de *prompt* sobre a fidelidade.

Já na Figura 3, além da fidelidade da métrica em relação ao problema A é apresentado, também, o efeito das variantes de *prompt* sobre a consistência da métrica em relação aos problemas B e C. Novamente, a variante tabular diminui a medição, alertando que a forma de alimentação interfere no critério inferido.

Figura 3 - Fidelidade e consistência da métrica em relação a variantes de *prompt*.

"precisa explicar como é feita cada variante"

V.6 - Bloco 2 — LLM como Aprendiz , Seleção de Exemplos (Problemas E)

Sem a demonstração de exemplos, o LLM é praticamente incapaz de reproduzir o critério do especialista. A acurácia média, sobre as quatro formas de seleção de exemplos é de 61% "estranho o valor se repetir". A Tabela 7 apresenta a variação do aprendizado para cada forma de seleção considerando o aprendizado em *zero-shot* e *few-shot* para n ∈ {4, 10, 20, 40} para o problema E.

Observando os resultados de acurácia é possível afirmar que a hipótese H4 deve ser refutada. A hipótese a *priori* de que a seleção na demonstração de exemplos difíceis ensina melhor que as outras formas não se confirmam nos experimentos realizados, particularmente em relação ao problema E. Na média dos resultados em *few-shot* , a ordem é Aleatória (90,3%) > Mista (88,0%) > Fácil (81,1%) > Difícil (75,1%), demonstrando que a estratégia "'Difícil" e a pior. A interpretação dos resultados é coerente com o estudo de Min et al., 2022. Com poucos exemplos o LLM precisa de âncoras prototípicas, entretanto, com muitos exemplos, a informação sobre a geometria da fronteira formada pelos exemplos difíceis supera o ruído. Este padrão se repete no modelo gemini-2.5-flash-lite na média dos resultados em *few-shot*, reportando Fácil (93,5) versus Difícil (78,1%), reforçando a refutação da hipótese H4 nos dois modelos.

Figura 4: Bloco 2 - Curva de aprendizado por estratégia de seleção de exemplos.

V.7 – Bloco 2 – Comparação com Classificadores *Baselines* (problema E e F)

O LLM não supera classificadores clássicos nas tarefas relacionadas ao problema E linearmente separável. A Tabela 8 compara a acurácia do LLM aos métodos k-NN, Regressão Logística e SVM com *kernel* RBF. Todos os classificadores são treinados nos mesmos 40 exemplos demonstrados no *few-shot*, tendo como tarefas as variantes P3 e P4 do Problema E, descritas na Tabela 3. Analisando o resultado de acurácia, observa-se que todos os métodos ficam com resultados muitos próximos, com o LLM

apresentando a melhor acurácia e superando a Regressão Logística na variante P3 mas perdendo para Regressão Logística na variante P4.

Tabela 8 - Bloco 2 - LLM (40-shot) versus *baselines* .

Por outro lado, em uma tarefa não linear relativa ao Problema F da Meia Lua, o Aprendizado em Contexto em *zero-shot* do modelo gpt-4o-mini colapsa em duas das três sementes (123 e 7), atribuindo um único rótulo a todos os 105 pontos no tempo de teste. Na semente 42 o modelo executa, mas o desempenho é fraco. A acurácia parte de 53,3% em *zero-shot* e satura em ≈ 68% com 40-shot, ficando muito abaixo do teto atingido nos problemas lineares. O gemini-2.5-flash-lite, por contraste, não colapsa em nenhuma semente, o que mostra que o colapso é uma fragilidade específica do modelo e da semente. A Figura 6 ilustra a execução do modelo gpt-4o-mini com a semente 42 apresentando o seu esquema de rotulação e a fronteira de decisão em comparação com o modelo SVM com *kernel* RBF treinado com o conjunto de rótulos verdadeiros.

Figura 6 - Problema F (Meia-Lua, seed 42, gpt-4o-mini): superfície de separação do SVM RBF treinado no *ground truth* versus zero-shot do LLM.

Um teste-oráculo que ajusta a métrica diagonal diretamente ao *ground truth* do problema Meia-Lua atinge 86,7% de acurácia no treinamento, sendo que as projeções em R^3 e R^4 não melhoram significativamente este valor. O limite, portanto, é estrutural. A fronteira de decisão na forma de uma curvatura em "S" exigiria uma métrica mais ampla envolvendo uma matriz completa de parâmetros.

Na Figura 7 - direita é apresentado uma análise do viés relativo à ordem de demonstração dos exemplos. As alternativas de ordem são: troca de classes, *shuffled* e alternada. Verifica-se que a variação da acurácia em *few-shot* para $n \in \{4, 10, 20\}$ é muito pequena. Na Figura 7 – esquerda é apresentado o viés relacionado ao número de exemplos, considerando 3 exemplos difíceis e um número crescente de exemplos fáceis. Verifica-se que, inicialmente, ocorre um aumento da acurácia, mas este aumento se estabiliza caracterizando uma saturação.

Figura 7 - Esquerda: experimento de diluição (acrescentar exemplos fáceis a três exemplos difíceis melhora de forma limitada a acurácia. Direita: viés de ordem (as quatro ordenações diferem por poucos pontos percentuais).